

# P03

## Memoria larga de corto plazo

### Long Short-Term Memory

Sepp Hochreiter, Jürgen Schmidhuber · 1997 · Neural Computation, 9(8), 1735–1780

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-16.

# P03 — LSTM

La arquitectura que convirtió «recordar durante mucho tiempo» en un problema de ingeniería resoluble, sustituyendo una multiplicación encadenada por una suma con compuertas.

Nivel: L2 · Motor: lstm · Notebook: P03\_lstm.ipynb · Anexo: cálculo y gradientes

## 1. Identificación

| Campo             | Valor                               |
|-------------------|-------------------------------------|
| Título original   | Long Short-Term Memory              |
| Autoría           | Sepp Hochreiter, Jürgen Schmidhuber |
| Año               | 1997                                |
| Venue             | Neural Computation, 9(8), 1735–1780 |
| Fuente primaria   | doi.org/10.1162/neco.1997.9.8.1735  |
| Acceso            | Restringido                         |
| Fecha de consulta | 2026-08-16                          |

## 2. Problema anterior

Una red recurrente procesa una secuencia reutilizando el mismo estado. Para entrenarla se despliega en el tiempo y se aplica retropropagación: el gradiente atraviesa un paso por cada instante.

Ahí está el problema. En cada paso el gradiente se multiplica por (aproximadamente)  $w \cdot \sigma'$ . Si ese factor es menor que 1, el producto colapsa exponencialmente; si es mayor, explota. Hochreiter lo había diagnosticado formalmente en su tesis de 1991. La consecuencia práctica: **una RNN clásica no aprende dependencias separadas por más de unas decenas de pasos**, y no por falta de datos ni de capacidad, sino por aritmética.

## 3. Propuesta

Introducir una **celda de memoria** cuyo estado se actualiza **sumando**, no aplicando una transformación no lineal encadenada. Esa ruta aditiva es el *constant error carousel* (CEC): por ella el gradiente viaja sin multiplicarse por derivadas de activación.

Alrededor del CEC se colocan **compuertas multiplicativas** que aprenden qué información entra (**i**) y qué información se expone al resto de la red (**o**). Las compuertas protegen la celda de escrituras y lecturas irrelevantes.

**Precisión histórica obligatoria:** la versión de 1997 tiene compuertas de **entrada** y **salida**. La compuerta de **olvido** —la que hoy aparece en todos los diagramas— la añadieron Gers, Schmidhuber y Cummins (1999/2000).

## 4. Intuición sin fórmulas

Una cinta transportadora que atraviesa toda la fábrica. Los operarios pueden depositar cosas encima (compuerta de entrada) y consultar lo que lleva (compuerta de salida), pero la cinta avanza sin que su contenido se transforme por el camino. Lo que subió al principio puede seguir intacto al final.

**Dónde deja de funcionar la analogía:** la cinta real no borra nada; la LSTM moderna sí, y lo hace con una compuerta aprendida. Y si esa compuerta aprende a cerrarse, el contenido se desvanece igual que en una RNN.

## 5. Matemática mínima

Formulación moderna (con compuerta de olvido, posterior al paper):

$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$   
 $i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$   
 $o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$   
 $g_t = \tanh(W_g \cdot [h_{t-1}, x_t] + b_g)$   
  
 $c_t = f_t \odot c_{t-1} + i_t \odot g_t$   
 $h_t = o_t \odot \tanh(c_t)$

olvido

entrada

salida

candidato

← SUMA: aquí está el CEC


La clave está en la penúltima línea:

$\partial c_t / \partial c_{t-1} = f_t$   
  
Con  $f_t \approx 1$  durante T pasos:  $\partial c_T / \partial c_0 \approx 1$   
Con una RNN tanh y factor 0,4:  $0,4^{40} \approx 1,2 \cdot 10^{-16}$

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

| Dónde                                      | Qué necesitas de ahí                                                                                    |
|--------------------------------------------|---------------------------------------------------------------------------------------------------------|
| A03 §4 · Por qué el gradiente se desvanece | por qué un producto de derivadas menores que 1 colapsa, que es el problema exacto que la celda resuelve |

## 6. Arquitectura o flujo



## 7. Qué observar en el paper original

- El artículo es **largo** (46 páginas) y buena parte es el **análisis del flujo de error**: ahí está el argumento, no en la arquitectura.
- La justificación de por qué las compuertas deben ser multiplicativas y el estado aditivo.
- Los experimentos con **problemas sintéticos de dependencia larga** (retardos de cientos de pasos) diseñados para que ninguna RNN previa pudiera resolverlos.
- Comprueba tú mismo: busca la palabra «forget gate» en el artículo de 1997. No está.

## 8. Evidencia y resultados

El paper compara la LSTM con RNN clásicas, BPTT truncado y otras alternativas de la época sobre tareas construidas para exigir memoria a largo plazo. La LSTM resuelve retardos con los que las alternativas fracasan.

Los detalles de tareas, retardos y tasas de éxito están en la sección de experimentos del artículo. Este eje no reproduce esas cifras: verificarlas en la fuente antes de citarlas.

La miniatura de este eje aporta la evidencia del mecanismo: tras 40 pasos, un factor de decaimiento 0,378 deja el gradiente en  $\approx 10^{-17}$ , mientras que una compuerta de olvido en 0,98 lo deja en  $\approx 0,45$ .

## 9. Impacto

- Durante casi dos décadas fue la arquitectura por defecto para secuencias: reconocimiento de voz, escritura manuscrita, traducción, series temporales.
- Hizo posible Seq2Seq y, con él, la traducción automática neuronal — el problema que llevó a la atención y al Transformer.
- Instaló una idea que sobrevive a la arquitectura: **las rutas aditivas preservan el gradiente**. Es exactamente el mismo principio que las conexiones residuales de ResNet y de cada bloque Transformer.

## 10. Limitaciones

1. **Sigue siendo secuencial**. El paso  $t$  necesita el  $t-1$ : no se puede paralelizar sobre la longitud. Este es el límite que motiva Po8.

2. **No elimina el gradiente desvaneciente; lo pone bajo control de una compuerta aprendida.** Si `f` aprende valores bajos, el desvanecimiento vuelve.
3. **Cuatro veces más parámetros** que una RNN simple del mismo tamaño de estado.
4. **Sigue comprimiendo** toda la historia en un estado de tamaño fijo.
5. **Difícil de interpretar:** qué guarda cada dimensión de la celda no es legible.
6. **La versión de 1997 carece de compuerta de olvido**, y sin ella el estado de celda puede crecer sin límite en secuencias largas — motivo por el que se añadió después.

## 11. Errores comunes

| Error                                                | Corrección                                                                                                                                                                 |
|------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| «La LSTM de 1997 tiene compuerta de olvido»          | No. Gers, Schmidhuber y Cummins (1999/2000). Es el anacronismo más repetido del campo.                                                                                     |
| «La LSTM resuelve el gradiente desvaneciente»        | Lo <b>mitiga</b> cuando la compuerta de olvido se mantiene cerca de 1 en el intervalo relevante.                                                                           |
| «La GRU es una LSTM simplificada del mismo paper»    | La GRU es de Cho et al. (2014), 17 años después.                                                                                                                           |
| «Las LSTM quedaron obsoletas»                        | Siguen siendo competitivas en series temporales, dispositivos con poca memoria y latencia baja. «Obsoleto» es una afirmación sobre un contexto, no sobre una arquitectura. |
| «El estado de celda y el estado oculto son lo mismo» | <code>c_t</code> es la memoria protegida; <code>h_t</code> es lo que la celda <b>expone</b> , filtrado por <code>o_t</code> .                                              |

## 12. Relación con trabajos anteriores

- **Po2 Backpropagation (1986)** — el método de entrenamiento cuyo problema en el tiempo se ataca aquí.
- **Elman (1990)** — redes recurrentes simples.
- **Hochreiter (1991)** — tesis que diagnostica formalmente el gradiente desvaneciente.
- **Werbos (1990)** — retropropagación en el tiempo (BPTT).

## 13. Relación con trabajos posteriores

- **Gers, Schmidhuber y Cummins (2000)** — compuerta de olvido.  
[doi.org/10.1162/089976600300015015](https://doi.org/10.1162/089976600300015015)
- **Cho et al. (2014)** — GRU, versión con menos compuertas. [arXiv:1406.1078](https://arxiv.org/abs/1406.1078)
- **Po6 Seq2Seq (2014)** — dos LSTM encadenadas para traducir.
- **He et al. (2015), ResNet** — el mismo principio aditivo aplicado a la profundidad.
- **Po8 Transformer (2017)** — elimina la recurrencia entera.

## 14. Notebook asociado

P03\_lstm.ipynb

**Qué implementa:** una pasada completa de la celda con valores explícitos de las cuatro compuertas, y la comparación cuantitativa del decaimiento del gradiente entre una RNN tanh y la ruta aditiva de la celda.

**Qué NO implementa:** entrenamiento real de una LSTM, BPTT, ni las tareas sintéticas del paper.

```
ai-evolution paper-lab P03 --seed 7
```

## 15. Actividades Bloom

| Nivel    | Actividad                                                                                                                             |
|----------|---------------------------------------------------------------------------------------------------------------------------------------|
| Recordar | Enumera las cuatro compuertas de la LSTM moderna y di cuáles estaban en 1997.                                                         |
| Explicar | Explica por qué una suma preserva el gradiente y un producto encadenado no.                                                           |
| Aplicar  | Calcula el estado de celda tras 3 pasos con $f = 0,9$ , $i = 0,5$ y $g = 1$ constantes.                                               |
| Analizar | ¿Cuál es el valor mínimo de $f$ que conserva el 1 % del gradiente tras 100 pasos? Resuélvelo analíticamente y compruébalo.            |
| Evaluar  | Un artículo divulgativo dice: «la LSTM recuerda porque tiene memoria». Reescríbelo con precisión técnica en dos frases.               |
| Crear    | Diseña una tarea sintética mínima donde una RNN simple falle y una LSTM acierte, y justifica por qué tu tarea discrimina entre ambas. |

## 16. Autoevaluación

1. ¿Qué significa exactamente «carrusel de error constante»?
2. ¿Por qué las compuertas usan sigmoide y el candidato usa tanh?
3. ¿Cuál es la diferencia funcional entre  $c_t$  y  $h_t$ ?
4. Si  $f_t = 1$  e  $i_t = 0$  para siempre, ¿qué hace la celda?
5. ¿Qué límite de la LSTM **no** resuelve el mecanismo de compuertas?
6. ¿Por qué la LSTM no se puede paralelizar sobre la longitud de la secuencia?
7. ¿Qué componente de la LSTM actual no aparece en el paper de 1997?

## 17. Respuestas esperadas

1. La ruta por la que el estado de celda se actualiza sumando, de modo que la derivada  $\partial c_t / \partial c_{t-1}$  vale  $f_t$  en lugar de un producto de derivadas de activación. Con  $f \approx 1$ , el error se conserva a través de muchos pasos.
2. La sigmoide devuelve  $[0,1]$ : es una compuerta, un porcentaje de paso. La tanh devuelve  $[-1,1]$ : es contenido con signo, que puede sumar o restar de la memoria.
3.  $c_t$  es la memoria interna protegida.  $h_t = o_t \odot \tanh(c_t)$  es la parte que la celda expone al resto de la red. Se puede recordar algo sin exponerlo.
4. Conserva su contenido indefinidamente sin admitir nada nuevo: memoria congelada.
5. La secuencialidad. El cómputo sigue siendo  $O(n)$  pasos no paralelizables, y el camino entre dos posiciones distantes sigue siendo largo.
6. Porque  $h_t$  depende de  $h_{t-1}$ : hay una dependencia de datos estricta entre pasos.

7. La compuerta de olvido (y también la conexión *peephole*, de Gers y Schmidhuber, 2000).

## 18. Fuentes primarias

---

- Hochreiter, S. y Schmidhuber, J. (1997). *Long Short-Term Memory*. **Neural Computation**, 9(8), 1735–1780. doi.org/10.1162/neco.1997.9.8.1735 · consultado 2026-08-16.
- Gers, F. A., Schmidhuber, J. y Cummins, F. (2000). *Learning to Forget: Continual Prediction with LSTM*. **Neural Computation**, 12(10), 2451–2471. doi.org/10.1162/089976600300015015 · consultado 2026-08-16.
- Cho, K. et al. (2014). *Learning Phrase Representations using RNN Encoder–Decoder*. arXiv:1406.1078 · consultado 2026-08-16.



# Evaluación — P03 · Memoria larga de corto plazo

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

**Paper:** *Long Short-Term Memory* (1997, Neural Computation, 9(8), 1735–1780) · **Nivel:** L2

## Parte A — Contexto histórico (20 pts)

---

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

## Parte B — Lectura crítica (20 pts)

---

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

## Parte C — Interpretación matemática (15 pts)

---

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

## Parte D — Implementación e interpretación (25 pts)

---

6. (10) Ejecuta `P03_lstm.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

## Parte E — Límites y transferencia (20 pts)

---

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

## Rúbrica

---



| Nivel                   | Descripción                                                                                                                                                  |
|-------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>A — Excelente</b>    | Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados. |
| <b>B — Suficiente</b>   | Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.                                    |
| <b>C — Insuficiente</b> | Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.  |

## Criterio automático de rechazo

---

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).