

# P06

## Aprendizaje de secuencia a secuencia con redes neuronales

### Sequence to Sequence Learning with Neural Networks

Ilya Sutskever, Oriol Vinyals, Quoc V. Le · 2014 · arXiv:1409.3215 · NeurIPS (NIPS) 2014

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-16.

# P06 — Seq2Seq

Una sola red aprende a convertir una secuencia de longitud variable en otra de longitud distinta, de extremo a extremo. Y, al hacerlo, revela el cuello de botella que definirá los tres papers siguientes.

Nivel: L3 · Motor: seq2seq · Notebook: P06\_seq2seq.ipynb · Anexo: álgebra y geometría

## 1. Identificación

| Campo             | Valor                                              |
|-------------------|----------------------------------------------------|
| Título original   | Sequence to Sequence Learning with Neural Networks |
| Autoría           | Ilya Sutskever, Oriol Vinyals, Quoc V. Le          |
| Año               | 2014                                               |
| Venue             | arXiv:1409.3215 · NeurIPS (NIPS) 2014              |
| Fuente primaria   | arXiv:1409.3215                                    |
| Acceso            | Abierto                                            |
| Fecha de consulta | 2026-08-16                                         |

## 2. Problema anterior

Las redes profundas funcionaban con entradas y salidas de **dimensión fija**: una imagen de 224×224, un vector de características. Pero traducir «el gato negro duerme» a inglés produce una secuencia de longitud distinta a la de entrada, y esa longitud no se conoce de antemano.

La traducción automática del momento se hacía con **sistemas estadísticos por frases**: muchos componentes ajustados por separado (modelo de traducción, modelo de lenguaje, reordenamiento, ajuste de pesos). Funcionaban bien, pero cada pieza se optimizaba con un criterio propio y no con el objetivo final.

## 3. Propuesta

Dos LSTM encadenadas:

1. el **codificador** lee la secuencia de entrada token a token y termina con un estado interno  $c$ , un vector de tamaño fijo que pretende resumirla entera;
2. el **decodificador** parte de  $c$  y genera la salida token a token, alimentándose de lo que ya generó.

Todo se entrena con un único objetivo: maximizar la probabilidad de la traducción correcta.

El artículo aporta además un truco empírico decisivo: **invertir el orden de la secuencia fuente**. Con la entrada invertida, las primeras palabras de origen quedan temporalmente cerca de las primeras de destino, lo que acorta las dependencias que la LSTM debe mantener.

## 4. Intuición sin fórmulas

Leer una frase entera, cerrar los ojos y escribir la traducción solo de memoria. Con frases cortas funciona. Con un párrafo, cuando llegas al final ya no recuerdas con precisión cómo empezaba.

**Dónde deja de funcionar la analogía:** una persona puede releer. El decodificador de este modelo no puede: solo dispone de  $c$ .

## 5. Matemática mínima

Codificador:  $c = h_n$ , con  $h_t = \text{LSTM}(h_{t-1}, x_t)$

Decodificador:  $p(y_1 \dots y_m \mid x_1 \dots x_n) = \prod_i p(y_i \mid y_{<t}, c)$

Entrenamiento: maximizar  $\sum \log p(y \mid x)$  sobre el corpus paralelo


Inferencia: búsqueda en haz (beam search) sobre la secuencia de salida

**El punto crítico:**  $c \in \mathbb{R}^d$  tiene dimensión **constante**, mientras que la información de  $x_1 \dots x_n$  crece con  $n$ . Comprimir algo de tamaño creciente en algo de tamaño fijo tiene un coste, y ese coste crece con la longitud.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

| Dónde                                      | Qué necesitas de ahí                                                                    |
|--------------------------------------------|-----------------------------------------------------------------------------------------|
| A01 §5 · Proyección y subespacios          | comprimir una frase en un vector fijo es una proyección, con la pérdida que eso implica |
| A03 §4 · Por qué el gradiente se desvanece | el gradiente que tiene que atravesar toda la secuencia                                  |

## 6. Arquitectura o flujo



## 7. Qué observar en el paper original

- La **discusión sobre invertir la secuencia fuente**: es una de las observaciones empíricas más comentadas del artículo, y los autores admiten no tener una explicación completa.

- El uso de **LSTM profundas** (varias capas apiladas) y su efecto en el resultado.
- La **búsqueda en haz** en inferencia y el efecto del tamaño del haz.
- La **visualización PCA** de los estados **c** : frases con significado parecido quedan cerca, y el espacio muestra sensibilidad al orden de las palabras y a la voz activa/pasiva.
- El experimento de **rescorear** las n-mejores hipótesis del sistema estadístico, en lugar de traducir directamente.

## 8. Evidencia y resultados

---

Evaluación sobre traducción **inglés** → **francés** de WMT'14, medida en BLEU, comparada contra un sistema estadístico por frases de referencia.

El artículo reporta dos regímenes: traducción directa con un conjunto de LSTM, y rescoring de las hipótesis del sistema estadístico —este último mejor que el primero—. También documenta que la calidad **cae con la longitud de la frase**, y que invertir la fuente mejora el resultado de forma consistente.

Los valores exactos de BLEU para cada configuración están en las tablas del artículo. Verificarlos allí: circulan cifras mezcladas entre el modelo único, el conjunto y el rescoring.

La miniatura de este eje mide el fenómeno estructural, no el BLEU: al pasar de longitud 2 a 32, la similitud del vector de contexto con el **primer** token se desploma mientras la del **último** se mantiene alta.

## 9. Impacto

---

- Convierte la traducción automática en un problema de aprendizaje de extremo a extremo, y en pocos años el paradigma estadístico por frases queda desplazado.
- Establece el patrón **codificador–decodificador** que sigue siendo la arquitectura de referencia para transformar una secuencia en otra.
- Populariza la **búsqueda en haz** como procedimiento estándar de decodificación.
- Y, sobre todo, **hace visible el cuello de botella**: al medir la caída de calidad con la longitud, define el problema que Bahdanau resolverá el mismo año.

## 10. Limitaciones

---

1. **Cuello de botella del vector fijo**. Es el límite estructural: capacidad constante frente a información creciente.
2. **La calidad cae con la longitud de la frase**. Documentado en el propio artículo.
3. **Sigue siendo secuencial**: no paraleliza sobre la longitud.
4. **Invertir la fuente es un parche**, no una solución. Reordena qué información se pierde.
5. **Coste de entrenamiento alto** para la época, y dependencia de grandes corpus paralelos.
6. **Sin alineación explícita**: no hay forma de saber qué parte de la entrada generó qué parte de la salida.

## 11. Errores comunes

---

| Error                                               | Corrección                                                                                                                               |
|-----------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------|
| «Seq2Seq usa atención»                              | No. La atención llega con P07, unas semanas después.                                                                                     |
| «El problema se arregla agrandando el estado»       | Un estado mayor retrasa el problema; no cambia que la capacidad sea constante y la longitud variable.                                    |
| «Invertir la entrada resuelve el cuello de botella» | Lo mitiga reordenando las dependencias. El cuello sigue ahí.                                                                             |
| «Seq2Seq inventó el codificador–decodificador»      | Cho et al. (2014) publicó una formulación muy próxima meses antes (arXiv:1406.1078). Ambos trabajos son contemporáneos e independientes. |
| «BLEU mide calidad de traducción»                   | Mide solapamiento de n-gramas con referencias. Correlaciona, imperfectamente, y no es comparable entre tokenizaciones distintas.         |

## 12. Relación con trabajos anteriores

- **P03 LSTM (1997)** — la celda que hace viable el codificador.
- **Cho et al. (2014)** — RNN encoder–decoder y GRU, contemporáneo. arXiv:1406.1078
- **Modelos estadísticos de traducción** (Brown et al., 1993; Koehn et al., 2003) — la línea base contra la que se compara.

## 13. Relación con trabajos posteriores

- **P07 Attention (2014)** — elimina el vector fijo.
- **P08 Transformer (2017)** — conserva el patrón codificador–decodificador y elimina la recurrencia.
- **BART, T5 (2019–2020)** — codificador–decodificador preentrenado.
- **Modelos de imagen a texto y voz a texto** — el mismo patrón aplicado a otras modalidades.

## 14. Notebook asociado

P06\_seq2seq.ipynb

**Qué implementa:** una medición directa del cuello de botella. Un codificador de juguete comprime secuencias de longitud creciente en un vector fijo y se mide cuánta información del principio sobrevive.

**Qué NO implementa:** LSTM entrenadas, traducción real, búsqueda en haz ni BLEU. El codificador es una mezcla con decaimiento fijo: aísla el fenómeno, no lo mide en un modelo real.

```
ai-evolution paper-lab P06 --seed 7
```

## 15. Actividades Bloom

| Nivel           | Actividad                                                                                             |
|-----------------|-------------------------------------------------------------------------------------------------------|
| <b>Recordar</b> | Escribe la factorización $p(y \setminus x)$ del decodificador y explica de qué depende cada término.  |
| <b>Explicar</b> | Explica por qué invertir la secuencia fuente ayuda, en términos de distancia entre dependencias.      |
| <b>Aplicar</b>  | Ejecuta el notebook y anota a partir de qué longitud el primer token deja de ser recuperable.         |
| <b>Analizar</b> | Argumenta por qué el problema es estructural y no de capacidad, con un contraejemplo numérico.        |
| <b>Evaluar</b>  | Alguien propone «duplicar la dimensión del estado» como solución. Evalúa la propuesta con evidencia.  |
| <b>Crear</b>    | Diseña una métrica que capture la pérdida de información del principio de la secuencia y justifícala. |

## 16. Autoevaluación

1. ¿Por qué las redes profundas previas no servían para traducir?
2. ¿Qué es exactamente el vector  $c$  y qué se le pide?
3. ¿Por qué la calidad cae con la longitud de la frase?
4. ¿Qué hace la búsqueda en haz y por qué no se usa simplemente el token más probable en cada paso?
5. ¿Invertir la fuente resuelve o mitiga el problema? Justifica.
6. ¿Qué información se pierde por completo en este modelo respecto a la alineación?
7. ¿Qué idea que hoy asociamos a Seq2Seq **no** está en este paper?

## 17. Respuestas esperadas

1. Porque exigían entrada y salida de dimensión fija, y la traducción tiene longitudes variables y desconocidas de antemano.
2. El estado final del codificador: un vector de dimensión fija que debe contener toda la información necesaria para reconstruir la salida.
3. Porque la información de entrada crece con  $n$  mientras la capacidad de  $c$  es constante. El estado acaba dominado por los últimos tokens leídos.
4. Mantiene las  $k$  hipótesis parciales más probables. La decodificación voraz puede quedar atrapada tras una primera elección localmente buena y globalmente mala.
5. Mitiga. Acorta la distancia entre las primeras palabras de origen y de destino, pero la compresión a tamaño fijo permanece intacta.
6. Qué parte de la entrada dio lugar a qué parte de la salida: no hay ningún mecanismo que lo exponga ni lo aprenda.
7. La atención. Es de Bahdanau, Cho y Bengio, y la publicación de arXiv es de septiembre de 2014, prácticamente simultánea.

## 18. Fuentes primarias

- Sutskever, I., Vinyals, O. y Le, Q. V. (2014). *Sequence to Sequence Learning with Neural Networks*. **NIPS 2014**. arXiv:1409.3215 · consultado 2026-08-16.
- Cho, K. et al. (2014). *Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation*. **EMNLP 2014**. arXiv:1406.1078 · consultado 2026-08-16.



# Evaluación — P06 · Aprendizaje de secuencia a secuencia con redes neuronales

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

**Paper:** *Sequence to Sequence Learning with Neural Networks* (2014, arXiv:1409.3215 · NeurIPS (NIPS) 2014) · **Nivel:** L3

## Parte A — Contexto histórico (20 pts)

---

- (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
- (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

## Parte B — Lectura crítica (20 pts)

---

- (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
- (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

## Parte C — Interpretación matemática (15 pts)

---

- (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

## Parte D — Implementación e interpretación (25 pts)

---

- (10) Ejecuta `P06_seq2seq.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
- (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
- (5) Aporta la corrección con su evidencia.

## Parte E — Límites y transferencia (20 pts)

---

- (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
- (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

## Rúbrica

---

| Nivel                   | Descripción                                                                                                                                                  |
|-------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>A — Excelente</b>    | Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados. |
| <b>B — Suficiente</b>   | Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.                                    |
| <b>C — Insuficiente</b> | Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.  |

## Criterio automático de rechazo

---

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).