

P12

Entrenar modelos de lenguaje para seguir instrucciones con retroalimentación humana

Training language models to follow instructions with human feedback

Long Ouyang, Jeff Wu, Xu Jiang, Diogo Almeida, y otros (OpenAI) · 2022 · arXiv:2203.02155 · NeurIPS 2022

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-16.

P12 — InstructGPT y RLHF

El salto de «modelo que completa texto» a «asistente que hace lo que se le pide». Y la constatación incómoda de que «mejor» es una decisión de quién etiqueta, no una propiedad del modelo.

Nivel: L3 · **Motor:** rlhf · **Notebook:** P12_instructgpt_rlhf.ipynb · **Anexo:** probabilidad y verosimilitud

1. Identificación

Campo	Valor
Título original	Training language models to follow instructions with human feedback
Autoría	Long Ouyang, Jeff Wu, Xu Jiang, Diogo Almeida y otros (OpenAI)
Año	2022
Venue	arXiv:2203.02155 · NeurIPS 2022
Fuente primaria	arXiv:2203.02155
Acceso	Abierto
Fecha de consulta	2026-08-16

2. Problema anterior

GPT-3 se entrena maximizando la verosimilitud del texto de internet. Ese objetivo **no es** «sé útil, honesto e inocuo». Es «predice qué viene después».

La consecuencia práctica: el modelo continúa el texto de la forma más plausible, que a menudo no es lo que el usuario quería. Ante «explícame X», puede generar más preguntas sobre X en lugar de explicarlo, porque en internet eso también es una continuación plausible.

A esto se le llama **desalineación de objetivo**: el objetivo de entrenamiento y la intención del usuario no coinciden. Y no se arregla con más escala, porque escalar mejora el objetivo equivocado.

3. Propuesta

Tres etapas encadenadas:

- SFT (ajuste supervisado).** Etiquetadores escriben respuestas de demostración a prompts reales; el modelo se ajusta sobre ellas.
- Modelo de recompensa (RM).** Para cada prompt se muestrean varias respuestas y los etiquetadores las **ordenan por preferencia**. Con esas comparaciones se entrena un modelo que asigna un escalar $r(x, y)$.
- Optimización por refuerzo.** La política se optimiza con PPO para maximizar r , con una **penalización KL** que la mantiene cerca del modelo SFT.

La decisión metodológica clave: **pedir comparaciones, no puntuaciones**. Ordenar dos respuestas es más fácil, más rápido y mucho más consistente entre anotadores que puntuar del 1 al 10.

4. Intuición sin fórmulas

Enseñar a alguien a cocinar sin darle recetas: le pones dos platos delante y le dices cuál está mejor. Con suficientes comparaciones, aprende qué buscas — aunque tú nunca hayas sabido formularlo con palabras.

Dónde deja de funcionar la analogía: el aprendiz humano entiende *por qué* un plato es mejor. El modelo de recompensa solo aprende **qué correlaciona** con la preferencia. Si tus platos preferidos resultan ser siempre los más grandes, aprenderá a servir raciones enormes.

5. Matemática mínima

Modelo de recompensa (Bradley-Terry)

$$p(y_w > y_l \mid x) = \sigma(r(x, y_w) - r(x, y_l))$$
$$L_{RM} = - E[\log \sigma(r(x, y_w) - r(x, y_l))]$$

y_w = respuesta preferida, y_l = rechazada. Solo importa la **diferencia**: la escala absoluta de r no está determinada.

Optimización con restricción


$$\max_{\pi} E_{\{y \sim \pi(\cdot|x)\}} [r(x, y)] - \beta \cdot KL(\pi(\cdot|x) \parallel \pi_{SFT}(\cdot|x))$$

El término KL es imprescindible: sin él la política deriva hacia texto degenerado que engaña al modelo de recompensa. β fija el precio de alejarse del modelo base.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A02 §5 · Bradley-Terry: aprender de comparaciones	Bradley-Terry convierte comparaciones humanas en una escala numérica
A03 §6 · Gradiente de política (REINFORCE)	el gradiente de política, que es cómo se optimiza contra esa recompensa

6. Arquitectura o flujo



7. Qué observar en el paper original

- El **resultado más citado**: los etiquetadores prefieren las salidas del modelo InstructGPT de **1 300 millones** de parámetros sobre las de GPT-3 de **175 000 millones**. Alinear resultó más rentable que escalar dos órdenes de magnitud.
- La sección sobre **quién etiquetó**: perfil demográfico de los anotadores, criterios de selección y guía de anotación. Es una de las secciones más honestas y menos leídas del artículo, y determina qué significa «mejor» en todo el trabajo.
- El **impuesto de alineación** (*alignment tax*): la caída de rendimiento en algunos benchmarks académicos, y la mezcla de gradientes de preentrenamiento que usan para mitigarla.
- Las secciones sobre **límites**: el modelo sigue alucinando, sigue siendo sensible al prompt y puede obedecer instrucciones dañinas si están bien formuladas.

8. Evidencia y resultados

Evaluación principal por **preferencia humana**: se comparan salidas de distintos modelos sobre la distribución de prompts real de la API y sobre conjuntos públicos.

- InstructGPT es preferido a GPT-3 por un margen amplio, **incluso con modelos mucho más pequeños**.
- Mejora en veracidad (TruthfulQA) y reducción de generación tóxica frente al modelo base.
- Generaliza a instrucciones y a idiomas poco representados en los datos de ajuste.
- Se documenta un retroceso en algunos benchmarks académicos, mitigado parcialmente.

Las proporciones exactas de preferencia y los resultados por benchmark están en las figuras y tablas del artículo. Verificarlos allí antes de citarlos.

La miniatura de este eje muestra el mecanismo del modelo de recompensa: cinco comparaciones bastan para que un r lineal ordene cuatro respuestas candidatas, situando arriba la útil y honesta y abajo la peligrosa.

9. Impacto

- Es la técnica que hizo posibles los asistentes conversacionales de uso masivo. **ChatGPT desciende directamente de este trabajo**, no de GPT-3 base.
- Convierte la **alineación** en una disciplina de ingeniería con etapas, datos y métricas, no solo en una discusión conceptual.
- Instala la **preferencia humana como métrica**, con todo lo que eso implica: la evaluación deja de ser puramente automática.
- Abre la línea de trabajo sobre reward hacking, RLAIIF y alineación con principios explícitos (Constitutional AI, 2022).

10. Limitaciones

1. **Reward hacking.** Si una característica superficial correlaciona con la preferencia (por ejemplo, la longitud), la política aprende a explotarla.
2. **Los valores son los de los anotadores.** El modelo de recompensa no descubre qué es mejor: reproduce el criterio de un grupo concreto de personas con una guía concreta.
3. **Pipeline complejo y caro:** tres modelos, datos humanos y un bucle de RL delicado de estabilizar. Este es el problema que ataca DPO.
4. **Impuesto de alineación:** caída en algunos benchmarks académicos.
5. **Sigue alucinando.** La alineación cambia el estilo y la obediencia, no añade conocimiento ni verificación.
6. **Sicofancia:** si a los anotadores les gustan las respuestas que les dan la razón, el modelo aprende a darla.
7. **PPO es sensible** a hiperparámetros; reproducirlo requiere mucho oficio no documentado.

11. Errores comunes

Error	Corrección
«RLHF hace que el modelo diga la verdad»	Hace que produzca respuestas preferidas por los anotadores . La correlación con la verdad es parcial y no está garantizada.
«RLHF añade conocimiento al modelo»	No. Reorganiza el comportamiento sobre el conocimiento que ya tenía.
«El modelo de recompensa es objetivo por ser un modelo»	Es un resumen estadístico de juicios humanos concretos, con sus sesgos.
«InstructGPT es GPT-3 con más datos»	Son tres etapas y dos modelos adicionales. La diferencia es de procedimiento, no de escala.
«Este paper inventó RLHF»	Christiano et al. (2017) ya lo aplicaba a control con preferencias humanas. Este trabajo lo lleva a modelos de lenguaje a escala.
«El término KL es un detalle de regularización»	Sin él la política colapsa hacia texto degenerado con recompensa alta. Es estructural.

12. Relación con trabajos anteriores

- **P10 GPT-3 (2020)** — el modelo base y el problema.
- **Christiano et al. (2017)** — RL a partir de preferencias humanas. [arXiv:1706.03741](#)
- **Stiennon et al. (2020)** — RLHF aplicado a resumen; el precedente directo. [arXiv:2009.01325](#)

- **Schulman et al. (2017), PPO** — el algoritmo de optimización. [arXiv:1707.06347](#)
- **Bradley y Terry (1952)** — el modelo de comparaciones por pares.

13. Relación con trabajos posteriores

- **Bai et al. (2022), Constitutional AI** — reemplazar parte del juicio humano por principios explícitos y crítica del propio modelo. [arXiv:2212.08073](#)
- **P15 DPO (2023)** — el mismo objetivo sin modelo de recompensa ni RL.
- **RLAIF (2023)** — retroalimentación generada por IA.
- **Trabajo sobre sicofancia y reward hacking (2023+)** — el estudio sistemático de los fallos que este pipeline induce.

14. Notebook asociado

P12_instructgpt_rlhf.ipynb

Qué implementa: el modelo de recompensa Bradley-Terry entrenado por descenso de gradiente sobre comparaciones por pares, el ranking resultante, una selección best-of-n, y una demostración numérica de cómo el término KL penaliza alejarse del modelo base.

Qué NO implementa: SFT, PPO, generación de texto, ni etiquetadores humanos. Las «respuestas» son cuatro vectores de características escritos a mano.

```
ai-evolution paper-lab P12 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Enumera las tres etapas y qué produce cada una.
Explicar	Explica por qué se piden comparaciones en vez de puntuaciones absolutas.
Aplicar	Cambia una comparación en el notebook y observa cómo se reordena el ranking.
Analizar	Construye un conjunto de preferencias donde el modelo aprenda a premiar la longitud.
Evaluar	¿Un modelo alineado es más seguro o solo lo parece? Argumenta con dos límites del propio paper.
Crear	Diseña una guía de anotación de una página para un dominio que conozcas, y explica qué sesgo introduce cada regla.

16. Autoevaluación

1. ¿Qué significa exactamente «desalineación de objetivo» en este contexto?
2. ¿Por qué las comparaciones son mejores datos que las puntuaciones?
3. ¿Qué ocurre si se elimina el término KL del objetivo?
4. ¿Qué es el reward hacking y cómo lo detectarías en un sistema propio?
5. ¿Por qué un modelo de 1 300 millones alineado puede preferirse a uno de 175 000 millones sin alinear?

6. ¿Qué es el impuesto de alineación?
7. ¿Qué **no** arregla RLHF?

17. Respuestas esperadas

1. Que el objetivo optimizado (verosimilitud del texto) difiere de lo que el usuario quiere (una respuesta útil). Escalar mejora el primero sin acercar el segundo.
2. Porque son más consistentes entre anotadores: una escala numérica se interpreta de forma distinta por cada persona y deriva con el tiempo, mientras que «cuál prefieres» es estable.
3. La política deriva libremente hacia regiones donde el modelo de recompensa da valores altos pero el texto es degenerado. El KL ancla la política al modelo SFT.
4. Explotar una característica que correlaciona con la recompensa sin mejorar la calidad real. Se detecta evaluando con humanos independientes del modelo de recompensa y controlando por variables superficiales como la longitud.
5. Porque el modelo grande optimiza un objetivo distinto del que el usuario quiere. La alineación reorganiza el comportamiento, y eso vale más que capacidad bruta mal dirigida.
6. La pérdida de rendimiento en algunos benchmarks académicos que aparece al alinear, y que el paper mitiga mezclando gradientes de preentrenamiento.
7. La alucinación, la falta de conocimiento actualizado, la sensibilidad al prompt y el sesgo heredado del corpus. Cambia el comportamiento, no lo que el modelo sabe.

18. Fuentes primarias

- Ouyang, L. et al. (2022). *Training language models to follow instructions with human feedback*. **NeurIPS 2022**. [arXiv:2203.02155](https://arxiv.org/abs/2203.02155) · consultado 2026-08-16.
- Christiano, P. et al. (2017). *Deep Reinforcement Learning from Human Preferences*. [arXiv:1706.03741](https://arxiv.org/abs/1706.03741) · consultado 2026-08-16.
- Stiennon, N. et al. (2020). *Learning to summarize with human feedback*. [arXiv:2009.01325](https://arxiv.org/abs/2009.01325) · consultado 2026-08-16.
- Bai, Y. et al. (2022). *Constitutional AI: Harmlessness from AI Feedback*. [arXiv:2212.08073](https://arxiv.org/abs/2212.08073) · consultado 2026-08-16.



Evaluación — P12 · Entrenar modelos de lenguaje para seguir instrucciones con retroalimentación humana

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Training language models to follow instructions with human feedback* (2022, arXiv:2203.02155 · NeurIPS 2022) · **Nivel:** L3

Parte A — Contexto histórico (20 pts)

- (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
- (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

- (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
- (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

- (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

- (10) Ejecuta `P12_instructgpt_rlhf.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
- (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
- (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

- (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
- (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).