

P17

Modelos probabilísticos de difusión con eliminación de ruido

Denoising Diffusion Probabilistic Models

Jonathan Ho, Ajay Jain, Pieter Abbeel · 2020 · [arXiv:2006.11239](https://arxiv.org/abs/2006.11239) · NeurIPS 2020

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-16.

P17 — Difusión (DDPM)

Ruta ampliada · La generación deja de ser un salto en la oscuridad: se aprende a deshacer, paso a paso, un proceso de ruido que se conoce en forma cerrada.

Nivel: L3 · **Motor:** `diffusion` · **Notebook:** `P17_diffusion.ipynb` · **Anexo matemático:** probabilidad y verosimilitud

1. Identificación

Campo	Valor
Título original	<i>Denoising Diffusion Probabilistic Models</i>
Autoría	Jonathan Ho, Ajay Jain, Pieter Abbeel
Año	2020
Venue	arXiv:2006.11239 · NeurIPS 2020
Fuente primaria	arXiv:2006.11239
Acceso	Abierto
Fecha de consulta	2026-08-16

2. Problema anterior

Generar imágenes tenía dos familias con defectos opuestos. Las **GAN** producían muestras nítidas pero su entrenamiento adversario era inestable y colapsaba la diversidad: el generador encontraba unos pocos modos que engañaban al discriminador y se quedaba ahí. Los **VAE** eran estables y tenían verosimilitud tratable, pero sus muestras salían borrosas.

Faltaba un objetivo que fuera **estable como el de un VAE** y produjera **calidad de GAN**.

3. Propuesta

Definir un proceso **directo** que destruye la imagen añadiendo ruido gaussiano en `T` pasos —fijo, sin parámetros que aprender, y con forma cerrada para saltar a cualquier paso— y entrenar una red para invertirlo.

El giro decisivo es la parametrización: en vez de predecir la imagen limpia, la red predice **el ruido ϵ que se añadió**. Con esa elección, la cota variacional se simplifica a un error cuadrático medio entre el ruido real y el predicho.

El artículo establece además la conexión entre esta formulación y el *denoising score matching* con dinámica de Langevin, lo que conecta dos líneas de investigación que iban por separado.

4. Intuición sin fórmulas

Una foto que se va llenando de nieve de televisor hasta quedar en ruido puro. Como sabes exactamente cuánta nieve echaste en cada paso, puedes entrenar a alguien a estimarla y quitarla. Generar es empezar desde nieve pura y quitar nieve muchas veces.

Dónde deja de funcionar la analogía: al quitar nieve no recuperas *la* foto original, sino *una* foto plausible. El proceso inverso es estocástico: ahí está la generación, no en la reconstrucción.

5. Matemática mínima

Proceso directo (conocido, no se aprende):

$$q(x_t | x_{t-1}) = N(x_t; \sqrt{1-\beta_t} \cdot x_{t-1}, \beta_t \cdot I)$$

Salto directo a cualquier paso (la propiedad que lo hace entrenable):

$$x_t = \sqrt{\alpha_t} \cdot x_0 + \sqrt{1-\alpha_t} \cdot \epsilon, \quad \epsilon \sim N(0, I), \quad \alpha_t = \prod_{s \leq t} (1-\beta_s)$$

Despejando la imagen:


$$x_0 = (x_t - \sqrt{1-\alpha_t} \cdot \epsilon) / \sqrt{\alpha_t}$$

Pérdida simplificada:

$$L = E_{\{t, x_0, \epsilon\}} \|\epsilon - \epsilon_\theta(x_t, t)\|^2$$

La segunda línea es la que convierte un problema generativo en **regresión supervisada**: el par de entrenamiento (x_t, ϵ) se fabrica gratis desde cualquier imagen y cualquier t .

6. Arquitectura o flujo



7. Qué observar en el paper original

- La **derivación de la cota variacional** y cómo, al reparametrizar en términos de ϵ , colapsa en un error cuadrático simple. Es el corazón del artículo.
- La sección que conecta con **score matching y Langevin**: explica por qué esto no es un truco aislado sino un punto de encuentro entre dos formulaciones.
- El **planificador de β** elegido y su efecto en la calidad de las muestras.
- Los resultados en **CIFAR-10** y **LSUN**, y la discusión sobre verosimilitud frente a calidad perceptual: el modelo no gana en ambas a la vez, y los autores lo dicen.

8. Evidencia y resultados

Síntesis de imágenes de alta calidad en CIFAR-10 y LSUN, con resultados del estado del arte de la época en calidad de muestra.

Los valores exactos de FID e Inception Score por conjunto están en las tablas del artículo. Verificarlos allí antes de citarlos.

La miniatura de este eje aporta la mecánica: la SNR cae de $\sim 10^4$ a $\sim 4,5$ en 20 pasos, la reconstrucción con el ϵ correcto es exacta hasta precisión de máquina, y el factor de amplificación $\sqrt{(1-\bar{\alpha}_t)}/\sqrt{\bar{\alpha}_t}$ explica por qué el muestreo va paso a paso.

9. Impacto

- Desplazó a las GAN como método por defecto para generación de imágenes en pocos años.
- Es la base técnica de los sistemas de texto a imagen posteriores, que añaden **condicionamiento** (a menudo con un codificador de texto tipo CLIP) y difusión en espacio latente.
- Trasladó la idea a audio, vídeo, moléculas y política de robots: cualquier dominio donde «añadir ruido» esté bien definido.

10. Limitaciones

1. **Muestreo lento.** Generar exige cientos o miles de pasadas por la red, frente a una sola de una GAN. Toda la investigación posterior de destilación y solucionadores rápidos ataca esto.
2. **Coste de entrenamiento alto.**
3. **Verosimilitud frente a calidad perceptual:** optimizar la cota no maximiza la calidad percibida, y el artículo lo documenta.
4. **Sin condicionamiento** en esta versión: no hay forma de pedir *qué* generar.
5. **Sesgo y contenido del conjunto de entrenamiento** se reproducen en las muestras; el artículo no aborda esa dimensión.
6. **El proceso directo gaussiano** no encaja igual de bien en datos discretos (texto), donde hicieron falta formulaciones distintas.

11. Errores comunes

Error	Corrección
«El modelo predice la imagen limpia»	Predice el ruido . Es la parametrización que hace la pérdida simple y bien condicionada.
«La difusión la inventó este paper»	Sohl-Dickstein et al. (2015) la propuso antes; DDPM la hizo funcionar y la simplificó.
«Es determinista, luego no genera»	El proceso inverso es estocástico: de ahí sale la diversidad.
«Difusión = texto a imagen»	El condicionamiento por texto es posterior . Este paper genera sin condición.
«Más pasos siempre es mejor»	Hay rendimientos decrecientes, y el coste crece linealmente.

12. Relación con trabajos anteriores

- **Sohl-Dickstein et al. (2015)** — difusión no supervisada; el antecedente directo. [arXiv:1503.03585](#)
- **VAE (2013) y GAN (2014)** — las dos familias cuyas debilidades motivan el trabajo.
- **P02 Backpropagation y P04 AlexNet** — la red que predice ϵ es una CNN entrenada por retropropagación.

13. Relación con trabajos posteriores

- **P18 CLIP (2021)** — aporta el espacio compartido imagen-texto que permite condicionar la generación con palabras.
- **Difusión latente y modelos de texto a imagen (2022+)** — difusión en un espacio comprimido en vez de en píxeles.
- **Destilación de muestreo (2022+)** — reducir cientos de pasos a unos pocos.

14. Notebook asociado

P17_diffusion.ipynb

Qué implementa: el proceso directo con forma cerrada, la trayectoria de SNR, la reconstrucción desde ϵ y la amplificación del error por paso.

Qué NO implementa: la red ϵ_θ , el muestreo estocástico inverso, la U-Net ni ninguna imagen. Cuatro números no son una imagen, y aquí el ϵ se conoce en lugar de predecirse.

```
ai-evolution paper-lab P17 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe la fórmula del salto directo a x_t y define $\bar{\alpha}_t$.
Explicar	Explica por qué predecir ϵ es mejor condicionado que predecir x_0 .
Aplicar	Calcula $\bar{\alpha}_t$ para un planificador lineal de 20 pasos y localiza dónde la SNR cruza 1.
Analizar	Deriva el factor de amplificación del error de ϵ sobre x_0 y explica su forma.
Evaluar	Un equipo reporta FID excelente y muestras poco diversas. ¿Qué métrica falta y por qué?
Crear	Diseña un proceso directo para datos discretos y argumenta qué se rompe respecto al gaussiano.

16. Autoevaluación

1. ¿Por qué el proceso directo no tiene parámetros que aprender?
2. ¿Qué propiedad permite entrenar sin simular los t pasos uno a uno?
3. ¿Por qué la pérdida acaba siendo un error cuadrático simple?
4. ¿De dónde sale la diversidad de las muestras?
5. ¿Por qué el muestreo es lento y qué se ha hecho después al respecto?
6. ¿Qué le falta a este paper para poder pedirle «un gato con sombrero»?

7. ¿Qué idea que hoy se asocia a «difusión» no está en este artículo?

17. Respuestas esperadas

1. Porque β_t es un planificador fijo elegido de antemano: añadir ruido gaussiano está completamente especificado, no hay nada que ajustar.
2. La composición de gaussianas es gaussiana, así que $q(x_t | x_0)$ tiene forma cerrada y se puede muestrear t al azar y saltar directamente.
3. Porque al reparametrizar la cota variacional en términos de ϵ , los términos se simplifican y queda $\|\epsilon - \epsilon_\theta\|^2$ con un peso que el paper decide ignorar.
4. Del proceso inverso, que es estocástico: se parte de ruido distinto y se añade ruido en cada paso de denoising.
5. Porque requiere una pasada por la red por cada paso. Después llegaron solucionadores de pocos pasos y destilación del muestreador.
6. Condicionamiento. Necesita un espacio donde el texto y la imagen sean comparables — el problema de P18.
7. El condicionamiento por texto, la difusión latente y la guía sin clasificador: todo posterior.

18. Fuentes primarias

- Ho, J., Jain, A. y Abbeel, P. (2020). *Denoising Diffusion Probabilistic Models*. **NeurIPS 2020**. arXiv:2006.11239 · consultado 2026-08-16.
- Sohl-Dickstein, J. et al. (2015). *Deep Unsupervised Learning using Nonequilibrium Thermodynamics*. arXiv:1503.03585 · consultado 2026-08-16.



Evaluación — P17 · Modelos probabilísticos de difusión con eliminación de ruido

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Denoising Diffusion Probabilistic Models* (2020, arXiv:2006.11239 · NeurIPS 2020) · **Nivel:** L3

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P17_diffusion.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).