

P20

Mamba: modelado de secuencias en tiempo lineal con espacios de estados selectivos

Mamba: Linear-Time Sequence Modeling with Selective State Spaces

Albert Gu, Tri Dao · 2023 · [arXiv:2312.00752](https://arxiv.org/abs/2312.00752) · COLM 2024 (Outstanding Paper Award)

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-16.

P20 — Mamba

Ruta ampliada · El primer competidor serio del Transformer en lenguaje: tiempo lineal y estado de tamaño fijo, sin atención.

Nivel: L4 · Motor: `ssm` · Notebook: `P20_mamba.ipynb` · Anexo matemático: complejidad, coste y escalado

1. Identificación

Campo	Valor
Título original	<i>Mamba: Linear-Time Sequence Modeling with Selective State Spaces</i>
Autoría	Albert Gu, Tri Dao
Año	2023 (arXiv v1, diciembre)
Venue	arXiv:2312.00752 · COLM 2024 (Outstanding Paper Award)
Fuente primaria	arXiv:2312.00752
Acceso	Abierto
Fecha de consulta	2026-08-16

2. Problema anterior

El Transformer compró paralelismo pagando $O(n^2)$ en cómputo y una caché que crece con la secuencia. Para contextos largos eso es prohibitivo, y no por falta de ingeniería: es la forma del mecanismo.

Existían alternativas subcuadráticas —atención lineal, convoluciones con puertas, modelos recurrentes, espacios de estados estructurados (S4)— y todas compartían el mismo destino: funcionaban bien en señales continuas (audio, series) y **perdían claramente frente a la atención en lenguaje**.

Los autores identifican por qué: esos modelos son **invariantes en el tiempo**. Sus parámetros no dependen de lo que están leyendo, así que no pueden decidir ignorar un token irrelevante ni retener uno importante. Les falta razonamiento sobre el **contenido**.

3. Propuesta

Hacer que los parámetros del espacio de estados sean **función de la entrada**. Esa es la selección: la puerta que decide cuánto se propaga y cuánto se olvida depende del token actual.

Tiene un coste inmediato: un SSM con parámetros variables ya no se puede expresar como una convolución, que era justo lo que hacía eficientes a los modelos previos. La segunda mitad de la contribución es resolver eso con un **algoritmo paralelo consciente del hardware** que opera en modo recurrente sin materializar el estado expandido en memoria lenta.

Con ambas piezas, integran el bloque en una arquitectura simplificada **sin atención y sin bloques MLP separados**, y reportan inferencia con 5× más rendimiento que Transformers comparables y escalado lineal en la longitud.

4. Intuición sin fórmulas

Un RNN es alguien tomando notas en una libreta de tamaño fijo: barato, pero acaba borrando. La atención es alguien que se guarda todos los papeles: no olvida nada, pero necesita releerlos todos cada vez. Mamba mantiene la libreta de tamaño fijo y añade criterio: **decide qué apuntar según lo que está leyendo**.

Dónde deja de funcionar la analogía: una libreta de tamaño fijo **es** compresión con pérdida. Por buena que sea la decisión, no puedes recuperar literalmente un token que decidiste no apuntar. La atención sí.

5. Matemática mínima

SSM invariante en el tiempo (S4 y anteriores):

$$h_t = A \cdot h_{t-1} + B \cdot x_t$$

$$y_t = C \cdot h_t$$
A, B, C FIJAS
→ equivalente a una convolución con un núcleo largo, y por tanto paralelizable

SSM selectivo (Mamba):

$$h_t = A(x_t) \cdot h_{t-1} + B(x_t) \cdot x_t$$


$$y_t = C(x_t) \cdot h_t$$
A, B, C DEPENDEN DE x_t
→ ya no es convolución; hace falta un escaneo paralelo explícito

Coste y memoria, para longitud n , dimensión d y estado N :

	Cómputo por capa	Memoria durante la generación	Camino entre posiciones
Atención	$O(n^2 \cdot d)$	$O(n \cdot d)$ — la caché KV crece	$O(1)$
SSM selectivo	$O(n \cdot d \cdot N)$	$O(d \cdot N)$ — constante	$O(n)$

Las dos últimas columnas son el compromiso completo: memoria constante a cambio de perder el acceso directo a cualquier posición.

6. Arquitectura o flujo



7. Qué observar en el paper original

- La **motivación por tareas sintéticas**: copia selectiva y cabezas de inducción. Están diseñadas para aislar exactamente la capacidad que falta a los SSM previos, y son la mejor parte pedagógica del artículo.
- La explicación de por qué la selección **rompe** la equivalencia con la convolución, y qué se hace al respecto. Es donde el paper es más honesto sobre su propio coste.
- El **algoritmo consciente del hardware**: qué se guarda en memoria rápida y qué se recomputa.
- Las **ablaciones** sobre qué parámetros conviene hacer selectivos.
- La comparación de **rendimiento de inferencia** y de escalado con la longitud, además de la calidad.

8. Evidencia y resultados

Evaluación en lenguaje, audio y genómica, con comparación frente a Transformers de tamaño comparable y frente a SSM previos.

El artículo reporta que **Mamba-3B supera a Transformers de su mismo tamaño e iguala a Transformers del doble de tamaño** en modelado de lenguaje, con **5× más rendimiento de inferencia** y escalado lineal, con mejoras que se mantienen en secuencias de hasta longitud de millones.

Las cifras por tarea, tamaño y línea base están en las tablas del artículo. Verificarlas allí: los resultados

dependen mucho de la escala evaluada, y el rango del paper no llega al de los modelos frontera.

La miniatura de este eje aísla el mecanismo: en una tarea de copia selectiva, el SSM selectivo separa tokens marcados de relleno con el doble de margen que el invariante, y la tabla de complejidad muestra la memoria constante frente a la caché creciente.

9. Impacto

- Reabrió una pregunta que se daba por cerrada: **si la atención es realmente necesaria**.
- Impulsó una línea completa de arquitecturas **híbridas** que alternan bloques de atención y de SSM para quedarse con lo mejor de ambos (por ejemplo Jamba, 2024).
- Llevó el foco al **coste de inferencia y a la memoria de contexto largo**, que la comunidad trataba como problema de ingeniería y aquí se ataca desde la arquitectura.
- Ganó el **Outstanding Paper Award de COLM 2024**.

10. Limitaciones

1. **Un estado fijo es compresión con pérdida**. No hay recuperación exacta de un token concreto, cosa que la atención sí ofrece.
2. **Rendimiento peor en tareas de copia literal y recuperación exacta**, precisamente donde la atención brilla.
3. **La escala evaluada** en el artículo es menor que la de los modelos frontera; extrapolar paridad general no está respaldado.
4. **El algoritmo depende del hardware**: parte de la ventaja proviene de una implementación cuidadosa, no solo de la arquitectura.
5. **Ecosistema mucho más pequeño** que el del Transformer: menos herramientas, menos kernels optimizados, menos experiencia acumulada.
6. **La selección añade parámetros y complejidad** frente a un SSM invariante.

11. Errores comunes

Error	Corrección
«Mamba sustituye al Transformer»	Afirmación sin tarea, escala ni presupuesto. El paper reporta paridad en su rango, no en general.
«Los SSM son nuevos»	S4 y la línea de espacios de estados son anteriores. Lo nuevo es la selección .
«Es un RNN»	Comparte el estado recurrente, pero se entrena con un escaneo paralelo, no secuencialmente paso a paso.
«Tiempo lineal = siempre más rápido»	Para secuencias cortas, un Transformer bien optimizado puede ganar. La ventaja aparece con n grande.
«Memoria constante significa contexto infinito»	Significa que la memoria no crece. Lo que cabe en un estado fijo sigue siendo finito.

12. Relación con trabajos anteriores

- **Po3 LSTM (1997)** — el estado recurrente con puertas; Mamba es su descendiente conceptual con entrenamiento paralelizable.
- **Po8 Transformer (2017)** — el coste cuadrático que motiva todo el trabajo.
- **S4 y espacios de estados estructurados (2021-2022)** — la base directa, invariante en el tiempo.
- **P19 Leyes de escalado (2022)** — el marco económico donde se juzga si una arquitectura compensa.

13. Relación con trabajos posteriores

- **Jamba (AI21, 2024)** — híbrido Transformer-Mamba con mezcla de expertos, con contexto largo. [arXiv:2403.19887](#)
- **P21 Mixtral (2024)** — el otro eje de abaratamiento: los parámetros en vez de la secuencia.
- **Arquitecturas híbridas posteriores** — la conclusión práctica de la comunidad: alternar ambos bloques en vez de elegir uno.

14. Notebook asociado

P20_mamba.ipynb

Qué implementa: la tarea de copia selectiva comparando puertas fijas frente a puertas dependientes de la entrada, y la tabla de cómputo y memoria frente a la atención.

Qué NO implementa: el escaneo paralelo consciente del hardware —que es la mitad de la contribución—, parámetros aprendidos ni ningún entrenamiento. Las puertas están fijadas a mano para aislar el mecanismo.

```
ai-evolution paper-lab P20 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe la recurrencia del SSM invariante y la del selectivo, y señala la diferencia.
Explicar	Explica por qué la selección impide expresar el modelo como convolución.
Aplicar	Ejecuta el notebook y compara la separación de ambos modelos.
Analizar	Calcula, para $n = 100\ 000$ y $d = 512$, cuántas veces más memoria usa la caché KV que un estado de $N = 16$.
Evaluar	¿En qué tarea concreta apostarías por atención y no por un SSM? Justifica con el mecanismo.
Crear	Diseña una arquitectura híbrida y argumenta en qué capas pondrías atención y por qué.

16. Autoevaluación

1. ¿Qué significa que un SSM sea «invariante en el tiempo» y por qué es una limitación?
2. ¿Qué se gana y qué se pierde al hacer los parámetros dependientes de la entrada?
3. ¿Por qué la memoria del SSM no crece con la longitud?
4. ¿Cuál es el camino entre dos posiciones distantes en cada arquitectura?
5. ¿En qué tipo de tarea esperarías que la atención siga ganando?

6. ¿Por qué el algoritmo consciente del hardware es parte de la contribución y no un detalle?
7. ¿Qué afirmación sobre Mamba **no** está respaldada por el paper?

17. Respuestas esperadas

1. Que **A**, **B** y **C** no dependen del token que se está procesando. Aplica la misma transformación a todo, así que no puede decidir ignorar el relleno ni retener lo relevante.
2. Se gana razonamiento sobre el contenido; se pierde la equivalencia con la convolución y, con ella, la vía eficiente de entrenamiento que había que reconstruir.
3. Porque el estado tiene dimensión fija $d \cdot N$, decidida por la arquitectura y no por la entrada. Cada token actualiza ese estado en lugar de añadirse a una caché.
4. $O(1)$ en atención —cualquier posición mira a cualquier otra directamente— y $O(n)$ en el SSM, donde la información viaja a través del estado paso a paso.
5. En recuperación literal: copiar un identificador exacto visto miles de tokens atrás, búsqueda de un dato concreto en un contexto largo, tareas de *needle in a haystack*.
6. Porque sin él la selección sería inviable en la práctica: la ventaja de rendimiento que se reporta depende de esa implementación, no solo de la formulación.
7. Que sustituya al Transformer en general, o que alcance paridad a cualquier escala. El artículo evalúa un rango concreto y no afirma eso.

18. Fuentes primarias

- Gu, A. y Dao, T. (2023). *Mamba: Linear-Time Sequence Modeling with Selective State Spaces*. **COLM 2024**. arXiv:2312.00752 · consultado 2026-08-16.
- Lieber, O. et al. (2024). *Jamba: A Hybrid Transformer-Mamba Language Model*. arXiv:2403.19887 · consultado 2026-08-16.



Evaluación — P20 · Mamba: modelado de secuencias en tiempo lineal con espacios de estados selectivos

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Mamba: Linear-Time Sequence Modeling with Selective State Spaces* (2023, arXiv:2312.00752 · COLM 2024 (Outstanding Paper Award)) · **Nivel:** L4

Parte A — Contexto histórico (20 pts)

- (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
- (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

- (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
- (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

- (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

- (10) Ejecuta `P20_mamba.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
- (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
- (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

- (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
- (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).