

P21

Mixtral: mezcla dispersa de expertos

Mixtral of Experts

Albert Q. Jiang, y otros (Mistral AI) · 2024 · arXiv:2401.04088

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-16.

P21 — Mixtral (mezcla dispersa de expertos)

Ruta ampliada · Desacopla capacidad de cómputo: muchos parámetros disponibles, pocos activos por token.

Nivel: L3 · **Motor:** moe · **Notebook:** P21_moe.ipynb · **Anexo:** complejidad y coste · **Anexo matemático:** complejidad, coste y escalado

1. Identificación

Campo	Valor
Título original	Mixtral of Experts
Autoría	Albert Q. Jiang y otros (Mistral AI)
Año	2024
Venue	arXiv:2401.04088
Fuente primaria	arXiv:2401.04088
Acceso	Abierto · pesos publicados con licencia Apache 2.0
Fecha de consulta	2026-08-16

2. Problema anterior

En un Transformer **denso**, cada token que entra activa **todos** los parámetros del modelo. Duplicar la capacidad duplica el coste de cada token, en entrenamiento y —lo que más duele— en cada petición de inferencia para siempre.

Chinchilla había dicho cuánto conviene gastar; no había dicho cómo obtener más capacidad **sin** pagarla en cada token. La capa dispersa de expertos existía desde Shazeer et al. (2017) y en trabajos posteriores, pero arrastraba fama de inestable y de difícil de reproducir, y los modelos que la usaban no eran abiertos.

3. Propuesta

Sustituir la capa feed-forward de cada bloque por **8 expertos** y un **router** que elige **2 por token**. La salida es la combinación ponderada de esos dos.

El modelo resultante tiene ≈47 000 millones de parámetros totales pero usa ≈13 000 millones por token. El artículo reporta que iguala o supera a Llama 2 70B y a GPT-3.5 en los benchmarks evaluados, con la variante ajustada a instrucciones superando también a varios modelos de chat de la época.

Y —la parte que más impacto tuvo— **publica los pesos bajo Apache 2.0**, lo que convirtió la arquitectura dispersa en algo que cualquiera podía inspeccionar, servir y ajustar.

4. Intuición sin fórmulas

Un hospital con ocho especialistas. Cada paciente no pasa por los ocho: recepción lo deriva a los dos que corresponden. El hospital tiene la capacidad de ocho; cada consulta cuesta dos.

Dónde deja de funcionar la analogía: los ocho especialistas tienen que estar **contratados y en el edificio** aunque solo trabajen dos. En un MoE hay que cargar todos los pesos en memoria aunque solo se computen dos expertos. Ahorra cómputo, no memoria.

5. Matemática mínima

Capa densa:
 $y = \text{FFN}(x)$

coste $\propto$ TODOS los parámetros

Capa MoE dispersa con top-k:
scores = $x \cdot W_{\text{router}}$
top = índices de los k scores mayores
 $g(x) = \text{softmax}(\text{scores}[\text{top}])$
 $y = \sum_{i \in \text{top}} g_i(x) \cdot E_i(x)$

(uno por experto)

pesos normalizados sobre los k elegidos
coste $\propto$ k expertos

Con `n_expertos = 8` y `k = 2`, la **fracción activa** es `k/n = 25 %`.


Balaneo de carga. El router puede colapsar: unos pocos expertos reciben casi todos los tokens y el resto no recibe gradiente. Se mitiga con un término auxiliar que penaliza el desequilibrio, medible con el coeficiente de variación de la carga:

$$\text{CV} = \text{desviación_típica}(\text{carga}) / \text{media}(\text{carga}) \quad \rightarrow \quad 0 = \text{reparto perfecto}$$

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A05 §7 · Dispersión: cuando los parámetros dejan de ser uno	dispersión: cuándo un parámetro deja de contar como coste por token

6. Arquitectura o flujo



Los seis expertos en gris **no se computan** para este token — pero **sí están cargados en memoria**, porque el siguiente token puede necesitarlos.

7. Qué observar en el paper original

- La **tabla de parámetros totales frente a activos**, y cómo se traduce en coste de inferencia.
- El **análisis de especialización del router**: los autores estudian si los expertos se especializan por dominio o por sintaxis. El resultado es menos limpio de lo que la intuición sugiere, y merece leerse con cuidado.
- La comparación de **coste efectivo** frente a modelos densos de rendimiento similar.
- La sección de la variante **instruct** y su evaluación.
- Que es un **informe técnico de un modelo publicado**, no un estudio controlado de la arquitectura: hay que leerlo con esa expectativa.

8. Evidencia y resultados

Evaluación frente a Llama 2 70B y GPT-3.5 en un conjunto amplio de benchmarks: razonamiento, matemáticas, código y multilingüe.

El artículo reporta que Mixtral iguala o supera a ambos usando **muchos menos parámetros activos por token**, y que la variante ajustada a instrucciones supera en evaluaciones humanas a varios modelos de chat contemporáneos.

Las cifras por benchmark están en las tablas del artículo. Verificarlas allí, y tener presente que un informe técnico de un laboratorio sobre su propio modelo pide replicación independiente antes de darse por firme.

La miniatura de este eje muestra la mecánica y su fallo característico: con 8 expertos y top-2, la fracción activa es del 25 %, y el reparto de carga es desigual ($CV \approx 0,13$) hasta que se añade el término de balanceo ($CV \approx 0,04$).

9. Impacto

- Normalizó la **mezcla de expertos** como arquitectura de producción, no como curiosidad de investigación.
- Al publicar los pesos con licencia permisiva, permitió que la comunidad estudiara, sirviera y ajustara un modelo disperso real.
- Obligó a la industria a distinguir **parámetros totales, parámetros activos y memoria necesaria** al comparar modelos: antes se citaba un solo número.
- Empujó el trabajo sobre servido de modelos dispersos: enrutado eficiente, expertos repartidos entre dispositivos y descarga a memoria del sistema.

10. Limitaciones

1. **Ahorra cómputo, no memoria.** Hay que cargar los 47 000 M aunque solo se computen 13 000 M. Es el malentendido más caro de esta arquitectura.
2. **Colapso del router:** sin balanceo, unos pocos expertos acaparan y el modelo disperso se comporta como uno denso más caro.
3. **Complejidad de servido:** enrutar tokens a expertos repartidos entre GPU añade comunicación y hace la latencia menos predecible.
4. **La especialización es difícil de interpretar:** los expertos no se corresponden con conceptos limpios.
5. **Informe técnico, no estudio controlado:** no aísla la contribución de la arquitectura frente a los datos o al entrenamiento.
6. **Ajuste fino más delicado** que en un modelo denso equivalente.

11. Errores comunes

Error	Corrección
«13 000 M activos, luego cabe en una GPU de 13 000 M»	Falso y caro. Hay que cargar todos los expertos: dimensiona por los 47 000 M.
«Los expertos se especializan por tema»	El análisis del paper no muestra una especialización semántica limpia.
«MoE es siempre más barato»	Es más barato en FLOPs por token . En memoria y en complejidad de servido, no.
«Mixtral inventó la mezcla de expertos»	Shazeer et al. (2017) y trabajos posteriores son anteriores. Mixtral la hizo abierta y de producción.
«Más expertos siempre es mejor»	Más expertos con el mismo k agravan el desbalanceo y la complejidad de comunicación.

12. Relación con trabajos anteriores

- **Shazeer et al. (2017)** — la capa MoE dispersa con puertas, el antecedente directo. [arXiv:1701.06538](#)
- **Po8 Transformer (2017)** — la capa feed-forward que se sustituye, y donde vive la mayoría de los parámetros de cada bloque.
- **P19 Leyes de escalado (2022)** — el marco de coste que esta arquitectura reescribe: $C \approx 6ND$ deja de valer con la misma N .

13. Relación con trabajos posteriores

- **Jamba (2024)** — combina MoE con bloques de Mamba. [arXiv:2403.19887](#)
- **P22 DeepSeek-R1 (2025)** — la línea de modelos abiertos de gran escala donde lo disperso ya es la norma.
- **Trabajo de servido de modelos dispersos (2024+)** — enrutado, descarga y paralelismo de expertos.

14. Notebook asociado

P21_moe.ipynb

Qué implementa: un router top-2 sobre 8 expertos con 400 tokens, el conteo de parámetros totales frente a activos, la medición del desbalanceo con CV y el efecto del término de balanceo. Incluye el cálculo de presupuesto de memoria correcto frente al incorrecto.

Qué NO implementa: los expertos no computan nada —solo se cuenta a quién se enruta—, no hay entrenamiento conjunto, ni capacidad por experto, ni comunicación entre dispositivos, que es donde está la dificultad real.

```
ai-evolution paper-lab P21 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe la salida de una capa MoE con top-k y define $g_i(x)$.
Explicar	Explica por qué MoE ahorra cómputo pero no memoria.
Aplicar	Calcula la fracción activa para (8, k=1), (8, k=2), (64, k=2).
Analizar	Ejecuta el notebook y explica qué mide el CV y por qué un CV alto es un problema de entrenamiento, no solo de eficiencia.
Evaluar	Un proveedor anuncia «modelo de 13 000 M» para un MoE 8×7B. ¿Qué le objetas?
Crear	Diseña un experimento que distinga si los expertos se especializan por dominio o por token frecuente.

16. Autoevaluación

1. ¿Qué se desacopla exactamente en una arquitectura dispersa?
2. ¿Por qué hace falta un término de balanceo de carga?
3. ¿Qué le pasa a un experto que no recibe tokens durante el entrenamiento?
4. ¿Por qué la memoria necesaria es la de **todos** los expertos?
5. ¿Cómo cambia $C \approx 6ND$ en un modelo disperso?
6. ¿Qué hace de este paper un informe técnico y no un estudio controlado?
7. ¿Qué ventaja no técnica tuvo publicar los pesos con Apache 2.0?

17. Respuestas esperadas

1. La **capacidad** (parámetros totales, que determinan cuánto puede saber el modelo) del **cómputo por token** (parámetros activos, que determinan cuánto cuesta cada token).
2. Porque el router tiende a concentrarse: si un experto empieza ligeramente mejor, recibe más tokens, mejora más y acapara. Es un bucle de realimentación positiva.
3. No recibe gradiente y deja de mejorar: su capacidad queda desperdiciada y el modelo disperso degenera hacia uno denso más pequeño y más caro de servir.
4. Porque el enrutado depende del token y cualquier token puede activar cualquier experto: no se puede saber de antemano cuáles harán falta.
5. Deja de valer con N = parámetros totales. El cómputo escala con los parámetros **activos**, así que hay que distinguir ambos en la ecuación.
6. Que describe un modelo concreto que se publica, sin ablaciones que aíslen la contribución de la arquitectura frente a los datos, el tamaño o la receta de entrenamiento.
7. Permitió replicación, auditoría y servido independientes, y convirtió lo disperso en algo estudiable por cualquiera en vez de en una afirmación de un laboratorio.

18. Fuentes primarias

- Jiang, A. Q. et al. (2024). *Mixtral of Experts*. arXiv:2401.04088 · consultado 2026-08-16.
- Shazeer, N. et al. (2017). *Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer*. arXiv:1701.06538 · consultado 2026-08-16.



Evaluación — P21 · Mixtral: mezcla dispersa de expertos

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Mixtral of Experts* (2024, arXiv:2401.04088) · **Nivel:** L3

Parte A — Contexto histórico (20 pts)

- (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
- (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

- (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
- (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

- (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

- (10) Ejecuta `P21_moe.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
- (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
- (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

- (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
- (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).