

P22

DeepSeek-R1: incentivar la capacidad de razonamiento mediante aprendizaje por refuerzo

DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning

DeepSeek-AI · 2025 · arXiv:2501.12948 · Nature 645, 633–638 (2025)

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-16.

P22 — DeepSeek-R1

Ruta ampliada · El razonamiento se incentiva con refuerzo puro, sin trazas humanas anotadas. Y es el primer LLM de pesos abiertos publicado tras revisión por pares.

Nivel: L5 · **Motor:** r1_reasoning · **Notebook:** P22_deepseek_r1.ipynb · **Anexo:** cálculo y gradientes · **Anexo matemático:** probabilidad y verosimilitud

1. Identificación

Campo	Valor
Título original	DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning
Autoría	DeepSeek-AI
Año	2025
Venue	arXiv:2501.12948 (enero 2025) · Nature 645, 633–638 (18 sept. 2025)
Fuente primaria	arXiv:2501.12948 · DOI Nature
Acceso	Abierto · pesos publicados
Fecha de consulta	2026-08-16

2. Problema anterior

El razonamiento en cadena de ReAct y del *chain-of-thought* funcionaba, pero dependía de **demostraciones humanas**: alguien tenía que escribir miles de razonamientos ejemplares para que el modelo los imitara. Eso es caro, no escala, y —más importante— **acota la capacidad del modelo a la de quien escribió los ejemplos**.

La alineación por preferencias de InstructGPT y DPO optimizaba lo que a un anotador *le parecía* mejor, una señal subjetiva y hackeable. Para razonar hay algo mejor disponible: en matemáticas y código, la respuesta **se puede comprobar**.

3. Propuesta

Entrenar con **refuerzo puro sobre una recompensa verificable**: no se premia el estilo del razonamiento ni se compara con una traza de referencia. Solo se comprueba si la respuesta final es correcta.

El resultado central es que el comportamiento de razonamiento **emerge** de ese incentivo. El artículo reporta la aparición de patrones como autorreflexión, verificación y adaptación dinámica de la estrategia, sin que nadie los demostrara. Y esos patrones, una vez presentes en un modelo grande, pueden **transferirse a modelos menores**.

El algoritmo de refuerzo concreto y las variantes del modelo se describen en el cuerpo del artículo. El resumen no los nombra: verificarlos allí antes de citarlos.

4. Intuición sin fórmulas

Enseñar a resolver problemas de matemáticas sin corregir el procedimiento: solo dices «bien» o «mal» al resultado. Con suficientes intentos, el alumno descubre por su cuenta que le renta comprobar antes de entregar — porque comprobar sube su tasa de aciertos, no porque se lo mandaran.

Dónde deja de funcionar la analogía: el alumno entiende *por qué* comprobar ayuda. El modelo solo ha encontrado una política con más recompensa esperada. Y esa distinción importa cuando el verificador no existe.

5. Matemática mínima

RLHF (P12): r = modelo de recompensa aprendido de preferencias humanas
 → subjetivo, aproximado, explotable (reward hacking)

Aquí : $r(x, y) = 1$ si `respuesta_final(y)` es correcta, 0 si no
 → objetivo, exacto, no explotable por estilo

Objetivo: maximizar $E_{y \sim \pi(\cdot|x)} [r(x, y)]$


La señal **no dice cómo razonar**. Solo dice si acertaste. Todo lo que aparezca entre el enunciado y la respuesta es instrumental: sobrevive si aumenta la probabilidad de acertar.

Consecuencia medible y no gratuita: las trayectorias que aciertan más son **más largas**, así que la política aprendida gasta más tokens por respuesta. El cómputo se desplaza del entrenamiento a la inferencia.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A03 §6 · Gradiente de política (REINFORCE)	el gradiente de política, con una recompensa verificable en vez de aprendida

6. Arquitectura o flujo



Nadie etiqueta el contenido de las trazas. La única flecha con información humana es la que aporta **la solución conocida** del problema.

7. Qué observar en el paper original

- El **algoritmo de refuerzo** empleado y por qué se elige frente a PPO: está en el cuerpo, no en el resumen.
- El **diseño de la recompensa**: qué se verifica exactamente y cómo se evita que el modelo aprenda a producir el formato correcto sin resolver el problema.
- Las **curvas de longitud de respuesta** a lo largo del entrenamiento: el modelo aprende solo a escribir más. Es la evidencia más elocuente de que el comportamiento emerge.
- La sección de **destilación** a modelos pequeños y qué se conserva.
- Las **limitaciones declaradas** y los dominios donde el método no aplica.
- Que existen **dos versiones**: el preprint de enero de 2025 y la versión revisada por pares en *Nature* de septiembre de 2025. Cita la que leíste.

8. Evidencia y resultados

Evaluación en matemáticas, código y tareas STEM, comparando frente a líneas base entrenadas con demostraciones humanas.

El artículo reporta que el enfoque de refuerzo puro **supera a las líneas base supervisadas** y que los patrones de razonamiento emergentes se pueden transferir a modelos menores.

Las cifras por benchmark, los tamaños de modelo y el detalle de la destilación están en el artículo. Verificarlos allí — y preferir la versión de *Nature*, que pasó revisión.

La miniatura de este eje reproduce el mecanismo con tres estrategias: la política se desplaza hacia la que verifica, la exactitud esperada sube de $\sim 0,61$ a $\sim 0,81$ **sin una sola traza anotada**, y el coste en tokens casi se duplica en el mismo movimiento.

9. Impacto

- Consolidó el **razonamiento con recompensa verificable** como línea principal de trabajo, frente a la imitación de demostraciones.
- Trasladó el foco del **cómputo de entrenamiento** al **cómputo de inferencia**: una variable que las leyes de escalado de P19 no modelan.
- Como primer LLM de pesos abiertos publicado tras revisión por pares, marcó un precedente sobre qué nivel de escrutinio es exigible a un modelo, en un campo acostumbrado a informes técnicos autopublicados.
- Popularizó la **destilación de capacidad de razonamiento** a modelos pequeños y ejecutables localmente.

10. Limitaciones

1. **Solo funciona donde hay verificador.** Matemáticas y código lo tienen; redacción, diagnóstico o consejo legal, no. Es la limitación de fondo.
2. **Coste de inferencia mayor:** razonar más es gastar más tokens en cada respuesta.
3. **La traza no es una prueba.** Se optimizó la corrección de la respuesta final, no la validez de cada paso intermedio. Un razonamiento largo y seguro de sí mismo puede contener pasos inválidos.
4. **Riesgo de sobreajuste al verificador:** aprender a satisfacer la comprobación sin resolver el problema.
5. **Coste de entrenamiento** fuera del alcance de casi cualquier equipo.
6. **La destilación transfiere comportamiento, no garantías:** el modelo pequeño imita el patrón sin la misma base.
7. **Evaluar razonamiento es un problema abierto:** los benchmarks de matemáticas y código se saturan y se contaminan rápido.

11. Errores comunes

Error	Corrección
«El modelo aprendió a razonar»	Aprendió una política con mayor recompensa esperada, en la que aparecen comportamientos que parecen razonamiento y que funcionan. Cuál de las dos descripciones es correcta es una pregunta abierta, no un hecho establecido.
«La cadena de pensamiento explica la respuesta»	Es el mismo error que en ReAct, ahora con textos más largos y persuasivos.
«Esto sustituye a RLHF»	Resuelve el razonamiento en dominios verificables. La alineación con preferencias sigue siendo necesaria para lo demás.
«Más tokens de razonamiento = mejor respuesta»	Hay rendimientos decrecientes y un coste lineal. Conviene medir dónde deja de compensar.
«Refuerzo puro significa sin datos humanos»	Los problemas y sus soluciones conocidas son datos humanos. Lo que falta son las trazas de razonamiento .

12. Relación con trabajos anteriores

- **P12 InstructGPT (2022)** — el refuerzo con retroalimentación humana cuya señal subjetiva aquí se sustituye por una verificable.
- **P13 ReAct (2022)** y el *chain-of-thought* — el razonamiento explícito que dependía de demostraciones.
- **P15 DPO (2023)** — la línea de alineación simplificada.
- **P19 Leyes de escalado (2022)** — el marco de cómputo que este trabajo desplaza hacia la inferencia.

13. Relación con trabajos posteriores

- **Snell et al. (2024)** — escalar cómputo en inferencia puede rendir más que escalar parámetros; el marco teórico del mismo fenómeno. [arXiv:2408.03314](https://arxiv.org/abs/2408.03314)

- **Lo posterior a 2025-08 no está aquí:** por el criterio de ascenso del eje, vive en `frontier/current-topics.yaml` con fecha de revisión.

Preguntas abiertas que conviene seguir:

- cómo definir recompensas verificables fuera de matemáticas y código;
- cómo evaluar la **validez de los pasos**, no solo del resultado;
- cuánto cómputo de inferencia compensa y cómo decidirlo por consulta.

14. Notebook asociado

P22_deepseek_r1.ipynb

Qué implementa: una política sobre tres estrategias de resolución entrenada **solo** con la corrección del resultado, la curva de exactitud frente a coste en tokens, y el análisis de cuándo el presupuesto de inferencia hace inviable la estrategia que más acierta.

Qué NO implementa: ningún modelo de lenguaje, ninguna generación de trazas y ningún algoritmo de refuerzo del artículo. Las exactitudes de cada estrategia están fijadas por diseño; en el paper emergen del entrenamiento.

```
ai-evolution paper-lab P22 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Enuncia la diferencia entre la recompensa de RLHF y la de este trabajo.
Explicar	Explica por qué una recompensa verificable resiste el reward hacking clásico.
Aplicar	Ejecuta el notebook con tres semillas y compara exactitud y coste finales.
Analizar	Diseña una tarea donde el modelo pueda satisfacer al verificador sin resolver el problema.
Evaluar	Un sistema mejora 3 puntos gastando 5× tokens. ¿Compensa? Di qué necesitas saber para responder.
Crear	Propón un verificador para un dominio no verificable y argumenta honestamente sus fallos.

16. Autoevaluación

1. ¿Qué señal sustituye a las trazas humanas anotadas?
2. ¿Por qué esa señal es más robusta que un modelo de recompensa aprendido?
3. ¿Qué comportamiento emerge y por qué, si nadie lo demostró?
4. ¿Qué le pasa al coste de inferencia y por qué es inevitable?
5. ¿Por qué el método no se traslada directamente a redactar un informe médico?
6. ¿Qué significa que sea el primer LLM de pesos abiertos revisado por pares?
7. ¿Qué NO demuestra una traza de razonamiento larga y convincente?

17. Respuestas esperadas

1. La corrección **verificable** de la respuesta final, comparada con una solución conocida.
2. Porque no se puede engañar con estilo, longitud o confianza aparente: o el resultado coincide o no. Un modelo de recompensa aprendido sí puede explotarse por esas vías.
3. Verificación, reflexión y cambio de estrategia. Emergen porque **aumentan la probabilidad de acertar**, que es lo único que se premia.
4. Sube, porque las trayectorias que aciertan tienden a ser más largas. Es inevitable: el incentivo premia acertar, y razonar más ayuda a acertar más.
5. Porque no existe un verificador barato y objetivo de «buen informe médico». Sin verificador, la recompensa vuelve a ser un juicio subjetivo y reaparecen todos los problemas de RLHF.
6. Que un tercero independiente examinó el método y las afirmaciones antes de publicarse, en un campo donde la norma es el informe técnico autopublicado por el propio laboratorio.
7. Que los pasos intermedios sean válidos. Se optimizó la respuesta final; el texto intermedio es un medio, no un certificado auditado.

18. Fuentes primarias

- DeepSeek-AI (2025). *DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning*. arXiv:2501.12948 · consultado 2026-08-16.
- DeepSeek-AI (2025). *DeepSeek-R1 incentivizes reasoning in LLMs through reinforcement learning*. **Nature** 645, 633–638. doi.org/10.1038/s41586-025-09422-z · consultado 2026-08-16.
- Snell, C., Lee, J., Xu, K. y Kumar, A. (2024). *Scaling LLM Test-Time Compute Optimally can be More Effective than Scaling Model Parameters*. arXiv:2408.03314 · consultado 2026-08-16.



Evaluación — P22 · DeepSeek-R1: incentivar la capacidad de razonamiento mediante aprendizaje por refuerzo

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning* (2025, arXiv:2501.12948 · Nature 645, 633–638 (2025)) · **Nivel:** L5

Parte A — Contexto histórico (20 pts)

- (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
- (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

- (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
- (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

- (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

- (10) Ejecuta `P22_deepseek_r1.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
- (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
- (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

- (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
- (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).