

# P23

## GloVe: vectores globales para representación de palabras

GloVe: Global Vectors for Word Representation

Jeffrey Pennington, Richard Socher, Christopher D. Manning · 2014 · EMNLP 2014 · ACL Anthology D14-1162

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-16.

# P23 — GloVe

Ruta de representación · Unifica las dos familias de embeddings: aprovechar las estadísticas globales del corpus y conseguir la estructura lineal de los métodos predictivos.

Nivel: L2 · Motor: glove · Notebook: P23\_glove.ipynb · Anexo: álgebra y geometría

## 1. Identificación

| Campo             | Valor                                                      |
|-------------------|------------------------------------------------------------|
| Título original   | GloVe: Global Vectors for Word Representation              |
| Autoría           | Jeffrey Pennington, Richard Socher, Christopher D. Manning |
| Año               | 2014                                                       |
| Venue             | EMNLP 2014 · ACL Anthology D14-1162                        |
| Fuente primaria   | aclanthology.org/D14-1162 · DOI                            |
| Acceso            | Abierto                                                    |
| Fecha de consulta | 2026-08-16                                                 |

## 2. Problema anterior

Había dos familias de métodos y cada una renunciaba a algo. Los métodos de **conteo** (LSA y derivados) construían la matriz de co-ocurrencia de todo el corpus —estadística global, entrenamiento rápido— pero producían espacios con peor estructura para analogías. Los métodos **predictivos** (Word2Vec) daban esa estructura, pero aprendían de ventanas locales, sin usar directamente las estadísticas agregadas del corpus.

La pregunta abierta: ¿qué propiedad de las estadísticas de co-ocurrencia es la que produce la estructura lineal, y se puede modelar directamente?

## 3. Propuesta

La respuesta de los autores: lo informativo **no es la co-ocurrencia, sino su razón**.

$P(\text{sólido} \mid \text{hielo}) / P(\text{sólido} \mid \text{vapor})$  es muy grande; para «gas» es muy pequeña; para «agua», que acompaña a ambos, es  $\approx 1$ . Esa razón discrimina lo que la co-ocurrencia bruta no.

Como las razones se convierten en diferencias al tomar logaritmos, proponen ajustar por mínimos cuadrados ponderados el producto de vectores al **logaritmo** de la co-ocurrencia. La función de peso evita que los pares muy frecuentes dominen y que los muy raros aporten ruido.

## 4. Intuición sin fórmulas

Word2Vec mira por una ventanita y aprende de lo que pasa cerca, millones de veces. GloVe cuenta primero todo el corpus en una tabla y luego busca vectores que expliquen esa tabla. Mismo destino, camino opuesto.

**Dónde deja de funcionar la analogía:** la tabla de conteos no es neutral. Cómo se define la ventana, si se pondera por distancia y qué se hace con las palabras muy frecuentes son decisiones que ya codifican una teoría del significado.

## 5. Matemática mínima

$$J = \sum_{ij} f(x_{ij}) \cdot (w_i \cdot \tilde{w}_j + b_i + \tilde{b}_j - \log x_{ij})^2$$

$x_{ij}$  = veces que la palabra  $j$  aparece en el contexto de  $i$

$w, \tilde{w}$  = vectores de palabra y de contexto (dos matrices, como en skip-gram)


$b, \tilde{b}$  = sesgos que absorben la frecuencia de cada palabra

$$f(x) = (x/x_{\max})^\alpha \quad \text{si } x < x_{\max}, \quad \text{si no } 1 \quad \text{con } \alpha = 3/4$$

Dos decisiones que conviene entender:

- El **logaritmo** convierte razones en diferencias, que es lo que la geometría vectorial sabe representar como desplazamientos.
- La **función de peso** es asimétrica a propósito: atenúa los pares raros (ruido estadístico) y satura en los muy frecuentes (que si no, dominarían la suma).

## 6. Arquitectura o flujo



Frente a Word2Vec, que recorre el corpus muchas veces por parejas, aquí el corpus se recorre **una vez** para construir  $X$  y después se entrena sobre los pares no nulos de esa matriz.

## 7. Qué observar en el paper original

- La **tabla de razones de co-ocurrencia** con hielo y vapor. Es el argumento entero del paper condensado en una tabla; si se entiende esa, se entiende todo lo demás.
- La **derivación** que va desde «queremos modelar razones» hasta la forma funcional concreta.
- La **función de peso** y por qué  $\alpha = 3/4$ .
- La comparación de **tiempo de entrenamiento** frente a los métodos predictivos: parte del argumento era práctico, no solo de calidad.

## 8. Evidencia y resultados

Evaluación en analogías de palabras, similitud y reconocimiento de entidades nombradas, frente a Word2Vec y a métodos de factorización, con distintos tamaños de corpus y de vector.

Las cifras por tarea, dimensión y tamaño de corpus están en las tablas del artículo. Verificarlas allí: las comparaciones de embeddings de esta época son muy sensibles al preprocesado y a los hiperparámetros, y ese es justamente el motivo de la sección 11.

La miniatura de este eje muestra el mecanismo: las razones separan limpiamente ( $\approx 25$  para lo propio del hielo,  $\approx 0,05$  para lo del vapor,  $\approx 1$  para lo compartido) y la pérdida baja mientras los vectores aprenden a reproducir el logaritmo de los conteos.

## 9. Impacto

- Los vectores GloVe preentrenados fueron durante años el punto de partida por defecto de cualquier sistema de PLN, junto con los de Word2Vec.
- Puso sobre la mesa una pregunta teórica —qué se está modelando exactamente— en un área que avanzaba de forma muy empírica.
- Consolidó la práctica de **publicar vectores preentrenados** como artefacto reutilizable, no solo el método.

## 10. Limitaciones

1. **Un vector por palabra:** la polisemia sigue colapsada. Lo resolverá ELMo.
2. **Memoria:** la matriz de co-ocurrencia de un corpus grande es enorme, aunque sea dispersa.
3. **Vocabulario cerrado:** sin vector para palabras no vistas.
4. **Sin composición:** no hay forma principitada de obtener el vector de una frase.
5. **Hereda los sesgos** del corpus, igual que cualquier método distribucional.
6. **La ventaja empírica sobre Word2Vec resultó frágil:** depende mucho de los hiperparámetros de ambos, como mostró trabajo posterior.

## 11. Errores comunes

| Error                                                          | Corrección                                                                                                                                                             |
|----------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| «GloVe es contador y word2vec predictivo, son cosas distintas» | Levy y Goldberg (2015) mostraron que word2vec con muestreo negativo factoriza implícitamente una matriz relacionada. La dicotomía es menos profunda de lo que parecía. |
| «GloVe es mejor que word2vec»                                  | Depende del corpus, la tarea y los hiperparámetros. Las comparaciones de la época estaban mal controladas.                                                             |
| «Modela la co-ocurrencia»                                      | Modela el <b>logaritmo</b> de la co-ocurrencia, y lo hace porque el objeto de interés son las <b>razones</b> .                                                         |
| «La función de peso es un detalle»                             | Sin ella, los pares funcionales frecuentes dominan la pérdida y el espacio se degrada.                                                                                 |

## 12. Relación con trabajos anteriores

- **P05 Word2Vec (2013)** — la familia predictiva que sirve de contraste.

- **LSA y factorización de matrices de co-ocurrencia (1990)** — la familia de conteo.
- **Harris (1954), Firth (1957)** — la hipótesis distribucional que ambas comparten.

## 13. Relación con trabajos posteriores

- **Levy y Goldberg (2015)** — el puente teórico entre ambas familias. ACL Anthology
- **FastText (2016)** — subpalabras, resuelve el vocabulario cerrado.
- **P24 ELMo (2018)** — el paso a representaciones contextuales.
- **P18 CLIP (2021)** — la misma idea de espacio compartido, con imágenes.

## 14. Notebook asociado

P23\_glove.ipynb

**Qué implementa:** el ajuste por mínimos cuadrados ponderados sobre una matriz de co-ocurrencia de juguete con la estructura del ejemplo del paper, y la tabla de razones que justifica el objetivo.

**Qué NO implementa:** ningún corpus real. Con seis palabras no emerge semántica: se ve la mecánica del ajuste, no el resultado.

```
ai-evolution paper-lab P23 --seed 7
```

## 15. Actividades Bloom

| Nivel           | Actividad                                                                                                              |
|-----------------|------------------------------------------------------------------------------------------------------------------------|
| <b>Recordar</b> | Escribe la función objetivo y di qué representa cada término.                                                          |
| <b>Explicar</b> | Explica por qué se modela el logaritmo y no la co-ocurrencia directa.                                                  |
| <b>Aplicar</b>  | Calcula las tres razones del ejemplo hielo/vapor a partir de la tabla del notebook.                                    |
| <b>Analizar</b> | ¿Qué pasa con la pérdida si $f(x) = 1$ para todo $x$ ? Razónalo y compruébalo.                                         |
| <b>Evaluar</b>  | Lee el resumen de Levy y Goldberg (2015) y decide si la distinción contador/predictivo sigue siendo útil para enseñar. |
| <b>Crear</b>    | Diseña una función de peso alternativa y argumenta qué propiedad conserva y cuál rompe.                                |

## 16. Autoevaluación

1. ¿Por qué la razón de co-ocurrencias discrimina mejor que la co-ocurrencia?
2. ¿Qué papel juegan los sesgos  $b_i$  y  $b_j$ ?
3. ¿Por qué hay dos matrices de vectores?
4. ¿Qué problema resuelve la función de peso, por sus dos extremos?
5. ¿En qué se parece realmente a Word2Vec, según trabajo posterior?
6. ¿Qué limitación comparte con Word2Vec y no puede resolver?
7. ¿Qué ventaja práctica, no de calidad, defendía el paper?

## 17. Respuestas esperadas

---

1. Porque cancela la frecuencia general de la palabra de contexto. «Agua» es frecuente con todo; la razón entre dos palabras revela qué es específico de cada una.
2. Absorben la frecuencia global de cada palabra, para que el producto de vectores capture la parte informativa y no el simple hecho de que una palabra sea común.
3. Porque cada palabra juega dos papeles —centro y contexto— y necesita una representación para cada uno. Suelen sumarse o promediarse al final.
4. Por arriba, evita que los pares muy frecuentes dominen la suma; por abajo, atenúa los pares raros, cuyos conteos son ruido estadístico.
5. Levy y Goldberg mostraron que skip-gram con muestreo negativo factoriza implícitamente una matriz de información mutua puntual desplazada: ambos acaban factorizando estadísticas.
6. Un vector por palabra: la polisemia. Lo resuelven los embeddings contextuales.
7. El coste de entrenamiento: una sola pasada para construir la matriz y después entrenar solo sobre entradas no nulas.

## 18. Fuentes primarias

---

- Pennington, J., Socher, R. y Manning, C. D. (2014). *GloVe: Global Vectors for Word Representation*. **EMNLP 2014**. ACL Anthology D14-1162 · DOI · consultado 2026-08-16.
- Levy, O. y Goldberg, Y. (2015). *Improving Distributional Similarity with Lessons Learned from Word Embeddings*. **TACL**. ACL Anthology Q15-1016 · consultado 2026-08-16.



# Evaluación — P23 · GloVe: vectores globales para representación de palabras

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

**Paper:** *GloVe: Global Vectors for Word Representation* (2014, EMNLP 2014 · ACL Anthology D14-1162) ·  
**Nivel:** L2

## Parte A — Contexto histórico (20 pts)

---

- (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
- (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

## Parte B — Lectura crítica (20 pts)

---

- (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
- (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

## Parte C — Interpretación matemática (15 pts)

---

- (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

## Parte D — Implementación e interpretación (25 pts)

---

- (10) Ejecuta `P23_glove.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
- (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
- (5) Aporta la corrección con su evidencia.

## Parte E — Límites y transferencia (20 pts)

---

- (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
- (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

## Rúbrica

---

| Nivel                   | Descripción                                                                                                                                                  |
|-------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>A — Excelente</b>    | Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados. |
| <b>B — Suficiente</b>   | Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.                                    |
| <b>C — Insuficiente</b> | Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.  |

## Criterio automático de rechazo

---

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).