

P23

GloVe: vectores globales para representación de palabras

GloVe: Global Vectors for Word Representation

Jeffrey Pennington, Richard Socher, Christopher D. Manning · 2014 · EMNLP 2014 · ACL Anthology D14-1162

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-16.

P23 — GloVe

Ruta de representación · Unifica las dos familias de embeddings: aprovechar las estadísticas globales del corpus y conseguir la estructura lineal de los métodos predictivos.

Nivel: L2 · Motor: glove · Notebook: P23_glove.ipynb · Anexo: álgebra y geometría

1. Identificación

Campo	Valor
Título original	GloVe: Global Vectors for Word Representation
Autoría	Jeffrey Pennington, Richard Socher, Christopher D. Manning
Año	2014
Venue	EMNLP 2014 · ACL Anthology D14-1162
Fuente primaria	aclanthology.org/D14-1162 · DOI
Acceso	Abierto
Fecha de consulta	2026-08-16

2. Problema anterior

Había dos familias de métodos y cada una renunciaba a algo. Los métodos de **conteo** (LSA y derivados) construían la matriz de co-ocurrencia de todo el corpus —estadística global, entrenamiento rápido— pero producían espacios con peor estructura para analogías. Los métodos **predictivos** (Word2Vec) daban esa estructura, pero aprendían de ventanas locales, sin usar directamente las estadísticas agregadas del corpus.

La pregunta abierta: ¿qué propiedad de las estadísticas de co-ocurrencia es la que produce la estructura lineal, y se puede modelar directamente?

3. Propuesta

La respuesta de los autores: lo informativo **no es la co-ocurrencia, sino su razón**.

$P(\text{sólido} \mid \text{hielo}) / P(\text{sólido} \mid \text{vapor})$ es muy grande; para «gas» es muy pequeña; para «agua», que acompaña a ambos, es ≈ 1 . Esa razón discrimina lo que la co-ocurrencia bruta no.

Como las razones se convierten en diferencias al tomar logaritmos, proponen ajustar por mínimos cuadrados ponderados el producto de vectores al **logaritmo** de la co-ocurrencia. La función de peso evita que los pares muy frecuentes dominen y que los muy raros aporten ruido.

4. Intuición sin fórmulas

Word2Vec mira por una ventanita y aprende de lo que pasa cerca, millones de veces. GloVe cuenta primero todo el corpus en una tabla y luego busca vectores que expliquen esa tabla. Mismo destino, camino opuesto.

Dónde deja de funcionar la analogía: la tabla de conteos no es neutral. Cómo se define la ventana, si se pondera por distancia y qué se hace con las palabras muy frecuentes son decisiones que ya codifican una teoría del significado.

5. Matemática mínima

$$J = \sum_{ij} f(x_{ij}) \cdot (w_i \cdot \tilde{w}_j + b_i + \tilde{b}_j - \log x_{ij})^2$$

x_{ij} = veces que la palabra j aparece en el contexto de i

$w, \tilde{w}$ = vectores de palabra y de contexto (dos matrices, como en skip-gram)


$b, \tilde{b}$ = sesgos que absorben la frecuencia de cada palabra

$$f(x) = (x/x_{\max})^\alpha \quad \text{si } x < x_{\max}, \quad \text{si no } 1 \quad \text{con } \alpha = 3/4$$

Dos decisiones que conviene entender:

- El **logaritmo** convierte razones en diferencias, que es lo que la geometría vectorial sabe representar como desplazamientos.
- La **función de peso** es asimétrica a propósito: atenúa los pares raros (ruido estadístico) y satura en los muy frecuentes (que si no, dominarían la suma).

6. Arquitectura o flujo



Frente a Word2Vec, que recorre el corpus muchas veces por parejas, aquí el corpus se recorre **una vez** para construir X y después se entrena sobre los pares no nulos de esa matriz.

7. Qué observar en el paper original

- La **tabla de razones de co-ocurrencia** con hielo y vapor. Es el argumento entero del paper condensado en una tabla; si se entiende esa, se entiende todo lo demás.
- La **derivación** que va desde «queremos modelar razones» hasta la forma funcional concreta.
- La **función de peso** y por qué $\alpha = 3/4$.
- La comparación de **tiempo de entrenamiento** frente a los métodos predictivos: parte del argumento era práctico, no solo de calidad.

8. Evidencia y resultados

Evaluación en analogías de palabras, similitud y reconocimiento de entidades nombradas, frente a Word2Vec y a métodos de factorización, con distintos tamaños de corpus y de vector.

Las cifras por tarea, dimensión y tamaño de corpus están en las tablas del artículo. Verificarlas allí: las comparaciones de embeddings de esta época son muy sensibles al preprocesado y a los hiperparámetros, y ese es justamente el motivo de la sección 11.

La miniatura de este eje muestra el mecanismo: las razones separan limpiamente (≈ 25 para lo propio del hielo, $\approx 0,05$ para lo del vapor, ≈ 1 para lo compartido) y la pérdida baja mientras los vectores aprenden a reproducir el logaritmo de los conteos.

9. Impacto

- Los vectores GloVe preentrenados fueron durante años el punto de partida por defecto de cualquier sistema de PLN, junto con los de Word2Vec.
- Puso sobre la mesa una pregunta teórica —qué se está modelando exactamente— en un área que avanzaba de forma muy empírica.
- Consolidó la práctica de **publicar vectores preentrenados** como artefacto reutilizable, no solo el método.

10. Limitaciones

1. **Un vector por palabra:** la polisemia sigue colapsada. Lo resolverá ELMo.
2. **Memoria:** la matriz de co-ocurrencia de un corpus grande es enorme, aunque sea dispersa.
3. **Vocabulario cerrado:** sin vector para palabras no vistas.
4. **Sin composición:** no hay forma principada de obtener el vector de una frase.
5. **Hereda los sesgos** del corpus, igual que cualquier método distribucional.
6. **La ventaja empírica sobre Word2Vec resultó frágil:** depende mucho de los hiperparámetros de ambos, como mostró trabajo posterior.

11. Errores comunes

Error	Corrección
«GloVe es contador y word2vec predictivo, son cosas distintas»	Levy y Goldberg (2015) mostraron que word2vec con muestreo negativo factoriza implícitamente una matriz relacionada. La dicotomía es menos profunda de lo que parecía.
«GloVe es mejor que word2vec»	Depende del corpus, la tarea y los hiperparámetros. Las comparaciones de la época estaban mal controladas.
«Modela la co-ocurrencia»	Modela el logaritmo de la co-ocurrencia, y lo hace porque el objeto de interés son las razones .
«La función de peso es un detalle»	Sin ella, los pares funcionales frecuentes dominan la pérdida y el espacio se degrada.

12. Relación con trabajos anteriores

- **P05 Word2Vec (2013)** — la familia predictiva que sirve de contraste.

- **LSA y factorización de matrices de co-ocurrencia (1990)** — la familia de conteo.
- **Harris (1954), Firth (1957)** — la hipótesis distribucional que ambas comparten.

13. Relación con trabajos posteriores

- **Levy y Goldberg (2015)** — el puente teórico entre ambas familias. ACL Anthology
- **FastText (2016)** — subpalabras, resuelve el vocabulario cerrado.
- **P24 ELMo (2018)** — el paso a representaciones contextuales.
- **P18 CLIP (2021)** — la misma idea de espacio compartido, con imágenes.

14. Notebook asociado

P23_glove.ipynb

Qué implementa: el ajuste por mínimos cuadrados ponderados sobre una matriz de co-ocurrencia de juguete con la estructura del ejemplo del paper, y la tabla de razones que justifica el objetivo.

Qué NO implementa: ningún corpus real. Con seis palabras no emerge semántica: se ve la mecánica del ajuste, no el resultado.

```
ai-evolution paper-lab P23 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe la función objetivo y di qué representa cada término.
Explicar	Explica por qué se modela el logaritmo y no la co-ocurrencia directa.
Aplicar	Calcula las tres razones del ejemplo hielo/vapor a partir de la tabla del notebook.
Analizar	¿Qué pasa con la pérdida si $f(x) = 1$ para todo x ? Razónalo y compruébalo.
Evaluar	Lee el resumen de Levy y Goldberg (2015) y decide si la distinción contador/predictivo sigue siendo útil para enseñar.
Crear	Diseña una función de peso alternativa y argumenta qué propiedad conserva y cuál rompe.

16. Autoevaluación

1. ¿Por qué la razón de co-ocurrencias discrimina mejor que la co-ocurrencia?
2. ¿Qué papel juegan los sesgos b_i y b_j ?
3. ¿Por qué hay dos matrices de vectores?
4. ¿Qué problema resuelve la función de peso, por sus dos extremos?
5. ¿En qué se parece realmente a Word2Vec, según trabajo posterior?
6. ¿Qué limitación comparte con Word2Vec y no puede resolver?
7. ¿Qué ventaja práctica, no de calidad, defendía el paper?

17. Respuestas esperadas

1. Porque cancela la frecuencia general de la palabra de contexto. «Agua» es frecuente con todo; la razón entre dos palabras revela qué es específico de cada una.
2. Absorben la frecuencia global de cada palabra, para que el producto de vectores capture la parte informativa y no el simple hecho de que una palabra sea común.
3. Porque cada palabra juega dos papeles —centro y contexto— y necesita una representación para cada uno. Suelen sumarse o promediarse al final.
4. Por arriba, evita que los pares muy frecuentes dominen la suma; por abajo, atenúa los pares raros, cuyos conteos son ruido estadístico.
5. Levy y Goldberg mostraron que skip-gram con muestreo negativo factoriza implícitamente una matriz de información mutua puntual desplazada: ambos acaban factorizando estadísticas.
6. Un vector por palabra: la polisemia. Lo resuelven los embeddings contextuales.
7. El coste de entrenamiento: una sola pasada para construir la matriz y después entrenar solo sobre entradas no nulas.

18. Fuentes primarias

- Pennington, J., Socher, R. y Manning, C. D. (2014). *GloVe: Global Vectors for Word Representation*. **EMNLP 2014**. ACL Anthology D14-1162 · DOI · consultado 2026-08-16.
- Levy, O. y Goldberg, Y. (2015). *Improving Distributional Similarity with Lessons Learned from Word Embeddings*. **TACL**. ACL Anthology Q15-1016 · consultado 2026-08-16.



Evaluación — P23 · GloVe: vectores globales para representación de palabras

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *GloVe: Global Vectors for Word Representation* (2014, EMNLP 2014 · ACL Anthology D14-1162) ·
Nivel: L2

Parte A — Contexto histórico (20 pts)

- (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
- (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

- (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
- (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

- (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

- (10) Ejecuta `P23_glove.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
- (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
- (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

- (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
- (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).