

P24

Representaciones profundas de palabras dependientes del contexto

Deep Contextualized Word Representations

Matthew E. Peters, Mark Neumann, Mohit Iyyer, Matt Gardner, Christopher Clark, Kenton Lee, Luke Zettlemoyer ·
2018 · NAACL 2018 · ACL Anthology N18-1202

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-16.

P24 — ELMo

Ruta de representación · Un vector por **aparición** y no por palabra: la polisemia deja de colapsar en un único punto del espacio.

Nivel: L3 · Motor: `elmo` · Notebook: `P24_elmo.ipynb` · Anexo: álgebra y geometría

1. Identificación

Campo	Valor
Título original	<i>Deep Contextualized Word Representations</i>
Autoría	Matthew E. Peters, Mark Neumann, Mohit Iyyer, Matt Gardner, Christopher Clark, Kenton Lee, Luke Zettlemoyer
Año	2018
Venue	NAACL-HLT 2018 · ACL Anthology N18-1202
Fuente primaria	aclanthology.org/N18-1202
Acceso	Abierto
Fecha de consulta	2026-08-16

2. Problema anterior

Word2Vec y GloVe dan **un vector por palabra**. Eso significa que «banco del parque», «banco central» y «banco del río» comparten exactamente la misma representación: el sentido se pierde antes de que el modelo de la tarea empiece a trabajar.

Existían intentos de inducir sentidos y agruparlos, pero exigían decidir de antemano cuántos sentidos tiene cada palabra —una decisión artificial— y no aprovechaban la frase concreta.

3. Propuesta

Calcular la representación **en función de la frase entera**, usando los estados internos de un modelo de lenguaje bidireccional profundo entrenado sobre un corpus grande.

Dos decisiones importantes:

1. Las representaciones son **profundas**: no se usa solo la última capa, sino una combinación de todas.
2. Los pesos de esa combinación se **aprenden por tarea**, porque distintas capas capturan cosas distintas —las bajas, más sintaxis; las altas, más semántica—.

Se usaban como **características congeladas**: se calculaban los vectores y se alimentaban a un modelo específico de la tarea.

4. Intuición sin fórmulas

Un diccionario da una entrada por palabra. Un lector da un significado por aparición. ELMo deja de ser diccionario y pasa a leer: el vector de «banco» se calcula tras haber leído la frase.

Dónde deja de funcionar la analogía: un lector entiende; ELMo solo condiciona su representación en el contexto. Que dos apariciones queden lejos no implica que el modelo sepa que son sentidos distintos, solo que las representa distinto.

5. Matemática mínima

Modelo de lenguaje bidireccional: se entrenan dos direcciones y se suman sus verosimilitudes

$$\Sigma_k [\log p(t_k | t_1...t_{k-1}) + \log p(t_k | t_{k+1}...t_N)]$$

Representación para la tarea:

$$ELMo_k = \gamma \cdot \sum_{j=0}^L s_j \cdot h_{k,j}$$

$h_{k,j}$

= estado de la capa j en la posición k

s_j

= pesos por capa, normalizados con softmax y APRENDIDOS por tarea

γ


= escala global, también aprendida

Lo esencial: $ELMo_k$ depende de k y de toda la frase. Un embedding estático no tiene el subíndice k .

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A01 §2 · Norma y coseno	el coseno, que es como se comprueba que dos apariciones de la misma palabra se separan

6. Arquitectura o flujo



7. Qué observar en el paper original

- El **análisis por capas**: la evidencia de que las capas bajas sirven mejor para tareas sintácticas y las altas para semánticas. Justifica que los pesos se aprendan por tarea.
- La comparación con usar **solo la capa superior**, que es lo que la intuición sugeriría.
- La sección de **desambiguación de sentidos**: es la comprobación directa de que la polisemia deja de colapsar.
- Que ELMo se **añade** a modelos existentes: el paper mejora seis tareas sin rediseñarlas.

8. Evidencia y resultados

Seis tareas de PLN —respuesta a preguntas, inferencia textual, análisis de sentimiento, etiquetado de roles semánticos, resolución de correferencia y reconocimiento de entidades— con mejoras al añadir ELMo a la arquitectura ya existente de cada una.

Las cifras por tarea y las ablaciones por capa están en las tablas del artículo. Verificarlas allí antes de citarlas.

La miniatura de este eje muestra el fenómeno central: con embedding estático las tres apariciones de «banco» tienen coseno 1,0 entre sí; con representación contextual bajan de forma desigual, y los sentidos más distintos quedan más separados.

9. Impacto

- Fue el paper que **normalizó las representaciones contextuales** en PLN, meses antes de BERT.
- Su análisis por capas abrió la línea de trabajo sobre **qué codifica cada capa** de un modelo de lenguaje, que sigue viva en interpretabilidad.
- Marcó la última etapa del paradigma «características congeladas»: BERT, poco después, ajustaría el modelo entero.

10. Limitaciones

1. **Bidireccionalidad superficial**: son dos modelos unidireccionales concatenados, no un modelo que atienda a ambos lados a la vez en cada capa. Ese es exactamente el argumento de BERT.
2. **Características congeladas**: no se ajusta el modelo base, así que se aprovecha menos.
3. **Basado en LSTM**: secuencial, no paraleliza sobre la longitud.
4. **Coste**: hay que ejecutar el modelo de lenguaje completo para obtener las representaciones.
5. **Los pesos por capa se aprenden por tarea**, lo que añade un ajuste extra.
6. **Sigue heredando** los sesgos del corpus de preentrenamiento.

11. Errores comunes

Error	Corrección
«ELMo es bidireccional como BERT»	Es una concatenación de dos direcciones independientes. BERT atiende a ambos lados en cada capa , y para eso necesita enmascarar.
«Basta con la última capa»	El paper muestra que distintas tareas prefieren distintas capas; por eso los pesos se aprenden.
«ELMo es un modelo de lenguaje»	Se entrena como tal, pero se usa como extractor de representaciones congeladas.
«Resolvió la polisemia»	Hace que las representaciones dependan del contexto. Que eso equivalga a distinguir sentidos es otra afirmación, y el paper la evalúa por separado.

12. Relación con trabajos anteriores

- **P05 Word2Vec** y **P23 GloVe** — los embeddings estáticos cuya limitación se ataca.

- **P03 LSTM (1997)** — la celda con la que se construye.
- **Howard y Ruder (2018), ULMFiT** — transferencia en PLN, contemporáneo. arXiv:1801.06146

13. Relación con trabajos posteriores

- **P09 BERT (2018)** — bidireccionalidad profunda real y ajuste fino del modelo completo; el paper con el que ELMo se compara explícitamente.
- **P25 T5 (2019)** — la unificación del formato de tarea.
- **Interpretabilidad por capas (2019+)** — la línea que abre su análisis.

14. Notebook asociado

P24_elmo.ipynb

Qué implementa: el vector de «banco» en tres frases con sentidos distintos, de forma estática y contextual, y la comparación de similitudes.

Qué NO implementa: ni LSTM ni modelo de lenguaje entrenado. La mezcla con decaimiento simula los estados internos, y los pesos por capa están fijados a mano en vez de aprendidos.

```
ai-evolution paper-lab P24 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe la fórmula de <code>ELMo_k</code> y di qué es <code>s_j</code> .
Explicar	Explica por qué dos LSTM concatenadas no son lo mismo que atención bidireccional.
Aplicar	Añade una cuarta frase con «banco» como asiento y mira con cuál se agrupa.
Analizar	¿Qué pesos por capa esperarías para etiquetado gramatical frente a respuesta a preguntas?
Evaluar	¿Es «resolvió la polisemia» una afirmación defendible? Argumenta con lo que el paper mide.
Crear	Diseña una prueba que distinga «representación distinta» de «sentido distinguido».

16. Autoevaluación

1. ¿Qué significa que la representación sea contextual, en términos de la fórmula?
2. ¿Por qué se combinan varias capas en vez de usar la última?
3. ¿En qué sentido la bidireccionalidad de ELMo es superficial?
4. ¿Qué quiere decir que se use como «características congeladas»?
5. ¿Qué ventaja tiene eso, y qué se pierde?
6. ¿Qué problema de P23 resuelve y cuál no?
7. ¿Qué hizo BERT distinto pocos meses después?

17. Respuestas esperadas

1. Que lleva subíndice k y depende de los estados del modelo sobre **esa** frase: la misma palabra en otra frase da otro vector.
2. Porque las capas codifican información distinta y cada tarea necesita una mezcla distinta; el paper lo demuestra con ablaciones.
3. Porque son dos modelos unidireccionales entrenados por separado y concatenados. En ninguna capa hay una representación que haya atendido a ambos lados simultáneamente.
4. Que el modelo base no se actualiza: se calculan los vectores y se pasan a un modelo específico de la tarea, que es el único que se entrena.
5. Ventaja: barato, reutilizable, no requiere reentrenar el modelo grande. Pérdida: se aprovecha mucho menos el conocimiento del preentrenamiento.
6. Resuelve el vector único por palabra. No resuelve el vocabulario cerrado, la composición de frases ni el sesgo del corpus.
7. Bidireccionalidad profunda mediante enmascarado, y ajuste fino del modelo entero en vez de características congeladas.

18. Fuentes primarias

- Peters, M. E. et al. (2018). *Deep Contextualized Word Representations*. **NAACL-HLT 2018**. ACL Anthology N18-1202 · consultado 2026-08-16.
- Howard, J. y Ruder, S. (2018). *Universal Language Model Fine-tuning for Text Classification*. arXiv:1801.06146 · consultado 2026-08-16.



Evaluación — P24 · Representaciones profundas de palabras dependientes del contexto

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Deep Contextualized Word Representations* (2018, NAACL 2018 · ACL Anthology N18-1202) · **Nivel:** L3

Parte A — Contexto histórico (20 pts)

- (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
- (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

- (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
- (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

- (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

- (10) Ejecuta `P24_elmo.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
- (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
- (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

- (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
- (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).