

P25

Explorar los límites del aprendizaje por transferencia con un Transformer unificado
texto a texto

Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer

Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li,
Peter J. Liu · 2019 · arXiv:1910.10683 · JMLR 21(140), 2020

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español
que enlaza a la fuente primaria. Consultado 2026-08-16.

P25 — T5

Ruta de representación · Todo problema de texto se reescribe como texto → texto: un solo modelo, una sola pérdida, cero cabezas específicas por tarea.

Nivel: L3 · Motor: t5 · Notebook: P25_t5.ipynb · Anexo: probabilidad y verosimilitud

1. Identificación

Campo	Valor
Título original	Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer
Autoría	Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, Peter J. Liu
Año	2019 (arXiv) · 2020 (JMLR)
Venue	arXiv:1910.10683 · JMLR 21(140)
Fuente primaria	arXiv:1910.10683 · JMLR
Acceso	Abierto
Fecha de consulta	2026-08-16

2. Problema anterior

Tras BERT, el campo se llenó de variantes: distintos objetivos de preentrenamiento, arquitecturas, corpus, tamaños y recetas de ajuste. Y **no se podían comparar**, porque cada trabajo cambiaba varias cosas a la vez y cada tarea usaba su propia cabeza, su propio formato y su propia métrica.

Además, ese zoo de cabezas —clasificación, regresión, extracción de índices, generación— era una fricción de ingeniería constante: nada se reutilizaba entre tareas.

3. Propuesta

Dos contribuciones que se apoyan la una en la otra.

El marco: reescribir toda tarea de texto como «texto de entrada → texto de salida», con un prefijo que indica cuál es. Clasificar es emitir la palabra `negative`; la regresión, emitir `4.2`; extraer, emitir el fragmento. Una sola pérdida: verosimilitud del texto de salida.

El estudio: una vez todo es comparable, hacer el barrido sistemático que faltaba —objetivos de preentrenamiento, arquitecturas, corpus, estrategias de ajuste, tamaños— midiendo cada decisión por separado. Y publicar el corpus resultante, **C4** (*Colossal Clean Crawled Corpus*).

4. Intuición sin fórmulas

Cinco máquinas distintas, cada una con su enchufe. T5 propone un enchufe único: si todo entra y sale como texto, sobra el adaptador.

Dónde deja de funcionar la analogía: el enchufe único tiene un coste real. Emitir un número como texto pierde precisión, y emitir una etiqueta como palabra permite que el modelo genere algo que no es ninguna de las etiquetas válidas.

5. Matemática mínima

Todas las tareas: maximizar $\log p_{\theta}(\text{texto_salida} \mid \text{texto_entrada})$

Lo único que cambia: el PREFIJO del texto de entrada

"translate English to German: That is good." → "Das ist gut."

"cola sentence: The movie was terrible." → "negative"

"sts sentence1: ... sentence2: ..." → "4.2"


"summarize: ..." → "..."

Objetivo de preentrenamiento elegido tras el barrido: **corrupción de tramos** — se enmascaran secuencias contiguas de tokens y el modelo debe emitirlas, con centinelas que marcan cada hueco. No es el enmascarado token a token de BERT, y el paper explica por qué gana.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A02 §3 · Verosimilitud y entropía cruzada	una sola pérdida —entropía cruzada sobre texto— para todas las tareas

6. Arquitectura o flujo



7. Qué observar en el paper original

- Es un artículo **largo** y su valor está en la sección de experimentos: cada subsección aísla una decisión de diseño. Leerlo como catálogo de resultados es más útil que leerlo en orden.
- La comparación de **objetivos de preentrenamiento**, que justifica la corrupción de tramos.

- La comparación de **arquitecturas** (encoder-decoder frente a solo decoder frente a solo encoder) a igualdad de parámetros y de cómputo.
- El apartado de **C4**: cómo se filtró Common Crawl y qué se descartó. Ese filtrado es una decisión editorial con consecuencias.
- La sección de **limitaciones y trabajo futuro**, inusualmente franca sobre lo que no midieron.

8. Evidencia y resultados

Resultados del estado del arte de la época en múltiples benchmarks (GLUE, SuperGLUE, SQuAD, resumen y traducción), obtenidos con el mismo modelo y el mismo procedimiento.

Las cifras por benchmark y por tamaño de modelo están en las tablas del artículo, junto con los resultados de cada ablación. Verificarlas allí: la mayoría del valor del paper está en esas tablas comparativas, no en la cifra final.

La miniatura de este eje muestra el marco: cinco tareas que exigían cinco tipos de cabeza se reducen a un único formato, con cero cabezas específicas y un solo objetivo.

9. Impacto

- Estableció **texto** → **texto** como interfaz por defecto, algo que hoy se da por evidente cada vez que se le pide algo a un modelo con una instrucción en lenguaje natural.
- **C4** se convirtió en corpus de referencia y en objeto de estudio por derecho propio.
- Su metodología —barrido sistemático con todo lo demás fijo— es el estándar de cómo se debe comparar en este campo, y sigue siendo raro verlo.
- La familia encoder-decoder que consolida sigue siendo la elección natural para traducir y resumir.

10. Limitaciones

1. **Precisión numérica**: emitir números como texto obliga a discretizar y pierde resolución.
2. **Salidas fuera del conjunto válido**: nada impide generar una etiqueta que no existe.
3. **Coste del estudio**: el barrido sistemático solo está al alcance de quien tiene mucho cómputo.
4. **C4 hereda los sesgos de Common Crawl**, y su filtrado introduce otros propios.
5. **Los prefijos son arbitrarios** y el rendimiento depende algo de cómo se redacten.
6. **No cubre** el aprendizaje en contexto de GPT-3, publicado meses después: T5 sigue asumiendo ajuste fino por tarea.

11. Errores comunes

Error	Corrección
«T5 es un modelo»	Es un marco más un estudio más un corpus. El modelo es el vehículo.
«Texto a texto es solo un formato»	Es lo que hace comparables las tareas, y por tanto lo que permite el estudio. Formato y método están acoplados.
«Usa el enmascarado de BERT»	Usa corrupción de tramos , y el paper justifica la diferencia con una ablación.
«Encoder-decoder es peor que solo decoder»	El paper mide ambos a igualdad de cómputo. La conclusión es matizada y depende de la tarea.
«La regresión como texto es un truco feo»	Es una decisión con coste explícito, medida y documentada en el propio artículo.

12. Relación con trabajos anteriores

- **P08 Transformer (2017)** — la arquitectura encoder-decoder.
- **P09 BERT (2018)** — el paradigma preentrenar-y-ajustar que sistematiza.
- **P24 ELMo (2018)** — la etapa anterior de transferencia en PLN.
- **Lewis et al. (2019), BART** — el otro encoder-decoder preentrenado, contemporáneo.
arXiv:1910.13461

13. Relación con trabajos posteriores

- **P10 GPT-3 (2020)** — cuestiona el ajuste fino por tarea que T5 asume.
- **P11 RAG (2020)** — usa un generador seq2seq de esta familia.
- **Modelos ajustados a instrucciones (2021+)** — llevan el prefijo a su conclusión: la tarea se describe en lenguaje natural.
- **Estudios sobre C4** — auditorías del corpus y de su filtrado.

14. Notebook asociado

P25_t5.ipynb

Qué implementa: cinco tareas reescritas al formato texto → texto, el recuento de cabezas específicas antes y después, y el coste de precisión al emitir números como texto.

Qué NO implementa: ningún modelo. Aquí se ve el **contrato de entrada y salida**, que es la idea; el estudio sistemático y C4 quedan por completo fuera de alcance local.

```
ai-evolution paper-lab P25 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe el objetivo único y di qué distingue una tarea de otra.
Explicar	Explica por qué unificar el formato es condición para poder comparar decisiones de diseño.
Aplicar	Reescribe una tarea propia al formato texto → texto con su prefijo.
Analizar	Calcula cuánta precisión se pierde al discretizar una escala continua en pasos de 0,2.
Evaluar	¿Qué tarea NO conviene reescribir como texto → texto? Justifica con el coste concreto.
Crear	Diseña una ablación propia sobre el objetivo de preentrenamiento y di qué mediría.

16. Autoevaluación

1. ¿Cuál es el objetivo de entrenamiento, exactamente, y para cuántas tareas vale?
2. ¿Qué distingue una tarea de otra en este marco?
3. ¿Por qué el marco es condición para el estudio, y no solo una comodidad?
4. ¿Qué objetivo de preentrenamiento elige el paper y en qué se diferencia del de BERT?
5. ¿Qué se pierde al emitir números como texto y cómo lo mitiga el paper?
6. ¿Qué es C4 y por qué su filtrado es una decisión editorial?
7. ¿Qué supuesto de T5 cuestiona GPT-3 pocos meses después?

17. Respuestas esperadas

1. Maximizar la verosimilitud del texto de salida dado el de entrada. Vale para todas: no hay objetivo específico de tarea.
2. Únicamente el prefijo del texto de entrada.
3. Porque si cada tarea tiene su propia cabeza, formato y métrica, cambiar el objetivo de preentrenamiento cambia varias cosas a la vez y no se puede atribuir la diferencia. Con formato único, se varía una sola cosa.
4. Corrupción de tramos: se enmascaran secuencias contiguas y se emiten con centinelas, frente al enmascarado token a token de BERT. El paper lo justifica con una ablación.
5. Resolución: 4.25 se convierte en 4.2. Se mitiga discretizando la escala en incrementos fijos, de modo que el modelo elige entre un conjunto pequeño de valores.
6. Un corpus derivado de Common Crawl con un filtrado explícito. Es editorial porque decidir qué se descarta —idioma, longitud, listas de palabras— determina qué aprende el modelo.
7. Que haga falta ajuste fino por tarea. GPT-3 muestra que se puede especificar la tarea en el prompt sin actualizar pesos.

18. Fuentes primarias

- Raffel, C. et al. (2020). *Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer*. **JMLR** 21(140). arXiv:1910.10683 · JMLR · consultado 2026-08-16.
- Lewis, M. et al. (2019). *BART: Denoising Sequence-to-Sequence Pre-training*. arXiv:1910.13461 · consultado 2026-08-16.



Evaluación — P25 · Explorar los límites del aprendizaje por transferencia con un Transformer unificado texto a texto

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer* (2019, arXiv:1910.10683 · JMLR 21(140), 2020) · **Nivel:** L3

Parte A — Contexto histórico (20 pts)

- (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
- (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

- (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
- (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

- (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

- (10) Ejecuta `P25_t5.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
- (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
- (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

- (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
- (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).