

P26

Control a nivel humano mediante aprendizaje por refuerzo profundo

Human-level control through deep reinforcement learning

Volodymyr Mnih, Koray Kavukcuoglu, David Silver, y otros (DeepMind) · 2015 · Nature 518, 529–533 (2015)

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-16.

P26 — DQN

Ruta de agentes · El primer agente que aprende a actuar directamente desde píxeles, con la misma arquitectura y los mismos hiperparámetros en decenas de juegos.

Nivel: L3 · Motor: `dqn` · Notebook: `P26_dqn.ipynb` · Anexo: cálculo y gradientes

1. Identificación

Campo	Valor
Título original	<i>Human-level control through deep reinforcement learning</i>
Autoría	Volodymyr Mnih, Koray Kavukcuoglu, David Silver y otros (DeepMind)
Año	2015
Venue	<i>Nature</i> 518, 529–533
Fuente primaria	doi.org/10.1038/nature14236
Acceso	Restringido (revista de suscripción)
Fecha de consulta	2026-08-16

2. Problema anterior

El aprendizaje por refuerzo tenía una teoría sólida —Q-learning es de 1989— pero funcionaba con tablas: un valor por cada par estado-acción. En cuanto el estado es una imagen, la tabla es imposible y hay que **aproximar** la función Q.

Y ahí estaba el problema conocido: combinar refuerzo con aproximación de función no lineal era notoriamente inestable, por dos motivos que se refuerzan. Las muestras consecutivas están muy **correlacionadas** (los fotogramas seguidos se parecen), y el **objetivo se mueve** mientras se aprende, porque se calcula con la misma red que se está actualizando.

3. Propuesta

Q-learning con una red convolucional que lee píxeles, estabilizado con dos mecanismos:

- Repetición de experiencia:** guardar las transiciones (s, a, r, s') en un buffer y entrenar con lotes muestreados al azar. Rompe la correlación temporal y permite reutilizar cada experiencia muchas veces.
- Red objetivo:** una copia congelada de la red que se usa para calcular el objetivo y solo se sincroniza cada cierto número de pasos. El blanco deja de moverse mientras se dispara.

Y una afirmación de generalidad: **la misma arquitectura y los mismos hiperparámetros** en decenas de juegos de Atari, sin ajuste específico por juego.

4. Intuición sin fórmulas

Aprender a jugar sin que nadie explique las reglas: pruebas, ves el marcador, ajustas. El problema es que si aprendes solo del último movimiento, te obsesionas con él. El buffer es una libreta de experiencias pasadas que lees en desorden.

Dónde deja de funcionar la analogía: una persona transfiere entre juegos parecidos. DQN aprende cada juego desde cero.

5. Matemática mínima

Actualización de Q-learning:
$$Q(s,a) \leftarrow Q(s,a) + \alpha \cdot [\underbrace{r + \gamma \cdot \max_{a'} Q(s',a')}_{\text{objetivo}} - Q(s,a)]$$


Con red objetivo congelada θ^- :
$$L(\theta) = E_{\{(s,a,r,s') \sim \text{buffer}\}} [(\underbrace{r + \gamma \cdot \max_{a'} Q(s',a'; \theta^-)}_{\uparrow \text{ NO se actualiza cada paso}} - Q(s,a; \theta))^2]$$

$\gamma \in [0,1)$ descuenta el futuro. α es la tasa de aprendizaje. El `max` sobre `a'` es lo que hace a Q-learning **fuera de política**: aprende el valor de actuar óptimamente aunque esté explorando.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A03 §3 · Retropropagación	la retropropagación sobre un objetivo que se mueve, que es la dificultad del método

6. Arquitectura o flujo



7. Qué observar en el paper original

- La **figura de la arquitectura**: convoluciones sobre fotogramas apilados, con una salida por acción posible. Una sola pasada da el valor de todas las acciones.
- La **tabla de resultados por juego** y, sobre todo, en cuáles **falla** —los que requieren planificación a largo plazo, como Montezuma's Revenge—. Esa columna es la más informativa.
- La **visualización t-SNE** de las representaciones aprendidas: estados perceptualmente distintos con valor similar acaban juntos.
- Las **ablaciones** de repetición de experiencia y red objetivo, que es donde se demuestra que cada mecanismo aporta.

8. Evidencia y resultados

Evaluación en 49 juegos de Atari 2600 con la misma red y los mismos hiperparámetros, comparando con un jugador humano profesional y con los mejores métodos de refuerzo previos.

Las puntuaciones por juego, la normalización respecto al desempeño humano y las ablaciones están en el artículo y su material suplementario. Verificarlos allí antes de citar cualquier cifra: el resumen frecuente «supera al humano» esconde que en varios juegos queda muy por debajo.

La miniatura de este eje aísla las dos estabilizaciones con Q tabular en una rejilla: con ambas, la política converge cerca del óptimo; sin ellas, empeora y varía más entre semillas.

9. Impacto

- Convirtió el refuerzo profundo en un área central, tras años de escepticismo sobre la combinación de refuerzo y redes.
- La **repetición de experiencia** y la **red objetivo** pasaron a ser piezas estándar.
- Es el antecedente directo de AlphaGo y, más adelante, del uso de refuerzo para alinear modelos de lenguaje (P12) y para incentivar razonamiento (P22).
- Fijó Atari como banco de pruebas de la comunidad durante casi una década.

10. Limitaciones

1. **Ineficiencia extrema en muestras:** necesita decenas de millones de fotogramas por juego, órdenes de magnitud más que una persona.
2. **Falla donde hace falta exploración dirigida:** recompensas muy dispersas o planificación larga.
3. **Un modelo por juego:** no transfiere entre juegos.
4. **Solo acciones discretas:** el control continuo requiere otros métodos.
5. **Sobreestimación del valor** por el `max`, que trabajos posteriores corrigen (Double DQN).
6. **Sensible a hiperparámetros** pese a la afirmación de uniformidad, y con alta varianza entre semillas — algo que la comunidad tardó años en reportar de forma sistemática.

11. Errores comunes

Error	Corrección
«DQN inventó Q-learning»	Q-learning es de Watkins (1989). La contribución es estabilizarlo con aproximación no lineal.
«Supera a los humanos en Atari»	Los supera en muchos juegos y queda muy por debajo en otros. El agregado esconde la distribución.
«Aprende como una persona»	Necesita millones de partidas para lo que una persona aprende en minutos.
«La red objetivo es un detalle de implementación»	Sin ella el objetivo se mueve con cada actualización y el entrenamiento diverge.
«Es aprendizaje no supervisado»	Es aprendizaje por refuerzo : hay una señal de recompensa, aunque no haya etiquetas.

12. Relación con trabajos anteriores

- **Watkins (1989)** — Q-learning tabular.
- **P02 Backpropagation** y **P04 AlexNet** — la red que aproxima Q y su capacidad de leer píxeles.
- **Sutton y Barto** — el marco teórico del refuerzo. libro abierto

13. Relación con trabajos posteriores

- **P27 AlphaGo (2016)** — añade búsqueda a la ecuación.
- **Double DQN, Dueling DQN, Rainbow (2015–2017)** — corrigen la sobreestimación y combinan mejoras.
- **P12 InstructGPT (2022)** y **P22 DeepSeek-R1 (2025)** — el refuerzo aplicado a modelos de lenguaje.

14. Notebook asociado

P26_dqn.ipynb

Qué implementa: Q tabular en una rejilla 4×4, con y sin repetición de experiencia y red objetivo, más una demostración numérica de por qué un objetivo móvil desestabiliza.

Qué NO implementa: ninguna red neuronal, ningún píxel, ningún juego. Con 16 estados no hace falta aproximar nada: se ve el efecto de las estabilizaciones, no el problema que las motiva.

```
ai-evolution paper-lab P26 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe la actualización de Q-learning y señala cuál es el objetivo.
Explicar	Explica por qué las muestras consecutivas correlacionadas perjudican el aprendizaje.
Aplicar	Ejecuta el notebook con tres semillas y compara ambas configuraciones.
Analizar	¿Por qué el <code>max</code> sobre <code>a'</code> produce sobreestimación del valor?
Evaluar	«DQN supera a los humanos en Atari». Reescribe la afirmación de forma defendible.
Crear	Diseña un entorno donde la repetición de experiencia sea contraproducente y explica por qué.

16. Autoevaluación

1. ¿Qué dos problemas hacen inestable el refuerzo con aproximación no lineal?
2. ¿Cómo ataca cada uno de los dos mecanismos propuestos?
3. ¿Qué significa que Q-learning sea «fuera de política»?
4. ¿Qué papel juega `γ` y qué pasa si vale 0?
5. ¿En qué tipo de juegos falla DQN y por qué?
6. ¿Qué afirmación de generalidad hace el paper, y por qué es más fuerte que un buen resultado?
7. ¿Qué relación tiene esto con alinear un modelo de lenguaje?

17. Respuestas esperadas

1. La correlación entre muestras consecutivas y el hecho de que el objetivo se calcule con la misma red que se está actualizando, de modo que el blanco se mueve.
2. La repetición de experiencia muestrea al azar de un buffer, rompiendo la correlación. La red objetivo congela la red que calcula el objetivo durante N pasos, fijando el blanco.
3. Que aprende el valor de la política **óptima** (por el $\max$) aunque los datos se hayan recogido con una política exploratoria distinta.
4. Descuenta el futuro. Con $\gamma = 0$ el agente solo optimiza la recompensa inmediata y no planifica.
5. En los de recompensa muy dispersa o que exigen planificación larga: explorar al azar casi nunca encuentra la primera recompensa.
6. Que la misma arquitectura y los mismos hiperparámetros valen para decenas de juegos. Es más fuerte porque descarta el ajuste específico como explicación del resultado.
7. Es el mismo marco: hay una señal de recompensa y una política que se optimiza. Cambia el entorno (texto en vez de juego) y el origen de la recompensa (humana o verificable).

18. Fuentes primarias

- Mnih, V. et al. (2015). *Human-level control through deep reinforcement learning*. **Nature** 518, 529–533. doi.org/10.1038/nature14236 · consultado 2026-08-16.
- Sutton, R. S. y Barto, A. G. *Reinforcement Learning: An Introduction*. versión abierta · consultado 2026-08-16.



Evaluación — P26 · Control a nivel humano mediante aprendizaje por refuerzo profundo

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Human-level control through deep reinforcement learning* (2015, Nature 518, 529–533 (2015)) ·

Nivel: L3

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P26_dqn.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).