

P3 1

Agentes generativos: simulacros interactivos de comportamiento humano

Generative Agents: Interactive Simulacra of Human Behavior

Joon Sung Park, Joseph C. O'Brien, Carrie J. Cai, Meredith Ringel Morris, Percy Liang, Michael S. Bernstein · 2023
· arXiv:2304.03442 · UIST 2023

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-16.

P31 — Generative Agents

Ruta de agentes · Resuelve la memoria de un agente que vive mucho tiempo: qué recordar, cuándo y por qué, cuando el contexto no da para todo.

Nivel: L3 · **Motor:** `generative_agents` · **Notebook:** `P31_generative_agents.ipynb` · **Anexo:** álgebra y geometría

1. Identificación

Campo	Valor
Título original	<i>Generative Agents: Interactive Simulacra of Human Behavior</i>
Autoría	Joon Sung Park, Joseph C. O'Brien, Carrie J. Cai, Meredith Ringel Morris, Percy Liang, Michael S. Bernstein
Año	2023
Venue	arXiv:2304.03442 · UIST 2023
Fuente primaria	arXiv:2304.03442
Acceso	Abierto
Fecha de consulta	2026-08-16

2. Problema anterior

Reflexion recuerda entre intentos de una misma tarea. Pero un agente que **vive** —que actúa durante días, conversa, cambia de plan— acumula una historia que no cabe en ninguna ventana de contexto.

Y la solución obvia no funciona: guardar todo y recuperar lo más reciente devuelve lo trivial. Si acabas de comprar café, eso será lo último; que mañana hay una fiesta importante quedará enterrado.

3. Propuesta

Una arquitectura de memoria con tres piezas:

- Flujo de memoria:** todo se registra, con marca de tiempo, en lenguaje natural.
- Recuperación puntuada** por tres señales combinadas —relevancia respecto a la situación actual, recencia con decaimiento, e importancia intrínseca del recuerdo (que el propio modelo puntúa al guardarlo)—.
- Reflexión:** periódicamente, el agente sintetiza sus recuerdos en conclusiones de nivel superior («Klaus está muy metido en su investigación»), que se guardan como recuerdos nuevos y pueden a su vez sintetizarse.

Sobre esa memoria se construyen planificación y reacción, y todo ello se demuestra en una simulación con veinticinco agentes.

4. Intuición sin fórmulas

Una persona no recuerda su día en orden cronológico: recuerda lo que viene a cuento. Si un agente guarda todo y recupera lo último, recordará que compró café en vez de que mañana hay una fiesta.

Dónde deja de funcionar la analogía: la memoria humana olvida, distorsiona y consolida durmiendo. Aquí nada se borra: se puntúa. Es un archivo con buen buscador, no una memoria.


5. Matemática mínima

```
puntuación(m) = α_rel · relevancia(m, consulta)
                + α_rec · recencia(m)
                + α_imp · importancia(m)
```

relevancia	= similitud coseno entre embeddings	(ver A01)
recencia	= $\gamma^{(\text{pasos desde el último acceso})}$	decaimiento exponencial
importancia	= puntuación del modelo al guardar	de 1 a 10

Se recuperan los **k** de mayor puntuación y **solo esos** entran al contexto. Las tres señales son necesarias: sin relevancia se recupera ruido, sin recencia se ignora lo que acaba de pasar, y sin importancia lo trivial reciente gana siempre.

6. Arquitectura o flujo



7. Qué observar en el paper original

- La **arquitectura de memoria** en detalle: es la contribución técnica, por encima de la simulación que da titulares.
- El **árbol de reflexión**: las conclusiones se construyen sobre recuerdos y sobre otras conclusiones. Eso es lo que permite comportamiento coherente a lo largo de días simulados.
- La **evaluación con humanos**: se pide a personas que juzguen si el comportamiento es creíble, y se hacen **ablaciones** quitando memoria, reflexión o planificación. Esa tabla es la evidencia.
- El caso de la **fiesta de San Valentín**, que se propaga entre agentes sin que nadie lo programe: es el ejemplo más citado y conviene leer cómo se produce realmente.

8. Evidencia y resultados

Simulación de veinticinco agentes en un entorno tipo pueblo, con evaluación humana de la credibilidad del comportamiento y ablaciones de cada componente de la arquitectura.

El resultado que sostiene el paper es de **ablación**: quitar memoria, reflexión o planificación degrada la credibilidad juzgada por personas, y quitar la memoria es lo que más daña.

Las condiciones del experimento, el número de evaluadores y los resultados por ablación están en el artículo. Verificarlos allí, y tener presente que «credibilidad juzgada por humanos» es una métrica subjetiva por construcción.

La miniatura de este eje aísla la recuperación: con las tres señales sube lo relevante e importante; ordenando solo por recencia sube lo trivial.

9. Impacto

- Es la referencia obligada sobre **memoria de agentes de larga duración**, y su esquema de puntuación se copió por todas partes.
- Popularizó la idea de **reflexión como síntesis** —no solo como corrección de un fallo, que es lo de Reflexion—.
- Abrió una línea de simulación social con agentes que se usa en ciencias sociales computacionales, con las cautelas metodológicas del caso.

10. Limitaciones

1. **Coste alto**: cada acción requiere recuperar, y cada reflexión más llamadas al modelo.
2. **La importancia la puntúa el propio modelo**, con sus sesgos y sin calibración.
3. **Nada se olvida nunca**: el flujo crece indefinidamente y la recuperación se encarece.
4. **La credibilidad no es corrección**: que un comportamiento parezca humano no lo hace correcto ni útil.
5. **Los pesos de las tres señales** son hiperparámetros sin una teoría que los fije.
6. **Riesgo de sobreinterpretación**: son simulacros de comportamiento, no modelos de personas, y usarlos como sustituto de participantes humanos en investigación es metodológicamente delicado.

11. Errores comunes

Error	Corrección
«Los agentes tienen memoria»	Tienen un archivo con recuperación puntuada . No olvidan, no consolidan, no distorsionan.
«Es una demo tipo Los Sims»	La simulación es el vehículo; la contribución es la arquitectura de memoria y sus ablaciones.
«Simulan personas»	Simulan comportamiento creíble según jueces humanos. Los propios autores advierten contra el salto.
«Basta con RAG sobre el historial»	RAG recupera por relevancia. Aquí hacen falta las tres señales, y la reflexión no es recuperación sino síntesis.
«Se puede sustituir a participantes humanos»	Es precisamente el uso contra el que la comunidad ha advertido.

12. Relación con trabajos anteriores

- **P11 RAG (2020)** — la memoria consultable; aquí se le añaden recencia, importancia y síntesis.
- **P13 ReAct (2022)** — el bucle de acción sobre el que se monta.
- **P30 Reflexion (2023)** — reflexión como corrección; aquí es síntesis.

13. Relación con trabajos posteriores

- **P32 Voyager (2023)** — memoria **procedimental** (habilidades) en vez de episódica (recuerdos).
- **P16 Sistemas agentic** — la síntesis operativa del bloque.
- **Arquitecturas de memoria jerárquica (2023+)** — gestionar el contexto como un sistema operativo gestiona la memoria.

14. Notebook asociado

P31_generative_agents.ipynb

Qué implementa: la puntuación de cinco recuerdos con las tres señales, la comparación con ordenar solo por recencia, el efecto del factor de decaimiento y la cuenta de por qué concatenar el historial no escala.

Qué NO implementa: la relevancia se calcula por solapamiento de conjuntos, no por embeddings; la importancia está escrita a mano; y falta la reflexión, que es la mitad del aporte.

```
ai-evolution paper-lab P31 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe la fórmula de puntuación y nombra las tres señales.
Explicar	Explica qué falla si se quita cada una de las tres.
Aplicar	Ejecuta el notebook y compara el ranking completo con el de solo recencia.
Analizar	Calcula cuántos tokens ocupa una semana de vida de un agente y decide si cabe.
Evaluar	«Credibilidad juzgada por humanos» como métrica: ¿qué mide y qué no?
Crear	Diseña una política de olvido y argumenta qué se pierde al no tenerla.

16. Autoevaluación

1. ¿Por qué recuperar por recencia no funciona?
2. ¿Qué aporta cada una de las tres señales?
3. ¿Qué es la reflexión aquí y en qué se diferencia de la de Reflexion?
4. ¿Por qué no cabe todo en el contexto? Da una cuenta aproximada.
5. ¿Qué demuestran las ablaciones del paper?
6. ¿Por qué «credibilidad» no equivale a «corrección»?

7. ¿Qué diferencia hay entre memoria episódica y procedimental?

17. Respuestas esperadas

1. Porque lo más reciente suele ser lo más trivial. La utilidad de un recuerdo no depende de cuándo ocurrió sino de si viene a cuento ahora.
2. Relevancia filtra por tema; recencia da peso a lo que acaba de pasar; importancia evita que lo trivial reciente desplace a lo significativo antiguo.
3. Aquí es **síntesis**: agregar recuerdos en conclusiones de nivel superior que se guardan como memoria. En Reflexion es **corrección**: analizar un fallo para no repetirlo.
4. Un agente con ~30 eventos por hora genera miles de eventos en una semana; a decenas de tokens cada uno, se van a cientos de miles. No cabe, y concatenar tampoco sería útil.
5. Que cada componente aporta: quitar memoria, reflexión o planificación degrada la credibilidad evaluada por personas, y la memoria es la más determinante.
6. Porque un comportamiento puede parecer humano y ser inútil, sesgado o falso. La credibilidad mide verosimilitud percibida, no acierto.
7. La episódica guarda **qué pasó** (recuerdos); la procedimental guarda **qué sé hacer** (habilidades ejecutables), que es lo de Voyager.

18. Fuentes primarias

- Park, J. S. et al. (2023). *Generative Agents: Interactive Simulacra of Human Behavior*. **UIST 2023**. arXiv:2304.03442 · consultado 2026-08-16.
- Lewis, P. et al. (2020). *Retrieval-Augmented Generation*. arXiv:2005.11401 · consultado 2026-08-16.



Evaluación — P31 · Agentes generativos: simulacros interactivos de comportamiento humano

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Generative Agents: Interactive Simulacra of Human Behavior* (2023, arXiv:2304.03442 · UIST 2023) · **Nivel:** L3

Parte A — Contexto histórico (20 pts)

- (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
- (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

- (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
- (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

- (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

- (10) Ejecuta `P31_generative_agents.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
- (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
- (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

- (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
- (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).