

P34

RoFormer: Transformer mejorado con codificación posicional rotatoria

RoFormer: Enhanced Transformer with Rotary Position Embedding

Jianlin Su, Yu Lu, Shengfeng Pan, Ahmed Murtadha, Bo Wen, Yunfeng Liu · 2021 · arXiv:2104.09864

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-16.

P34 — RoPE

Memoria y contexto · La posición se codifica **rotando**, y la atención pasa a depender solo de la distancia relativa. Es la base de casi todo modelo actual.

Nivel: L3 · Motor: rope · Notebook: P34_rope.ipynb · Anexo: álgebra y geometría

1. Identificación

Campo	Valor
Título original	RoFormer: Enhanced Transformer with Rotary Position Embedding
Autoría	Jianlin Su, Yu Lu, Shengfeng Pan, Ahmed Murtadha, Bo Wen, Yunfeng Liu
Año	2021
Venue	arXiv:2104.09864
Fuente primaria	arXiv:2104.09864
Acceso	Abierto
Fecha de consulta	2026-08-16

2. Problema anterior

La codificación sinusoidal del Transformer se **suma** al embedding y codifica posición **absoluta**. Pero en lenguaje lo que importa casi siempre es la distancia: que dos palabras estén separadas por tres posiciones significa lo mismo al principio de un documento que al final.

Existían variantes con posición relativa (Shaw et al., 2018), pero añadían parámetros, tablas o términos extra en el cálculo de la atención.

3. Propuesta

Rotar los vectores de consulta y clave según su posición, por pares de coordenadas. La propiedad que se busca —y que se demuestra— es que el producto escalar entre una consulta en la posición m y una clave en la n depende **solo de $m - n$** .

La posición absoluta se usa para construir la rotación, pero desaparece del resultado. Sin parámetros nuevos, sin tablas y sin cambiar la forma de la ecuación de atención.

4. Intuición sin fórmulas

Dos relojes puestos en hora distinta. Si comparas sus manecillas, lo que obtienes no depende de qué hora marque cada uno, sino de la diferencia entre ambos.

Dónde deja de funcionar la analogía: las manecillas dan la vuelta y se repiten. Las frecuencias de RoPE están elegidas para que, en el rango de trabajo, posiciones distintas no colisionen — y ese rango es finito.

5. Matemática mínima

Para cada par de coordenadas $(2i, 2i+1)$ y posición m , con $\theta_i = 10000^{(-2i/d)}$:

$$R_m = \begin{bmatrix} \cos(m\theta_i) & -\sin(m\theta_i) \\ \sin(m\theta_i) & \cos(m\theta_i) \end{bmatrix}$$

$$q_m = R_m \cdot q \qquad k_n = R_n \cdot k$$


$$\langle q_m, k_n \rangle = \langle R_m \cdot q, R_n \cdot k \rangle = q^T R_{\{n-m\}} k \qquad \leftarrow \text{solo la DIFERENCIA}$$

La última igualdad sale de que las rotaciones componen: $R_m^T R_n = R_{\{n-m\}}$. Ahí está todo el paper.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A01 §4 · Matrices como transformaciones	una rotación es una matriz ortogonal: preserva la norma y cambia el ángulo
A04 · la atención paso a paso	dónde entra exactamente la posición dentro del cálculo de la atención

6. Arquitectura o flujo



7. Qué observar en el paper original

- La **demostración** de que el producto solo depende de $m - n$. Es corta y merece seguirse.
- La elección de **frecuencias** por par de coordenadas, heredada de la codificación sinusoidal.
- El argumento sobre el **decaimiento** del producto con la distancia, que se presenta como propiedad deseable en lenguaje.
- Que se aplica a **q y k**, no al embedding de entrada: eso es lo que permite que la cancelación ocurra dentro de la atención.

8. Evidencia y resultados

Experimentos en tareas de comprensión y en modelado de lenguaje comparando RoPE con codificaciones absolutas y relativas previas.

Las cifras por tarea están en el artículo. Verificarlas allí. La adopción masiva de RoPE se debe tanto a sus resultados como a su simplicidad de implementación, y conviene no confundir ambas razones.

La miniatura de este eje comprueba la propiedad central: las parejas (5,3), (50,48) y (500,498) dan **exactamente** el mismo producto escalar.

9. Impacto

- Es la codificación posicional de la mayoría de modelos de lenguaje abiertos actuales.
- Al no añadir parámetros, se convirtió en el valor por defecto sin coste de adopción.
- Su formulación abrió la vía a las técnicas de **extensión de contexto** por interpolación de posiciones, que son posteriores y no están en este paper.

10. Limitaciones

1. **No garantiza extrapolación:** fuera del rango de posiciones visto en entrenamiento, el rendimiento cae. Las técnicas para arreglarlo son posteriores.
2. El **decaimiento con la distancia** es un sesgo, y hay tareas donde es indeseable.
3. Se aplica a la atención: **no** resuelve el coste cuadrático, que es otro problema (P35).
4. **Es un preprint** sin revisión por pares en su forma original.
5. La elección de la base (10000) es heredada y no está optimizada en el artículo.

11. Errores comunes

Error	Corrección
«RoPE permite contexto infinito»	Da posición relativa. Extender el contexto exige interpolación de posiciones, que es trabajo posterior.
«Es una codificación posicional más»	Es la única común que hace que la posición absoluta se cancele dentro del producto de atención.
«Se suma al embedding»	Se aplica rotando q y k , dentro de la atención. Ahí está la diferencia.
«Resuelve el coste de la atención»	No toca el coste. Ese es el problema de FlashAttention y de Mamba.

12. Relación con trabajos anteriores

- **Po8 Transformer (2017)** — la codificación sinusoidal que sustituye.
- **Shaw et al. (2018)** — posición relativa con parámetros extra. arXiv:1803.02155

13. Relación con trabajos posteriores

- **P35 FlashAttention (2022)** — el otro pilar del contexto largo.
- **Interpolación y extensión de posiciones (2023+)** — hacen extrapolable lo que RoPE no extrapola solo.
- **P20 Mamba (2023)** — la alternativa que prescinde de posiciones.

14. Notebook asociado

P34_rope.ipynb

Qué implementa: la rotación por posición, la comprobación de invariancia relativa y la tabla de decaimiento con la distancia.

Qué NO implementa: ni modelo, ni entrenamiento, ni extensión de contexto.

```
ai-evolution paper-lab P34 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe la matriz de rotación y di sobre qué se aplica.
Explicar	Explica por qué la posición absoluta se cancela en el producto.
Aplicar	Ejecuta el notebook y verifica la invariancia con tres parejas propias.
Analizar	¿Qué le pasa al producto con distancia 0? ¿Y por qué decae?
Evaluar	«RoPE da contexto infinito». Reescribe la afirmación de forma defendible.
Crear	Diseña un experimento que mida hasta qué posición extrapola un modelo con RoPE.

16. Autoevaluación

1. ¿Sobre qué vectores se aplica la rotación y por qué ahí?
2. ¿Por qué $R_m^T R_n = R_{\{n-m\}}$ es la clave de todo?
3. ¿Qué parámetros nuevos añade RoPE?
4. ¿Qué NO resuelve?
5. ¿Por qué el decaimiento con la distancia se considera deseable en lenguaje?
6. ¿Qué hace falta para extender el contexto más allá del entrenamiento?
7. ¿En qué se diferencia de la codificación sinusoidal de Po8?

17. Respuestas esperadas

1. Sobre q y k , dentro de la atención. Si se aplicara al embedding de entrada, la cancelación no ocurriría en el producto escalar.
2. Porque hace que el producto dependa solo de la diferencia de posiciones: es la propiedad que convierte una codificación absoluta en un efecto relativo.
3. Ninguno. La rotación se calcula, no se aprende.

4. El coste cuadrático de la atención, la extrapolación a longitudes no vistas y la calidad del uso del contexto largo.
5. Porque en lenguaje la dependencia entre palabras tiende a decaer con la distancia: es un sesgo inductivo alineado con el dominio.
6. Técnicas posteriores de interpolación o reescalado de posiciones. No está en este paper.
7. La sinusoidal se **suma** al embedding y codifica posición absoluta; RoPE **rota** q y k, y el resultado depende solo de la distancia.

18. Fuentes primarias

- Su, J. et al. (2021). *RoFormer: Enhanced Transformer with Rotary Position Embedding*. arXiv:2104.09864 · consultado 2026-08-16.
- Shaw, P., Uszkoreit, J. y Vaswani, A. (2018). *Self-Attention with Relative Position Representations*. arXiv:1803.02155 · consultado 2026-08-16.



Evaluación — P34 · RoFormer: Transformer mejorado con codificación posicional rotatoria

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *RoFormer: Enhanced Transformer with Rotary Position Embedding* (2021, arXiv:2104.09864) ·

Nivel: L3

Parte A — Contexto histórico (20 pts)

- (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
- (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

- (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
- (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

- (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

- (10) Ejecuta `P34_rope.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
- (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
- (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

- (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
- (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).