

P35

FlashAttention: atención exacta, rápida y eficiente en memoria, consciente de la E/S

FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness

Tri Dao, Daniel Y. Fu, Stefano Ermon, Atri Rudra, Christopher Ré · 2022 · arXiv:2205.14135 · NeurIPS 2022

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-16.

P35 — FlashAttention

Memoria y contexto · El cuello de botella de la atención no eran los FLOPs sino las lecturas y escrituras a memoria. Y la solución es **exacta**, no una aproximación.

Nivel: L4 · **Motor:** flashattention · **Notebook:** P35_flashattention.ipynb · **Anexo:** complejidad y coste

1. Identificación

Campo	Valor
Título original	FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness
Autoría	Tri Dao, Daniel Y. Fu, Stefano Ermon, Atri Rudra, Christopher Ré
Año	2022
Venue	arXiv:2205.14135 · NeurIPS 2022
Fuente primaria	arXiv:2205.14135
Acceso	Abierto
Fecha de consulta	2026-08-16

2. Problema anterior

Desde 2019 la comunidad atacaba el coste $O(n^2)$ de la atención con **aproximaciones**: atención dispersa, lineal, de bajo rango. Reducían los FLOPs sobre el papel y, en la práctica, muchas no aceleraban nada — y sí perdían calidad.

El diagnóstico estaba equivocado. El proceso no estaba limitado por cómputo sino por **memoria**: materializar la matriz de atención $n \times n$ y moverla entre la memoria lenta de la GPU (HBM) y la rápida del chip (SRAM) costaba más que las multiplicaciones.

3. Propuesta

Reorganizar el cálculo para que la matriz de atención **nunca llegue a existir** en memoria lenta. Se recorre por bloques que caben en SRAM, se calcula el softmax de forma **incremental** con reescalado, y se acumula el resultado.

Dos consecuencias que conviene separar: el resultado es **numéricamente exacto** —no es una aproximación — y los FLOPs son los mismos. Lo único que cambia es el tráfico de memoria.

4. Intuición sin fórmulas

Cocinar con la despensa lejos. No es que cortar y freír sea lento: es que vas y vuelves a la despensa por cada ingrediente. La solución no es cocinar menos, es traer una bandeja con lo que necesitas y trabajar sin moverte.

Dónde deja de funcionar la analogía: el softmax necesita el máximo y la suma de **toda** la fila, que no cabe en la bandeja. Por eso hace falta el reescalado incremental, que es la parte técnicamente difícil.

5. Matemática mínima

Softmax incremental (estabilidad + acumulación por bloques):

para cada bloque j:
 m_nuevo = max(m_viejo, max(S_j))
 l_nuevo = e^{m_viejo - m_nuevo} · l_viejo + ∑ e^{S_j - m_nuevo}
 O_nuevo = e^{m_viejo - m_nuevo} · O_viejo + e^{S_j - m_nuevo} · V_j


Accesos a memoria lenta:
 estándar: $\Theta(n^2 + n \cdot d)$ ← materializa la matriz
 por bloques: $\Theta(n^2 \cdot d^2 / M)$ ← M = tamaño de SRAM

Como $M \gg d$, el segundo es mucho menor. Y la salida es idéntica bit a bit salvo redondeo.


[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A05 §3 · La cuenta que decide el hardware: memoria	la cuenta de memoria y de ancho de banda, que es la tesis entera del paper
A04 · la atención paso a paso	qué se calcula, para entender qué se está reorganizando sin aproximar

6. Arquitectura o flujo



mismos FLOPs
mismo resultado



7. Qué observar en el paper original

- El **análisis de accesos a memoria**: es la contribución conceptual, más que el algoritmo.
- La derivación del **softmax por bloques con reescalado**, que es lo que hace posible no materializar la matriz.
- Los **speedups medidos**, y en qué configuraciones: no son uniformes.
- El apartado de **Path-X y Path-256**: por primera vez un Transformer supera el azar en esas tareas de secuencia larguísima, no por ser más listo sino por poder ejecutarse.

8. Evidencia y resultados

Medidas de aceleración de extremo a extremo en entrenamiento, y resultados en tareas de secuencia larga que antes eran inabordables.

El artículo reporta **15 % de aceleración en BERT-large** (longitud 512), **3× en GPT-2** (longitud 1K) y **2,4× en Long Range Arena** (1K–4K), además de habilitar Path-X (16K) y Path-256 (64K), donde antes no se superaba el azar.

Verificar las condiciones exactas en el artículo: los speedups dependen del hardware, la longitud y la configuración.

La miniatura de este eje cuenta accesos a memoria frente a FLOPs, y muestra que con $n = 65\,536$ la reducción de tráfico es de más de un orden de magnitud **con los mismos FLOPs**.

9. Impacto

- Es una de las razones prácticas de que existan modelos con contexto largo: pasó de ser un problema de investigación a uno de ingeniería resuelta.
- Se integró como implementación por defecto en las bibliotecas principales, así que casi todo el mundo lo usa sin saberlo.
- Reorientó el trabajo sobre eficiencia: de reducir FLOPs a **considerar la jerarquía de memoria**.

10. Limitaciones

1. **No cambia la complejidad asintótica**: sigue siendo $O(n^2)$ en cómputo.
2. **Depende del hardware**: la ganancia se calcula sobre una jerarquía de memoria concreta.
3. **Implementación compleja**: es un kernel de bajo nivel, no unas líneas de código.
4. **No ayuda con lotes muy pequeños** ni secuencias cortas, donde el proceso no está limitado por memoria.
5. **No resuelve** que el modelo **use** bien el contexto largo, que es el problema de P36.

11. Errores comunes

Error	Corrección
«Es una atención aproximada»	Es exacta . Da el mismo resultado; cambia cómo se calcula.
«Reduce el coste a $O(n)$ »	El cómputo sigue siendo cuadrático. Lo que baja es el tráfico de memoria.
«Resuelve el contexto largo»	Lo hace viable . Que el modelo lo aproveche es otro problema.
«Optimizar FLOPs es optimizar velocidad»	Es la lección del paper: en hardware moderno, mover datos suele costar más que calcular.

12. Relación con trabajos anteriores

- **Po8 Transformer (2017)** — la atención cuyo coste se ataca.
- **Atención aproximada (2019–2021)** — la línea de trabajo que este paper desplaza.
- **Modelo roofline y jerarquía de memoria** — la clase O81 del programa.

13. Relación con trabajos posteriores

- **P36 Lost in the Middle (2023)** — el contexto largo ya es viable; ahora se mide si sirve.
- **P20 Mamba (2023)** — la alternativa por arquitectura al mismo problema.
- **Versiones posteriores de FlashAttention** — más optimizaciones sobre la misma idea.

14. Notebook asociado

P35_flashattention.ipynb

Qué implementa: el conteo comparado de FLOPs y accesos a memoria, y la memoria que ocuparía la matriz de atención a distintas longitudes.

Qué NO implementa: el kernel, el softmax por bloques con reescalado ni ninguna medida real de tiempo. Es un modelo de coste, no una implementación.

```
ai-evolution paper-lab P35 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Di qué se materializa en la versión estándar y qué no en la de bloques.
Explicar	Explica por qué el algoritmo es exacto pese a calcular por bloques.
Aplicar	Ejecuta el notebook y calcula la memoria de la matriz para $n = 128\,000$.
Analizar	¿Por qué no ayuda con secuencias cortas?
Evaluar	Un método reduce FLOPs a la mitad y no acelera. ¿Qué hipótesis formulas?
Crear	Diseña un experimento que distinga si tu proceso está limitado por cómputo o por memoria.

16. Autoevaluación

1. ¿Cuál era el diagnóstico equivocado que dominó tres años?
2. ¿Qué significa que el algoritmo sea «exacto»?
3. ¿Por qué hace falta reescalar el softmax al ir por bloques?
4. ¿Cambia la complejidad asintótica?
5. ¿Por qué la ganancia depende del hardware?
6. ¿Qué problema del contexto largo **no** resuelve?
7. ¿Qué lección general deja, más allá de la atención?

17. Respuestas esperadas

1. Que el cuello de botella eran los FLOPs. Por eso se buscaban aproximaciones que reducían cómputo y seguían moviendo la matriz por memoria lenta.
2. Que produce el mismo resultado numérico que la atención estándar, salvo redondeo. No sacrifica calidad por velocidad.
3. Porque el softmax necesita el máximo y la suma de toda la fila, y al procesar por bloques solo se conoce una parte: hay que corregir lo acumulado cuando aparece un máximo mayor.
4. No: sigue siendo cuadrática en cómputo. Cambia el término de memoria.
5. Porque se calcula sobre una jerarquía concreta (tamaño de SRAM, ancho de banda de HBM); en otra máquina el punto de equilibrio cambia.
6. Que el modelo **aproveche** el contexto largo, que es lo que mide P36.
7. Que en hardware moderno mover datos suele costar más que calcular, y que optimizar sin medir dónde está el límite lleva a soluciones que no aceleran nada.

18. Fuentes primarias

- Dao, T., Fu, D. Y., Ermon, S., Rudra, A. y Ré, C. (2022). *FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness*. **NeurIPS 2022**. [arXiv:2205.14135](https://arxiv.org/abs/2205.14135) · consultado 2026-08-16.



Evaluación — P35 · FlashAttention: atención exacta, rápida y eficiente en memoria, consciente de la E/S

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness* (2022, arXiv:2205.14135 · NeurIPS 2022) · **Nivel:** L4

Parte A — Contexto histórico (20 pts)

- (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
- (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

- (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
- (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

- (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

- (10) Ejecuta `P35_flashattention.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
- (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
- (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

- (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
- (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).