

P36

Perdidos en el medio: cómo usan los modelos de lenguaje los contextos largos

Lost in the Middle: How Language Models Use Long Contexts

Nelson F. Liu, Kevin Lin, John Hewitt, Ashwin Paranjape, Michele Bevilacqua, Fabio Petroni, Percy Liang · 2023 ·
arXiv:2307.03172 · TACL

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español
que enlaza a la fuente primaria. Consultado 2026-08-16.

P36 — Lost in the Middle

Memoria y contexto · Tener contexto largo no es usarlo: el rendimiento cae en forma de U cuando el dato relevante está en el medio.

Nivel: L3 · **Motor:** `lost_in_middle` · **Notebook:** `P36_lost_in_middle.ipynb` · **Anexo:** complejidad y coste

1. Identificación

Campo	Valor
Título original	<i>Lost in the Middle: How Language Models Use Long Contexts</i>
Autoría	Nelson F. Liu, Kevin Lin, John Hewitt, Ashwin Paranjape, Michele Bevilacqua, Fabio Petroni, Percy Liang
Año	2023
Venue	arXiv:2307.03172 · TACL
Fuente primaria	arXiv:2307.03172
Acceso	Abierto
Fecha de consulta	2026-08-16

2. Problema anterior

Con RoPE y FlashAttention, el contexto largo dejó de ser un problema técnico. La industria pasó a competir en tamaño de ventana: 4K, 32K, 128K, un millón de tokens.

Nadie estaba midiendo lo obvio: **si el modelo realmente usa todo ese espacio**. La ficha técnica dice cuántos tokens caben, no cuántos se aprovechan.

3. Propuesta

Un experimento controlado y sencillo. Se coloca el **mismo** documento relevante en distintas posiciones dentro del contexto, se hace la **misma** pregunta y se mide la exactitud en función de la posición.

Nada más cambia: ni el contenido, ni la pregunta, ni el modelo, ni la longitud total.

4. Intuición sin fórmulas

Un examen a libro abierto con veinte páginas de apuntes. Recuerdas bien lo primero que leíste y lo último; lo del medio se difumina. El modelo hace lo mismo.


Dónde deja de funcionar la analogía: una persona puede volver a mirar la página del medio. El modelo tiene todo delante a la vez y aun así lo usa peor.

5. Matemática mínima

No hay ecuación: hay un protocolo experimental, que es el aporte.

```
para posición p en 1..k:  
  contexto = [doc1 ... doc_{p-1}, DOC_RELEVANTE, doc_{p+1} ... doc_k]  
  exactitud[p] = evaluar(modelo, contexto, pregunta)  
  
resultado: exactitud[p] tiene forma de U  
  alta en p=1      (primacia)  
  baja en p≈k/2    ← el hallazgo  
  alta en p=k      (recencia)
```

6. Arquitectura o flujo



7. Qué observar en el paper original

- Las **curvas por modelo y por longitud**: la forma de U aparece de forma consistente, incluso en modelos anunciados como de contexto largo.
- El experimento con **modelos de contexto extendido**: tener más ventana no aplanla la curva.
- La conexión con **sistemas de recuperación**: cuántos pasajes conviene pasar y en qué orden.
- La discusión sobre posibles **causas**, que el paper plantea sin cerrar.

8. Evidencia y resultados

Evaluación en respuesta a preguntas con múltiples documentos y en recuperación de clave-valor, sobre varios modelos y longitudes de contexto.

El hallazgo central: el rendimiento es más alto cuando la información relevante está al principio o al final, y **cae de forma marcada** cuando está en el medio — incluso en modelos diseñados explícitamente para contexto largo.

Las magnitudes por modelo están en el artículo. Verificarlas allí: la caída varía y tomarla como constante sería un error.

La miniatura de este eje reproduce la forma de la curva con un perfil didáctico de primacía y recencia, para poder razonar sobre sus consecuencias.

9. Impacto

- Cambió el discurso comercial: el tamaño de ventana dejó de ser un argumento suficiente.
- Introdujo la **prueba de aguja en el pajar por posición** como evaluación estándar de contexto largo.
- Tiene consecuencia directa en RAG: **el orden de los pasajes recuperados importa**, y colocar el mejor en medio es sabotearse.

10. Limitaciones

1. **Mide unos modelos concretos en un momento concreto**: los resultados envejecen.
2. **No explica la causa**, solo la documenta. Las hipótesis quedan abiertas.
3. Las tareas son **sintéticas y de recuperación**: no cubren razonamiento sobre todo el contexto.
4. La magnitud de la caída **depende del modelo**; generalizar un número sería incorrecto.
5. No dice **cuánto contexto conviene usar**, solo que más no es automáticamente mejor.

11. Errores comunes

Error	Corrección
«Este modelo tiene 128K de contexto, luego maneja 128K»	La ventana dice qué cabe, no qué se aprovecha. Hay que medirlo.
«Basta con meter todos los documentos»	Añadir pasajes irrelevantes empuja el bueno hacia el medio y empeora el resultado.
«El problema se arregla con más ventana»	El paper prueba modelos de contexto extendido y la curva sigue ahí.
«Es un fallo de un modelo concreto»	Se observa de forma consistente en varios modelos y familias.

12. Relación con trabajos anteriores

- **P34 RoPE** y **P35 FlashAttention** — hicieron viable el contexto largo cuya utilidad aquí se cuestiona.
- **P11 RAG (2020)** — el sistema al que más directamente afecta.
- **P10 GPT-3 (2020)** — la sensibilidad al prompt, de la que esto es un caso.

13. Relación con trabajos posteriores

- **P37 MemGPT (2023)** — si la ventana no basta ni usándola bien, hay que gestionarla como memoria.
- **Reordenamiento de pasajes en RAG (2023+)** — consecuencia práctica directa.

- **Evaluaciones de contexto largo (2024+)** — el género de benchmark que este paper inaugura.

14. Notebook asociado

P36_lost_in_middle.ipynb

Qué implementa: la curva en U con un perfil de primacía y recencia, la caída entre extremos y el protocolo de comprobación por posición.

Qué NO implementa: ningún modelo. El perfil está **modelado**, no medido: sirve para razonar sobre las consecuencias, no para afirmar magnitudes.

```
ai-evolution paper-lab P36 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Describe el protocolo experimental en tres líneas.
Explicar	Explica por qué esto afecta a un sistema RAG.
Aplicar	Ejecuta el notebook y localiza la peor posición.
Analizar	Si recuperas 10 pasajes y el mejor va tercero, ¿qué harías?
Evaluar	Un proveedor anuncia 1M de tokens. ¿Qué le pides antes de crearlo?
Crear	Diseña una prueba de aguja en el pajar para tu propio sistema.

16. Autoevaluación

1. ¿Qué se mantiene constante en el experimento y por qué es imprescindible?
2. ¿Qué forma tiene la curva y cómo se llaman sus dos extremos altos?
3. ¿Se arregla con una ventana mayor?
4. ¿Qué implicación tiene para ordenar pasajes en RAG?
5. ¿Explica el paper la causa?
6. ¿Por qué no conviene citar una magnitud concreta de caída?
7. ¿Qué evaluación estándar inaugura?

17. Respuestas esperadas

1. El documento, la pregunta, el modelo y la longitud total. Solo cambia la posición; si algo más cambiara, la diferencia no sería atribuible a la posición.
2. Forma de U: primacía al principio y recencia al final, con un valle en el medio.
3. No. El paper evalúa modelos de contexto extendido y el patrón persiste.
4. Que conviene colocar los pasajes más relevantes al principio o al final, y no pasar pasajes irrelevantes que empujen el bueno hacia el medio.
5. No. Documenta el fenómeno y plantea hipótesis, sin cerrarlas.

6. Porque varía según el modelo y la tarea; tomarla como constante convierte una observación en un dato falso.
7. La prueba de aguja en el pajar por posición, hoy habitual al evaluar contexto largo.

18. Fuentes primarias

- Liu, N. F. et al. (2023). *Lost in the Middle: How Language Models Use Long Contexts*. **TACL**. arXiv:2307.03172 · consultado 2026-08-16.



Evaluación — P36 · Perdidos en el medio: cómo usan los modelos de lenguaje los contextos largos

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Lost in the Middle: How Language Models Use Long Contexts* (2023, arXiv:2307.03172 · TACL) ·

Nivel: L3

Parte A — Contexto histórico (20 pts)

- (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
- (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

- (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
- (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

- (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

- (10) Ejecuta `P36_lost_in_middle.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
- (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
- (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

- (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
- (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).