

P38

Bayes variacional con autocodificación

Auto-Encoding Variational Bayes

Diederik P. Kingma, Max Welling · 2013 · arXiv:1312.6114 · ICLR 2014

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-16.

P38 — VAE

Arquitectura y entrenamiento · Hace entrenable un modelo generativo latente: el truco de reparametrización deja pasar el gradiente a través del muestreo.

Nivel: L3 · Motor: `vae` · Notebook: `P38_vae.ipynb` · Anexo: probabilidad y verosimilitud

1. Identificación

Campo	Valor
Título original	<i>Auto-Encoding Variational Bayes</i>
Autoría	Diederik P. Kingma, Max Welling
Año	2013
Venue	arXiv:1312.6114 · ICLR 2014
Fuente primaria	arXiv:1312.6114
Acceso	Abierto
Fecha de consulta	2026-08-16

2. Problema anterior

Un modelo generativo con variables latentes dice: hay un z oculto que explica el dato x . Para entrenarlo hay que **muestrear** z , y muestrear es un nodo estocástico: no tiene derivada, así que la retropropagación no puede atravesarlo.

La inferencia variacional existía, pero requería aproximaciones costosas y no escalaba a conjuntos grandes ni encajaba con el entrenamiento por gradiente.

3. Propuesta

Dos piezas que se apoyan.

El truco de reparametrización: escribir $z = \mu + \sigma \cdot \epsilon$ con ϵ de una normal fija. La distribución de z es la misma, pero ahora el azar está **fuera** del camino del gradiente: μ y σ son funciones deterministas de la entrada, y se puede derivar respecto a ellas.

El objetivo: maximizar una cota inferior de la verosimilitud (ELBO), con dos términos —uno de reconstrucción y otro que mantiene el espacio latente cerca de una distribución simple—.

4. Intuición sin fórmulas

Quieres derivar respecto a la media de un dado trucado. Pero tirar el dado no tiene derivada. La solución: tira un dado normal aparte, y luego aplica la media y la escala con una fórmula que sí se puede derivar.

Dónde deja de funcionar la analogía: el truco solo vale para familias de distribuciones que se pueden escribir así. No es universal.

5. Matemática mínima

Reparametrización: $z = \mu_{\theta}(x) + \sigma_{\theta}(x) \cdot \epsilon$, $\epsilon \sim N(0, I)$


ELBO: $\log p(x) \geq \mathbb{E}_q[\log p(x|z)] - \text{KL}(q(z|x) \parallel p(z))$
└─ reconstrucción ─┘ └─ regularización ─┘

Con ambas gaussianas, la KL tiene forma cerrada:

$$\text{KL} = -\frac{1}{2} \sum (1 + \log \sigma^2 - \mu^2 - \sigma^2)$$

Sin el término KL, el codificador puede mapear cada x a una gaussiana estrechísima y aislada: el espacio latente deja de ser continuo y muestrear de la prior no genera nada coherente.

6. Arquitectura o flujo



7. Qué observar en el paper original

- La **derivación del ELBO** y por qué es una cota inferior de la verosimilitud.
- El **estimador reparametrizado** y su comparación de varianza con alternativas: ahí está el argumento cuantitativo.
- Los **experimentos con espacio latente 2D**, que muestran una variedad continua e interpolable.
- Que se publica casi a la vez que Rezende et al. (2014), con la misma idea: es un caso claro de descubrimiento simultáneo.

8. Evidencia y resultados

Experimentos de estimación de verosimilitud y generación en conjuntos de imágenes pequeños, comparando con métodos de inferencia variacional previos.

Las cifras están en el artículo. Verificarlas allí; lo transferible es el estimador, no los números de 2013.

La miniatura de este eje comprueba lo esencial: $z = \mu + \sigma \cdot \epsilon$ reproduce la distribución buscada y el gradiente respecto a μ existe y vale 1.

9. Impacto

- Hizo entrenable por gradiente toda una familia de modelos latentes profundos.
- El truco de reparametrización se usa hoy mucho más allá del VAE: políticas estocásticas, cuantización diferenciable, atención con puertas.
- Su espacio latente continuo e interpolable es un antecedente directo de los espacios latentes de los modelos de difusión modernos.

10. Limitaciones

1. **Muestras borrosas:** el término de reconstrucción penaliza el error medio, y la media de varias imágenes plausibles es borrosa.
2. **Colapso posterior:** si el decodificador es muy potente, puede ignorar z por completo.
3. **La KL en forma cerrada** solo existe para familias concretas.
4. **Es una cota inferior:** optimizarla no es optimizar la verosimilitud.
5. **Compromiso reconstrucción/regularización** difícil de ajustar.

11. Errores comunes

Error	Corrección
«Es un autoencoder con ruido»	Es inferencia variacional. El ruido tiene un papel probabilístico, no de regularización.
«Maximiza la verosimilitud»	Maximiza una cota inferior . La brecha depende de lo buena que sea q .
«El término KL es opcional»	Sin él, el espacio latente deja de ser muestreable y el modelo deja de ser generativo.
«Las muestras borrosas son un bug»	Son consecuencia directa del objetivo. Es un límite del método, no un error de implementación.

12. Relación con trabajos anteriores

- **P02 Backpropagation (1986)** — el método que el truco permite aplicar aquí.
- **Inferencia variacional clásica** — el marco que se hace escalable.
- **Rezende et al. (2014)** — derivación independiente y simultánea. [arXiv:1401.4082](#)

13. Relación con trabajos posteriores

- **P39 GAN (2014)** — la respuesta opuesta al mismo problema.
- **P17 Difusión (2020)** — combina estabilidad de entrenamiento y calidad de muestra, que era justo lo que ninguno de los dos lograba a la vez.

- **Difusión latente (2022)** — difusión sobre un espacio latente tipo autoencoder.

14. Notebook asociado

P38_vae.ipynb

Qué implementa: el truco de reparametrización aislado, la comprobación de que la distribución se preserva, el gradiente respecto a μ y el cálculo de la KL en forma cerrada.

Qué NO implementa: codificador, decodificador ni datos. Solo el mecanismo.

```
ai-evolution paper-lab P38 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe la reparametrización y los dos términos del ELBO.
Explicar	Explica por qué el azar tiene que quedar fuera del camino del gradiente.
Aplicar	Ejecuta el notebook y comprueba media y varianza empíricas.
Analizar	¿Qué pasa con el espacio latente si el peso de la KL tiende a 0?
Evaluar	¿Por qué las muestras son borrosas? ¿Es un fallo o una consecuencia?
Crear	Diseña un experimento que detecte colapso posterior.

16. Autoevaluación

1. ¿Por qué muestrear bloquea el gradiente?
2. ¿Qué hace exactamente la reparametrización?
3. ¿Qué mide cada término del ELBO?
4. ¿Por qué es una cota inferior y no la verosimilitud?
5. ¿De dónde vienen las muestras borrosas?
6. ¿Qué es el colapso posterior?
7. ¿Dónde más se usa el truco de reparametrización?

17. Respuestas esperadas

1. Porque es un nodo estocástico: la salida no es una función determinista de los parámetros, así que no hay derivada que propagar.
2. Reescribe la muestra como una función determinista de los parámetros y de una fuente de ruido independiente, de modo que el gradiente puede atravesarla.
3. Uno mide si el decodificador reconstruye x desde z ; el otro, cuánto se aleja la posterior aproximada de la prior, para que el espacio latente sea muestreable.
4. Porque se aproxima la posterior verdadera con una familia q más simple; la diferencia entre ambas es la brecha entre la cota y la verosimilitud real.

5. Del término de reconstrucción: penaliza el error medio, y la media de varias reconstrucciones plausibles es una imagen difusa.
6. Que el decodificador se vuelva tan potente que ignore z , y el término KL empuje q hacia la prior: el latente deja de codificar información.
7. En políticas estocásticas de refuerzo, en cuantización diferenciable y en cualquier sitio donde haya que derivar a través de una muestra.

18. Fuentes primarias

- Kingma, D. P. y Welling, M. (2014). *Auto-Encoding Variational Bayes*. **ICLR 2014**. arXiv:1312.6114 · consultado 2026-08-16.
- Rezende, D. J., Mohamed, S. y Wierstra, D. (2014). *Stochastic Backpropagation and Approximate Inference in Deep Generative Models*. arXiv:1401.4082 · consultado 2026-08-16.



Evaluación — P38 · Bayes variacional con autocodificación

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Auto-Encoding Variational Bayes* (2013, arXiv:1312.6114 · ICLR 2014) · **Nivel:** L3

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P38_vae.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).