

P39

Redes generativas adversarias

Generative Adversarial Networks

Ian J. Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, y otros · 2014 · arXiv:1406.2661 · NeurIPS 2014

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-16.

P39 — GAN

Arquitectura y entrenamiento · Convierte la generación en un juego: dos redes compiten y ninguna necesita una verosimilitud explícita.

Nivel: L3 · Motor: gan · Notebook: P39_gan.ipynb · Anexo: probabilidad y verosimilitud

1. Identificación

Campo	Valor
Título original	Generative Adversarial Networks
Autoría	Ian J. Goodfellow, Jean Pouget-Abadie, Mehdi Mirza y otros
Año	2014
Venue	arXiv:1406.2661 · NeurIPS (NIPS) 2014
Fuente primaria	arXiv:1406.2661
Acceso	Abierto
Fecha de consulta	2026-08-16

2. Problema anterior

Los modelos generativos de la época exigían definir y optimizar una **verosimilitud explícita**. Eso obligaba a aproximaciones costosas —cadenas de Markov, inferencia variacional— o producía muestras borrosas, como en el VAE publicado meses antes.

La pregunta abierta: ¿se puede entrenar un generador **sin** escribir nunca la probabilidad que asigna a cada muestra?

3. Propuesta

Sí, si otro modelo aporta la señal. Se entrenan dos redes en un juego de suma cero:

- el **discriminador** D aprende a distinguir muestras reales de sintéticas;
- el **generador** G aprende a producir muestras que D no distinga.

El generador nunca ve datos reales directamente: solo recibe gradiente **a través** del discriminador. No hay verosimilitud, no hay cadenas de Markov, no hay inferencia aproximada — solo retropropagación a través de dos redes.

En el óptimo teórico, D no puede distinguir y la distribución del generador iguala a la real.

4. Intuición sin fórmulas

Un falsificador y un policía que aprenden a la vez. El falsificador mejora porque el policía lo pilla; el policía mejora porque el falsificador se refina. Nadie le enseña al falsificador qué es un billete bueno: solo si coló o no.

Dónde deja de funcionar la analogía: al falsificador le basta con dominar **un** tipo de billete para colar siempre. No necesita saber hacer toda la serie — y eso es exactamente el modo de fallo del método.

5. Matemática mínima

$$\min_G \max_D V(D, G) = E_{\{x \sim p_{\text{datos}}\}} [\log D(x)] + E_{\{z \sim p_z\}} [\log(1 - D(G(z)))]$$


Discriminador óptimo para un G fijo:

$$D^*(x) = p_{\text{datos}}(x) / (p_{\text{datos}}(x) + p_G(x))$$

Sustituyendo, el objetivo de G equivale a minimizar la divergencia de Jensen-Shannon entre p_{datos} y p_G .

Detalle práctico del propio paper: al principio del entrenamiento D rechaza todo con facilidad, $\log(1 - D(G(z)))$ se satura y el gradiente para G casi desaparece. Por eso se entrena G maximizando $\log D(G(z))$ en lugar de minimizando el término original — mismo punto fijo, gradientes mucho mejores.

6. Arquitectura o flujo



7. Qué observar en el paper original

- La **demostración de convergencia** con capacidad infinita: es elegante y también explica por qué las garantías no se trasladan al caso real de redes con capacidad limitada.
- El **truco del gradiente no saturante**, en la sección de entrenamiento. Es un detalle de implementación con consecuencias enormes.
- Que el algoritmo alterna k pasos de D por cada paso de G , y por qué ese equilibrio importa.
- Que las muestras del paper son **modestas** para los estándares actuales: lo que se propone es un marco, y los resultados espectaculares llegan con trabajos posteriores.

8. Evidencia y resultados

Experimentos de generación en conjuntos de imágenes pequeños, con estimaciones de verosimilitud mediante ventanas de Parzen y comparación con modelos generativos de la época.

Las cifras están en el artículo. Verificarlas allí, y tener presente que la métrica usada (ventanas de Parzen) fue criticada después por poco fiable en alta dimensión: es un buen ejemplo de cómo una métrica dominante puede resultar inadecuada.

La miniatura de este eje muestra el modo de fallo característico: con tres modos en la distribución real, el generador converge a **uno solo** — y desde el punto de vista de su objetivo, hace bien.

9. Impacto

- Abrió una década de investigación en generación adversaria: rostros sintéticos, traducción de imagen a imagen, superresolución, datos sintéticos.
- Introdujo la idea de **aprender la función de pérdida** en vez de escribirla, que reaparece en el modelo de recompensa de RLHF.
- Popularizó el problema social de los medios sintéticos, con todo lo que trajo después.
- Y fue desplazado por la difusión hacia 2021-2022, precisamente por su inestabilidad y su colapso de modos.

10. Limitaciones

1. **Colapso de modos**: el generador cubre una región de la distribución y abandona el resto.
2. **Entrenamiento inestable**: dos objetivos en competencia, sin una pérdida que baje de forma monótona y que sirva para saber si va bien.
3. **Sin verosimilitud**: no se puede evaluar la probabilidad que el modelo asigna a un dato.
4. **Métricas difíciles**: no hay una medida sencilla y fiable de calidad y cobertura a la vez.
5. **Sensible a la arquitectura y a los hiperparámetros** de forma notoria.
6. **Las garantías teóricas suponen capacidad infinita** y optimización perfecta: ninguna de las dos se cumple.

11. Errores comunes

Error	Corrección
«Las muestras son buenas, luego el modelo es bueno»	El colapso de modos produce muestras excelentes y poco diversas. Hay que medir cobertura , no solo calidad.
«El generador aprende de los datos reales»	Nunca los ve. Solo recibe gradiente a través del discriminador.
«La pérdida baja, luego va bien»	En un juego adversario, la pérdida no es un indicador de progreso: puede oscilar mientras el modelo mejora, o bajar mientras colapsa.
«Las GAN quedaron obsoletas»	Fueron desplazadas en generación de imagen general, pero siguen siendo competitivas donde la latencia importa: generan en una pasada, no en cientos.
«El objetivo del paper es el que se usa»	Se usa la variante no saturante, que el propio artículo introduce por el problema de gradiente.

12. Relación con trabajos anteriores

- **P38 VAE (2013)** — el enfoque opuesto al mismo problema: cota variacional frente a juego adversario.
- **P02 Backpropagation (1986)** — el único mecanismo de entrenamiento que hace falta.
- **Modelos generativos con verosimilitud explícita** — la familia que se esquiva.

13. Relación con trabajos posteriores

- **DCGAN (2015), Wasserstein GAN (2017), StyleGAN (2018-2020)** — estabilización, mejores métricas y calidad fotorrealista.
- **P17 Difusión (2020)** — estabilidad de entrenamiento y calidad de muestra, que es justo lo que ni GAN ni VAE lograban a la vez.
- **P12 InstructGPT (2022)** — aprender la señal de entrenamiento con otro modelo, la misma idea en otro dominio.

14. Notebook asociado

P39_gan.ipynb

Qué implementa: la dinámica del generador persiguiendo el modo más cercano en una distribución de tres modos, el conteo de modos cubiertos y la lista de lo que hay que reportar en un modelo generativo.

Qué NO implementa: el discriminador está simplificado a una comparación de medias y no hay entrenamiento adversario alterno real. Se modela la dinámica del colapso, no se ejecuta una GAN.

```
ai-evolution paper-lab P39 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe el objetivo minimax e identifica qué maximiza y qué minimiza cada red.
Explicar	Explica por qué el generador nunca necesita ver datos reales.
Aplicar	Ejecuta el notebook y observa a qué modo colapsa según la posición inicial.
Analizar	Deriva $D^*(x)$ para un G fijo y explica qué significa que valga $1/2$ en todas partes.
Evaluar	Un equipo enseña 20 muestras excelentes. ¿Qué métrica falta y por qué?
Crear	Diseña una medida de cobertura de modos para una distribución 2D conocida.

16. Autoevaluación

1. ¿Qué señal de entrenamiento sustituye a la verosimilitud?
2. ¿Por qué se entrena G maximizando $\log D(G(z))$ y no con el término original?
3. ¿Qué es el colapso de modos y por qué es racional desde el objetivo del generador?
4. ¿Por qué la pérdida no sirve como indicador de progreso?

5. ¿Qué supone la demostración de convergencia que no se cumple en la práctica?
6. ¿En qué gana todavía una GAN frente a un modelo de difusión?
7. ¿Qué idea de este paper reaparece en RLHF?

17. Respuestas esperadas

1. El discriminador: una red que aprende a distinguir, y cuyo gradiente le dice al generador cómo mejorar. Se aprende la pérdida en vez de escribirla.
2. Porque al principio D rechaza casi todo, $\log(1 - D(G(z)))$ se satura y el gradiente para G se anula. La variante no saturante tiene el mismo punto fijo y gradientes útiles.
3. Que el generador cubre solo una parte de la distribución. Es racional porque su objetivo es engañar al discriminador, y para eso basta con ser convincente en una región.
4. Porque es un juego: si D mejora, la pérdida de G sube aunque G también haya mejorado. No hay una cantidad que descienda de forma monótona hacia el óptimo.
5. Capacidad infinita para ambas redes y optimización perfecta en cada paso. Con redes reales y descenso de gradiente alterno, ninguna se cumple.
6. En velocidad de muestreo: genera en **una** pasada, mientras la difusión necesita decenas o cientos. Donde la latencia manda, sigue siendo relevante.
7. Aprender la función objetivo con otro modelo en vez de escribirla: el modelo de recompensa de RLHF cumple el papel que aquí cumple el discriminador.

18. Fuentes primarias

- Goodfellow, I. J. et al. (2014). *Generative Adversarial Networks*. **NIPS 2014**. arXiv:1406.2661 · consultado 2026-08-16.
- Kingma, D. P. y Welling, M. (2014). *Auto-Encoding Variational Bayes*. arXiv:1312.6114 · consultado 2026-08-16.



Evaluación — P39 · Redes generativas adversarias

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Generative Adversarial Networks* (2014, arXiv:1406.2661 · NeurIPS 2014) · **Nivel:** L3

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P39_gan.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).