

P41

Adam: un método de optimización estocástica

Adam: A Method for Stochastic Optimization

Diederik P. Kingma, Jimmy Ba · 2014 · arXiv:1412.6980 · ICLR 2015

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-16.

P41 — Adam

Arquitectura y entrenamiento · Un paso de aprendizaje por dimensión, adaptado a la escala de su propio gradiente. Es el optimizador por defecto de casi todo lo que vino después.

Nivel: L2 · Motor: adam · Notebook: P41_adam.ipynb · Anexo: cálculo y gradientes

1. Identificación

Campo	Valor
Título original	Adam: A Method for Stochastic Optimization
Autoría	Diederik P. Kingma, Jimmy Ba
Año	2014
Venue	arXiv:1412.6980 · ICLR 2015
Fuente primaria	arXiv:1412.6980
Acceso	Abierto
Fecha de consulta	2026-08-16

2. Problema anterior

El descenso de gradiente estocástico usa **la misma tasa de aprendizaje en todas las direcciones**. En un problema mal condicionado —donde una dirección es mucho más curva que otra— eso obliga a elegir entre dos males: una tasa grande hace oscilar la dirección empujada, y una pequeña deja la dirección plana avanzando a paso de tortuga.

Existían métodos adaptativos (AdaGrad, RMSProp) pero cada uno tenía su punto débil: AdaGrad acumula gradientes al cuadrado desde el inicio y su paso efectivo tiende a cero; RMSProp lo arregla con una media móvil pero no usa momento.

3. Propuesta

Combinar ambas ideas y añadir la pieza que faltaba:

- Primer momento:** una media móvil del gradiente, que suaviza la dirección (momento clásico).
- Segundo momento:** una media móvil del gradiente al cuadrado, que estima la escala típica de cada coordenada.
- Corrección de sesgo:** ambas medias empiezan en cero y por tanto subestiman al principio; se corrige dividiendo por $1 - \beta^t$.

El paso de cada coordenada acaba siendo del orden de η , sea cual sea la magnitud de su gradiente.

4. Intuición sin fórmulas

Bajar un valle largo y estrecho. En la dirección estrecha, un paso normal te hace rebotar de pared a pared; en la larga, ese mismo paso no avanza nada. Adam mide cuánto se mueve cada dirección y ajusta su paso por separado.

Dónde deja de funcionar la analogía: el valle real está fijo. En una red, el paisaje cambia con cada minilote, y las estimaciones de escala se hacen sobre un objetivo que se mueve.

5. Matemática mínima

$$\begin{aligned} m_t &= \beta_1 \cdot m_{t-1} + (1 - \beta_1) \cdot g_t && \text{primer momento} \\ v_t &= \beta_2 \cdot v_{t-1} + (1 - \beta_2) \cdot g_t^2 && \text{segundo momento} \\ \hat{m}_t &= m_t / (1 - \beta_1^t) && \text{corrección de sesgo} \\ \hat{v}_t &= v_t / (1 - \beta_2^t) \\ \theta_t &= \theta_{t-1} - \eta \cdot \hat{m}_t / (\sqrt{\hat{v}_t} + \epsilon) \end{aligned}$$


Valores por defecto del paper: $\beta_1 = 0,9$, $\beta_2 = 0,999$, $\epsilon = 1e-8$.

Por qué hace falta la corrección de sesgo: con $m_0 = 0$ y $\beta_1 = 0,9$, tras el primer paso $m_1 = 0,1 \cdot g_1$, diez veces menor que el gradiente real. Sin corregir, los primeros pasos serían diminutos justo cuando más falta hace avanzar.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A03 §1 · Derivada: la pregunta que resuelve	qué es una derivada y qué información da su magnitud
A03 §2 · Regla de la cadena	la regla de la cadena, que produce los gradientes que Adam consume

6. Arquitectura o flujo



7. Qué observar en el paper original

- La **derivación de la corrección de sesgo**: es la aportación técnica que distingue a Adam de RMSProp con momento.
- El **análisis de regret** en el caso convexo: da garantías, y conviene ver hasta dónde llegan (y hasta dónde no, porque las redes no son convexas).
- La discusión sobre el **paso efectivo acotado** por η , que es lo que da robustez frente a la escala del gradiente.
- **AdaMax**, la variante con norma infinito, que el mismo artículo introduce y casi nadie usa.

8. Evidencia y resultados

Experimentos de regresión logística, redes densas y convolucionales, comparando con SGD con momento, AdaGrad, RMSProp y otros.

Las curvas por experimento están en el artículo. Verificarlas allí, y con una cautela: la literatura posterior encontró que con SGD bien ajustado la comparación es más ajustada de lo que sugieren esas figuras, sobre todo en visión.

La miniatura de este eje aísla el argumento en un problema con número de condición 100: SGD queda oscilando con pérdida ~ 100 y Adam converge a $\sim 1e-8$.

9. Impacto

- Es el optimizador por defecto de prácticamente todos los modelos de este eje.
- Redujo drásticamente el esfuerzo de ajustar la tasa de aprendizaje, que era una de las mayores fricciones prácticas del deep learning.
- Su ubicuidad lo convirtió también en objeto de crítica: buena parte del trabajo posterior sobre optimización se define por comparación con él.

10. Limitaciones

1. **No siempre generaliza mejor**: hay evidencia de que SGD con momento bien ajustado generaliza mejor en algunas tareas de visión.
2. **El decaimiento de pesos se comporta mal** dentro de Adam: al dividirse también por $\sqrt{t}$, la regularización acaba siendo distinta por coordenada. Lo corrige AdamW (2017).
3. **Más memoria**: guarda dos estados por parámetro, lo que en modelos enormes es significativo.
4. **La prueba de convergencia original tenía un error**, señalado en 2018, que motivó variantes como AMSGrad.
5. **Sensible a ϵ** en regímenes de gradiente muy pequeño.
6. **Las garantías son para el caso convexo**, y las redes no lo son.

11. Errores comunes

Error	Corrección
«Adam es siempre mejor que SGD»	Converge más rápido en muchos casos; generalizar mejor es otra afirmación y no siempre se sostiene.
Usar el decaimiento de pesos de SGD tal cual	Dentro de Adam se divide también por $\sqrt{v}$ y deja de ser la regularización pretendida. Para eso está AdamW.
«La corrección de sesgo es un detalle»	Sin ella, los primeros pasos son diminutos, justo cuando más importa avanzar.
«Adapta la tasa de aprendizaje»	Adapta el paso por coordenada . La tasa global η sigue siendo un hiperparámetro que hay que elegir.
«Tiene garantías de convergencia»	Para el caso convexo, y la prueba original fue corregida después. En redes profundas no hay garantía.

12. Relación con trabajos anteriores

- **P02 Backpropagation (1986)** — quien calcula el gradiente que Adam consume.
- **AdaGrad (2011) y RMSProp (2012)** — los métodos adaptativos que combina.
- **Momento de Polyak (1964)** — el primer momento.

13. Relación con trabajos posteriores

- **AdamW (2017)** — desacopla el decaimiento de pesos del paso adaptativo. [arXiv:1711.05101](#)
- **AMSGrad (2018)** — corrige el problema de la prueba de convergencia.
- **Optimizadores para modelos grandes (2023+)** — la línea que busca reducir el estado por parámetro que Adam necesita.

14. Notebook asociado

P41_adam.ipynb

Qué implementa: SGD y Adam sobre una cuadrática con número de condición 100, con los tres componentes explícitos, y la explicación de por qué el decaimiento de pesos necesita tratamiento aparte.

Qué NO implementa: ninguna red, ningún minilote, ningún paisaje no convexo. Es el mecanismo aislado.

```
ai-evolution paper-lab P41 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe las cuatro líneas del algoritmo y di qué hace cada una.
Explicar	Explica por qué el paso efectivo es del orden de η en toda coordenada.
Aplicar	Ejecuta el notebook y sube el número de condición a 10 000.
Analizar	Calcula $\hat{m}_1$ con y sin corrección de sesgo y compara.
Evaluar	¿Cuándo elegirías SGD con momento pese a la conveniencia de Adam?
Crear	Diseña un experimento que compare generalización, no solo velocidad de convergencia.

16. Autoevaluación

1. ¿Qué estima el segundo momento y para qué sirve?
2. ¿Por qué las medias móviles empiezan sesgadas?
3. ¿Qué problema de AdaGrad resuelve la media móvil?
4. ¿Por qué el decaimiento de pesos se comporta mal dentro de Adam?
5. ¿Cuánta memoria extra necesita por parámetro?
6. ¿Qué garantiza el análisis del paper y qué no?
7. ¿En qué caso puede convenir SGD?

17. Respuestas esperadas

1. La magnitud típica del gradiente de cada coordenada. Dividir por su raíz normaliza el paso, de modo que cada dirección avanza a un ritmo comparable.
2. Porque se inicializan a cero: las primeras iteraciones promedian con ese cero y subestiman el valor real. La corrección $1 - \beta^t$ lo compensa y desaparece al crecer t .
3. Que AdaGrad acumula **todos** los gradientes al cuadrado desde el inicio, así que el denominador solo crece y el paso efectivo tiende a cero. La media móvil olvida lo antiguo.
4. Porque el término de decaimiento se suma al gradiente y acaba dividido por $\sqrt{v}$: la fuerza de la regularización pasa a depender de la escala de gradiente de cada coordenada, que no es lo que se quería.
5. Dos estados por parámetro (m y v), es decir, aproximadamente el doble de memoria que los propios pesos.
6. Una cota de regret en el caso **convexo**. No garantiza nada en el no convexo, y la prueba original tuvo que corregirse.
7. En tareas donde la generalización importe más que la velocidad de convergencia y haya presupuesto para ajustar bien la tasa de aprendizaje y su planificación.

18. Fuentes primarias

- Kingma, D. P. y Ba, J. (2015). *Adam: A Method for Stochastic Optimization*. **ICLR 2015**. arXiv:1412.6980 · consultado 2026-08-16.
- Loshchilov, I. y Hutter, F. (2019). *Decoupled Weight Decay Regularization (AdamW)*. arXiv:1711.05101 · consultado 2026-08-16.



Evaluación — P41 · Adam: un método de optimización estocástica

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Adam: A Method for Stochastic Optimization* (2014, arXiv:1412.6980 · ICLR 2015) · **Nivel:** L2

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P41_adam.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).