

P42

Explicar y aprovechar los ejemplos adversarios

Explaining and Harnessing Adversarial Examples

Ian J. Goodfellow, Jonathon Shlens, Christian Szegedy · 2014 · arXiv:1412.6572 · ICLR 2015

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-16.

P42 — Ejemplos adversarios

Arquitectura y entrenamiento · Una perturbación imperceptible cambia la predicción. Y la causa no es la profundidad: es la **linealidad** en dimensión alta.

Nivel: L3 · Motor: adversarial · Notebook: P42_adversarial.ipynb · Anexo: álgebra y geometría

1. Identificación

Campo	Valor
Título original	<i>Explaining and Harnessing Adversarial Examples</i>
Autoría	Ian J. Goodfellow, Jonathon Shlens, Christian Szegedy
Año	2014
Venue	arXiv:1412.6572 · ICLR 2015
Fuente primaria	arXiv:1412.6572
Acceso	Abierto
Fecha de consulta	2026-08-16

2. Problema anterior

Szegedy et al. (2013) habían descubierto algo desconcertante: perturbaciones minúsculas e invisibles al ojo humano hacían que una red clasificara mal con altísima confianza. La explicación que se manejaba era que las redes profundas son **extremadamente no lineales** y tienen bolsas de comportamiento errático repartidas por el espacio.

Esa hipótesis no explicaba dos observaciones incómodas: que los ejemplos adversarios **transfieran** entre modelos distintos, y que también afecten a modelos lineales sencillos.

3. Propuesta

La explicación contraria: el problema es que los modelos se comportan de forma **demasiado lineal** en dimensión alta.

Si la salida depende de $w^T x$ y perturbas cada componente en ϵ en la dirección del signo de w , el cambio total es $\epsilon \cdot \sum |w_i|$, que **crece con la dimensión**. Con miles de componentes, una perturbación invisible por píxel produce un cambio enorme en la salida.

De ahí sale un ataque de un solo paso —**FGSM**— y una defensa: entrenar con ejemplos adversarios generados sobre la marcha.

4. Intuición sin fórmulas

Mover una milésima cada uno de diez mil dígitos de una suma. Ninguna cifra cambia visiblemente, y el total se mueve diez unidades. La imperceptibilidad es **por componente**; el efecto es sobre la **suma**.

Dónde deja de funcionar la analogía: en una suma sabes exactamente cuánto contribuye cada sumando. Aquí lo que hace peligroso el ataque es que la dirección de máximo daño se puede calcular con un solo gradiente.

5. Matemática mínima

FGSM (Fast Gradient Sign Method):

$$x' = x + \epsilon \cdot \text{sign}(\nabla_x L(\theta, x, y))$$

Para un modelo lineal $w^T x$, el cambio en la salida es:

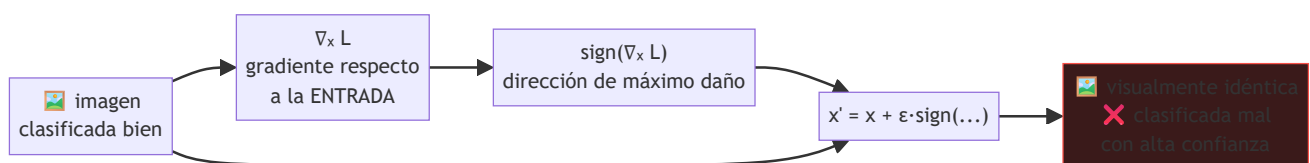
$$w^T(x' - x) = \epsilon \cdot \sum_i |w_i| = \epsilon \cdot \|w\|_1$$

→ crece linealmente con la DIMENSIÓN

dimensión	ϵ por componente	cambio en la salida
10	0,01	~0,1
784 (imagen 28×28)	0,01	~7,8
10 000	0,01	~100

La perturbación se mide en norma infinito —cuánto cambia **cada** componente— y el efecto se acumula en norma 1.

6. Arquitectura o flujo



7. Qué observar en el paper original

- El **argumento de la linealidad**, con el ejemplo del modelo lineal. Es corto y es toda la tesis.
- La famosa **figura del panda**: la imagen original, la perturbación amplificada y el resultado. Conviene mirar la escala real de la perturbación.
- La sección de **entrenamiento adversario** como regularizador, y cuánto cuesta en exactitud limpia.
- La discusión sobre **transferencia**: por qué el ataque generado contra un modelo funciona en otro. Es lo que convierte esto en un problema de seguridad y no en una curiosidad.

8. Evidencia y resultados

Experimentos sobre modelos lineales y redes en conjuntos de imágenes, midiendo la tasa de error bajo ataque y el efecto del entrenamiento adversario.

Las tasas por modelo y ϵ están en el artículo. Verificarlas allí: la exactitud robusta depende por completo del ataque usado y de su presupuesto, y una cifra sin esos dos datos no significa nada.

La miniatura de este eje aísla el argumento dimensional: con $\epsilon = 0,01$, el cambio en la salida pasa de $\sim 0,1$ en dimensión 10 a ~ 100 en dimensión 10 000.

9. Impacto

- Fundó el área de **aprendizaje automático adversario** como disciplina.
- El **entrenamiento adversario** sigue siendo la defensa de referencia, una década después.
- Cambió la forma de evaluar: la exactitud sobre la distribución natural dejó de considerarse suficiente en aplicaciones donde alguien puede atacar la entrada.
- Es un antecedente conceptual de los ataques a modelos de lenguaje: inyección de prompt y jailbreaks son la versión textual del mismo problema.

10. Limitaciones

1. **FGSM es un ataque débil**: un solo paso. Ataques iterativos como PGD son mucho más fuertes.
2. **El entrenamiento adversario cuesta exactitud limpia** y multiplica el coste de entrenamiento.
3. **Defenderse de un ataque concreto no es ser robusto**: muchas defensas publicadas cayeron ante ataques adaptativos.
4. **La explicación lineal es parcial**: describe bien el fenómeno pero no lo agota.
5. **La norma infinito es una elección**: hay amenazas que no encajan en ese modelo (rotaciones, parches físicos, cambios de iluminación).

11. Errores comunes

Error	Corrección
«Es un fallo de las redes profundas»	Afecta también a modelos lineales. La causa es la dimensión alta, no la profundidad.
«Exactitud alta = modelo robusto»	Son métricas distintas: una sobre la distribución natural, otra bajo entrada elegida por un atacante.
«Mi defensa funciona: baja la tasa de éxito de FGSM»	FGSM es débil. Hay que evaluar con ataques adaptativos que conozcan la defensa.
«La perturbación es invisible, luego es un truco de laboratorio»	Existen ataques físicos con parches y pegatinas. La invisibilidad no es un requisito del problema.
«Se resolvió»	Sigue abierto. La robustez certificada solo se consigue con garantías limitadas y a un coste alto.

12. Relación con trabajos anteriores

- **Szegedy et al. (2013)** — el descubrimiento original del fenómeno. [arXiv:1312.6199](#)
- **P04 AlexNet (2012)** — los modelos de visión sobre los que se demuestra.
- **P02 Backpropagation** — el gradiente respecto a la **entrada**, no a los pesos, es lo que hace posible el ataque.

13. Relación con trabajos posteriores

- **PGD y entrenamiento adversario robusto (2017)** — el ataque y la defensa de referencia actuales.
- **Robustez certificada (2019+)** — garantías demostrables, con un coste alto.
- **P52 Superposición** — otra vía para entender qué hay dentro del modelo y por qué se comporta así.
- **Inyección de prompt y jailbreaks** — la versión en lenguaje del mismo problema estructural.

14. Notebook asociado

P42_adversarial.ipynb

Qué implementa: el cálculo del cambio en la salida frente a la dimensión, para varios ϵ , y el protocolo de evaluación con exactitud limpia y robusta por separado.

Qué NO implementa: ninguna red ni ningún gradiente real. Se usa el signo de los pesos, que en el caso lineal coincide con el signo del gradiente.

```
ai-evolution paper-lab P42 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe la fórmula de FGSM y di respecto a qué se deriva.
Explicar	Explica por qué el efecto crece con la dimensión.
Aplicar	Calcula el ϵ necesario para mover la salida 10 unidades en dimensión 784.
Analizar	¿Por qué la transferencia entre modelos es más preocupante que el ataque en sí?
Evaluar	Una defensa reporta 95 % de exactitud bajo FGSM. ¿Qué objetas?
Crear	Diseña un protocolo de evaluación de robustez que resista un ataque adaptativo.

16. Autoevaluación

1. ¿Cuál era la explicación anterior y por qué no encajaba?
2. ¿Respecto a qué se calcula el gradiente en FGSM?
3. ¿Por qué la perturbación es imperceptible y el efecto no?
4. ¿Qué es la transferencia y por qué importa?
5. ¿Qué cuesta el entrenamiento adversario?

6. ¿Por qué una defensa evaluada solo con FGSM no es creíble?
7. ¿Qué relación tiene esto con los jailbreaks de modelos de lenguaje?

17. Respuestas esperadas

1. Que las redes son extremadamente no lineales y tienen bolsas erráticas. No encajaba porque el fenómeno también afecta a modelos lineales y porque los ataques transfieren entre modelos.
2. Respecto a la **entrada**, no a los pesos. Es la misma retropropagación, usada para preguntar cómo cambiar la imagen en vez de cómo cambiar el modelo.
3. Porque la perturbación se acota **por componente** (norma infinito) y el efecto se acumula sobre **todas** las componentes: crece con la dimensión.
4. Que un ataque generado contra un modelo funciona contra otro entrenado por separado. Importa porque significa que no hace falta acceso al modelo objetivo para atacarlo.
5. Exactitud sobre datos limpios y coste de entrenamiento, porque hay que generar ejemplos adversarios en cada paso.
6. Porque FGSM es un ataque de un solo paso y muy débil. Una defensa puede vencerlo y caer ante un ataque iterativo o adaptativo que conozca la defensa.
7. Es el mismo problema estructural: una entrada cuidadosamente construida lleva al modelo fuera del comportamiento esperado, y la superficie de ataque crece con la expresividad de la entrada.

18. Fuentes primarias

- Goodfellow, I. J., Shlens, J. y Szegedy, C. (2015). *Explaining and Harnessing Adversarial Examples*. **ICLR 2015**. arXiv:1412.6572 · consultado 2026-08-16.
- Szegedy, C. et al. (2014). *Intriguing properties of neural networks*. arXiv:1312.6199 · consultado 2026-08-16.

Evaluación — P42 · Explicar y aprovechar los ejemplos adversarios

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Explaining and Harnessing Adversarial Examples* (2014, arXiv:1412.6572 · ICLR 2015) · **Nivel:** L3

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P42_adversarial.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).