

P43

Normalización por lotes: acelerar el entrenamiento profundo

Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift

Sergey Ioffe, Christian Szegedy · 2015 · arXiv:1502.03167 · ICML 2015

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-16.

P43 — Batch Normalization

Arquitectura y entrenamiento · Normalizar las activaciones dentro de la red permite tasas de aprendizaje mucho mayores y hace el entrenamiento profundo mucho menos frágil.

Nivel: L2 · **Motor:** `batchnorm` · **Notebook:** `P43_batchnorm.ipynb` · **Anexo:** cálculo y gradientes

1. Identificación

Campo	Valor
Título original	<i>Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift</i>
Autoría	Sergey Ioffe, Christian Szegedy
Año	2015
Venue	arXiv:1502.03167 · ICML 2015
Fuente primaria	arXiv:1502.03167
Acceso	Abierto
Fecha de consulta	2026-08-16

2. Problema anterior

Entrenar redes profundas exigía tasas de aprendizaje pequeñas e inicializaciones cuidadosas. El motivo práctico era observable: la distribución de las activaciones de cada capa **se desplaza** durante el entrenamiento, porque los pesos de las capas anteriores cambian.

Con activaciones saturantes como sigmoide o tanh, eso es fatal: si las entradas de una capa se van a la zona plana, la derivada se acerca a cero y esa capa deja de aprender. El resultado era un entrenamiento lento y muy sensible a la configuración inicial.

3. Propuesta

Normalizar cada activación usando la media y la varianza **del minilote**, dentro de la red, como una capa más.

Y una pieza que evita perder capacidad expresiva: dos parámetros aprendidos, γ y β , que permiten reescalar y desplazar el resultado. Si a la red le conviene deshacer la normalización, puede hacerlo — pero ahora es una decisión aprendida, no un accidente.

En inferencia no hay minilote, así que se usan estadísticas acumuladas durante el entrenamiento.

4. Intuición sin fórmulas

Una tubería de doce filtros donde cada uno amplifica un poco. Al final, la señal está saturada o extinguida. Normalizar entre etapas es reajustar el caudal para que cada filtro reciba lo que sabe procesar.

Dónde deja de funcionar la analogía: el caudal se mide sobre el **lote**, no sobre cada muestra. Eso significa que la salida para una muestra depende de con quién le tocó viajar, algo que no tiene equivalente en la tubería y que es la raíz de sus problemas prácticos.

5. Matemática mínima

Sobre el minilote B, para cada activación:

$$\mu_B = (1/m) \sum x_i$$
$$\sigma^2_B = (1/m) \sum (x_i - \mu_B)^2$$
$$\hat{x}_i = (x_i - \mu_B) / \sqrt{(\sigma^2_B + \epsilon)}$$
$$y_i = \gamma \cdot \hat{x}_i + \beta$$

normalizar

reescalar y desplazar (APRENDIDOS)



Inferencia: μ y σ^2 son estadísticas acumuladas (media móvil), no del lote.

El ϵ no es decorativo: con un lote donde todas las activaciones sean iguales, $\sigma^2 = 0$ y la división explota. Ese epsilon evita un NaN que se propagaría a toda la red.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A02 §2 · Entropía	media y varianza de un lote, y por qué estimarlas con pocas muestras es ruido
A03 §4 · Por qué el gradiente se desvanece	el gradiente que se desvanece al saturar, que es lo que la normalización evita

6. Arquitectura o flujo



7. Qué observar en el paper original

- La **definición de «internal covariate shift»** y cómo la miden. Esta parte es la que envejeció peor, y merece leerse sabiéndolo.
- Que la normalización se aplica **antes** de la no linealidad, y por qué.
- El experimento donde eliminan el **dropout** al añadir batch norm: sugiere que tiene un efecto regularizador propio, por el ruido que introduce la estadística del lote.
- Los resultados con **tasas de aprendizaje mucho mayores**: ese es el beneficio práctico principal y el más fácil de verificar.

8. Evidencia y resultados

Experimentos en clasificación de imágenes mostrando convergencia mucho más rápida con la misma arquitectura, tolerancia a tasas de aprendizaje mayores y menor dependencia de la inicialización.

Las curvas y el número de pasos hasta una exactitud dada están en el artículo. Verificarlos allí. La aceleración reportada es grande y es lo que explica su adopción inmediata.

La miniatura de este eje muestra el mecanismo: sin normalizar, la fracción de activaciones saturadas en la capa 11 es muy alta; con normalización, la desviación se mantiene cerca de 1 y las unidades siguen en su rango útil.

9. Impacto

- Adopción prácticamente universal en visión durante media década.
- Hizo entrenables arquitecturas mucho más profundas, y es una de las piezas que permitieron ResNet ese mismo año.
- Abrió la familia de técnicas de normalización: LayerNorm —la que usa el Transformer—, GroupNorm, InstanceNorm, RMSNorm.
- Y es un caso de estudio sobre la diferencia entre **que algo funcione** y **que la explicación ofrecida sea correcta**.

10. Limitaciones

1. **Depende del tamaño de lote**: con lotes muy pequeños las estadísticas son ruido y el método se degrada. Es su punto débil práctico.
2. **Comportamiento distinto en entrenamiento e inferencia**, lo que causa fallos sutiles si las estadísticas acumuladas no se gestionan bien.
3. **Complica el paralelismo de datos**: las estadísticas son por dispositivo salvo que se sincronicen, con su coste.
4. **La explicación original fue cuestionada**: Santurkar et al. (2018) argumentan que el beneficio viene de suavizar el paisaje de optimización, no de reducir el desplazamiento de covariables.
5. **Interacción no trivial con dropout**, que produjo errores frecuentes al combinarlos.
6. **No encaja bien en secuencias de longitud variable**, motivo por el que el Transformer usa LayerNorm.

11. Errores comunes

Error	Corrección
«Funciona porque reduce el internal covariate shift»	Es la explicación del paper y fue discutida después . Que la técnica funcione no valida la explicación.
Olvidar poner el modelo en modo evaluación	En inferencia se usan estadísticas acumuladas. Si se dejan las del lote, la salida depende de con quién viaje la muestra.
Usarlo con lotes de 1 o 2	La estadística es ruido puro. Para eso están GroupNorm o LayerNorm.
« γ y β son opcionales»	Sin ellos la red pierde capacidad expresiva: no podría representar una activación con media distinta de 0.
«Es lo mismo que normalizar la entrada»	Normalizar la entrada se hace una vez; esto ocurre en cada capa y en cada paso , con estadísticas que cambian.

12. Relación con trabajos anteriores

- **P02 Backpropagation (1986)** — el gradiente que se intenta mantener vivo.
- **P04 AlexNet (2012)** — su normalización de respuesta local es el antecedente que este método deja obsoleto.
- **Inicialización de Glorot (2010) y He (2015)** — la vía alternativa al mismo problema.

13. Relación con trabajos posteriores

- **P44 ResNet (2015)** — la usa en cada bloque.
- **LayerNorm (2016)** y **P08 Transformer (2017)** — normalización por muestra, que no depende del lote.
- **Santurkar et al. (2018)** — la revisión de la explicación. [arXiv:1805.11604](https://arxiv.org/abs/1805.11604)

14. Notebook asociado

P43_batchnorm.ipynb

Qué implementa: la propagación de activaciones por doce capas con y sin normalización, midiendo media, desviación y fracción saturada; el error relativo de la estadística según el tamaño de lote; y la comparación con LayerNorm y GroupNorm.

Qué NO implementa: no hay entrenamiento, así que no se mide el efecto real sobre la convergencia — que es el beneficio principal del método.

```
ai-evolution paper-lab P43 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe las cuatro líneas del algoritmo y di qué se aprende.
Explicar	Explica por qué γ y β no anulan el propósito de normalizar.
Aplicar	Ejecuta el notebook y observa la fracción saturada por capa.
Analizar	¿Por qué el error de la estadística escala como $1/\sqrt{lote}$?
Evaluar	«Funciona porque reduce el covariate shift». Evalúa la afirmación.
Crear	Diseña un experimento que distinga aceleración de convergencia de efecto regularizador.

16. Autoevaluación

1. ¿Sobre qué se calculan la media y la varianza, y qué cambia en inferencia?
2. ¿Para qué sirven γ y β ?
3. ¿Por qué hace falta el ϵ y qué pasa sin él?
4. ¿Por qué falla con lotes pequeños?
5. ¿Cuál es el beneficio práctico más claro y verificable?
6. ¿Por qué el Transformer usa LayerNorm en vez de esto?
7. ¿Qué parte del paper envejeció peor?

17. Respuestas esperadas

1. Sobre el **minilote** durante el entrenamiento. En inferencia no hay lote, así que se usan estadísticas acumuladas por media móvil.
2. Permiten reescalar y desplazar el resultado normalizado. Sin ellos la red no podría representar activaciones con media o escala distintas de la normalizada, y perdería capacidad expresiva.
3. Para evitar dividir por cero cuando la varianza del lote es nula. Sin él, un lote de valores idénticos produce un NaN que se propaga a toda la red.
4. Porque la media y la varianza estimadas sobre pocas muestras son ruido: el error relativo va como $1/\sqrt{lote}$, y con lote 2 la normalización deja de tener sentido.
5. Que permite usar tasas de aprendizaje mucho mayores y reduce la dependencia de la inicialización. Es fácil de comprobar barriando tasas con y sin normalización.
6. Porque las secuencias tienen longitud variable y el tamaño de lote efectivo por posición cambia. LayerNorm normaliza por muestra y no depende del lote.
7. La explicación —el «internal covariate shift»—. Trabajo posterior argumenta que el beneficio viene de suavizar el paisaje de optimización.

18. Fuentes primarias

- Ioffe, S. y Szegedy, C. (2015). *Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift*. **ICML 2015**. arXiv:1502.03167 · consultado 2026-08-16.
- Santurkar, S. et al. (2018). *How Does Batch Normalization Help Optimization?* arXiv:1805.11604 · consultado 2026-08-16.



Evaluación — P43 · Normalización por lotes: acelerar el entrenamiento profundo

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift* (2015, arXiv:1502.03167 · ICML 2015) · **Nivel:** L2

Parte A — Contexto histórico (20 pts)

- (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
- (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

- (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
- (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

- (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

- (10) Ejecuta `P43_batchnorm.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
- (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
- (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

- (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
- (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).