

P44

Aprendizaje residual profundo para reconocimiento de imágenes

Deep Residual Learning for Image Recognition

Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun · 2015 · arXiv:1512.03385 · CVPR 2016

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-16.

P44 — ResNet

Arquitectura y entrenamiento · Un atajo que suma la entrada a la salida convierte la profundidad de obstáculo en recurso.

Nivel: L2 · Motor: `resnet` · Notebook: `P44_resnet.ipynb` · Anexo: cálculo y gradientes

1. Identificación

Campo	Valor
Título original	<i>Deep Residual Learning for Image Recognition</i>
Autoría	Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun
Año	2015
Venue	arXiv:1512.03385 · CVPR 2016
Fuente primaria	arXiv:1512.03385
Acceso	Abierto
Fecha de consulta	2026-08-16

2. Problema anterior

Una observación que no cuadraba con nada: al añadir capas, el error de **entrenamiento** empeoraba.

No era sobreajuste —eso empeora el error de test, no el de entrenamiento— y no era falta de capacidad —una red de 56 capas contiene a una de 20 más capas identidad, así que **como mínimo** debería igualarla—. El paper llama a esto **degradación**, y su conclusión es incómoda: el problema no estaba en el modelo, sino en la optimización. El descenso de gradiente no encontraba esa solución trivial.

3. Propuesta

Cambiar lo que cada bloque tiene que aprender. En vez de pedirle la transformación completa $H(x)$, se le pide el **residuo**:

$$y = F(x) + x$$

Si lo óptimo para ese bloque es no hacer nada, basta con que F se acerque a cero —y llevar pesos a cero es fácil. La identidad deja de ser una solución difícil de alcanzar y pasa a ser el punto de partida.

El atajo tiene además un efecto sobre el gradiente: la derivada de cada bloque es $1 + F'(x)$, y ese 1 sostiene el producto al retropropagar aunque los términos residuales sean pequeños.

4. Intuición sin fórmulas

Corregir un texto ajeno frente a reescribirlo entero. Si el original ya está bien, corregir es no tocar nada; reescribir obliga a reproducirlo de memoria y siempre sale peor.

Dónde deja de funcionar la analogía: el corrector ve el texto y decide. La red no decide: es que la parametrización hace que «no tocar nada» sea el estado más barato al que llegar.

5. Matemática mínima


Bloque plano : $y = H(x)$ → aprender H desde cero
Bloque residual: $y = F(x) + x$ → aprender solo la CORRECCIÓN

Al retropropagar:
 $\partial y / \partial x = I + \partial F / \partial x$

Producto sobre L bloques:
plano : $\prod f'_i$ → si $f'_i < 1$, colapsa exponencialmente
residual : $\prod (1 + F'_i)$ → el 1 sostiene el producto

El notebook lo hace explícito con factores fijados a mano: con 152 capas y un factor de 0,85 por capa, el gradiente sin atajo cae a **1,9e-11**; con $1 + (-0,02)$ por bloque, se queda en **4,6e-02**. Nueve órdenes de magnitud de diferencia entre desaparecer y sobrevivir.

6. Arquitectura o flujo



7. Qué observar en el paper original

- La **figura de la degradación**: 20 capas frente a 56, con el error de **entrenamiento** peor en la más profunda. Es el dato que motiva todo y conviene mirarlo antes que la solución.
- Que el atajo es **identidad y sin parámetros** en el caso general. Añade cero coste.
- El **bloque cuello de botella** (1×1, 3×3, 1×1) para las variantes de 50 capas en adelante, y por qué reduce el cómputo.
- Los resultados a **152 capas**: no solo entrena, sino que mejora — que es justo lo que la degradación impedía.

8. Evidencia y resultados

Resultados en clasificación de imágenes a gran escala y en detección, con redes de 18, 34, 50, 101 y 152 capas, comparadas contra sus equivalentes planas.

Las cifras de error por profundidad están en el artículo. Verificarlas allí. Lo relevante es el patrón: en las planas el error sube con la profundidad y en las residuales baja.

La miniatura de este eje aísla el mecanismo del gradiente, con factores puestos a mano. No mide exactitud ni entrena nada: muestra por qué el producto no colapsa.

9. Impacto

- Es, con el Transformer, una de las dos arquitecturas más citadas del campo.
- La conexión residual está **dentro** del Transformer: cada subcapa es $x + \text{Sublayer}(x)$. Sin ella, los modelos de lenguaje profundos no entrenarían.
- Cambió el techo práctico de profundidad de decenas a cientos de capas.
- Y reencuadró un problema: lo que parecía un límite de capacidad era un límite de optimización.

10. Limitaciones

1. **No elimina la necesidad de normalización:** sin BatchNorm y buena inicialización, la profundidad sigue siendo difícil.
2. **Más profundidad no es gratis:** más cómputo, más memoria de activaciones, más latencia.
3. **Rendimientos decrecientes:** de 152 a 1000 capas el paper reporta problemas, no mejoras proporcionales.
4. **La explicación de por qué funciona siguió discutiéndose:** hay trabajo que lo describe como un ensamblado implícito de rutas de distinta longitud (Veit et al., 2016).
5. **El atajo obliga a que las dimensiones cuadren;** cuando cambian hace falta una proyección, que ya no es gratuita.

11. Errores comunes

Error	Corrección
«Resuelve el gradiente que se desvanece»	Ayuda mucho, pero el problema que motiva el paper es la degradación del error de entrenamiento , que es otra cosa.
«El problema era que faltaba capacidad»	Al revés: la red profunda contiene a la superficial. Era la optimización la que no llegaba.
«El atajo tiene pesos»	En el caso general es la identidad, sin parámetros. Solo se proyecta cuando cambian las dimensiones.
«Es específico de visión»	La conexión residual es hoy universal: está en cada bloque de cada Transformer.
«Más capas siempre mejor»	El paper mismo muestra que el retorno decrece y que a profundidades extremas reaparecen problemas.

12. Relación con trabajos anteriores

- **P43 BatchNorm (2015)** — se usa dentro de cada bloque; las dos piezas juntas son lo que hace entrenable la profundidad.
- **Po4 AlexNet (2012)** y **VGG (2014)** — la línea de «más profundo es mejor» que aquí choca contra un muro.
- **Po3 LSTM (1997)** — la misma idea en el tiempo: un camino aditivo por el que el gradiente viaja sin atenuarse.

13. Relación con trabajos posteriores

- **Po8 Transformer (2017)** — $x + \text{Sublayer}(x)$ en cada subcapa.
- **DenseNet (2016)** — lleva la idea al extremo conectando cada capa con todas las siguientes.
- **Veit et al. (2016)** — la lectura de las redes residuales como ensamblado de rutas. [arXiv:1605.06431](https://arxiv.org/abs/1605.06431)
- **P46 Vision Transformer (2020)** — el sucesor que discute su hegemonía en visión, y que también usa residuos.

14. Notebook asociado

P44_resnet.ipynb

Qué implementa: el producto de derivadas a 10, 20, 50 y 152 capas, con y sin atajo, para mostrar cuándo colapsa el gradiente.

Qué NO implementa: no hay convoluciones, ni datos, ni entrenamiento. Los factores están fijados a mano para aislar el efecto; el aporte experimental del paper —entrenar 152 capas de verdad— no está aquí.

```
ai-evolution paper-lab P44 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe la ecuación del bloque residual y di qué aprende F .
Explicar	Explica por qué la degradación no es sobreajuste.
Aplicar	Ejecuta el notebook y cambia el factor por capa a 0,95.
Analizar	Deriva $\partial y / \partial x$ y explica el papel del término 1 .
Evaluar	«Una red de 56 capas debería ser al menos tan buena como una de 20». Evalúa el argumento.
Crear	Diseña una variante del atajo para cuando cambian las dimensiones y justifica el coste.

16. Autoevaluación

1. ¿Qué es la degradación y por qué no es sobreajuste?
2. ¿Qué aprende un bloque residual que no aprende uno plano?
3. ¿Por qué la identidad es fácil de alcanzar con el atajo y difícil sin él?
4. ¿Cuál es la derivada de un bloque residual y por qué importa?

5. ¿El atajo tiene parámetros?
6. ¿Dónde aparece esta idea fuera de visión?
7. ¿Qué no resuelve el atajo?

17. Respuestas esperadas

1. Que al añadir capas empeora el error de **entrenamiento**. El sobreajuste empeora el de test mientras el de entrenamiento baja: es un síntoma distinto y apunta a la optimización.
2. La **corrección** sobre su entrada, no la transformación completa. Si lo óptimo es no hacer nada, le basta con llevar F a cero.
3. Porque con atajo la identidad se obtiene con $F = 0$, que es el estado más barato. Sin atajo, la red tendría que aprender explícitamente la transformación identidad con sus pesos.
4. $I + \partial F / \partial x$. Al multiplicar sobre muchos bloques, ese 1 impide que el producto colapse exponencialmente hacia cero.
5. No, en el caso general es la identidad y no añade ningún coste. Solo hace falta una proyección cuando cambian las dimensiones entre entrada y salida.
6. En el Transformer: cada subcapa de atención y cada red feed-forward está envuelta en $x + \text{Sublayer}(x)$. Es una pieza universal en modelos profundos.
7. La necesidad de normalización y de una inicialización razonable. Y no hace que más profundidad sea siempre mejor: el retorno decrece.

18. Fuentes primarias

- He, K., Zhang, X., Ren, S. y Sun, J. (2016). *Deep Residual Learning for Image Recognition*. **CVPR 2016**. arXiv:1512.03385 · consultado 2026-08-16.
- Veit, A., Wilber, M. y Belongie, S. (2016). *Residual Networks Behave Like Ensembles of Relatively Shallow Networks*. arXiv:1605.06431 · consultado 2026-08-16.



Evaluación — P44 · Aprendizaje residual profundo para reconocimiento de imágenes

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Deep Residual Learning for Image Recognition* (2015, arXiv:1512.03385 · CVPR 2016) · **Nivel:** L3

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P44_resnet.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).