

P45

Destilar el conocimiento de una red neuronal

Distilling the Knowledge in a Neural Network

Geoffrey Hinton, Oriol Vinyals, Jeff Dean · 2015 · arXiv:1503.02531

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-16.

P45 — Destilación de conocimiento

Arquitectura y entrenamiento · Lo que un modelo grande sabe no está en su respuesta, está en **cómo reparte** la probabilidad entre las respuestas que descartó.

Nivel: L2 · **Motor:** `distillation` · **Notebook:** `P45_distillation.ipynb` · **Anexo:** probabilidad y verosimilitud

1. Identificación

Campo	Valor
Título original	<i>Distilling the Knowledge in a Neural Network</i>
Autoría	Geoffrey Hinton, Oriol Vinyals, Jeff Dean
Año	2015
Venue	arXiv:1503.02531 · NIPS 2014 Deep Learning Workshop
Fuente primaria	arXiv:1503.02531
Acceso	Abierto
Fecha de consulta	2026-08-16

2. Problema anterior

Los mejores resultados venían de modelos enormes o de ensamblados de muchos modelos. Servir eso en producción —con latencia y coste acotados— era inviable.

La salida obvia, entrenar un modelo pequeño con las mismas etiquetas, daba resultados claramente peores. Y había una asimetría desaprovechada: el modelo grande produce, para cada entrada, una distribución completa sobre las clases, y de todo eso solo se usaba el argmax.

3. Propuesta

Entrenar el modelo pequeño contra la **distribución** del grande, no contra la etiqueta.

Una etiqueta dura dice «perro» y asigna 0 a lobo, a gato y a coche por igual. La distribución del maestro dice «perro, pero se parece bastante a un lobo, algo a un gato y nada a un coche». Esa estructura de similitud —el paper la llama **conocimiento oscuro**— es información que la etiqueta tira a la basura.

Para hacerla visible se aplica una **temperatura** T al softmax: subirla aplanar la distribución y saca a la luz las probabilidades pequeñas, que son justo las informativas.

4. Intuición sin fórmulas

Un examen corregido con solo «bien/mal» frente a uno donde el profesor anota qué alternativas estuviste a punto de marcar y cuáles ni te rozaron. Lo segundo enseña mucho más rápido.

Dónde deja de funcionar la analogía: el profesor sabe la verdad. El maestro aquí solo tiene sus creencias, aciertos y errores incluidos — y el alumno hereda ambos.

5. Matemática mínima

Softmax con temperatura:

$$p_i = \exp(z_i / T) / \sum_j \exp(z_j / T)$$

$T = 1$ → distribución habitual

$T > 1$ → más plana, más entropía, más estructura visible

Pérdida del alumno:

$$L = \alpha \cdot \text{CE}(\text{alumno}_T, \text{maestro}_T) \cdot T^2 + (1 - \alpha) \cdot \text{CE}(\text{alumno}_1, \text{etiqueta})$$


El factor T^2 no es opcional: los gradientes del término suave escalan como $1/T^2$, y sin compensarlo el peso relativo de los dos términos cambiaría al mover la temperatura.

Con logits $[4, 0 \cdot 2, 0 \cdot 1, 5 \cdot -1, 0]$ para perro, lobo, gato y coche:

T	perro	lobo	gato	coche	entropía
1	0,817	0,111	0,067	0,006	0,619
5	0,378	0,254	0,229	0,139	1,328
10	0,312	0,256	0,243	0,189	1,371

El orden $\text{lobo} > \text{gato} > \text{coche}$ está siempre; la temperatura solo lo hace **utilizable** como señal de gradiente.

6. Arquitectura o flujo



7. Qué observar en el paper original

- El **ejemplo del 2 y el 7**: por qué la probabilidad que el maestro asigna a la clase equivocada contiene información sobre la geometría del problema.
- La **derivación del factor T^2** y la relación con entrenar contra logits directamente.

- El experimento donde el alumno aprende clases que **casi no vio** en su conjunto de transferencia: es el resultado más sorprendente del artículo.
- Los **modelos especialistas** para conjuntos con muchísimas clases, una parte del paper que casi nadie cita.

8. Evidencia y resultados

Experimentos en reconocimiento de dígitos, reconocimiento de voz a gran escala y un conjunto interno con miles de clases, comparando el alumno destilado contra el mismo alumno entrenado solo con etiquetas.

Las cifras están en el artículo. Verificarlas allí. Lo que hay que retener es el patrón: el alumno destilado se acerca al maestro mucho más que el alumno entrenado con etiquetas duras.

La miniatura de este eje no entrena nada: exhibe la información que contiene la distribución del maestro y cómo la temperatura la revela.

9. Impacto

- Es el fundamento de casi todos los modelos pequeños de uso práctico: DistilBERT, TinyBERT y la familia entera de modelos «mini» derivados de otros grandes.
- Se convirtió en pieza estándar del pipeline de despliegue, junto a la cuantización y la poda.
- En la era de los LLM, entrenar con salidas de un modelo mayor es una práctica generalizada — y una fuente de disputas sobre licencias y términos de servicio.
- Sostiene también el argumento de que **la capacidad no siempre necesita el tamaño** que se usó para descubrirla.

10. Limitaciones

1. **El alumno hereda los errores del maestro**, y también sus sesgos: la destilación transfiere comportamiento, no corrección.
2. **Sigue haciendo falta el maestro**: hay que entrenarlo y ejecutarlo sobre todo el conjunto de transferencia.
3. **Techo de capacidad**: si el alumno es demasiado pequeño, no hay temperatura que lo salve.
4. **T y α son hiperparámetros más** que ajustar.
5. **Explicación incompleta**: por qué funciona tan bien sigue siendo objeto de estudio; hay trabajo que lo atribuye tanto a la regularización como a la transferencia de similitud.
6. **Cuestiones de licencia**: destilar de un modelo ajeno puede violar sus términos de uso.

11. Errores comunes

Error	Corrección
«El alumno copia al maestro»	Aprende su distribución , que es una señal mucho más rica y suave que copiar predicciones.
«La temperatura crea información»	La información ya está en los logits. La temperatura solo la hace visible al gradiente.
Olvidar el factor T^2	Los gradientes del término suave escalan como $1/T^2$. Sin compensar, cambiar T cambia el equilibrio entre los dos términos.
«Un alumno destilado es tan bueno como el maestro»	Se acerca mucho más que sin destilar, pero hay un techo impuesto por su capacidad.
«Sirve para corregir al maestro»	Al contrario: le transfiere también sus errores y sesgos.

12. Relación con trabajos anteriores

- **Buciluă, Caruana y Niculescu-Mizil (2006)** — comprimir un ensamblado en un modelo único; el antecedente directo.
- **P04 AlexNet (2012)** — los modelos grandes cuyo despliegue motiva el problema.
- **Ensamblados** — la técnica cara que se busca comprimir.

13. Relación con trabajos posteriores

- **DistilBERT (2019)** — la aplicación más citada, sobre BERT.
- **P48 LoRA (2021)** y **P49 QLoRA (2023)** — la otra vía para reducir coste: no achicar el modelo, sino su ajuste y sus bits.
- **Destilación desde LLM (2023+)** — entrenar modelos pequeños con salidas de modelos grandes, con el debate de licencias que arrastra.

14. Notebook asociado

P45_distillation.ipynb

Qué implementa: la distribución del maestro a cuatro temperaturas, su entropía, y la comparación explícita contra la etiqueta dura.

Qué NO implementa: no hay maestro ni alumno entrenados, ni conjunto de transferencia, ni el factor T^2 en una pérdida real. Se exhibe la información, no se destila.

```
ai-evolution paper-lab P45 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe el softmax con temperatura y di qué hace $T > 1$.
Explicar	Explica qué es el conocimiento oscuro con el ejemplo perro/lobo/coche.
Aplicar	Ejecuta el notebook y añade $T = 20$. ¿Qué pasa con la entropía?
Analizar	¿Por qué la etiqueta dura y la distribución del maestro no son intercambiables?
Evaluar	Un maestro tiene un sesgo conocido. ¿Qué implica destilarlo?
Crear	Diseña un protocolo para destilar sin heredar un sesgo identificado.

16. Autoevaluación

1. ¿Qué información tira la etiqueta dura?
2. ¿Qué hace la temperatura y por qué hace falta?
3. ¿Por qué el término suave se multiplica por T^2 ?
4. ¿El alumno puede superar al maestro?
5. ¿Qué hereda el alumno además de la capacidad?
6. ¿Qué relación tiene esto con los modelos «mini» actuales?
7. ¿Qué problema legal puede plantear destilar?

17. Respuestas esperadas

1. La estructura de similitud entre clases: que un perro se parece a un lobo y nada a un coche. La etiqueta asigna o a todo lo que no es la clase correcta, sin distinguir entre esos ceros.
2. Aplana la distribución y aumenta su entropía, de modo que las probabilidades pequeñas —las que contienen la estructura de similitud— tengan magnitud suficiente para producir gradiente útil.
3. Porque los gradientes de ese término escalan como $1/T^2$. Sin el factor, subir la temperatura reduciría de facto el peso del término suave frente al de la etiqueta dura.
4. En general no lo supera; se acerca mucho más de lo que lograría entrenando solo con etiquetas. Su capacidad impone un techo.
5. Los errores y los sesgos del maestro. La destilación transfiere comportamiento, no corrección.
6. Es su mecanismo: DistilBERT y toda la familia de modelos pequeños de uso práctico se obtienen destilando un modelo mayor.
7. Que los términos de uso del modelo maestro pueden prohibir usar sus salidas para entrenar otro modelo. Es objeto de disputa activa.

18. Fuentes primarias

- Hinton, G., Vinyals, O. y Dean, J. (2015). *Distilling the Knowledge in a Neural Network*. arXiv:1503.02531 · consultado 2026-08-16.
- Buciluă, C., Caruana, R. y Niculescu-Mizil, A. (2006). *Model Compression*. **KDD 2006**. dl.acm.org/doi/10.1145/1150402.1150464 · consultado 2026-08-16.



Evaluación — P45 · Destilar el conocimiento de una red neuronal

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Distilling the Knowledge in a Neural Network* (2015, arXiv:1503.02531) · **Nivel:** L2

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P45_distillation.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).