

P47

Predicción de estructura de proteínas de alta precisión con AlphaFold

Highly accurate protein structure prediction with AlphaFold

John Jumper, Richard Evans, Alexander Pritzel, y otros (DeepMind) · 2021 · Nature 596, 583–589 (2021)

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-16.

P47 — AlphaFold 2

Arquitectura y entrenamiento · El caso donde el aprendizaje profundo resolvió, en la práctica, un problema abierto de la biología durante cincuenta años.

Nivel: L4 · Motor: `alphafold` · Notebook: `P47_alphafold.ipynb` · Anexo: álgebra y geometría

1. Identificación

Campo	Valor
Título original	<i>Highly accurate protein structure prediction with AlphaFold</i>
Autoría	John Jumper, Richard Evans, Alexander Pritzel y otros (DeepMind)
Año	2021
Venue	<i>Nature</i> 596, 583–589
Fuente primaria	doi.org/10.1038/s41586-021-03819-2
Acceso	Abierto
Fecha de consulta	2026-08-16

2. Problema anterior

Una proteína es una cadena de aminoácidos que se pliega en una forma tridimensional concreta, y esa forma determina lo que hace. Determinarla experimentalmente —cristalografía, resonancia, criomicroscopía— cuesta meses o años y mucho dinero por estructura.

Predecirla desde la secuencia era un problema abierto desde los años setenta. La evaluación comunitaria **CASP**, celebrada cada dos años desde 1994, mostraba progreso lento: en 2018 el mejor resultado seguía lejos de la precisión experimental.

3. Propuesta

Un sistema entrenado de extremo a extremo con tres piezas que se refuerzan:

- Alineamientos múltiples de secuencias (MSA):** proteínas homólogas de otras especies. Si dos posiciones mutan juntas a lo largo de la evolución, probablemente estén en contacto. Es información evolutiva, no solo química.
- Evoformer:** atención que opera a la vez sobre el MSA y sobre una representación de **pares** de residuos, dejando que ambas se actualicen mutuamente.
- Módulo de estructura:** produce coordenadas 3D directamente, con una arquitectura equivariante a rotaciones y traslaciones, y **recicla** su salida como entrada varias veces.

El puente conceptual: la geometría 3D queda determinada —salvo rotación y reflexión— por las distancias entre pares. Predecir qué residuos están cerca es, en la práctica, predecir la forma.

4. Intuición sin fórmulas

Reconstruir el plano de una ciudad conociendo solo las distancias entre cada par de esquinas. Con suficientes distancias, la disposición queda fijada; solo puedes girar o reflejar el mapa entero.

Dónde deja de funcionar la analogía: las distancias de la ciudad te las dan. Aquí hay que **predecirlas** desde la secuencia, y ese es el problema entero.

5. Matemática mínima

De distancias a coordenadas:

dado d_{ij} para todo par (i,j) , encontrar $x_i \in \mathbb{R}^3$ tal que

$\|x_i - x_j\| \approx d_{ij}$

minimizando $\sum_{\{i<j\}} (\|x_i - x_j\| - d_{ij})^2$


La solución es única salvo rotación, traslación y reflexión.

La miniatura del eje hace exactamente esto: parte de ocho puntos en posiciones **aleatorias** y, usando solo la matriz de distancias, converge por descenso de gradiente a la estructura correcta — el error cuadrático cae de 20,04 a 0,0 en menos de 150 pasos.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A01 §2 · Norma y coseno	distancias y normas: la geometría queda fijada por las distancias entre pares
A01 §5 · Proyección y subespacios	por qué la solución es única solo salvo rotación, traslación y reflexión

6. Arquitectura o flujo



7. Qué observar en el paper original

- El **resultado de CASP14**: mediana de GDT en torno a 92 sobre 100, con la precisión experimental como referencia. Es el dato que cambió el campo.
- El papel del **MSA**: cómo la señal coevolutiva sustituye a información física que no se modela.
- El **reciclado**: pasar la predicción de vuelta por la red varias veces, un truco simple con mucho efecto.
- La métrica **pLDDT** de confianza por residuo. Que el modelo diga *dónde* no está seguro es posiblemente tan importante como la predicción misma.

8. Evidencia y resultados

Evaluación en CASP14, la competición comunitaria a ciegas donde las estructuras reales no son públicas cuando se predice. AlphaFold 2 alcanzó una exactitud comparable a la determinación experimental en la mayoría de los objetivos.

Las cifras exactas de GDT por categoría están en el artículo de *Nature* y en los materiales de CASP14. Verificarlas allí. El diseño a ciegas de CASP es lo que hace creíble el resultado, y merece más atención que el número.

La miniatura de este eje **no predice** nada: recibe la matriz de distancias y reconstruye la geometría. Aísla la mitad geométrica del problema, no la difícil.

9. Impacto

- La base de datos derivada publicó predicciones para más de 200 millones de proteínas, de acceso abierto, transformando la práctica en biología estructural.
- Demis Hassabis y John Jumper compartieron el **Premio Nobel de Química de 2024** por este trabajo.
- Es el argumento más sólido a favor de que estos métodos producen conocimiento científico y no solo productos.
- Cambió las expectativas sobre qué problemas científicos son abordables así, con el riesgo de extrapolar de más.

10. Limitaciones

1. **Predice estructuras estáticas**: una proteína real se mueve, y su función suele depender de ese movimiento.
2. **Depende del MSA**: con proteínas huérfanas, sin homólogos conocidos, la calidad cae.
3. **No modela bien complejos ni ligandos** en la versión de 2021; eso llega con AlphaFold-Multimer y AlphaFold 3.
4. **Predecir la estructura no es entender el plegamiento**: el proceso físico por el que la proteína llega a esa forma sigue sin explicarse.
5. **No predice el efecto de mutaciones** de forma fiable, que es lo que muchas aplicaciones clínicas necesitan.
6. **Coste computacional alto** para el entrenamiento, y dependencia de bases de datos curadas durante décadas por la comunidad.

11. Errores comunes

Error	Corrección
«Resolvió el problema del plegamiento»	Resolvió la predicción de estructura . El plegamiento —cómo llega físicamente a esa forma— sigue abierto.
«Simula la física de la proteína»	No hay simulación física. Aprende de estructuras conocidas y de señal evolutiva.
«Sustituye al trabajo experimental»	Es una hipótesis de altísima calidad. La validación experimental sigue siendo necesaria, y el pLDDT indica dónde más.
«Funciona igual con cualquier proteína»	Depende críticamente de tener homólogos. Sin MSA útil, la calidad cae.
«Una proteína tiene una estructura»	Muchas tienen regiones desordenadas o varias conformaciones funcionales. Una predicción estática no captura eso.

12. Relación con trabajos anteriores

- **Po8 Transformer (2017)** — la atención, adaptada a operar sobre MSA y sobre pares.
- **P44 ResNet (2015)** — la profundidad con atajos que el sistema usa.
- **AlphaFold 1 (2020)** — la versión anterior, basada en predecir distancias y optimizar aparte.
doi.org/10.1038/s41586-019-1923-7
- **Anfinsen (1972)** — la hipótesis de que la secuencia determina la estructura, que es la premisa de todo el problema.

13. Relación con trabajos posteriores

- **AlphaFold-Multimer (2021)** y **AlphaFold 3 (2024)** — complejos, ácidos nucleicos y ligandos.
- **ESMFold (2022)** — predicción sin MSA usando un modelo de lenguaje de proteínas.
- **Modelos de fundación para la ciencia (2023+)** — la línea que este trabajo legitima.
- **P16 Sistemas agénticos** — la aplicación de estos métodos al ciclo de descubrimiento completo, todavía muy abierta.

14. Notebook asociado

P47_alphafold.ipynb

Qué implementa: la reconstrucción de coordenadas 3D a partir de una matriz de distancias por descenso de gradiente, con ocho puntos, partiendo de posiciones aleatorias.

Qué NO implementa: absolutamente nada del sistema real. No hay MSA, ni Evoformer, ni módulo de estructura, ni proteína. La matriz de distancias **se da**, y predecirla desde la secuencia es el problema entero. Es la parte geométrica, que es la fácil.

```
ai-evolution paper-lab P47 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Enumera las tres piezas del sistema y qué aporta cada una.
Explicar	Explica por qué la coevolución de dos posiciones sugiere contacto físico.
Aplicar	Ejecuta el notebook con 16 puntos y observa la convergencia.
Analizar	¿Por qué la solución es única solo salvo rotación y reflexión?
Evaluar	«AlphaFold resolvió el plegamiento de proteínas». Evalúa la afirmación.
Crear	Diseña un criterio para decidir cuándo una predicción necesita validación experimental.

16. Autoevaluación

1. ¿Qué predice exactamente el sistema y qué no?
2. ¿Qué información aporta el MSA que no está en la secuencia?
3. ¿Por qué las distancias entre pares determinan la geometría?
4. ¿Qué es el pLDDT y por qué importa tanto?
5. ¿Por qué CASP hace creíble el resultado?
6. ¿Qué pasa con una proteína sin homólogos conocidos?
7. ¿Qué diferencia hay entre predecir la estructura y entender el plegamiento?

17. Respuestas esperadas

1. Predice la **estructura tridimensional** de la proteína a partir de su secuencia. No predice el proceso físico de plegamiento, ni su dinámica, ni de forma fiable el efecto de mutaciones.
2. Señal **coevolutiva**: si dos posiciones mutan de forma correlacionada a lo largo de la evolución, es probable que estén en contacto en la estructura. Eso no se ve en una sola secuencia.
3. Porque fijar todas las distancias entre pares fija la configuración salvo movimientos rígidos: rotación, traslación y reflexión.
4. Es una estimación de confianza **por residuo**. Importa porque indica en qué partes de la predicción se puede confiar y cuáles requieren validación experimental.
5. Porque es una evaluación a ciegas: las estructuras reales no son públicas en el momento de predecir, así que no puede haber contaminación ni ajuste al conjunto de prueba.
6. La calidad de la predicción cae, porque falta la señal evolutiva de la que el sistema depende.
7. Predecir la estructura es dar el resultado final. Entender el plegamiento sería explicar el proceso físico por el que la cadena llega a esa forma, que sigue sin resolverse.

18. Fuentes primarias

- Jumper, J. et al. (2021). *Highly accurate protein structure prediction with AlphaFold*. **Nature** 596, 583–589. doi.org/10.1038/s41586-021-03819-2 · consultado 2026-08-16.
- Senior, A. W. et al. (2020). *Improved protein structure prediction using potentials from deep learning* (AlphaFold 1). **Nature** 577, 706–710. doi.org/10.1038/s41586-019-1923-7 · consultado 2026-08-16.



Evaluación — P47 · Predicción de estructura de proteínas de alta precisión con AlphaFold

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Highly accurate protein structure prediction with AlphaFold* (2021, Nature 596, 583–589 (2021)) ·

Nivel: L4

Parte A — Contexto histórico (20 pts)

- (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
- (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

- (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
- (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

- (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

- (10) Ejecuta `P47_alphafold.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
- (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
- (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

- (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
- (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).