

P50

IA constitucional: inocuidad a partir de retroalimentación de IA

Constitutional AI: Harmlessness from AI Feedback

Yuntao Bai, Saurav Kadavath, Sandipan Kundu, y otros (Anthropic) · 2022 · [arXiv:2212.08073](https://arxiv.org/abs/2212.08073)

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-16.

P50 — IA constitucional

Evaluación y seguridad · Sustituir parte del juicio humano por un conjunto de principios **escritos**, y dejar que el modelo se critique a sí mismo contra ellos.

Nivel: L4 · **Motor:** constitutional_ai · **Notebook:** P50_constitutional_ai.ipynb · **Anexo:** probabilidad y verosimilitud

1. Identificación

Campo	Valor
Título original	Constitutional AI: Harmlessness from AI Feedback
Autoría	Yuntao Bai, Saurav Kadavath, Sandipan Kundu y otros (Anthropic)
Año	2022
Venue	arXiv:2212.08073
Fuente primaria	arXiv:2212.08073
Acceso	Abierto
Fecha de consulta	2026-08-16

2. Problema anterior

RLHF funcionaba, y traía tres problemas de fondo.

El primero es de **escala**: hacen falta muchísimas comparaciones humanas, y son caras y lentas. El segundo es **humano**: revisar contenido dañino durante meses tiene un coste real sobre las personas que lo hacen. El tercero es de **auditoría**: lo que el modelo aprende son las preferencias implícitas de un grupo de anotadores, con sus criterios y sus sesgos, y no hay documento contra el cual verificar si el comportamiento resultante es el pretendido.

Además, los modelos alineados así tendían a la **evasión**: negarse sin explicar, que es seguro y poco útil.

3. Propuesta

Escribir los principios y ponerlos en el bucle. Dos fases:

- Supervisada**: el modelo genera una respuesta, se le pide que la **critique** contra un principio concreto de la lista y que la **revise**. Se entrena con las respuestas revisadas.
- Refuerzo (RLAIF)**: en vez de comparaciones humanas, el propio modelo compara pares de respuestas guiándose por los principios, y con esas preferencias se entrena el modelo de recompensa.

El cambio importante no es que se ahorren etiquetas. Es que **el criterio pasa a ser un documento legible**: se puede leer, discutir, versionar y criticar. Deja de estar disperso en el juicio implícito de anotadores.

4. Intuición sin fórmulas

Un código deontológico escrito frente a «pregúntale al jefe». El código no garantiza buenas decisiones, pero sí que se pueda discutir la regla, y no solo el caso.

Dónde deja de funcionar la analogía: un profesional entiende el código; el modelo solo lo recibe como texto en su contexto. Que lo cite no prueba que sea la causa de su comportamiento.

5. Matemática mínima

Fase 1 – supervisada:

```
respuesta ← modelo(petición)
crítica   ← modelo(respuesta, principio_i)    ¿lo viola?
revisión  ← modelo(respuesta, crítica)
entrenar el modelo sobre (petición → revisión)
```

Fase 2 – RLAIIF:

```
preferencia ← modelo(respuesta_A, respuesta_B, principios)
modelo de recompensa ← preferencias generadas por IA
política ← RL contra ese modelo de recompensa
```


Etiquetas humanas de inocuidad usadas: 0

La miniatura del eje ejecuta la fase 1 con reglas explícitas: la respuesta inicial «*No pienso ayudarte con eso, deberías replantearte por qué lo preguntas*» cumple el principio de seguridad y **viola los otros dos** —juzga al usuario y se niega sin explicar—. La revisión corrige ambos sin una sola etiqueta humana nueva.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A02 §5 · Bradley-Terry: aprender de comparaciones	Bradley-Terry, ahora con preferencias generadas por IA en vez de humanas

6. Arquitectura o flujo



7. Qué observar en el paper original

- **La constitución misma**, en el apéndice. Leerla completa es el ejercicio más instructivo del artículo: se ve qué es un principio operativo y qué es una declaración de intenciones.
- La **cadena crítica-revisión**, con ejemplos reales de respuestas antes y después.
- El resultado sobre **evasión**: modelos menos evasivos y a la vez menos dañinos, que es lo interesante — se suele asumir que ese intercambio es forzoso.
- Que la **utilidad** sigue entrenándose con retroalimentación humana. Solo la inocuidad pasa a retroalimentación de IA.

8. Evidencia y resultados

Comparaciones entre modelos entrenados con RLHF y con IA constitucional, evaluando inocuidad, utilidad y evasión mediante comparaciones por preferencia.

Las curvas están en el artículo. Verificarlas allí. El resultado que importa es la relación conjunta entre inocuidad y evasión, no cada métrica por separado.

La miniatura de este eje **no es el método**: la crítica está codificada con reglas fijas, mientras que en el paper la genera el propio modelo y puede fallar. Es la forma del bucle, no su contenido.

9. Impacto

- Estableció la retroalimentación de IA como alternativa práctica a la humana en parte del proceso de alineamiento.
- Popularizó publicar el criterio: hoy varias organizaciones publican documentos de especificación de comportamiento, versionados y criticables.
- Redujo la exposición de anotadores humanos a contenido dañino.
- Y trasladó el debate de «qué hace el modelo» a «quién escribe los principios y con qué autoridad» — que es la pregunta correcta, aunque el método no la responda.

10. Limitaciones

1. **No resuelve quién decide los principios.** Los hace explícitos, que es distinto y también valioso, pero la legitimidad sigue siendo una cuestión política abierta.
2. **La autocrítica hereda las limitaciones del modelo:** si no reconoce un daño, no lo criticará.
3. **Riesgo de retroalimentación circular:** el modelo evalúa según criterios que él mismo interpreta, y los sesgos pueden reforzarse.
4. **Los principios se contradicen entre sí** en casos reales, y su resolución no está especificada.
5. **Cumplir la letra no es cumplir la intención:** un modelo puede satisfacer el texto y fallar en el fondo.
6. **La utilidad sigue necesitando humanos**, así que el ahorro es parcial.

11. Errores comunes

Error	Corrección
«Elimina a los humanos del alineamiento»	Solo de la retroalimentación de inocuidad. Los principios los escriben personas y la utilidad sigue usando retroalimentación humana.
«Los principios garantizan el comportamiento»	Son entrada de entrenamiento, no una restricción verificable. El modelo puede violarlos.
«Es una constitución en sentido jurídico»	Es un documento de criterios de entrenamiento, sin mecanismo de aplicación ni de apelación.
«Resuelve el problema de los valores»	Lo hace explícito y discutible , que es un avance real, pero no decide de quién son esos valores.
«Si el modelo cita el principio, lo está siguiendo»	Citar es comportamiento superficial. Que el principio sea la causa del comportamiento es una afirmación causal que hay que probar aparte.

12. Relación con trabajos anteriores

- **P12 InstructGPT / RLHF (2022)** — el método que extiende y cuyos costes ataca.
- **P10 GPT-3 (2020)** — la capacidad de seguir instrucciones en contexto que hace viable la autocrítica.
- **P28 Cadena de pensamiento (2022)** — el razonamiento explícito en el que se apoya la crítica.

13. Relación con trabajos posteriores

- **P15 DPO (2023)** — simplifica la otra mitad, la optimización de preferencias.
- **RLAIF (2023)** — el estudio comparativo directo entre retroalimentación humana y de IA.
arXiv:2309.00267
- **Especificaciones de comportamiento publicadas (2024+)** — la práctica de publicar el criterio.
- **P51 SWE-bench (2023)** — el enfoque opuesto para evaluar: un verificador objetivo en vez de un juicio.

14. Notebook asociado

P50_constitutional_ai.ipynb

Qué implementa: el bucle crítica-revisión sobre una respuesta evasiva, con tres principios y la traza de qué principio viola y por qué.

Qué NO implementa: la crítica está codificada con reglas, no generada por un modelo. Falta entera la segunda fase de refuerzo. Es la **forma** del método, no el método.

```
ai-evolution paper-lab P50 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Enumera las dos fases y qué produce cada una.
Explicar	Explica por qué hacer explícito el criterio es un avance aunque no decida los valores.
Aplicar	Ejecuta el notebook y añade un cuarto principio.
Analizar	¿Qué pasa si dos principios se contradicen en un caso concreto?
Evaluar	«El modelo cita el principio, luego lo sigue». Evalúa el razonamiento.
Crear	Escribe tres principios operativos para un asistente de tu dominio, con su criterio de violación.

16. Autoevaluación

1. ¿Qué tres problemas de RLHF ataca?
2. ¿Qué hace la fase supervisada y qué la de refuerzo?
3. ¿Qué significa que el criterio sea auditable?
4. ¿Qué es la evasión y por qué es un problema?
5. ¿Qué parte del alineamiento sigue necesitando humanos?
6. ¿Cuál es el riesgo de que el modelo se evalúe a sí mismo?
7. ¿Qué pregunta deja abierta el método?

17. Respuestas esperadas

1. El coste de las etiquetas humanas, el impacto sobre los anotadores expuestos a contenido dañino, y la imposibilidad de auditar un criterio que solo existe implícito en sus juicios.
2. La supervisada genera crítica y revisión contra los principios y entrena sobre las respuestas revisadas. La de refuerzo genera **preferencias** con el propio modelo y entrena un modelo de recompensa con ellas.
3. Que existe un documento legible que se puede leer, discutir, versionar y criticar, en vez de un criterio disperso en el juicio implícito de un grupo de anotadores.
4. Negarse sin explicar. Es un problema porque es seguro pero inútil, y porque un modelo puede parecer alineado simplemente por no ayudar nunca.
5. Escribir los principios, y la retroalimentación de **utilidad**, que en el paper sigue siendo humana. Solo la inocuidad pasa a retroalimentación de IA.
6. Retroalimentación circular: si el modelo no reconoce un daño, no lo critica, y sus sesgos pueden reforzarse en vez de corregirse.
7. Quién escribe los principios y con qué legitimidad. El método hace la pregunta visible y explícita, pero no la responde.

18. Fuentes primarias

- Bai, Y. et al. (2022). *Constitutional AI: Harmlessness from AI Feedback*. arXiv:2212.08073 · consultado 2026-08-16.
- Lee, H. et al. (2023). *RLAIF: Scaling Reinforcement Learning from Human Feedback with AI Feedback*. arXiv:2309.00267 · consultado 2026-08-16.



Evaluación — P50 · IA constitucional: inocuidad a partir de retroalimentación de IA

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Constitutional AI: Harmlessness from AI Feedback* (2022, arXiv:2212.08073) · **Nivel:** L4

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P50_constitutional_ai.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).