

P52

Hacia la monosemanticidad: descomponer modelos de lenguaje con aprendizaje de diccionario

Towards Monosemanticity: Decomposing Language Models With Dictionary Learning

Trenton Bricken, Adly Templeton, Joshua Batson, y otros (Anthropic) · 2023 · Transformer Circuits Thread

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-16.

P52 — Superposición y autoencoders dispersos

Evaluación y seguridad · Un modelo guarda más conceptos que neuronas tiene. Por eso una neurona no significa una cosa — y por eso interpretarlo es difícil.

Nivel: L4 · Motor: `superposition` · Notebook: `P52_superposition.ipynb` · Anexo: álgebra y geometría

1. Identificación

Campo	Valor
Título original	<i>Toy Models of Superposition</i> (2022) y <i>Towards Monosemanticity: Decomposing Language Models With Dictionary Learning</i> (2023)
Autoría	Nelson Elhage, Tristan Hume, Trenton Bricken y otros (Anthropic)
Año	2022–2023
Venue	<i>Transformer Circuits Thread</i>
Fuente primaria	transformer-circuits.pub/2022/toy_model · transformer-circuits.pub/2023/monosemantic-features
Acceso	Abierto
Fecha de consulta	2026-08-16

2. Problema anterior

Al mirar dentro de una red buscando qué representa cada neurona, aparecía un patrón desconcertante: la mayoría responde a **cosas sin relación aparente**. Una misma unidad se activa con texto en japonés, con citas bíblicas y con nombres de compuestos químicos.

Ese fenómeno —la **polisemanticidad**— bloqueaba la interpretabilidad. Si la unidad de análisis natural no corresponde a un concepto, no hay por dónde empezar.

La explicación cómoda era que las redes son un desorden. Resultó ser lo contrario.

3. Propuesta

La polisemanticidad no es desorden: es **compresión**, y es óptima.

En un espacio de `d` dimensiones solo caben `d` direcciones perfectamente ortogonales. Pero si se acepta un poco de solape, caben **muchísimas más** direcciones casi ortogonales. Si el modelo necesita representar más conceptos que dimensiones tiene —y los necesita, porque el mundo tiene más conceptos que neuronas una capa—, guardarlos en superposición es la estrategia correcta.

El precio es la **interferencia**: los conceptos se pisan un poco. Y funciona porque los conceptos son **dispersos**: en un texto dado, casi ninguno está activo, así que la interferencia rara vez se manifiesta a la vez.

De ahí la propuesta práctica: entrenar un **autoencoder disperso** con muchas más unidades que la capa original, que descomponga las activaciones en características más interpretables.

4. Intuición sin fórmulas

Un armario donde caben diez cajas si no se tocan, y cuarenta si se aceptan solapes — sabiendo que casi nunca abres más de dos a la vez.

Dónde deja de funcionar la analogía: las cajas del armario existen físicamente separadas. Aquí los conceptos son **direcciones** en un espacio continuo, y su solape se suma en cada activación.

5. Matemática mínima

En $\mathbb{R}^d$ hay exactamente d direcciones ortogonales.
Pero hay exponencialmente muchas casi ortogonales (Johnson-Lindenstrauss).

Con vectores aleatorios normalizados en dimensión 8:


conceptos	ratio conceptos/dim	solape medio	solape máximo
8	1,0×	0,253	0,734
24	3,0×	0,310	0,900
80	10,0×	0,290	0,925

El solape **medio** apenas cambia —depende de la dimensión, no del número de conceptos—. Lo que crece es el **peor caso**: con 80 conceptos hay algún par que se solapa 0,925, casi paralelo. Esa es la interferencia que el modelo tiene que tolerar, y por eso la dispersión es la condición que hace viable el truco.

[!TIP] **Puente matemático**. Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A01 §1 · Producto escalar	el producto escalar entre direcciones es la interferencia
A01 §2 · Norma y coseno	coseno y casi-ortogonalidad: cuántas direcciones caben de verdad en d dimensiones

6. Arquitectura o flujo



7. Qué observar en el paper original

- Los **modelos de juguete** de 2022: el fenómeno se reproduce en una red minúscula y controlada, con la dispersión como parámetro. Es la evidencia más limpia.
- Las **estructuras geométricas** que emergen —dígonos, triángulos, pentágonos, tetraedros— según el nivel de dispersión. Es un resultado inesperado y bonito.
- En el trabajo de 2023, las **características encontradas** y sus ejemplos activadores. Vale la pena juzgar por uno mismo cuán interpretables son.
- Los **experimentos de ablación**: activar o suprimir una característica y ver qué cambia en la salida. Es lo único que respalda una afirmación causal.

8. Evidencia y resultados

Los modelos de juguete muestran superposición de forma controlada, con la dispersión como variable. El trabajo de 2023 aplica autoencoders dispersos a una capa de un modelo de lenguaje pequeño y obtiene miles de características con ejemplos activadores coherentes.

Los resultados están en los artículos originales, con visualizaciones interactivas que no se pueden resumir en una tabla. Consultarlos allí. Esta es también la parte del eje donde el trabajo está más **en curso**: es investigación abierta, no un método asentado.

La miniatura de este eje usa **direcciones aleatorias**, no características aprendidas. Muestra que el fenómeno es posible geoméricamente, no que sea lo que un modelo real hace.

9. Impacto

- Dio a la interpretabilidad mecanicista una unidad de análisis utilizable: la característica en lugar de la neurona.
- Convirtió el problema de «las redes son cajas negras» en algo más preciso y por tanto atacable: la base natural no es la correcta, hay que encontrar otra.
- Abrió una línea de trabajo activa sobre control de modelos mediante intervención en características.
- Y dio una explicación de por qué la interpretabilidad era tan difícil, que es en sí un avance.

10. Limitaciones

1. **Interpretable no es causal:** que una característica se active con textos legales no prueba que el modelo la **use** para nada. Hace falta intervenir y medir.
2. **Elegir el tamaño del diccionario es un arte:** demasiado pequeño y no separa, demasiado grande y las características se fragmentan.
3. **Se aplica a una capa a la vez:** componer una explicación del modelo completo sigue abierto.
4. **La reconstrucción no es perfecta,** y lo que se pierde puede importar.
5. **Coste alto:** entrenar autoencoders sobre modelos grandes es caro.
6. **El fenómeno está bien demostrado en modelos de juguete;** su forma exacta en modelos de frontera es objeto de investigación activa.

11. Errores comunes

Error	Corrección
«Cada neurona representa un concepto»	La mayoría son polisemánticas. Ese es el punto de partida del trabajo.
«La superposición es un defecto»	Es una estrategia de compresión eficiente. El modelo hace bien en usarla.
«El autoencoder revela lo que el modelo piensa»	Da una descomposición que reconstruye las activaciones. Que corresponda a lo que el modelo usa causalmente hay que demostrarlo aparte.
«Más características, mejor interpretación»	Diccionarios muy grandes fragmentan conceptos en trozos sin sentido. Hay un compromiso.
«Esto ya resolvió la interpretabilidad»	Es investigación en curso, con limitaciones reconocidas por sus autores.

12. Relación con trabajos anteriores

- **P08 Transformer (2017)** — la arquitectura que se intenta interpretar.
- **P05 Word2Vec (2013)** — la idea de concepto-como-dirección, aquí llevada al interior del modelo.
- **Johnson-Lindenstrauss (1984)** — el resultado geométrico que hace posible la superposición.
- **P42 Ejemplos adversarios (2014)** — la otra cara de la dimensión alta: la interferencia también se puede explotar.

13. Relación con trabajos posteriores

- **Scaling Monosemanticity (2024)** — la aplicación a un modelo de producción, con millones de características. transformer-circuits.pub/2024/scaling-monosemanticity
- **Control mediante características (2024+)** — intervenir en el modelo actuando sobre ellas.
- **Interpretabilidad como herramienta de seguridad** — la promesa: auditar lo que el modelo hace antes de desplegarlo, todavía lejos de cumplirse.

14. Notebook asociado

P52_superposition.ipynb

Qué implementa: el almacenamiento de 8, 24 y 80 direcciones aleatorias en 8 dimensiones, con el solape medio y máximo entre pares.

Qué NO implementa: no hay autoencoder disperso, ni modelo, ni características aprendidas. Las direcciones aleatorias muestran que el fenómeno es geoméricamente posible; en un modelo real la estructura no es aleatoria y esa diferencia importa.

```
ai-evolution paper-lab P52 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Define polisemanticidad y superposición con tus palabras.
Explicar	Explica por qué la dispersión es la condición que hace viable la superposición.
Aplicar	Ejecuta el notebook con dimensión 16 y compara los solapes.
Analizar	¿Por qué el solape medio no crece con el número de conceptos y el máximo sí?
Evaluar	«Encontramos la característica del engaño». ¿Qué evidencia exiges?
Crear	Diseña un experimento de ablación que distinga correlación de uso causal.

16. Autoevaluación

1. ¿Qué es la polisemanticidad y por qué bloquea la interpretabilidad?
2. ¿Cuántas direcciones ortogonales caben en `d` dimensiones, y cuántas casi ortogonales?
3. ¿Por qué la superposición es óptima y no un defecto?
4. ¿Qué papel juega la dispersión?
5. ¿Qué hace un autoencoder disperso?
6. ¿Por qué interpretable no implica causal?
7. ¿Qué distancia hay entre estos resultados y un modelo de frontera?

17. Respuestas esperadas

1. Que una misma neurona responde a conceptos sin relación entre sí. Bloquea la interpretabilidad porque la unidad de análisis natural —la neurona— no corresponde a nada interpretable.
2. Exactamente `d` ortogonales. Casi ortogonales, un número exponencial en `d`, que es lo que garantiza el resultado de Johnson-Lindenstrauss.
3. Porque el modelo necesita representar más conceptos de los que caben en direcciones ortogonales, y aceptar un poco de solape le permite guardar muchísimos más con una pérdida pequeña.
4. Es la condición que hace tolerable la interferencia: como casi ningún concepto está activo a la vez, los solapes rara vez se manifiestan simultáneamente.
5. Descompone las activaciones de una capa en muchas más unidades que la capa original, con una penalización que fuerza que casi todas estén en cero, buscando características que representen una sola cosa.

6. Porque el autoencoder solo garantiza que la descomposición **reconstruye** las activaciones. Que el modelo use esa característica para producir su salida es una afirmación causal que exige intervenir — activarla o suprimirla— y medir el efecto.
7. Los modelos de juguete demuestran el fenómeno de forma limpia y controlada; en modelos de frontera el trabajo está en curso, es caro, y sus propios autores reconocen las limitaciones.

18. Fuentes primarias

- Elhage, N. et al. (2022). *Toy Models of Superposition*. **Transformer Circuits Thread**. transformer-circuits.pub/2022/toy_model · consultado 2026-08-16.
- Bricken, T. et al. (2023). *Towards Monosemanticity: Decomposing Language Models With Dictionary Learning*. **Transformer Circuits Thread**. transformer-circuits.pub/2023/monosemantic-features · consultado 2026-08-16.



Evaluación — P52 · Hacia la monosemanticidad: descomponer modelos de lenguaje con aprendizaje de diccionario

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Towards Monosemanticity: Decomposing Language Models With Dictionary Learning* (2023, Transformer Circuits Thread) · **Nivel:** L5

Parte A — Contexto histórico (20 pts)

- (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
- (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

- (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
- (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

- (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

- (10) Ejecuta `P52_superposition.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
- (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
- (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

- (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
- (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).