

P60

Por qué la mayoría de los hallazgos publicados son falsos

Why Most Published Research Findings Are False

John P. A. Ioannidis · 2005 · PLoS Medicine, 2(8), e124

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-17.

P60 — Valor predictivo

Ruta de fundamentos · Le pone fórmula a la pregunta que el valor p no responde: dado que esto se publicó, ¿qué probabilidad hay de que sea cierto?

Nivel: L3 · **Motor:** valor_predictivo · **Notebook:** P60_valor_predictivo.ipynb · **Anexo:** probabilidad y verosimilitud

1. Identificación

Campo	Valor
Título original	Why Most Published Research Findings Are False
Autoría	John P. A. Ioannidis
Año	2005
Venue	PLoS Medicine, 2(8), e124
Fuente primaria	doi:10.1371/journal.pmed.0020124
Acceso	Abierto
Fecha de consulta	2026-08-17

2. Problema anterior

La significancia estadística se leía —y se sigue leyendo— como sinónimo de verdad. « $p < 0,05$ » se interpretaba como «hay un 95 % de probabilidad de que esto sea cierto», que es una lectura sencillamente incorrecta.

El valor p responde: *si la hipótesis nula fuese cierta, ¿qué probabilidad habría de observar un dato tan extremo?* La pregunta que interesa es la inversa: *dado este dato, y dado que el estudio se publicó, ¿qué probabilidad hay de que la hipótesis sea cierta?* Nadie estaba poniendo número a esa segunda pregunta, y depende de cosas que no aparecen en el artículo publicado.

3. Propuesta

Modelar explícitamente el **valor predictivo positivo** de un hallazgo: la probabilidad de que sea cierto, dado que ha resultado significativo. El modelo depende de cuatro cosas, y solo una de ellas es el umbral de significancia:

- R : las **odds previas** de que la hipótesis probada sea cierta en ese campo;
- $1 - \beta$: el **poder** del estudio;
- α : el nivel de significancia;
- u : el **sesgo**, entendido como la parte de resultados no significativos que acaban presentándose como significativos por decisiones de análisis.

Y una extensión por **número de equipos**: cuanta más gente persiga el mismo hallazgo, más probable es que alguien lo encuentre por azar y lo publique primero.

4. Intuición sin fórmulas

Un detector de metales en una playa. Suena el 95 % de las veces que hay una moneda y se equivoca el 5 % de las veces que no la hay. Suena. ¿Hay una moneda?

Depende de cuántas monedas hay enterradas. Si la playa está llena, casi seguro. Si hay una en todo el arenal, la mayoría de los pitidos son falsas alarmas por más bueno que sea el detector.

Dónde deja de funcionar la analogía: la playa no cambia según cuánta gente busque. En la ciencia sí: si cien equipos rastrean el mismo arenal, el primero que publique será probablemente el que tuvo la falsa alarma más llamativa.

5. Matemática mínima

PPV = P(hipótesis cierta | resultado significativo)

Sin sesgo: $PPV = (1-\beta) \cdot R / (R - \beta \cdot R + \alpha)$

Con sesgo u: $PPV = [(1-\beta)R + u \cdot \beta \cdot R] / [R + \alpha - \beta \cdot R + u - u \cdot \alpha + u \cdot \beta \cdot R]$

Con n equipos: $PPV = (R - R \cdot \beta^n) / (R + 1 - (1-\alpha)^n - R \cdot \beta^n)$

La miniatura evalúa cinco escenarios con **el mismo $\alpha = 0,05$** en todos:


Escenario	R	poder	sesgo	equipos	PPV
ensayo confirmatorio	1,0	0,80	0	1	0,9412
exploratorio típico	0,1	0,50	0	1	0,5
exploratorio con sesgo	0,1	0,50	0,3	1	0,1625
cinco equipos en carrera	0,1	0,50	0	5	0,2998
barrido masivo	0,001	0,60	0,1	1	0,0044

El umbral de significancia no se mueve en ninguna fila. Lo que se mueve es todo lo demás.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A02 §3 · Verosimilitud y entropía cruzada	la diferencia entre P(dato

6. Arquitectura o flujo



7. Qué observar en el paper original

- Los **seis corolarios** del artículo. Son la parte práctica: cuanto más pequeños los estudios, más pequeños los efectos, más relaciones probadas, más flexibilidad de diseño, más intereses y más equipos, menos probable es que un hallazgo sea cierto.
- Que el modelo es **analítico**: no mide cuántos resultados son falsos, demuestra qué implican sus supuestos. Confundir esas dos cosas es el error de lectura más común.
- La definición operativa de **sesgo**: no es fraude, es la acumulación de decisiones de análisis que empujan en la dirección deseada.
- El tratamiento de la **competencia entre equipos**, que es la parte más aplicable a un campo con el ritmo de publicación de la IA.

8. Evidencia y resultados

El artículo no presenta datos empíricos. Es un modelo probabilístico con supuestos declarados y sus consecuencias.

El título es una afirmación fuerte y el artículo la sostiene **condicionalmente**: es cierta si los supuestos sobre R, poder y sesgo son los que él estima para los campos que discute.

La confirmación empírica llega después, con los proyectos de replicación: el más citado, el de la Open Science Collaboration (2015), reprodujo con éxito 36 de 100 estudios de psicología.

La miniatura de este eje calcula el modelo sobre escenarios explícitos, para que se vea qué palanca mueve qué.

9. Impacto

- Es uno de los artículos más citados de la historia de PLoS Medicine y una de las piezas fundacionales de la crisis de replicación.
- Cambió prácticas concretas: preinscripción de estudios, informes registrados, exigencia de declarar el poder y el tamaño del efecto.
- En IA, sus corolarios se traducen casi literalmente: muchos equipos persiguiendo el mismo benchmark, mucha flexibilidad de diseño —semillas, hiperparámetros, elección de comparación— y efectos pequeños. Es el diagnóstico que P63 intenta tratar.
- Da al programa su criterio de lectura: preguntar por las odds previas y por el poder antes de aceptar un resultado.

10. Limitaciones

1. **Los parámetros no se observan.** R, el poder real y el sesgo se estiman o se suponen; el modelo es un marco de razonamiento, no una calculadora.
2. **Es analítico, no empírico.** No mide la tasa de falsedad de ninguna literatura concreta.
3. **El título es más categórico que el resultado.** «La mayoría» depende enteramente de los valores que se den a los parámetros.
4. **Supone el marco frecuentista de contraste de hipótesis**, que no describe bien buena parte de la investigación en IA, donde el problema dominante es otro.
5. **Trasladarlo a la IA exige cuidado:** aquí el modo de fallo característico no es el valor p, sino la fuga de datos, la selección de semilla y la comparación con líneas base mal ajustadas.

11. Errores comunes

Error	Corrección
« $p < 0,05$ significa 95 % de probabilidad de que sea cierto»	α es P(dato extremo)
«El artículo demuestra que la ciencia está rota»	Demuestra qué implican ciertos supuestos sobre diseño e incentivos. Es un modelo, y su conclusión es condicional.
«Basta con bajar α a 0,005 para arreglarlo»	Ayuda, pero el poder y el sesgo pesan más. En la tabla del motor, subir el poder de 0,2 a 0,95 mueve el PPV de 0,29 a 0,66 con α fijo.
«El sesgo es fraude»	Es la acumulación de decisiones de análisis defendibles una a una que empujan en la misma dirección. No hace falta mala fe.
«Esto no aplica a la IA porque no usamos valores p »	Los corolarios sí aplican: muchos equipos, efectos pequeños, mucha flexibilidad de diseño. Cambia el mecanismo, no la conclusión.

12. Relación con trabajos anteriores

- **Neyman y Pearson (1933)** — el marco de contraste de hipótesis con α y β dentro del cual se formula todo el modelo.
- **Sterling (1959)** — la primera documentación del sesgo de publicación: casi todo lo publicado era significativo.
- **Cohen (1962)** — el análisis del poder estadístico y la constatación de que la mayoría de los estudios lo tenían bajo.

13. Relación con trabajos posteriores

- **Open Science Collaboration (2015)** — la replicación de 100 estudios de psicología: la confirmación empírica. doi:10.1126/science.aac4716
- **Wasserstein y Lazar (2016)** — la declaración de la ASA sobre los valores p . doi:10.1080/00031305.2016.1154108
- **P63 Reproducibilidad (2021)** — la respuesta operativa dentro del aprendizaje automático.
- **P62 Validez de benchmarks (2021)** — el otro filo del mismo problema: no si el número es real, sino si mide lo que dice.

14. Notebook asociado

P60_valor_predictivo.ipynb

Qué implementa: el cálculo del valor predictivo positivo sobre cinco escenarios con el mismo α , el efecto del sesgo y del número de equipos, y el barrido del poder estadístico con odds previas fijas.

Qué NO implementa: no hay datos reales ni estimación de los parámetros a partir de una literatura concreta. R, poder y sesgo se fijan a mano para ver qué palanca mueve qué.

```
ai-evolution paper-lab P60 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe la fórmula del PPV e identifica cada símbolo.
Explicar	Explica la diferencia entre α y P(hipótesis cierta)
Aplicar	Ejecuta el notebook y calcula el PPV de un escenario con odds previas 1:100.
Analizar	Analiza cuál de las cuatro palancas mueve más el PPV y por qué.
Evaluar	«Bajar el umbral a 0,005 resolvería el problema». Evalúa la afirmación con los datos del motor.
Crear	Aplica el modelo a un anuncio reciente de mejora en un benchmark: estima R, poder, sesgo y número de equipos, y documenta cada supuesto.

16. Autoevaluación

1. ¿Qué es el valor predictivo positivo?
2. ¿Por qué $p < 0,05$ no significa 95 % de probabilidad de ser cierto?
3. ¿Qué papel juegan las odds previas?
4. ¿Qué es el sesgo en este modelo y por qué no es fraude?
5. ¿Por qué empeora el PPV cuando compiten más equipos?
6. ¿Es este un artículo empírico?
7. ¿Cómo se traducen sus corolarios a la investigación en IA?

17. Respuestas esperadas

1. La probabilidad de que un hallazgo sea cierto **dado que** ha resultado significativo. Es la pregunta que le interesa a quien lee, y no es la que responde el valor p .
2. Porque α es la probabilidad de observar un dato extremo **si la hipótesis nula fuese cierta**. Invertir el condicional exige conocer cuántas de las hipótesis que se prueban son ciertas.
3. Son el factor dominante. Con odds previas 1:10, poder 0,5 y α 0,05, el PPV es 0,5: la mitad de los hallazgos significativos son falsos antes de contar sesgo alguno.
4. Es la parte de resultados no significativos que acaban presentándose como significativos por decisiones de análisis. Cada decisión puede ser defendible; el problema es que todas empujan en la misma dirección.
5. Porque con n equipos probando lo mismo, la probabilidad de que **alguno** tenga una falsa alarma crece como $1 - (1-\alpha)^n$, y el que publica primero suele ser ese. Con cinco equipos el PPV cae de 0,5 a 0,2998.
6. No. Es un modelo analítico con supuestos declarados. La confirmación empírica llegó después con los proyectos de replicación.
7. Casi literalmente: muchos equipos persiguiendo el mismo benchmark, efectos pequeños y mucha flexibilidad de diseño —semillas, hiperparámetros, elección de la línea base—. Cambia el mecanismo, no la conclusión.

18. Fuentes primarias

- Ioannidis, J. P. A. (2005). *Why Most Published Research Findings Are False*. **PLoS Medicine**, 2(8), e124. doi:10.1371/journal.pmed.0020124 · consultado 2026-08-17.

- Open Science Collaboration (2015). *Estimating the reproducibility of psychological science*. doi:10.1126/science.aac4716 · consultado 2026-08-17.
- Wasserstein, R. y Lazar, N. (2016). *The ASA Statement on p-Values*. doi:10.1080/00031305.2016.1154108 · consultado 2026-08-17.



Evaluación — P60 · Por qué la mayoría de los hallazgos publicados son falsos

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Why Most Published Research Findings Are False* (2005, PLoS Medicine, 2(8), e124) · **Nivel:** L3

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P60_valor_predictivo.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).