

P62

La IA y el benchmark del todo en el mundo entero

AI and the Everything in the Whole Wide World Benchmark

Inioluwa Deborah Raji, Emily M. Bender, Amandalynne Paullada, Emily Denton, Alex Hanna · 2021 · NeurIPS 2021
· Datasets and Benchmarks Track · [arXiv:2111.15366](https://arxiv.org/abs/2111.15366)

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-17.

P62 — Validez de benchmarks

Ruta de fundamentos · Trae al campo la validez de constructo: un número alto no prueba la capacidad que el benchmark dice medir, y a veces mide un atajo.

Nivel: L3 · **Motor:** benchmark_validez · **Notebook:** P62_benchmark_validez.ipynb · **Anexo:** probabilidad y verosimilitud

1. Identificación

Campo	Valor
Título original	AI and the Everything in the Whole Wide World Benchmark
Autoría	Inioluwa Deborah Raji, Emily M. Bender, Amandalynne Paullada, Emily Denton, Alex Hanna
Año	2021
Venue	NeurIPS 2021 · Datasets and Benchmarks Track · arXiv:2111.15366
Fuente primaria	arXiv:2111.15366
Acceso	Abierto
Fecha de consulta	2026-08-17

2. Problema anterior

Los benchmarks pasaron de ser herramientas de comparación acotada a presentarse como pruebas de capacidades generales: «comprensión de lenguaje natural», «razonamiento», «sentido común».

El salto es de escala pero también de tipo. Un conjunto de ítems mide lo que miden sus ítems. Si la etiqueta promete un constructo general y los ítems cubren una porción estrecha —y encima admiten estrategias que los superan sin la capacidad—, el ranking mide otra cosa distinta de la que nombra. El campo no tenía vocabulario para señalar ese problema.

3. Propuesta

Importar de la psicometría el concepto de **validez de constructo** y aplicarlo a los benchmarks como instrumentos de medida. Las preguntas que propone hacerle a cualquier benchmark:

- ¿Qué constructo dice medir, y está definido?
- ¿Qué cubren realmente sus ítems, y qué parte del constructo queda fuera?
- ¿Existe alguna estrategia que lo supere sin poseer la capacidad?
- ¿Quién decidió qué entra y qué no, y con qué criterio?

El título alude al libro infantil de Grover: un «museo de todo lo que hay en el mundo entero» que resulta contener una sola habitación. La tesis es que un benchmark general es una contradicción, no un objetivo

difícil.

4. Intuición sin fórmulas

Un examen de conducir que solo evalúa aparcar en línea. Quien lo aprueba sabe aparcar. Llamarlo «examen de conducción» es una promesa que los ejercicios no respaldan.

Peor todavía: si en ese examen el aparcamiento correcto siempre está en el mismo lado, se aprueba memorizando el lado. La nota sube y la capacidad no.

Dónde deja de funcionar la analogía: el examen de conducir tiene un dominio bien definido. Los constructos que nombran los benchmarks de IA —«comprensión», «razonamiento»— no lo tienen, y esa es justamente la mitad del problema.

5. Matemática mínima


No hay formalismo. Hay un procedimiento de auditoría, que la miniatura ejecuta sobre un benchmark ficticio de 12 ítems:

```
capacidad declarada      : «comprensión de lenguaje natural»
subhabilidades declaradas: 6
subhabilidades medidas  : 2          ← cobertura 2/6

estrategia sin capacidad : «responder siempre la opción más larga»
  aciertos: 11/12 = 91,7 %
azar (4 opciones)       : 3/12 = 25,0 %
```

Una regla que no lee el ítem saca 91,7 %. El número publicado por el benchmark no distingue esa estrategia de la capacidad que dice medir, y ninguna métrica de agregación va a arreglarlo: el problema está en los ítems, no en la media.

6. Arquitectura o flujo



7. Qué observar en el paper original

- La distinción entre **validez interna, externa y de constructo**, y por qué el campo solo vigilaba la primera.
- El argumento sobre los **benchmarks «generales»**: no es que sean difíciles de construir, es que la generalidad no se puede operacionalizar en un conjunto finito de ítems.
- El análisis de **quién decide** qué entra en un benchmark, que es una decisión de poder poco documentada.
- Los **ejemplos históricos** que analizan, incluidos benchmarks de visión y de lenguaje muy usados, y cómo sus etiquetas prometieron más de lo que medían.

8. Evidencia y resultados

Es un artículo de análisis conceptual con estudios de caso, no un experimento. Su aportación es un marco de evaluación, no una medición.

La evidencia empírica que respalda su tesis viene de otra literatura: el aprendizaje por atajos (Geirhos et al., 2020) y el sesgo de los conjuntos de datos (Torralla y Efros, 2011).

La miniatura de este eje construye un benchmark ficticio para que el modo de fallo se pueda ver y contar. No mide ningún benchmark real, y no debe leerse como si lo hiciera.

9. Impacto

- Introdujo en el vocabulario del campo la validez de constructo, que hoy aparece de forma rutinaria en las discusiones sobre evaluación.
- Contribuyó al cambio de diseño hacia benchmarks con **verificación externa**, donde el acierto no depende del formato del ítem: SWE-bench es el ejemplo canónico, porque los tests del repositorio son

difíciles de fingir.

- Dio argumentos a la crítica de los rankings agregados y de las tablas de líderes como forma principal de comunicar progreso.
- Aporta al programa el procedimiento de lectura crítica de la clase 010: mirar los ítems, buscar el atajo, comprobar la cobertura.

10. Limitaciones

1. **No propone un benchmark alternativo.** Es un diagnóstico; construir instrumentos válidos es más difícil que señalar su invalidez.
2. **La validez de constructo viene de la psicometría**, donde los constructos tienen décadas de teoría detrás. Trasplantarla a «razonamiento» no es inmediato.
3. **El criterio de «demasiado general» no está operacionalizado.** Queda como juicio.
4. **No cuantifica** cuántos benchmarks en uso sufren el problema ni en qué grado.
5. **Puede leerse como nihilismo evaluativo**, y no lo es: la conclusión es medir cosas más estrechas y nombrarlas con precisión, no dejar de medir.

11. Errores comunes

Error	Corrección
«El problema se arregla con más ítems»	Si los ítems admiten el mismo atajo, más ítems dan el mismo número con más decimales. El problema es de diseño, no de tamaño.
«Si dos modelos se evalúan igual, la comparación es justa»	Es justa entre ellos y sobre ese instrumento. No autoriza a hablar de la capacidad que el instrumento nombra.
«La validez es un problema de la métrica»	La métrica puede ser perfecta. El problema es la distancia entre lo que miden los ítems y lo que afirma la etiqueta.
«Un benchmark general es un objetivo difícil pero deseable»	La tesis del artículo es que es una contradicción: la generalidad no se operacionaliza en un conjunto finito de ítems.
«Basta con que el conjunto de test no se haya filtrado al entrenamiento»	Es necesario y no suficiente. Sin fuga de datos, un atajo de formato sigue produciendo una puntuación alta sin capacidad.

12. Relación con trabajos anteriores

- **Torralba y Efros (2011)** — *Unbiased Look at Dataset Bias*: la constatación de que un modelo puede reconocer de qué conjunto viene una imagen.
- **Geirhos et al. (2020)** — aprendizaje por atajos: la evidencia empírica de que las redes aprenden regularidades superficiales. doi:10.1038/s42256-020-00257-z
- **P61 Loros estocásticos (2021)** — el mismo escepticismo aplicado al corpus en vez de al instrumento de medida.

13. Relación con trabajos posteriores

- **P51 SWE-bench (2023)** — un benchmark cuyo criterio de acierto es externo al formato del ítem: pasan o no pasan los tests del repositorio.

- **Bowman y Dahl (2021)** — *What Will it Take to Fix Benchmarking in NLU?*
doi:10.18653/v1/2021.naacl-main.385
- **P63 Reproducibilidad (2021)** — el otro requisito: que el número sea repetible, además de válido.
- **P52 Superposición (2023)** — mirar dentro del modelo cuando medir por fuera no basta.

14. Notebook asociado

P62_benchmark_validez.ipynb

Qué implementa: la auditoría de un benchmark ficticio: cobertura declarada frente a real, puntuación de una estrategia sin capacidad, línea del azar y muestra de ítems a inspeccionar a mano.

Qué NO implementa: no evalúa ningún benchmark real ni ningún modelo. Los ítems son inventados para exhibir el modo de fallo, y no deben citarse como resultado.

```
ai-evolution paper-lab P62 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Define validez de constructo con tus palabras.
Explicar	Explica por qué una puntuación alta puede ser compatible con no tener la capacidad.
Aplicar	Ejecuta el notebook y calcula la ventaja del atajo sobre el azar.
Analizar	Analiza por qué añadir más ítems no resuelve el problema.
Evaluar	«El modelo A comprende mejor el lenguaje porque saca más puntos». Evalúa la afirmación.
Crear	Audita un benchmark real de tu área: lee veinte ítems, identifica el constructo declarado, la cobertura y un atajo posible.

16. Autoevaluación

1. ¿Qué es la validez de constructo?
2. ¿Qué mide realmente un benchmark que admite un atajo?
3. ¿Por qué el artículo sostiene que un benchmark general es una contradicción?
4. ¿Resuelve el problema añadir más ítems?
5. ¿Qué hace distinto a un benchmark con verificación externa?
6. ¿Aporta el artículo mediciones propias?
7. ¿Cuál es el procedimiento mínimo antes de citar una puntuación?

17. Respuestas esperadas

1. La correspondencia entre lo que un instrumento mide y el concepto que dice medir. Un instrumento puede ser fiable y preciso y aun así medir otra cosa.

2. Mide el atajo. En la miniatura, «responder la opción más larga» acierta 11 de 12 frente a 3 de 12 del azar, sin ninguna capacidad detrás.
3. Porque la generalidad no se puede operacionalizar en un conjunto finito de ítems: cualquier conjunto concreto cubre una porción y deja fuera el resto, por grande que sea.
4. No, si los ítems nuevos comparten el mismo atajo o la misma cobertura estrecha. Se obtiene el mismo número con menos varianza, que es peor: parece más sólido.
5. Que el criterio de acierto no depende del formato del ítem. En SWE-bench, pasar los tests del repositorio es difícil de fingir con una heurística de superficie.
6. No. Es análisis conceptual con estudios de caso. La evidencia empírica de los atajos viene de otra literatura, como Geirhos et al. (2020).
7. Tres pasos: leer una muestra de ítems, buscar una estrategia que los supere sin la capacidad, y comprobar qué parte del constructo declarado cubren realmente.

18. Fuentes primarias

- Raji, I. D., Bender, E. M., Paullada, A., Denton, E. y Hanna, A. (2021). *AI and the Everything in the Whole Wide World Benchmark*. **NeurIPS 2021 Datasets and Benchmarks**. arXiv:2111.15366 · consultado 2026-08-17.
- Bowman, S. y Dahl, G. (2021). *What Will it Take to Fix Benchmarking in Natural Language Understanding?* doi:10.18653/v1/2021.naacl-main.385 · consultado 2026-08-17.
- Geirhos, R. et al. (2020). *Shortcut Learning in Deep Neural Networks*. doi:10.1038/s42256-020-00257-z · consultado 2026-08-17.



Evaluación — P62 · La IA y el benchmark del todo en el mundo entero

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *AI and the Everything in the Whole Wide World Benchmark* (2021, NeurIPS 2021 · Datasets and Benchmarks Track · arXiv:2111.15366) · **Nivel:** L3

Parte A — Contexto histórico (20 pts)

- (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
- (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

- (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
- (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

- (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

- (10) Ejecuta `P62_benchmark_validez.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
- (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
- (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

- (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
- (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).