

P73

Cuantización por mínimos cuadrados en PCM

Least Squares Quantization in PCM

Stuart P. Lloyd · 1982 · IEEE Transactions on Information Theory, 28(2), 129–137

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-17.

P73 — k-medias

Ruta clásica · Dos pasos que se alternan y siempre terminan. Terminar no es acertar: converge a un óptimo local, y con qué arranque se decide el resultado.

Nivel: L2 · Motor: `kmeans` · Notebook: `P73_kmeans.ipynb` · Anexo: álgebra y geometría

1. Identificación

Campo	Valor
Título original	<i>Least Squares Quantization in PCM</i>
Autoría	Stuart P. Lloyd
Año	1982
Venue	IEEE Transactions on Information Theory, 28(2), 129–137 · manuscrito de 1957
Fuente primaria	doi:10.1109/TIT.1982.1056489
Acceso	Restringido
Fecha de consulta	2026-08-17

2. Problema anterior

Transmitir una señal continua por un canal digital exige representarla con un número finito de niveles. Elegir esos niveles minimizando el error cuadrático es un problema de optimización combinatorio: hay que decidir a la vez dónde poner los representantes y qué puntos van con cada uno, y las dos decisiones dependen entre sí.

La solución exacta exige recorrer todas las particiones posibles. Para cualquier tamaño realista eso es inabordable.

3. Propuesta

Alternar las dos decisiones, resolviendo cada una de forma óptima dada la otra:

- 1. **asignar**: cada punto va con el representante más cercano;
- 2. **mover**: cada representante se coloca en el centro de los puntos que le tocaron.

Ambos pasos reducen el error cuadrático total —o lo dejan igual—, y el número de asignaciones posibles es finito. De ahí sale la demostración de convergencia: el algoritmo **termina siempre**.

Lo que no demuestra —y el artículo no lo pretende— es que termine en el óptimo global.

4. Intuición sin fórmulas

Repartir k tiendas por una ciudad. Cada vecino compra en la más cercana; cada tienda se muda al centro de su clientela. Cuando nadie cambia de tienda y ninguna se mueve, has terminado.

Y si empiezas colocando las tiendas en otro sitio, puedes acabar en un reparto distinto, también estable, también peor.

Dónde deja de funcionar la analogía: las tiendas tienen costes y los vecinos preferencias. Aquí solo hay distancia euclídea, y eso implica un supuesto fuerte: que los grupos son aproximadamente esféricos y de tamaño parecido.

5. Matemática mínima

Inercia: $J = \sum_i \|x_i - c(x_i)\|^2$

Paso de asignación : $c(x_i) \leftarrow \operatorname{argmin}_j \|x_i - c_j\| \rightarrow J$ no sube

Paso de movimiento : $c_j \leftarrow \text{media de los } x_i \text{ asignados a } j \rightarrow J$ no sube

J no sube nunca + hay un número finito de asignaciones $\Rightarrow$ el algoritmo TERMINA

La miniatura ejecuta ocho arranques aleatorios sobre los mismos doce puntos:


Magnitud	Valor
pasos hasta converger	3
inercias finales distintas	2
mejor inercia	1,4125
peor inercia	61,5854

Y la inercia por k : $[167,88 \cdot 61,87 \cdot 1,41 \cdot 1,12 \cdot 0,68]$ para $k = 1, 2, 3, 4, 6$. **Decrece siempre**, y por eso no sirve para elegir k .

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A01 §2 · Norma y coseno	qué mide la distancia euclídea y qué supone sobre la forma de los grupos

6. Arquitectura o flujo



7. Qué observar en el paper original

- El contexto: es un artículo de **cuantización de señales**, no de agrupamiento. El manuscrito es de 1957 en los Laboratorios Bell y no se publicó hasta 1982.
- La **demostración de convergencia**, que es corta y depende solo de que ambos pasos no suben el error.
- Que el artículo **no propone un método de inicialización**. Ese hueco es el que llena k-means++ cincuenta años después.
- La condición de optimalidad para el caso continuo —cada representante en el centroide de su región y cada frontera equidistante—, que es de donde sale la teselación de Voronoi.

8. Evidencia y resultados

El artículo es teórico: demuestra las condiciones necesarias de optimalidad y la convergencia del procedimiento iterativo, con ejemplos de cuantización escalar.

No hay evaluación comparativa. En 1957 no existía ni el problema de «agrupamiento» tal como se plantea hoy, ni conjuntos de prueba con los que comparar.

La miniatura mide lo que se puede comprobar en un cuaderno y es lo que más importa en la práctica: que la convergencia no protege del óptimo local, y que la inercia no sirve para elegir k .

9. Impacto

- Es, con la regresión, el algoritmo más ejecutado de la historia del análisis de datos. Está en todas las bibliotecas y en casi todos los pipelines de exploración.
- Su estructura de **alternar dos pasos, cada uno óptimo dado el otro**, es un patrón que reaparece en todas partes: es el esqueleto del algoritmo EM.
- La cuantización que motiva el artículo es hoy una técnica central en compresión de modelos: los métodos de cuantificación a 4 y 8 bits de QLoRA resuelven el mismo problema con otro vocabulario.
- Y sus dos debilidades —inicialización y elección de k — generaron literatura propia durante décadas.

10. Limitaciones

1. **Óptimo local.** Converger no es acertar: la miniatura obtiene dos resultados muy distintos sobre los mismos puntos según el arranque.
2. **La inercia no elige k .** Decrece siempre al aumentar k , con mínimo en un grupo por punto.
3. **Supone grupos esféricos y de tamaño similar**, porque minimiza distancia euclídea al centro. Con formas alargadas o anidadas falla y no avisa.
4. **Sensible a la escala.** Una variable con rango numérico grande domina la distancia.
5. **Sensible a valores atípicos**, porque la media lo es. La variante con medianas (k -medoides) es más robusta y más cara.

11. Errores comunes

Error	Corrección
«Si converge, ha encontrado la mejor solución»	Converge siempre y a un óptimo local. La miniatura muestra inercias finales de 1,41 y 61,59 sobre los mismos datos.
«El k óptimo es el que minimiza la inercia»	La inercia decrece siempre al subir k . Su mínimo está en $k = n$, un grupo por punto.
«Da igual la escala de las variables»	La distancia euclídea suma las dimensiones. Una variable en milímetros pesa mil veces más que la misma en metros.
«Sirve para cualquier forma de grupo»	Minimiza la distancia al centro: eso presupone grupos convexos y aproximadamente esféricos. Con dos anillos concéntricos falla por completo.
«Lo inventó Lloyd en 1982»	El manuscrito es de 1957 y circuló como informe interno; MacQueen le puso el nombre « k -means» en 1967. La publicación llegó veinticinco años después.

12. Relación con trabajos anteriores

- **P53 PCA (1901)** — la otra forma de resumir: reducir dimensiones en vez de agrupar puntos.
- **Steinhaus (1956)** — la formulación del problema de partición óptima, contemporánea e independiente.
- **P55 Shannon (1948)** — la teoría de la información dentro de la cual se plantea la cuantización.

13. Relación con trabajos posteriores

- **MacQueen (1967)** — el nombre «k-means» y la variante en línea.
- **Arthur y Vassilvitskii (2007)** — k-means++: una inicialización con garantía de aproximación.
- **P83 t-SNE (2008)** — ver la estructura en vez de imponerle k grupos.
- **P49 QLoRA (2023)** — la cuantización que motiva este artículo, aplicada a los pesos de un modelo de lenguaje.

14. Notebook asociado

P73_kmeans.ipynb

Qué implementa: el algoritmo completo con la monotonía de la inercia, ocho arranques aleatorios con sus inercias finales, y la curva de inercia frente a k.

Qué NO implementa: no hay k-means++, ni criterios de selección de k (codo, silueta), ni variantes robustas. Tampoco hay datos de alta dimensión, donde la distancia euclídea se comporta peor.

```
ai-evolution paper-lab P73 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe los dos pasos del algoritmo y di qué minimiza cada uno.
Explicar	Explica por qué el algoritmo termina siempre.
Aplicar	Ejecuta el notebook y compara el mejor y el peor arranque.
Analizar	Analiza por qué la inercia no puede usarse para elegir k.
Evaluar	«El algoritmo convergió, luego el resultado es bueno». Evalúa la afirmación.
Crear	Aplica k-medias a datos reales con y sin estandarizar, y documenta cuánto cambian los grupos.

16. Autoevaluación

1. ¿Qué minimiza k-medias?
2. ¿Por qué está garantizada la convergencia?
3. ¿Garantiza eso el óptimo global?
4. ¿Por qué no sirve la inercia para elegir k?
5. ¿Qué supone el algoritmo sobre la forma de los grupos?
6. ¿Por qué importa la escala de las variables?

7. ¿De dónde viene el algoritmo?

17. Respuestas esperadas

1. La inercia: la suma de distancias al cuadrado de cada punto a su centro asignado.
2. Porque los dos pasos —asignar y mover— nunca aumentan la inercia, y el número de asignaciones posibles es finito. No se puede bajar indefinidamente ni repetir una asignación.
3. No. Garantiza llegar a un óptimo **local**. La miniatura obtiene inercias finales de 1,41 y 61,59 sobre los mismos doce puntos, según el arranque.
4. Porque decrece de forma monótona al aumentar k : su mínimo absoluto está en un grupo por punto, que no es una respuesta útil. El criterio tiene que venir de fuera.
5. Que son aproximadamente esféricos y de tamaño similar, porque minimiza la distancia euclídea al centro. Con grupos alargados o anidados el resultado no significa nada.
6. Porque la distancia euclídea suma las diferencias de todas las dimensiones. Una variable con rango numérico grande domina la asignación sin aportar más información.
7. De un manuscrito de Lloyd de 1957 en los Laboratorios Bell sobre cuantización de señales. Se publicó en 1982; el nombre «k-means» es de MacQueen (1967).

18. Fuentes primarias

- Lloyd, S. P. (1982). *Least Squares Quantization in PCM*. **IEEE Transactions on Information Theory**, 28(2), 129–137. doi:10.1109/TIT.1982.1056489 · consultado 2026-08-17.
- MacQueen, J. (1967). *Some methods for classification and analysis of multivariate observations*. Proyecto Euclid · consultado 2026-08-17.
- Arthur, D. y Vassilvitskii, S. (2007). *k-means++: The Advantages of Careful Seeding*. **ACM DL** · consultado 2026-08-17.



Evaluación — P73 · Cuantización por mínimos cuadrados en PCM

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Least Squares Quantization in PCM* (1982, IEEE Transactions on Information Theory, 28(2), 129–137) · **Nivel:** L2

Parte A — Contexto histórico (20 pts)

- (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
- (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

- (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
- (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

- (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

- (10) Ejecuta `P73_kmeans.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
- (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
- (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

- (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
- (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).