

P76

Un estudio de la validación cruzada y el bootstrap para estimar exactitud y seleccionar modelos

A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection

Ron Kohavi · 1995 · IJCAI'95, 1137–1143

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-17.

P76 — Validación cruzada

Ruta clásica · Mide los estimadores en vez de suponerlos. De aquí sale la costumbre de los diez pliegues estratificados, y la razón por la que no es una costumbre.

Nivel: L3 · **Motor:** `validacion_cruzada` · **Notebook:** `P76_validacion_cruzada.ipynb` · **Anexo:** probabilidad y verosimilitud

1. Identificación

Campo	Valor
Título original	<i>A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection</i>
Autoría	Ron Kohavi
Año	1995
Venue	IJCAI'95, 1137–1143
Fuente primaria	Actas IJCAI'95
Acceso	Abierto
Fecha de consulta	2026-08-17

2. Problema anterior

Los artículos reportaban exactitudes sin decir cómo las habían estimado. Holdout, validación cruzada con distintos números de pliegues y bootstrap dan números **distintos** sobre los mismos datos y el mismo modelo.

Peor: dos personas con el mismo modelo y el mismo conjunto pueden publicar cifras muy diferentes sin que ninguna haga nada incorrecto. Nadie había medido cuál de esos estimadores es preferible, ni en qué sentido.

3. Propuesta

Tratar el estimador como objeto de estudio. Kohavi compara empíricamente holdout, validación cruzada con k de 2 a 20 —con y sin estratificación— y bootstrap sobre conjuntos reales, descomponiendo el error en **sesgo** y **varianza**.

La recomendación que sale de ahí, y que se convirtió en el estándar del campo: **validación cruzada estratificada de diez pliegues**. No porque tenga el menor sesgo —dejar-uno-fuera lo tiene menor— sino porque su varianza es mucho menor a un coste computacional razonable.

4. Intuición sin fórmulas

Medir la altura media de una ciudad. Puedes medir a treinta personas al azar, o dividir a los cien vecinos en diez grupos y medirlos a todos, un grupo cada vez.

Las dos formas dan la altura media correcta **en promedio**. Pero si repites el experimento, la primera te dará números que oscilan mucho más — porque solo mides a treinta.

Dónde deja de funcionar la analogía: medir la altura no cambia a las personas. Entrenar con menos datos sí cambia el modelo, y ese es el otro efecto que Kohavi mide: los estimadores con conjuntos de entrenamiento pequeños subestiman lo que el modelo haría con todos los datos.

5. Matemática mínima

Holdout p/q	: entrena con p %, evalúa con q %	→ test de tamaño q·n
Validación k	: k particiones; cada ejemplo pasa por el test exactamente una vez	→ test de tamaño n
Dejar uno fuera	: k = n	→ sesgo mínimo, varianza alta
Estratificada	: cada pliegue conserva la proporción de clases	

La miniatura simula 200 conjuntos extraídos de una población con exactitud real **0,78**:


Estimador	Media	Desviación	Rango	Ejemplos de test
holdout 70/30	0,7765	0,0753	[0,60 – 0,97]	30
validación cruzada 5	0,7836	0,0468	—	100
validación cruzada 10	0,7836	0,0454	—	100

Los sesgos son de milésimas: el problema **no es el sesgo**. Es que el holdout es **1,66× más disperso**, y la razón es aritmética — evalúa sobre 30 ejemplos en lugar de 100.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A02 §3 · Verosimilitud y entropía cruzada	por qué una estimación sobre pocos ejemplos tiene tanta varianza y qué la reduce

6. Arquitectura o flujo



7. Qué observar en el paper original

- La **descomposición en sesgo y varianza** del estimador, que es el marco con el que se compara todo lo demás.
- Por qué **dejar-uno-fuera no gana** pese a tener el sesgo menor: su varianza es alta y su coste, n entrenamientos.

- El efecto de la **estratificación**, que reduce tanto sesgo como varianza y es gratis. Es la parte de la recomendación que más se olvida.
- La advertencia sobre **usar la misma validación para seleccionar y para reportar**: eso sesga el número reportado, y es el error más común treinta años después.

8. Evidencia y resultados

Experimentos sistemáticos sobre conjuntos reales de la época, con miles de repeticiones, midiendo sesgo y varianza de cada estimador.

Es un artículo empírico sobre metodología: su aportación no es un algoritmo sino una medición de las herramientas que todo el mundo usaba sin medir.

La miniatura simula el fenómeno con una moneda sesgada para aislar la varianza del estimador. No reentrena modelos, así que no reproduce el otro efecto —el sesgo por entrenar con menos datos— que el artículo sí mide.

9. Impacto

- Fijó la práctica estándar de evaluación en aprendizaje automático durante treinta años. Cuando una biblioteca ofrece `cv=10` por defecto, es por este artículo.
- Estableció que la **elección del estimador es parte del método**, no un detalle de implementación.
- Es antecedente directo del checklist de reproducibilidad de P63: declarar cómo se estimó es tan importante como el número.
- Su advertencia sobre seleccionar y evaluar con la misma validación es el origen de la práctica de la **validación anidada**.

10. Limitaciones

1. **Los conjuntos son pequeños** para el estándar actual, y las conclusiones sobre el número óptimo de pliegues pueden no trasladarse a millones de ejemplos.
2. **Supone ejemplos independientes e idénticamente distribuidos**. Con series temporales o datos agrupados, barajar es sencillamente incorrecto.
3. **No cubre el caso de fuga de datos** por preprocesado hecho antes de partir, que hoy es el modo de fallo más frecuente.
4. **La validación cruzada es cara**: k entrenamientos. Con modelos grandes eso puede ser prohibitivo, y ahí el compromiso cambia.
5. **No resuelve la selección de modelo y la estimación a la vez**: hacerlo con la misma partición sesga, y la corrección —validación anidada— multiplica el coste.

11. Errores comunes

Error	Corrección
«Validación cruzada y holdout dan lo mismo si el conjunto es grande»	Convergen, pero con los tamaños habituales el holdout es mucho más disperso: 1,66× en la miniatura, sobre 100 ejemplos.
«Dejar-uno-fuera es el mejor estimador porque tiene menos sesgo»	Tiene menos sesgo y mucha más varianza, y cuesta n entrenamientos. El artículo recomienda 10 pliegues justamente por el compromiso.
«Da igual estratificar»	La estratificación reduce sesgo y varianza sin coste. Con clases desbalanceadas, no estratificar puede dejar pliegues sin ejemplos de la clase minoritaria.
«Se puede usar la misma validación para elegir hiperparámetros y para reportar»	Eso sesga el número reportado hacia arriba. Hace falta validación anidada o un conjunto de test reservado.
«Se puede barajar cualquier conjunto de datos»	Con series temporales, barajar mezcla futuro y pasado y produce estimaciones sistemáticamente optimistas. Ahí hay que validar en ventanas.

12. Relación con trabajos anteriores

- **Stone (1974)** — la formulación de la validación cruzada como método de evaluación.
- **Efron (1979)** — el bootstrap, la alternativa que Kohavi compara.
- **P74 Árboles de decisión (1986)** — uno de los modelos sobre los que se hacen los experimentos.

13. Relación con trabajos posteriores

- **Varma y Simon (2006)** — el sesgo de seleccionar y evaluar con la misma validación. doi:10.1186/1471-2105-7-91
- **Cawley y Talbot (2010)** — sobreajuste en la selección de modelo y cómo evitarlo. JMLR 11
- **P63 Reproducibilidad (2021)** — declarar el estimador como requisito de publicación.
- **P86 Competición M4 (2018)** — el mismo problema con datos temporales, donde la validación cruzada estándar no vale.

14. Notebook asociado

P76_validacion_cruzada.ipynb

Qué implementa: la simulación de 200 conjuntos con exactitud real conocida, y la comparación de sesgo, desviación y rango entre holdout y validación cruzada de 5 y 10 pliegues.

Qué NO implementa: no reentrena modelos, así que no reproduce el sesgo por entrenar con menos datos, ni la estratificación, ni el bootstrap. Aísla la varianza del estimador.

```
ai-evolution paper-lab P76 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Explica la diferencia entre holdout y validación cruzada de k pliegues.
Explicar	Explica por qué el holdout tiene más varianza.
Aplicar	Ejecuta el notebook y calcula cuántas veces más disperso es el holdout.
Analizar	Analiza por qué dejar-uno-fuera no es la mejor opción pese a su bajo sesgo.
Evaluar	«El modelo alcanza un 92 %». Evalúa qué falta para que la afirmación sea comparable.
Crear	Evalúa un modelo tuyo con holdout repetido y con validación cruzada de 10 pliegues, y publica media, desviación y número de corridas.

16. Autoevaluación

1. ¿Qué se compara en el artículo?
2. ¿Por qué el holdout tiene más varianza que la validación cruzada?
3. ¿Cuál es la recomendación del artículo y por qué?
4. ¿Por qué no gana dejar-uno-fuera?
5. ¿Qué aporta la estratificación?
6. ¿Cuándo NO se puede usar validación cruzada estándar?
7. ¿Qué error metodológico advierte el artículo?

17. Respuestas esperadas

1. Los estimadores de exactitud: holdout, validación cruzada con distintos k y bootstrap, descompuestos en sesgo y varianza sobre conjuntos reales.
2. Porque evalúa sobre una fracción de los datos. En la miniatura, 30 ejemplos frente a 100: menos ejemplos de test significa más ruido en la estimación.
3. Validación cruzada estratificada de diez pliegues, porque su varianza es baja a un coste computacional razonable. No es la de menor sesgo: es el mejor compromiso.
4. Porque su varianza es alta —los modelos entrenados en cada iteración son casi idénticos y sus errores están muy correlacionados— y cuesta n entrenamientos.
5. Conserva la proporción de clases en cada pliegue. Reduce sesgo y varianza sin coste adicional, y es imprescindible con clases desbalanceadas.
6. Con datos que no son independientes: series temporales, medidas repetidas del mismo sujeto, datos agrupados. Barajar mezcla información que en producción no estaría disponible.
7. Usar la misma validación para seleccionar el modelo y para reportar su exactitud. Eso sesga el número hacia arriba y exige validación anidada.

18. Fuentes primarias

- Kohavi, R. (1995). *A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection*. **IJCAI'95**, 1137–1143. *Actas* · consultado 2026-08-17.
- Varma, S. y Simon, R. (2006). *Bias in error estimation when using cross-validation for model selection*. doi:10.1186/1471-2105-7-91 · consultado 2026-08-17.
- Cawley, G. y Talbot, N. (2010). *On Over-fitting in Model Selection*. **JMLR 11** · consultado 2026-08-17.



Evaluación — P76 · Un estudio de la validación cruzada y el bootstrap para estimar exactitud y seleccionar modelos

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection* (1995, IJCAI'95, 1137–1143) · **Nivel:** L3

Parte A — Contexto histórico (20 pts)

- (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
- (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

- (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
- (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

- (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

- (10) Ejecuta `P76_validacion_cruzada.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
- (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
- (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

- (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
- (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).