

P77

Contracción y selección en regresión mediante el lasso

Regression Shrinkage and Selection via the Lasso

Robert Tibshirani · 1996 · Journal of the Royal Statistical Society, Series B, 58(1), 267–288

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-17.

P77 — Lasso

Ruta clásica · Una penalización con esquinas. Los coeficientes irrelevantes no se encogen: caen exactamente a cero, y el modelo se selecciona solo.

Nivel: L3 · Motor: `lasso` · Notebook: `P77_lasso.ipynb` · Anexo: cálculo y gradientes

1. Identificación

Campo	Valor
Título original	<i>Regression Shrinkage and Selection via the Lasso</i>
Autoría	Robert Tibshirani
Año	1996
Venue	Journal of the Royal Statistical Society, Series B, 58(1), 267–288
Fuente primaria	doi:10.1111/j.2517-6161.1996.tb02080.x
Acceso	Restringido
Fecha de consulta	2026-08-17

2. Problema anterior

Con muchas variables, los mínimos cuadrados dan coeficientes grandes de signo arbitrario que sobreajustan y producen un modelo imposible de interpretar.

Había dos remedios y ninguno servía del todo. La **selección por subconjuntos** —probar combinaciones de variables y quedarse con la mejor— es discreta y por tanto inestable: cambiar un dato puede cambiar el conjunto elegido. La **regresión de cresta** es estable y continua, pero encoge todos los coeficientes y no elimina ninguno: el modelo sigue teniendo todas las variables.

3. Propuesta

Penalizar la suma de los **valores absolutos** de los coeficientes en lugar de la suma de sus cuadrados:

minimizar $RSS + \alpha \cdot \sum |\beta_j|$

La consecuencia es geométrica y sorprendente. La restricción $\sum |\beta_j| \leq t$ define un rombo —en más dimensiones, un politopo— con **esquinas sobre los ejes**. El óptimo tiende a caer en una esquina, y estar en una esquina significa que algunas coordenadas valen exactamente cero.

La bola de la cresta es lisa y no tiene esquinas: por eso encoge y no anula. El lasso **estima y selecciona en la misma operación**, y lo hace de forma continua y por tanto estable.

4. Intuición sin fórmulas

Un presupuesto que repartir entre variables. Con la cresta, el coste de una variable crece con el cuadrado: la primera unidad es casi gratis, así que compensa dar un poco a todas.

Con el lasso, el coste es lineal: la primera unidad cuesta lo mismo que la última. Si una variable no aporta lo suficiente para pagar su primera unidad, se queda **sin nada**.

Dónde deja de funcionar la analogía: el presupuesto reparte algo escaso entre usos independientes. Aquí las variables interactúan, y si dos son casi idénticas el lasso se queda con una de las dos casi al azar — que es su punto débil conocido.

5. Matemática mínima

Cresta (L2): minimizar $RSS + \alpha \cdot \sum \beta_j^2$ → encoge, nunca anula
Lasso (L1): minimizar $RSS + \alpha \cdot \sum |\beta_j|$ → ANULA

Operador de umbral suave, que es de donde sale el cero exacto:


$\beta \leftarrow \text{signo}(z) \cdot \max(0, |z| - \alpha \cdot 1r)$
si $|z| \leq \alpha \cdot 1r \rightarrow \beta = 0$ exactamente

La miniatura ajusta sobre 60 observaciones y 8 variables, de las que solo 3 tienen efecto real:

Método	Coefficientes exactamente cero	Nulos reales detectados
sin penalización	0	—
cresta L2	0	—
lasso L1	4	4 de 5

Y el camino de regularización muestra el mando: con $\alpha = 0,05$ sobreviven 6 variables; con $\alpha = 1, 2, 4$. Elegir α es elegir cuánta parsimonia se compra y a qué precio en ajuste.

6. Arquitectura o flujo



7. Qué observar en el paper original

- El **argumento geométrico** de las esquinas, que es la parte que hay que entender y la que explica todo el comportamiento del método.
- La discusión sobre **estabilidad** frente a la selección por subconjuntos: el lasso es continuo en los datos, la selección discreta no.
- Los **algoritmos** que propone para resolverlo, anteriores a LARS y al descenso por coordenadas que se usan hoy.
- El tratamiento de la **elección de t** por validación cruzada, que conecta directamente con P76: sin un estimador honesto, el hiperparámetro se elige mal.

8. Evidencia y resultados

Simulaciones con estructuras de correlación controladas y ejemplos reales, comparando error de predicción y número de variables seleccionadas frente a mínimos cuadrados, cresta y selección por subconjuntos.

El resultado no es que el lasso gane siempre en predicción: es que consigue modelos mucho más pequeños con un error comparable, y de forma estable.

La miniatura reproduce el mecanismo con datos sintéticos donde se conoce la verdad, que es lo único que permite decir «identificó 4 de las 5 variables nulas».

9. Impacto

- Es uno de los artículos más citados de la estadística moderna y el punto de partida de la literatura sobre esparsidad.
- Abrió el problema de la **alta dimensión** —más variables que observaciones—, central en genómica, y con él toda la teoría de recuperación esparsa.
- La idea de **restringir el espacio de soluciones para obtener algo manejable** reaparece en LoRA: en vez de ajustar todos los pesos, restringir la actualización a rango bajo.
- Y su lección práctica sigue vigente: la regularización no es un truco contra el sobreajuste, es una forma de codificar qué modelos consideramos aceptables.

10. Limitaciones

1. **Inestable con variables muy correlacionadas:** se queda con una del grupo casi al azar. La red elástica (Zou y Hastie, 2005) existe por esto.
2. **Selecciona como mucho n variables** cuando hay más variables que observaciones, por construcción.
3. **Los coeficientes están sesgados hacia cero**, incluso los de las variables que sí importan.
4. **La inferencia post-selección es delicada:** los intervalos de confianza calculados sobre las variables seleccionadas no son válidos sin corrección.
5. **Un cero no es una afirmación causal:** significa que, dadas las demás variables y esa penalización, no aporta.

11. Errores comunes

Error	Corrección
«El lasso y la cresta hacen lo mismo con distinta fórmula»	La cresta encoge y nunca anula; el lasso pone coeficientes exactamente en cero. La miniatura lo comprueba: 4 ceros frente a 0.
«Un coeficiente en cero significa que la variable no influye»	Significa que, dadas las demás variables y esa penalización, no aporta. Es condicional y no es causal.
«Con variables correlacionadas el lasso elige la mejor»	Se queda con una casi arbitrariamente. Cambiar unos pocos datos puede cambiar cuál.
«Elegir alpha es un detalle»	Alpha determina cuántas variables sobreviven. En la miniatura, de 6 a 4 según el valor: es parte del modelo y se elige por validación.
«La regularización es un truco contra el sobreajuste»	Es una forma de declarar qué soluciones consideramos aceptables. El sobreajuste se reduce como consecuencia.

12. Relación con trabajos anteriores

- **Hoerl y Kennard (1970)** — la regresión de cresta: la penalización L2 que encoge sin anular.
- **Breiman (1995)** — el garrote no negativo, el antecedente directo del lasso.
- **P76 Validación cruzada (1995)** — el estimador con el que se elige el parámetro de penalización.

13. Relación con trabajos posteriores

- **Zou y Hastie (2005)** — red elástica: combina L1 y L2 para manejar variables correlacionadas. doi:10.1111/j.1467-9868.2005.00503.x
- **Efron et al. (2004)** — LARS: el camino de regularización completo con el coste de una única regresión. doi:10.1214/009053604000000067
- **P48 LoRA (2021)** — restringir el espacio de actualizaciones para obtener algo manejable, con otra restricción.
- **P81 Selección de variables (2003)** — el panorama completo de métodos, donde el lasso es la familia embebida.

14. Notebook asociado

P77_lasso.ipynb

Qué implementa: el descenso con umbral suave para L1 y con gradiente para L2 sobre datos donde se conoce qué variables importan, y el camino de regularización completo.

Qué NO implementa: no hay LARS, ni descenso por coordenadas, ni elección de alpha por validación cruzada, ni red elástica. Tampoco el caso de más variables que observaciones.

```
ai-evolution paper-lab P77 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe las dos funciones objetivo, con penalización L1 y L2.
Explicar	Explica por qué la geometría de la bola L1 produce ceros exactos.
Aplicar	Ejecuta el notebook y observa el camino de regularización.
Analizar	Analiza qué hace cada penalización con la variable que es copia ruidosa de otra.
Evaluar	«El lasso identificó las variables importantes». Evalúa qué afirma exactamente eso.
Crear	Ajusta un lasso con alpha elegido por validación cruzada sobre datos reales y comprueba si el conjunto seleccionado es estable al cambiar la partición.

16. Autoevaluación

1. ¿Qué penaliza el lasso y qué la cresta?
2. ¿Por qué el lasso produce ceros exactos?
3. ¿Qué ventaja tiene sobre la selección por subconjuntos?
4. ¿Qué le pasa con dos variables muy correlacionadas?
5. ¿Qué significa que un coeficiente sea cero?
6. ¿Qué papel juega alpha?
7. ¿Dónde reaparece esta idea en el aprendizaje profundo?

17. Respuestas esperadas

1. El lasso penaliza la suma de valores absolutos de los coeficientes (norma L1); la cresta, la suma de sus cuadrados (norma L2).
2. Porque la región $\sum |\beta_j| \leq t$ es un polítopo con esquinas sobre los ejes, y el óptimo tiende a caer en una esquina. Estar en una esquina significa tener coordenadas exactamente nulas.
3. Que es continuo en los datos y por tanto **estable**: la selección por subconjuntos es discreta, y cambiar un dato puede cambiar por completo el conjunto elegido.
4. Se queda con una de las dos casi arbitrariamente, y cuál puede cambiar con pequeñas variaciones en los datos. La red elástica se propuso para corregirlo.
5. Que, dadas las demás variables incluidas y ese valor de alpha, esa variable no aporta. Es una afirmación condicional sobre el modelo, no causal sobre el mundo.
6. Controla cuánta penalización se aplica y, con ella, cuántas variables sobreviven. En la miniatura, de 6 variables vivas con alpha 0,05 a 4 con alpha 1,2.
7. En LoRA: restringir las actualizaciones a un subespacio de rango bajo en lugar de ajustar todos los pesos. Es la misma estrategia —restringir el espacio de soluciones— con otra restricción.

18. Fuentes primarias

- Tibshirani, R. (1996). *Regression Shrinkage and Selection via the Lasso*. **JRSS-B**, 58(1), 267–288. doi:10.1111/j.2517-6161.1996.tb02080.x · consultado 2026-08-17.
- Zou, H. y Hastie, T. (2005). *Regularization and variable selection via the elastic net*. doi:10.1111/j.1467-9868.2005.00503.x · consultado 2026-08-17.

- Efron, B. et al. (2004). *Least Angle Regression*. doi:10.1214/009053604000000067 · consultado 2026-08-17.



Evaluación — P77 · Contracción y selección en regresión mediante el lasso

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Regression Shrinkage and Selection via the Lasso* (1996, Journal of the Royal Statistical Society, Series B, 58(1), 267–288) · **Nivel:** L3

Parte A — Contexto histórico (20 pts)

- (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
- (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

- (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
- (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

- (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

- (10) Ejecuta `P77_lasso.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
- (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
- (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

- (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
- (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).