

P78

Una generalización decisional del aprendizaje en línea y su aplicación al boosting

A Decision-Theoretic Generalization of On-Line Learning and an Application to Boosting

Yoav Freund, Robert E. Schapire · 1997 · Journal of Computer and System Sciences, 55(1), 119–139

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-17.

P78 — AdaBoost

Ruta clásica · Muchos clasificadores apenas mejores que el azar, en serie, cada uno mirando lo que el anterior falló. La suma ponderada resuelve lo que ninguno sabía.

Nivel: L3 · Motor: `adaboost` · Notebook: `P78_adaboost.ipynb` · Anexo: cálculo y gradientes

1. Identificación

Campo	Valor
Título original	<i>A Decision-Theoretic Generalization of On-Line Learning and an Application to Boosting</i>
Autoría	Yoav Freund, Robert E. Schapire
Año	1997
Venue	Journal of Computer and System Sciences, 55(1), 119–139
Fuente primaria	doi:10.1006/jcss.1997.1504
Acceso	Restringido
Fecha de consulta	2026-08-17

2. Problema anterior

Kearns y Valiant habían planteado una pregunta teórica: ¿un aprendiz **débil** —uno que solo garantiza acertar un poco más que el azar— puede convertirse en uno **fuerte**, arbitrariamente preciso?

Schapire había demostrado que sí en 1990, pero su construcción era impracticable: exigía conocer de antemano la ventaja del aprendiz débil sobre el azar, y esa cantidad no se conoce. El resultado era teóricamente importante y operativamente inútil.

3. Propuesta

AdaBoost, donde «Ada» es por **adaptativo**: el algoritmo se ajusta solo a la calidad de cada aprendiz, sin que nadie se la diga.

En cada ronda se entrena un clasificador sobre una distribución de pesos, se mide su error **ponderado**, y de ahí salen dos cosas: cuánto vota ese clasificador en la decisión final ($\alpha = \frac{1}{2} \cdot \ln((1-\epsilon)/\epsilon)$) y cómo se redistribuyen los pesos para la ronda siguiente —sube el peso de lo que falló, baja el de lo que acertó—.

El artículo demuestra además que el error de entrenamiento del conjunto decrece **exponencialmente** con el número de rondas.

4. Intuición sin fórmulas

Un comité de especialistas estrechos. El primero solo sabe distinguir por el precio. El segundo se contrata sabiendo qué casos falló el primero, y se especializa en ellos. El tercero, en lo que fallan los dos.

Ninguno resuelve el problema. El comité, con voto ponderado por acierto, sí.

Dónde deja de funcionar la analogía: los especialistas humanos tienen conocimiento propio. Aquí el «especialista» es el mismo algoritmo simple aplicado a datos reponderados; toda la especialización viene de los pesos. Y si un caso está mal etiquetado, el comité contratará a alguien tras otro para acertar algo que es imposible acertar.

5. Matemática mínima

```

D1(i) = 1/n
Para t = 1..T:
    ht ← aprendiz débil sobre Dt
    εt ← Σi Dt(i) · [ht(xi) ≠ yi]      ← error PONDERADO
    αt ← ½ · ln((1 - εt)/εt)                ← más voto a quien menos falla
    Dt+1(i) ∝ Dt(i) · exp(-αt · yi · ht(xi))

H(x) = signo( Σt αt · ht(x) )

Error de entrenamiento ≤ Πt 2 · √(εt(1-εt)) → decrece exponencialmente


```

La miniatura ataca un problema de **banda central** — $y = +1$ si $4 \leq x \leq 7$ — que ningún corte único puede describir:

Modelo	Exactitud
mejor tocón individual (de 22)	75,0 %
conjunto ponderado, ronda 3	91,7 %

Y el peso del ejemplo más difícil pasa de 0,0833 —el reparto uniforme— a **0,293**.

6. Arquitectura o flujo



7. Qué observar en el paper original

- La **cota exponencial** sobre el error de entrenamiento y su demostración, que es breve y elegante.
- La discusión sobre por qué AdaBoost **no sobreajusta tanto como debería** según la teoría VC — un fenómeno que se explicó después en términos de márgenes y que dio literatura para una década.
- El marco general: el artículo va de aprendizaje en línea y decisión, y el boosting es la aplicación. El resultado es más general que el algoritmo famoso.
- Que el aprendiz débil es una **caja negra**: cualquier algoritmo que acepte pesos sirve.

8. Evidencia y resultados

Análisis teórico con la cota exponencial, más experimentos sobre conjuntos de referencia de la época comparando con el aprendiz débil suelto y con bagging.

La cota es sobre el error de **entrenamiento**. Que el error de prueba también baje —y que siga bajando después de que el de entrenamiento llegue a cero— es un fenómeno empírico que motivó la teoría de márgenes posterior.

La miniatura elige un problema representable por una suma de tocones para que el efecto se vea sin ambigüedad. La exactitud reportada es de entrenamiento: no hay conjunto de prueba.

9. Impacto

- Ganó el premio Gödel en 2003. Es uno de los resultados más influyentes del aprendizaje automático.
- Su descendencia domina hoy los **datos tabulares**: gradient boosting, XGBoost, LightGBM y CatBoost son variantes de la misma idea con otra función de pérdida.
- Friedman, Hastie y Tibshirani (2000) lo reinterpreataron como **ajuste aditivo por etapas** con pérdida exponencial, y esa lectura es la que abrió el camino al gradient boosting.
- El detector de caras de Viola-Jones (2001), que puso detección facial en cámaras baratas, es AdaBoost sobre características simples.

10. Limitaciones

1. **Sensible al ruido de etiqueta.** Un ejemplo mal etiquetado no se puede acertar nunca, y su peso crece ronda tras ronda hasta acaparar la atención del conjunto.
2. **La cota es sobre error de entrenamiento**, no de generalización. La resistencia al sobreajuste es empírica y su explicación teórica llegó después.
3. **Serial por construcción.** Cada ronda depende de la anterior: no se paraleliza como un bosque.
4. **Requiere que el aprendiz débil acepte pesos**, o simular los pesos por remuestreo.
5. **Con muchas rondas y aprendices poco débiles** puede sobreajustar como cualquier otro modelo: la resistencia no es inmunidad.

11. Errores comunes

Error	Corrección
«AdaBoost no sobreajusta»	Sobreajusta menos de lo que la teoría VC predeciría, y con datos ruidosos sobreajusta claramente. La resistencia es empírica y tiene condiciones.
«Los clasificadores débiles se promedian»	Se combinan con voto PONDERADO por competencia: $\alpha = \frac{1}{2} \cdot \ln((1-\epsilon)/\epsilon)$. No es una media.
«El peso alto de un ejemplo indica que es importante»	Indica que el conjunto lo falla. Si está mal etiquetado, un peso alto es una señal de alarma, no de que el algoritmo esté trabajando bien.
«Boosting y bagging son variantes de lo mismo»	Bagging entrena en paralelo sobre remuestreos y reduce varianza. Boosting entrena en serie corrigiendo residuos y reduce sesgo. Son estrategias opuestas.
«Hace falta un aprendiz base bueno»	Al contrario: funciona con aprendices apenas mejores que el azar, y ese es el resultado. Un tocón de un solo corte basta.

12. Relación con trabajos anteriores

- **Schapire (1990)** — la primera demostración de que el aprendizaje débil implica el fuerte, sin algoritmo práctico.
- **Kearns y Valiant (1989)** — la pregunta original en el marco PAC.
- **P74 Árboles de decisión (1986)** — la fuente del aprendiz débil canónico: el tocón de decisión.

13. Relación con trabajos posteriores

- **Friedman, Hastie y Tibshirani (2000)** — boosting como modelo aditivo: la lectura que abre el gradient boosting. doi:10.1214/aos/1016218223
- **Viola y Jones (2001)** — detección de caras en tiempo real con AdaBoost.
- **Chen y Guestrin (2016)** — XGBoost: la implementación que domina los datos tabulares. doi:10.1145/2939672.2939785
- **P79 Bosques aleatorios (2001)** — la estrategia opuesta: paralelo y descorrelacionado.

14. Notebook asociado

P78_adaboost.ipynb

Qué implementa: el bucle completo de AdaBoost sobre un problema de banda, con el error ponderado, el alpha de cada ronda, la evolución de la exactitud del conjunto y la migración de los pesos hacia los ejemplos difíciles.

Qué NO implementa: no hay conjunto de prueba, ni la cota teórica, ni gradient boosting. Los aprendices débiles son tocones de un solo corte sobre una dimensión.

```
ai-evolution paper-lab P78 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe la fórmula de alpha y explica qué mide.
Explicar	Explica por qué el peso de un ejemplo sube cuando se falla.
Aplicar	Ejecuta el notebook y sigue la exactitud del conjunto ronda a ronda.
Analizar	Analiza por qué ningún tocón describe una banda y la suma de dos sí.
Evaluar	«AdaBoost no sobreajusta». Evalúa la afirmación.
Crear	Introduce un 5 % de etiquetas erróneas y observa qué le pasa a los pesos y a la exactitud.

16. Autoevaluación

1. ¿Qué pregunta teórica responde el boosting?
2. ¿Qué significa que AdaBoost sea adaptativo?
3. ¿Cómo se calcula el voto de cada clasificador?
4. ¿Qué se hace con los pesos de los ejemplos?
5. ¿Qué demuestra el artículo sobre el error?
6. ¿Cuál es su punto débil conocido?
7. ¿En qué se diferencia del bagging?

17. Respuestas esperadas

1. Si un aprendiz débil —apenas mejor que el azar— puede convertirse en uno fuerte. La respuesta era afirmativa desde 1990; lo que faltaba era un algoritmo practicable.
2. Que no necesita conocer de antemano la ventaja del aprendiz débil sobre el azar: la mide en cada ronda y ajusta el peso del voto en consecuencia.
3. Con $\alpha = \frac{1}{2} \ln((1-\epsilon)/\epsilon)$, donde ϵ es su error ponderado. Cuanto menos falla, más vota. Es una media ponderada por competencia, no una media.
4. Se multiplican por $\exp(-\alpha \cdot y \cdot h(x))$: suben los de los ejemplos fallados y bajan los de los acertados. La ronda siguiente se concentra en lo que la anterior no resolvió.
5. Que el error de **entrenamiento** del conjunto decrece exponencialmente con el número de rondas, mientras cada aprendiz sea algo mejor que el azar.
6. El ruido de etiqueta. Un ejemplo mal etiquetado es imposible de acertar, su peso crece sin límite y el conjunto acaba dedicando capacidad a memorizar el error.
7. El bagging entrena en paralelo sobre remuestreos independientes y reduce varianza. El boosting entrena en serie, cada modelo corrigiendo al anterior, y reduce sesgo.

18. Fuentes primarias

- Freund, Y. y Schapire, R. E. (1997). *A Decision-Theoretic Generalization of On-Line Learning and an Application to Boosting*. **JCSS**, 55(1), 119–139. doi:10.1006/jcss.1997.1504 · consultado 2026-08-17.
- Friedman, J., Hastie, T. y Tibshirani, R. (2000). *Additive Logistic Regression*. doi:10.1214/aos/1016218223 · consultado 2026-08-17.
- Chen, T. y Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System*. doi:10.1145/2939672.2939785 · consultado 2026-08-17.



Evaluación — P78 · Una generalización decisional del aprendizaje en línea y su aplicación al boosting

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *A Decision-Theoretic Generalization of On-Line Learning and an Application to Boosting* (1997, Journal of Computer and System Sciences, 55(1), 119–139) · **Nivel:** L3

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P78_adaboost.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).