

P81

Introducción a la selección de variables y características

An Introduction to Variable and Feature Selection

Isabelle Guyon, André Elisseeff · 2003 · Journal of Machine Learning Research, 3, 1157–1182

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-17.

P81 — Selección de variables

Ruta clásica · Ordenar variables por su correlación con la etiqueta falla en las dos direcciones, y el artículo lo demuestra con contraejemplos que caben en una figura.

Nivel: L3 · Motor: `seleccion_de_caracteristicas` · Notebook: `P81_seleccion_de_caracteristicas.ipynb` · Anexo: probabilidad y verosimilitud

1. Identificación

Campo	Valor
Título original	<i>An Introduction to Variable and Feature Selection</i>
Autoría	Isabelle Guyon, André Elisseeff
Año	2003
Venue	Journal of Machine Learning Research, 3, 1157–1182
Fuente primaria	JMLR 3:1157–1182
Acceso	Abierto
Fecha de consulta	2026-08-17

2. Problema anterior

Con miles de variables y pocas muestras —el caso típico en genómica o en texto— hay que reducir antes de modelar. El método habitual era ordenar las variables por su correlación con la etiqueta y quedarse con las primeras.

Es rápido, es intuitivo y falla de dos formas que casi nadie enunciaba: descarta variables que solas no informan pero juntas lo determinan todo, y descarta como «redundantes» variables que juntas cancelan ruido.

3. Propuesta

Un marco que ordena el problema en tres familias:

- **filtros**: puntúan variables antes de modelar, con un criterio propio;
- **envolturas**: usan el modelo como caja negra y buscan el subconjunto que mejor rinde;
- **métodos embebidos**: la selección ocurre dentro del ajuste, como en el lasso.

Y dos advertencias con contraejemplo, que son la parte que se recuerda:

1. una variable **inútil por separado puede ser imprescindible acompañada**;
2. dos variables **redundantes pueden ser mejores juntas** que cualquiera de ellas sola.

4. Intuición sin fórmulas

Elegir a los miembros de un equipo por su rendimiento individual. Dos jugadores mediocres pueden funcionar perfectamente juntos, y un fichaje estrella puede no aportar nada si duplica lo que ya tienes.

Y al revés: dos jugadores que hacen lo mismo no siempre sobran, porque entre los dos cometen menos errores que cualquiera solo.

Dónde deja de funcionar la analogía: en un equipo la complementariedad se ve a simple vista. Aquí no: la correlación de cada variable con la etiqueta puede ser exactamente cero mientras el par determina la respuesta por completo.

5. Matemática mínima

Caso 1 – complementariedad (XOR):

$a, b \in \{-1, +1\}, \quad y = 1 \text{ si } a \cdot b > 0$

$\text{corr}(a, y) \approx 0 \quad \text{corr}(b, y) \approx 0 \quad \text{y el par la determina por completo}$

Caso 2 – redundancia útil:

$r_1 = \text{señal} + \text{ruido}_1, \quad r_2 = \text{señal} + \text{ruido}_2, \quad \text{ruidos independientes}$


$\text{Var}[(r_1+r_2)/2] = \text{Var}[\text{ruido}]/2 \quad \leftarrow \text{promediar cancela ruido}$

La miniatura mide los dos casos sobre 400 observaciones:

Situación	Resultado
exactitud con «a» sola	0,5
exactitud con «b» sola	0,5083
exactitud con las dos	1,0
correlaciones univariantes de a y b con y	0,0903 y 0,0091
error estimando con «r1» sola	0,5379
error promediando «r1» y «r2»	0,3003

Un ranking por correlación descarta «a» y «b» antes de llegar a mirarlas juntas, y descarta «r2» por redundante justo cuando promediarla es lo que reduce el error.

6. Arquitectura o flujo



7. Qué observar en el paper original

- Las **dos figuras de contraejemplo**, que son lo más citado del artículo y lo que hay que tener presente cada vez que alguien ordena variables por correlación.
- La distinción entre **relevancia** y **utilidad**: una variable puede ser relevante y no aportar nada dado el resto, y al revés.
- La discusión sobre **validación**: seleccionar variables usando todos los datos y después evaluar con validación cruzada es una fuga de información, y produce estimaciones optimistas.
- La sección práctica con la lista de comprobación, que sigue siendo un buen punto de partida.

8. Evidencia y resultados

Es un artículo de revisión y síntesis, con contraejemplos contruidos y referencias a los resultados de las competiciones de selección de variables del NIPS.

Su valor no está en un resultado nuevo sino en organizar el campo y en enunciar con precisión dos modos de fallo que se cometían —y se cometen— constantemente.

La miniatura construye los dos contraejemplos con datos sintéticos y los mide, que es la única forma de que «una variable inútil sola puede ser imprescindible» deje de ser una frase y pase a ser un número.

9. Impacto

- Es la referencia estándar sobre selección de variables y una de las más citadas de JMLR.
- Su taxonomía —filtros, envolturas, embebidos— es la que se usa para clasificar cualquier método nuevo.
- La advertencia sobre la fuga de información al seleccionar antes de validar corrigió una práctica muy extendida, especialmente en bioinformática.

- Y su tesis central sobrevive al cambio de paradigma: en la era de los modelos que aprenden sus propias representaciones, la pregunta «¿qué aporta esta variable **dadas las demás?**» sigue siendo la correcta, y es la que responden métodos como SHAP.

10. Limitaciones

1. **Es de 2003.** El panorama previo a los modelos que aprenden representaciones; muchas técnicas concretas están superadas.
2. **No resuelve la inestabilidad de la selección:** con datos correlacionados, el conjunto elegido cambia con pequeñas variaciones de la muestra.
3. **Las envolturas son caras** y el artículo no ofrece un criterio claro de cuándo compensan.
4. **Los contraejemplos son extremos.** En datos reales la complementariedad suele ser parcial y el ranking univariante no falla de forma tan limpia.
5. **No cubre la selección causal:** qué variables *hay que* incluir para estimar un efecto es otro problema, con otras reglas.

11. Errores comunes

Error	Corrección
«Las variables con baja correlación con la etiqueta se pueden descartar»	En el ejemplo XOR, ambas tienen correlación casi nula y juntas determinan la etiqueta por completo.
«Las variables correlacionadas entre sí son redundantes»	Si sus ruidos son independientes, promediarlas reduce la varianza. «Redundante» es una propiedad de la información, no de la correlación.
«Seleccionar variables y luego validar con validación cruzada es correcto»	Si la selección usó todos los datos, la validación posterior está contaminada. La selección tiene que ocurrir dentro de cada pliegue.
«Menos variables siempre generaliza mejor»	Reducir ayuda cuando hay ruido y pocas muestras. Quitar variables complementarias empeora, y el ranking univariante es precisamente el método que las quita.
«Con modelos profundos ya no hace falta seleccionar»	Cambia el método, no la pregunta. «¿Qué aporta esta variable dadas las demás?» sigue siendo lo que responden los métodos de atribución.

12. Relación con trabajos anteriores

- **P77 Lasso (1996)** — el ejemplo canónico de método embebido.
- **Kohavi y John (1997)** — las envolturas para selección de subconjuntos. doi:10.1016/S0004-3702(97)00043-X
- **P76 Validación cruzada (1995)** — el estimador que hay que usar bien para no contaminar la selección.

13. Relación con trabajos posteriores

- **Lundberg y Lee (2017)** — SHAP: atribución con garantías de la teoría de juegos. arXiv:1705.07874
- **P52 Superposición (2023)** — la misma pregunta dentro de un modelo denso: qué representa cada dirección.

- **P8o Las dos culturas (2001)** — por qué la importancia de una variable depende del modelo que se ajuste.

14. Notebook asociado

P81_seleccion_de_caracteristicas.ipynb

Qué implementa: los dos contraejemplos medidos: complementariedad tipo XOR con correlaciones univariantes casi nulas, y reducción de ruido al promediar dos variables «redundantes».

Qué NO implementa: no hay envolturas, ni métodos embebidos, ni estabilidad de la selección. Los clasificadores son reglas de una línea: se aísla la relación entre variables y etiqueta.

```
ai-evolution paper-lab P81 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Enumera las tres familias de métodos de selección.
Explicar	Explica por qué una variable con correlación nula puede ser imprescindible.
Aplicar	Ejecuta el notebook y comprueba las exactitudes por separado y conjuntas.
Analizar	Analiza por qué promediar dos variables «redundantes» reduce el error.
Evaluar	«Estas dos variables están correlacionadas, quito una». Evalúa la decisión.
Crear	Compara ranking univariante, selección hacia delante y lasso sobre un conjunto propio.

16. Autoevaluación

1. ¿Qué tres familias de métodos distingue el artículo?
2. ¿Cuál es el primer modo de fallo del ranking univariante?
3. ¿Y el segundo?
4. ¿Por qué promediar dos variables ruidosas ayuda?
5. ¿Qué error de validación advierte el artículo?
6. ¿A qué familia pertenece el lasso?
7. ¿Sigue siendo pertinente con modelos que aprenden representaciones?

17. Respuestas esperadas

1. Filtros, que puntúan las variables antes de modelar; envolturas, que buscan subconjuntos evaluando el modelo; y métodos embebidos, donde la selección ocurre dentro del ajuste.
2. Que descarta variables complementarias: en el caso XOR, «a» y «b» tienen correlación casi nula con la etiqueta y juntas la determinan por completo.
3. Que descarta variables «redundantes» que en realidad reducen ruido. Promediar dos medidas de la misma señal con ruidos independientes baja el error a la mitad de la varianza.

4. Porque los ruidos son independientes y se cancelan parcialmente al promediar, mientras la señal común se conserva. En la miniatura, el error baja de 0,5379 a 0,3003.
5. Seleccionar variables usando todos los datos y validar después. La selección ya vio el conjunto de test, y la estimación resultante es optimista.
6. A la de los métodos embebidos: la penalización L1 selecciona mientras estima, dentro del mismo problema de optimización.
7. Sí. Cambia el método —hoy se usan atribuciones como SHAP— pero la pregunta es la misma: qué aporta esta variable **dadas las demás**.

18. Fuentes primarias

- Guyon, I. y Elisseeff, A. (2003). *An Introduction to Variable and Feature Selection*. **JMLR**, 3, 1157–1182. JMLR · consultado 2026-08-17.
- Kohavi, R. y John, G. (1997). *Wrappers for feature subset selection*. doi:10.1016/S0004-3702(97)00043-X · consultado 2026-08-17.
- Lundberg, S. y Lee, S.-I. (2017). *A Unified Approach to Interpreting Model Predictions*. arXiv:1705.07874 · consultado 2026-08-17.



Evaluación — P81 · Introducción a la selección de variables y características

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *An Introduction to Variable and Feature Selection* (2003, Journal of Machine Learning Research, 3, 1157–1182) · **Nivel:** L3

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P81_seleccion_de_caracteristicas.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).