

P82

Predecir buenas probabilidades con aprendizaje supervisado

Predicting Good Probabilities with Supervised Learning

Alexandru Niculescu-Mizil, Rich Caruana · 2005 · ICML '05, 625–632

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-17.

P82 — Calibración

Ruta clásica · Ordenar bien no es estimar bien. Un modelo con AUC excelente puede tener probabilidades sistemáticamente sesgadas, y nadie lo nota si no se mide.

Nivel: L3 · **Motor:** `calibracion` · **Notebook:** `P82_calibracion.ipynb` · **Anexo:** probabilidad y verosimilitud

1. Identificación

Campo	Valor
Título original	<i>Predicting Good Probabilities with Supervised Learning</i>
Autoría	Alexandru Niculescu-Mizil, Rich Caruana
Año	2005
Venue	ICML '05, 625–632
Fuente primaria	doi:10.1145/1102351.1102430
Acceso	Restringido
Fecha de consulta	2026-08-17

2. Problema anterior

La salida de un clasificador se trata rutinariamente como una probabilidad: se compara con un umbral de coste, se combina con otra, se le enseña a una persona que tiene que decidir.

Pero las métricas de uso común —exactitud, AUC— solo miden si el **orden** es correcto. Un modelo puede ordenar perfectamente y devolver números que no corresponden a ninguna frecuencia real, y ninguna de esas métricas lo delata. Peor: distintas familias de modelos se descalibran de formas características y distintas, y nadie lo había caracterizado.

3. Propuesta

Medir la calibración como propiedad aparte, con dos herramientas:

- el **diagrama de fiabilidad**: agrupar las predicciones por tramos y comparar la probabilidad media predicha con la frecuencia observada en cada tramo;
- puntuaciones propias como el **Brier**, que penalizan orden y calibración a la vez.

Y corregirla con dos métodos que **no alteran el orden**: el escalado de Platt —ajustar una sigmoide sobre las salidas— y la **regresión isotónica** —una función monótona por tramos ajustada a los datos—.

El artículo caracteriza además cómo se descalibra cada familia: los bosques y el boosting empujan hacia el centro, el bayes ingenuo hacia los extremos.

4. Intuición sin fórmulas

Un meteorólogo que siempre acierta cuál de dos días llueve más, pero cuyos porcentajes no significan nada: dice 90 % los días que llueve el 60 % de las veces.

Para decidir si llevas paraguas cuando te lo dice al 90 %, el orden no basta. Necesitas que el número corresponda a una frecuencia.

Dónde deja de funcionar la analogía: el meteorólogo puede aprender de su historial. Un modelo no se recalibra solo: hay que hacerlo explícitamente y —esto es lo que más se olvida— con datos distintos de los que se usaron para entrenarlo.

5. Matemática mínima

Calibrado $\Leftrightarrow P(y = 1 \mid \hat{p} = p) = p$ para todo p

Diagrama de fiabilidad: por tramo, comparar $\hat{p}$ media con frecuencia observada

$Brier = (1/n) \cdot \sum (\hat{p}_i - y_i)^2$ $\leftarrow$ orden Y calibración a la vez

Corrección monótona $\rightarrow$ no cambia el orden $\rightarrow$ no cambia el AUC

La miniatura simula un modelo que **ordena bien y exagera hacia los extremos**:

Medida	Antes	Después de calibrar
AUC	0,8214	0,8268
Brier	0,1774	0,1673
error medio de calibración	0,0542	0,0


El AUC apenas se mueve —lo poco que cambia son empates que introduce el troceado— y el Brier baja. La calibración **reescala, no reordena**.

Ese 0,0 final está medido sobre los mismos datos con los que se calibró, así que es optimista por construcción. En un caso real hay que reservar un conjunto aparte.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A02 §3 · Verosimilitud y entropía cruzada	por qué una pérdida propia premia decir la probabilidad correcta y no la más segura

6. Arquitectura o flujo



7. Qué observar en el paper original

- La **caracterización por familias**: qué modelos se descalibran hacia el centro y cuáles hacia los extremos, y por qué. Es la parte más útil en la práctica.
- La comparación entre **Platt e isotónica**: la sigmoide necesita menos datos y supone una forma; la isotónica es más flexible y sobreajusta con pocos datos.
- La insistencia en **calibrar con un conjunto reservado**. Es el error más frecuente al aplicar estas técnicas.
- Las **métricas propias** y por qué importan: una métrica propia se optimiza diciendo la probabilidad verdadera, no la más conveniente.

8. Evidencia y resultados

Estudio empírico amplio sobre múltiples conjuntos y familias de modelos —bosques, boosting, SVM, redes, bayes ingenuo, árboles— con y sin calibración, midiendo varias métricas.

Es un artículo de medición sistemática: su aportación es el mapa de qué familia se descalibra cómo, y qué corrección le conviene a cada una.

La miniatura simula un modelo mal calibrado a partir de una probabilidad real conocida, que en un problema de verdad no se observa. Sirve para exhibir la diferencia entre orden y estimación, no para reproducir el estudio.

9. Impacto

- Fijó la calibración como propiedad que hay que **medir y reportar**, no suponer.
- El diagrama de fiabilidad y el Brier son hoy herramientas estándar en cualquier evaluación seria de clasificadores probabilísticos.
- El problema resurgió con fuerza en aprendizaje profundo: Guo et al. (2017) mostraron que las redes modernas están **peor calibradas** que las de los noventa pese a ser más exactas.
- Y es directamente relevante para los modelos de lenguaje: la confianza expresada por un modelo —en logits o en palabras— rara vez está calibrada, y se usa constantemente como si lo estuviera.

10. Limitaciones

1. **Calibrar exige datos reservados.** Hacerlo sobre los mismos datos de evaluación da un resultado optimista, como el 0,0 de la miniatura.
2. **La calibración es específica de la distribución.** Si cambia la población, hay que recalibrar.
3. **La isotónica sobreajusta con pocos datos;** Platt supone una forma sigmoide que puede no valer.
4. **No arregla el orden.** Un modelo que ordena mal seguirá ordenando mal después de calibrar.
5. **Calibración global no implica calibración por subgrupos:** un modelo puede estar calibrado en conjunto y sesgado en un subgrupo concreto, que es el problema de equidad.

11. Errores comunes

Error	Corrección
«Un AUC alto implica buenas probabilidades»	El AUC solo mide el orden. La miniatura tiene AUC 0,82 y un error medio de calibración de 0,054.
«La calibración mejora la exactitud»	No cambia el orden y por tanto no cambia las decisiones con un umbral fijo del 0,5. Cambia las decisiones cuando el umbral es otro, y las probabilidades que se comunican.
«Se puede calibrar con los datos de evaluación»	Eso sobreajusta la calibración. Hace falta un conjunto reservado, igual que para cualquier otro ajuste.
«Las redes modernas están bien calibradas»	Guo et al. (2017) mostraron lo contrario: están peor calibradas que modelos más antiguos y menos exactos.
«Si el modelo está calibrado, es justo»	La calibración global no implica calibración por subgrupos. Un modelo puede estar calibrado en conjunto y sesgado en una población concreta.

12. Relación con trabajos anteriores

- **Platt (1999)** — el escalado sigmoide para convertir salidas de SVM en probabilidades.
- **P75 Vectores soporte (1995)** — un modelo cuya salida es una distancia con signo, no una probabilidad.
- **Brier (1950)** — la puntuación propia que lleva su nombre.
- **P80 Las dos culturas (2001)** — qué medir cuando el objetivo es predecir.

13. Relación con trabajos posteriores

- **Guo et al. (2017)** — la descalibración de las redes profundas modernas. [arXiv:1706.04599](https://arxiv.org/abs/1706.04599)
- **P50 IA constitucional (2022)** — cuando la salida de un modelo se usa para decidir, la fiabilidad de su confianza importa.
- **P62 Validez de benchmarks (2021)** — la misma pregunta un nivel más arriba: si el número mide lo que dice.

14. Notebook asociado

`P82_calibracion.ipynb`

Qué implementa: el diagrama de fiabilidad por tramos antes y después de calibrar, con AUC y Brier, sobre un modelo que ordena bien y exagera hacia los extremos.

Qué NO implementa: la calibración se hace sobre los mismos datos que se evalúan, que es justo lo que no se debe hacer y se declara. Tampoco hay escalado de Platt ni comparación entre familias de modelos.

```
ai-evolution paper-lab P82 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Define qué significa que un modelo esté calibrado.
Explicar	Explica por qué el AUC no detecta la descalibración.
Aplicar	Ejecuta el notebook y localiza el tramo con mayor desviación.
Analizar	Analiza por qué la calibración no cambia el AUC.
Evaluar	«El modelo tiene 0,95 de AUC, sus probabilidades son fiables». Evalúa la afirmación.
Crear	Calibra un modelo tuyo con Platt y con isotónica en un conjunto reservado y compara AUC y Brier.

16. Autoevaluación

1. ¿Qué significa que un modelo esté calibrado?
2. ¿Por qué el AUC no mide calibración?
3. ¿Qué es un diagrama de fiabilidad?
4. ¿Qué mide el Brier que no mide el AUC?
5. ¿Por qué la calibración no cambia el orden?
6. ¿Dónde hay que calibrar?
7. ¿Cuándo importa especialmente la calibración?

17. Respuestas esperadas

1. Que entre los casos a los que asigna probabilidad p , la proporción de positivos reales sea aproximadamente p . El número corresponde a una frecuencia.
2. Porque el AUC solo depende del **orden** de las puntuaciones. Aplicar cualquier transformación monótona no lo cambia, aunque destroce la correspondencia con las frecuencias.
3. Una tabla o gráfico que agrupa las predicciones por tramos y compara, en cada tramo, la probabilidad media predicha con la frecuencia observada de positivos.
4. El Brier penaliza también la distancia entre la probabilidad predicha y el resultado. Un modelo que ordena bien y exagera tiene buen AUC y peor Brier.
5. Porque tanto el escalado de Platt como la regresión isotónica son transformaciones **monótonas**: reescalan los valores sin cambiar su orden relativo.
6. En un conjunto reservado, distinto del de entrenamiento y del de evaluación. Calibrar sobre los datos de evaluación da un resultado optimista por construcción.
7. Cuando la probabilidad se usa para algo más que ordenar: decidir con un umbral de coste, combinarla con otra fuente, o presentarla a una persona que va a decidir con ella.

18. Fuentes primarias

- Niculescu-Mizil, A. y Caruana, R. (2005). *Predicting Good Probabilities with Supervised Learning*. **ICML '05**, 625–632. doi:10.1145/1102351.1102430 · consultado 2026-08-17.
- Guo, C. et al. (2017). *On Calibration of Modern Neural Networks*. arXiv:1706.04599 · consultado 2026-08-17.
- Brier, G. (1950). *Verification of forecasts expressed in terms of probability*. doi:10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2 · consultado 2026-08-17.



Evaluación — P82 · Predecir buenas probabilidades con aprendizaje supervisado

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Predicting Good Probabilities with Supervised Learning* (2005, ICML '05, 625–632) · **Nivel:** L3

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P82_calibracion.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).