

P83

Visualizar datos con t-SNE

Visualizing Data using t-SNE

Laurens van der Maaten, Geoffrey Hinton · 2008 · Journal of Machine Learning Research, 9, 2579–2605

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-17.

P83 — t-SNE

Ruta clásica · Hace visible la estructura local de datos de muchas dimensiones. Y hay tres cosas del mapa resultante que no significan nada, aunque todo el mundo las lea.

Nivel: L3 · Motor: `tsne` · Notebook: `P83_tsne.ipynb` · Anexo: probabilidad y verosimilitud

1. Identificación

Campo	Valor
Título original	<i>Visualizing Data using t-SNE</i>
Autoría	Laurens van der Maaten, Geoffrey Hinton
Año	2008
Venue	Journal of Machine Learning Research, 9, 2579–2605
Fuente primaria	JMLR 9:2579–2605
Acceso	Abierto
Fecha de consulta	2026-08-17

2. Problema anterior

Al proyectar de muchas dimensiones a dos, aparece un problema geométrico que no es un defecto del método sino del espacio de partida: en dimensión alta hay **muchísimo más sitio lejos que cerca**. El volumen de una corona esférica crece con el radio elevado a la dimensión.

Cuando se intenta reproducir esas distancias en un plano, todos los puntos moderadamente lejanos se apiñan en el centro y la estructura desaparece. Es el **problema del apiñamiento**, y era el límite de SNE, el método anterior de los mismos autores.

3. Propuesta

Dos cambios sobre SNE. El primero es técnico: simetrizar las afinidades, lo que simplifica el gradiente.

El segundo es la idea central: usar en el **mapa** una distribución con cola pesada —una t de Student con un grado de libertad— mientras en el espacio **original** se sigue usando una gaussiana.

La asimetría es deliberada. La cola pesada deja mucha más masa de probabilidad a distancias grandes, así que dos puntos moderadamente lejanos en el espacio original pueden colocarse **muy lejos** en el mapa sin penalización. Eso libera espacio en el centro y la estructura local se puede desplegar.

4. Intuición sin fórmulas

Un mapa del metro. Conserva perfectamente qué estación viene después de cuál y qué líneas se cruzan. No conserva ni las distancias ni las direcciones, y a nadie le extraña: para lo que sirve el mapa, esa información sobra.

t-SNE hace lo mismo con datos: preserva **quién está cerca de quién** y sacrifica todo lo demás.

Dónde deja de funcionar la analogía: el mapa del metro es siempre el mismo. Dos ejecuciones de t-SNE con semillas distintas producen mapas distintos —los mismos vecinos, otras posiciones— y eso sorprende a mucha gente que interpreta la primera figura que le sale.

5. Matemática mínima

Espacio original:

$p_{j|i} \propto \exp(-\|x_i - x_j\|^2 / 2\sigma_i^2)$

gaussiana, σ_i por perplejidad

Mapa:

$q_{ij} \propto (1 + \|y_i - y_j\|^2)^{-1}$

t de Student, 1 grado de libertad

Objetivo:

minimizar $KL(P \parallel Q)$

por descenso de gradiente

Por qué la cola pesada resuelve el apiñamiento:

Distancia	Gaussiana	t de Student	Razón
1	6,07e-01	5,00e-01	0,82
2	1,35e-01	2,00e-01	1,48
4	3,35e-04	5,88e-02	175
8	1,27e-14	1,54e-02	1,2e+12

A distancia 8 la t deja una masa un billón de veces mayor. Y sobre la estabilidad, la miniatura ejecuta dos veces con semillas distintas:


- vecinos conservados: **0,9556** en ambas;
- desplazamiento medio de los puntos entre las dos: **2,85**.

La vecindad es estable. La posición, no.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A02 §4 · Divergencia KL	qué mide $KL(P\ Q)$, por qué no es simétrica y qué penaliza más: separar lo cercano o juntar lo lejano

6. Arquitectura o flujo



7. Qué observar en el paper original

- La **justificación de la cola pesada**: es el corazón del artículo y lo que lo separa de SNE.
- El papel de la **perplejidad**: fija cuántos vecinos efectivos considera cada punto. Es el hiperparámetro que más cambia el resultado, y el artículo recomienda probar varios valores.
- La **exageración temprana**: multiplicar las afinidades originales durante las primeras iteraciones para que los grupos se separen antes de afinar. Es un truco de optimización, no parte del modelo.
- La discusión sobre **qué NO preserva**, que está en el artículo y que casi nadie cita.

8. Evidencia y resultados

Comparaciones visuales y cuantitativas contra Sammon, Isomap, LLE y SNE sobre conjuntos de referencia — dígitos manuscritos, caras, documentos— con medidas de preservación de vecindad.

La evidencia es en buena parte visual, que es lo apropiado para una herramienta de visualización, y se complementa con métricas de vecinos conservados.

La miniatura implementa el mecanismo sobre quince puntos con anchura fija en lugar de perplejidad ajustada por punto. Sirve para exhibir las dos propiedades que importan al leer un mapa —vecindad estable, posición inestable— no para reproducir el método.

9. Impacto

- Se convirtió en la figura por defecto de media década de artículos de aprendizaje automático y de biología computacional.
- En genómica de célula única es una herramienta estándar de exploración.
- Su éxito generó también un problema: la sobreinterpretación de mapas. El artículo de Distill «How to Use t-SNE Effectively» (2016) existe porque hacía falta.
- **UMAP** (2018) lo desplazó parcialmente por velocidad y por preservar algo mejor la estructura global, con los mismos avisos de lectura.

10. Limitaciones

1. **La distancia entre grupos no es interpretable.** El objetivo no la restringe.
2. **El tamaño aparente de un grupo tampoco:** depende de la densidad local, no del número de puntos.
3. **Depende fuertemente de la perplejidad.** Con valores distintos aparecen estructuras distintas, y hay que probar varios antes de concluir nada.

4. **No es determinista.** Dos semillas dan mapas distintos: en la miniatura, un desplazamiento medio de 2,85 con los mismos vecinos.
5. **No es una reducción de dimensionalidad para alimentar modelos.** No hay transformación aplicable a datos nuevos, y usar sus coordenadas como rasgos es un error frecuente.

11. Errores comunes

Error	Corrección
«Estos dos grupos están lejos, luego son muy distintos»	La distancia entre grupos no está restringida por el objetivo. Con otra semilla pueden quedar más cerca.
«Este grupo es más grande, luego tiene más elementos»	El tamaño aparente depende de la densidad local en el espacio original, no del número de puntos.
«t-SNE reduce dimensionalidad como PCA»	PCA da una transformación lineal aplicable a datos nuevos. t-SNE optimiza posiciones para este conjunto concreto: no hay función que aplicar a un punto nuevo.
«El mapa es reproducible»	Depende de la inicialización aleatoria. Los vecinos son estables; las posiciones, no.
«Con la perplejidad por defecto basta»	Es el hiperparámetro que más cambia el resultado. El propio artículo recomienda explorar varios valores antes de concluir.

12. Relación con trabajos anteriores

- **Hinton y Roweis (2002)** — SNE: el método anterior, con gaussiana también en el mapa y por tanto con el problema del apiñamiento.
- **P53 PCA (1901)** — la reducción lineal, que sí da una transformación aplicable a datos nuevos.
- **P73 k-medias (1982)** — la alternativa que impone grupos en vez de mostrarlos.

13. Relación con trabajos posteriores

- **Wattenberg, Viégas y Johnson (2016)** — *How to Use t-SNE Effectively*: la guía de lectura que hizo falta escribir. doi:10.23915/distill.00002
- **McInnes et al. (2018)** — UMAP: más rápido y con mejor estructura global. arXiv:1802.03426
- **P05 word2vec (2013)** — los espacios de representación que t-SNE se usa constantemente para inspeccionar.
- **P18 CLIP (2021)** — otro espacio de representación cuyo mapa aparece en casi todas las presentaciones.

14. Notebook asociado

P83_tsne.ipynb

Qué implementa: una implementación mínima del gradiente de t-SNE sobre quince puntos, dos ejecuciones con semillas distintas para comparar vecindad y posición, y la tabla de masa de las dos distribuciones a distancias crecientes.

Qué NO implementa: no hay perplejidad ajustada por punto, ni exageración temprana, ni aproximación de Barnes-Hut. Con quince puntos se ve el mecanismo, no el comportamiento a escala.

```
ai-evolution paper-lab P83 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Explica en qué consiste el problema del apiñamiento.
Explicar	Explica por qué una cola pesada en el mapa lo resuelve.
Aplicar	Ejecuta el notebook y compara las dos ejecuciones.
Analizar	Analiza qué preserva t-SNE y qué no.
Evaluar	«Estos dos grupos están lejos en el mapa, luego son muy distintos». Evalúa la afirmación.
Crear	Aplica t-SNE a datos reales con dos perplejidades y dos semillas, y documenta qué conclusiones sobreviven a los cuatro mapas.

16. Autoevaluación

1. ¿Qué es el problema del apiñamiento?
2. ¿Qué distribución usa t-SNE en el mapa y por qué?
3. ¿Qué preserva t-SNE?
4. ¿Qué NO preserva?
5. ¿Es determinista?
6. ¿Se puede usar para transformar datos nuevos?
7. ¿Qué hiperparámetro es el más importante?

17. Respuestas esperadas

1. Que en dimensión alta hay muchísimo más volumen lejos que cerca, y al proyectar a dos dimensiones todos los puntos moderadamente lejanos se apiñan en el centro.
2. Una t de Student con un grado de libertad. Su cola pesada deja mucha más masa a distancias grandes — a distancia 8, del orden de 10^{12} veces más que una gaussiana—, lo que permite separar grupos sin comprimir el centro.
3. La **vecindad**: qué puntos están cerca de qué otros. En la miniatura, dos ejecuciones distintas conservan la misma proporción de vecinos.
4. Las distancias entre grupos, el tamaño aparente de los grupos y las posiciones absolutas. Ninguna de las tres cosas está restringida por el objetivo.
5. No. Depende de la inicialización aleatoria: en la miniatura, dos semillas producen un desplazamiento medio de 2,85 con los mismos vecinos.
6. No. No aprende una transformación aplicable: optimiza las posiciones de estos puntos concretos. Usar sus coordenadas como rasgos de un modelo es un error frecuente.

7. La perplejidad, que fija cuántos vecinos efectivos considera cada punto. El propio artículo recomienda explorar varios valores.

18. Fuentes primarias

- Van der Maaten, L. y Hinton, G. (2008). *Visualizing Data using t-SNE*. **JMLR**, 9, 2579–2605. JMLR · consultado 2026-08-17.
- Wattenberg, M., Viégas, F. y Johnson, I. (2016). *How to Use t-SNE Effectively*. doi:10.23915/distill.00002 · consultado 2026-08-17.
- McInnes, L., Healy, J. y Melville, J. (2018). *UMAP: Uniform Manifold Approximation and Projection*. arXiv:1802.03426 · consultado 2026-08-17.



Evaluación — P83 · Visualizar datos con t-SNE

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Visualizing Data using t-SNE* (2008, Journal of Machine Learning Research, 9, 2579–2605) · **Nivel:** L3

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P83_tsne.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).