

P84

Bosque de aislamiento

Isolation Forest

Fei Tony Liu, Kai Ming Ting, Zhi-Hua Zhou · 2008 · ICDM 2008, 413–422

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-17.

P84 — Bosque de aislamiento

Ruta clásica · Da la vuelta a la detección de anomalías: en vez de modelar lo normal, mide cuántos cortes al azar hacen falta para dejar cada punto solo.

Nivel: L2 · **Motor:** `isolation_forest` · **Notebook:** `P84_isolation_forest.ipynb` · **Anexo:** complejidad y coste

1. Identificación

Campo	Valor
Título original	<i>Isolation Forest</i>
Autoría	Fei Tony Liu, Kai Ming Ting, Zhi-Hua Zhou
Año	2008
Venue	ICDM 2008, 413–422
Fuente primaria	doi:10.1109/ICDM.2008.17
Acceso	Restringido
Fecha de consulta	2026-08-17

2. Problema anterior

Todos los métodos de detección de anomalías hacían lo mismo: construir un modelo de lo **normal** —una densidad, un conjunto de vecindades, un perfil— y medir la distancia a ese modelo.

Eso tiene tres costes. Es caro: modelar bien la normalidad requiere estimar densidades o calcular distancias entre todos los pares. Supone una forma para la distribución normal, que puede ser falsa. Y dedica casi todo el esfuerzo computacional a caracterizar los puntos que **no interesan**, porque las anomalías son pocas por definición.

3. Propuesta

No modelar nada. Construir árboles cortando el espacio al azar —una variable al azar, un umbral al azar dentro de su rango— y contar **cuántos cortes hacen falta para dejar cada punto solo**.

La intuición es directa: un punto en una zona densa necesita muchos cortes para quedar aislado, porque siempre hay vecinos al otro lado. Un punto raro está en una región poco poblada y un corte cualquiera lo separa enseguida.

La longitud media del camino sobre muchos árboles, normalizada por la longitud esperada en un árbol de búsqueda binaria, da la puntuación de anomalía. Y el coste es lineal, con submuestras pequeñas.

4. Intuición sin fórmulas

Encontrar al que no encaja en una fiesta. No hace falta un perfil del invitado típico: basta con ir dividiendo la sala por criterios arbitrarios —los de camisa clara a un lado, los altos al otro—. Quien se queda solo en dos o tres divisiones es el que desentona.

Dónde deja de funcionar la analogía: funciona con quien desentona **globalmente**. Alguien que está en medio de un grupo pero se comporta distinto no se queda solo antes que los demás: este método no lo ve, y hace falta otra idea.

5. Matemática mínima

$h(x)$

= número de cortes aleatorios hasta aislar x

$E[h(x)]$

= media sobre los árboles del bosque

$c(m)$

$= 2 \cdot H(m-1) - 2(m-1)/m$

← camino medio en un árbol binario con m nodos

(H = número armónico)

$s(x)$

$= 2^{(-E[h(x)] / c(m))}$

$s \rightarrow 1$

se aísla enseguida

→ anomalía

$s \approx 0,5$

camino medio

→ normal

La miniatura, con 60 puntos normales, 3 anómalos y 40 árboles sobre submuestras de 32:


Medida	Normales	Anómalos
longitud media de camino	6,64	2,27
puntuación media	0,471	0,772

Y en el ranking por puntuación, las **3 de 3** anomalías reales aparecen en las tres primeras posiciones.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A05 §1 · Notación $O()$: qué dice y qué no	por qué el coste lineal frente al cuadrático cambia qué problemas son abordables

6. Arquitectura o flujo



7. Qué observar en el paper original

- La **inversión conceptual**, enunciada en la introducción: aislar en vez de modelar. Es toda la aportación y cabe en una frase.

- El análisis del **submuestreo**: usar submuestras pequeñas —128 puntos por árbol— no solo es más barato, sino que **mejora** la detección al reducir el enmascaramiento entre anomalías cercanas.
- La **normalización por $c(m)$** , que hace comparables las puntuaciones entre conjuntos de distinto tamaño.
- El límite de altura $\lceil \log_2 m \rceil$: no hace falta aislar del todo los puntos normales, basta con saber que están lejos de aislarse.

8. Evidencia y resultados

Comparación con métodos de la época —LOF, ORCA, técnicas de una clase— sobre conjuntos de referencia, midiendo AUC y tiempo de ejecución.

El resultado más citado es el de **coste**: tiempo lineal y memoria constante frente a métodos cuadráticos, con detección comparable o mejor en anomalías globales.

La miniatura reproduce el mecanismo con anomalías muy separadas. Confirma la separación de caminos y el ranking; no dice nada sobre el caso difícil, que es el de las anomalías locales.

9. Impacto

- Es hoy uno de los métodos por defecto de detección de anomalías, disponible en las bibliotecas estándar y usado en producción para fraude, mantenimiento predictivo y detección de intrusiones.
- Su **coste lineal** lo hizo aplicable a volúmenes donde los métodos basados en distancias eran impensables.
- La idea de que **el submuestreo mejora** —y no solo abarata— fue contraintuitiva y generó literatura propia.
- Es también un buen ejemplo metodológico: replantear la pregunta suele rendir más que optimizar la respuesta a la pregunta anterior.

10. Limitaciones

1. **Anomalías locales.** Un punto dentro de la nube con densidad distinta no se aísla antes que sus vecinos. Para eso está LOF, con otra idea.
2. **Cortes paralelos a los ejes.** Las anomalías que solo lo son en una dirección oblicua se detectan peor; la variante *extended isolation forest* lo corrige.
3. **No da un umbral.** La puntuación ordena; decidir dónde cortar exige conocer o suponer la proporción de anomalías.
4. **Sensible a variables irrelevantes:** si la mayoría de las variables son ruido, los cortes al azar caen casi siempre en ellas.
5. **No explica** por qué un punto es anómalo, solo que se aísla pronto.

11. Errores comunes

Error	Corrección
«Detecta cualquier tipo de anomalía»	Detecta bien las globales —puntos alejados de todo— y mal las locales, que viven dentro de la nube con densidad distinta.
«Hay que usar todos los datos en cada árbol»	El artículo muestra que submuestras pequeñas (≈ 128) funcionan mejor: reducen el enmascaramiento entre anomalías cercanas y abaratan el cálculo.
«La puntuación es una probabilidad»	Es un valor en $(0, 1)$ construido para ordenar. No corresponde a ninguna frecuencia y no está calibrado.
«Necesita datos etiquetados»	Es completamente no supervisado: no ve etiquetas en ningún momento. Las etiquetas solo hacen falta para evaluarlo.
«Modela la distribución normal de los datos»	No modela nada. Esa es la inversión conceptual del artículo: mide directamente la facilidad de aislamiento.

12. Relación con trabajos anteriores

- **Breunig et al. (2000)** — LOF: el factor de anomalía local, el método de referencia anterior y el que sí ve las anomalías locales. doi:10.1145/335191.335388
- **P79 Bosques aleatorios (2001)** — la estructura de conjunto de árboles con cortes aleatorios, aquí llevada al caso no supervisado.

13. Relación con trabajos posteriores

- **Liu, Ting y Zhou (2012)** — la versión extendida con el análisis del submuestreo. doi:10.1145/2133360.2133363
- **Hariri et al. (2019)** — *extended isolation forest*: cortes no paralelos a los ejes.
- **P42 Ejemplos adversarios (2014)** — el problema inverso: puntos contruidos para NO parecer anómalos.

14. Notebook asociado

P84_isolation_forest.ipynb

Qué implementa: la construcción de árboles con cortes aleatorios, la longitud media de camino por punto, la puntuación normalizada y el ranking con las anomalías reales marcadas.

Qué NO implementa: no implementa el límite de altura $\lceil \log_2 m \rceil$ ni el submuestreo exacto del artículo, y usa anomalías muy separadas. El caso de anomalías locales, que es donde el método falla, no está.

```
ai-evolution paper-lab P84 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Explica qué mide $h(x)$.
Explicar	Explica por qué un punto anómalo se aísla con menos cortes.
Aplicar	Ejecuta el notebook y compara las longitudes medias de camino.
Analizar	Analiza por qué el submuestreo puede mejorar la detección y no solo abaratarla.
Evaluar	«La puntuación 0,8 significa un 80 % de probabilidad de ser anomalía». Evalúa la afirmación.
Crear	Aplica un bosque de aislamiento a un registro real, revisa a mano las veinte primeras posiciones y documenta cuántas eran anomalías de verdad.

16. Autoevaluación

1. ¿Qué inversión conceptual propone el artículo?
2. ¿Qué mide la longitud de camino?
3. ¿Para qué sirve la normalización por $c(m)$?
4. ¿Qué tipo de anomalías detecta bien?
5. ¿Y cuáles detecta mal?
6. ¿Por qué ayuda el submuestreo?
7. ¿Es la puntuación una probabilidad?

17. Respuestas esperadas

1. No modelar la normalidad para medir la distancia a ella, sino medir directamente lo fácil que es aislar cada punto con cortes aleatorios.
2. Cuántos cortes aleatorios hacen falta para dejar el punto solo. En la miniatura, 2,27 de media para los anómalos y 6,64 para los normales.
3. Para hacer comparables las puntuaciones entre conjuntos de distinto tamaño: $c(m)$ es la longitud media esperada en un árbol de búsqueda binaria con m nodos.
4. Las **globales**: puntos alejados de todo, en regiones poco pobladas del espacio.
5. Las **locales**: puntos dentro de la nube pero en una zona de densidad distinta. Para esos hace falta LOF u otra idea.
6. Porque reduce el enmascaramiento: cuando hay varias anomalías cercanas, en la muestra completa se protegen entre sí y ninguna queda aislada pronto. Con submuestras pequeñas es improbable que coincidan.
7. No. Es un valor en $(0, 1)$ construido para ordenar. No está calibrado y no corresponde a ninguna frecuencia observable.

18. Fuentes primarias

- Liu, F. T., Ting, K. M. y Zhou, Z.-H. (2008). *Isolation Forest*. **ICDM 2008**, 413–422. doi:10.1109/ICDM.2008.17 · consultado 2026-08-17.
- Liu, F. T., Ting, K. M. y Zhou, Z.-H. (2012). *Isolation-Based Anomaly Detection*. doi:10.1145/2133360.2133363 · consultado 2026-08-17.

- Breunig, M. et al. (2000). *LOF: Identifying Density-Based Local Outliers*. doi:10.1145/335191.335388 · consultado 2026-08-17.



Evaluación — P84 · Bosque de aislamiento

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Isolation Forest* (2008, ICDM 2008, 413–422) · **Nivel:** L2

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P84_isolation_forest.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).