

P85

Técnicas de factorización matricial para sistemas de recomendación

Matrix Factorization Techniques for Recommender Systems

Yehuda Koren, Robert Bell, Chris Volinsky · 2009 · IEEE Computer, 42(8), 30–37

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-17.

P85 — Factorización matricial

Ruta clásica · Predecir en una matriz donde falta casi todo. Y una lección que se salta casi todo el mundo: los sesgos hacen la mitad del trabajo, antes que los gustos.

Nivel: L3 · **Motor:** factorizacion_matricial · **Notebook:** P85_factorizacion_matricial.ipynb · **Anexo:** álgebra y geometría

1. Identificación

Campo	Valor
Título original	Matrix Factorization Techniques for Recommender Systems
Autoría	Yehuda Koren, Robert Bell, Chris Volinsky
Año	2009
Venue	IEEE Computer, 42(8), 30–37
Fuente primaria	doi:10.1109/MC.2009.263
Acceso	Restringido
Fecha de consulta	2026-08-17

2. Problema anterior

Una matriz de usuarios por artículos con el 99 % de las celdas vacías. Hay que predecir las que faltan.

Los métodos por **vecindad** —buscar usuarios parecidos y promediar sus notas— eran los estándar y tenían dos problemas: escalaban mal, porque exigen comparar todos los pares, y no capturaban estructura latente. Si a dos usuarios les gustan películas distintas del mismo género, la similitud directa no lo ve.

3. Propuesta

Describir a cada usuario y a cada artículo con un vector de pocos **factores latentes**, y predecir la nota como su producto escalar. Los factores no se declaran: emergen del ajuste.

Dos decisiones hacen que funcione. La primera: ajustar **solo sobre las celdas observadas** con descenso de gradiente estocástico, en vez de rellenar las vacías con la media —que era lo que se hacía y sesgaba todo—. La segunda: incluir **términos de sesgo** explícitos para usuario y artículo, más la media global.

$$\hat{r}(u,i) = \mu + b_u + b_i + p_u \cdot q_i$$

Sin esos sesgos, los factores latentes acaban gastándose en aprender que hay usuarios generosos y artículos populares, en lugar de aprender preferencias.

4. Intuición sin fórmulas

Describir el gusto de alguien con cinco números en vez de con la lista de todo lo que ha visto. Y describir cada película con los mismos cinco ejes. La afinidad es cuánto coinciden.

Nadie decide qué significan esos ejes. Salen del ajuste, y a veces se parecen a géneros y a veces no se parecen a nada nombrable.

Dónde deja de funcionar la analogía: la persona real no tiene cinco números. El modelo tampoco afirma que los tenga: afirma que con cinco números predice bien las notas que faltan, que es una afirmación mucho más modesta y comprobable.

5. Matemática mínima

$$\hat{r}(u,i) = \mu + b_u + b_i + p_u \cdot q_i$$

$$\text{minimizar } \sum_{\{(u,i) \text{ observadas}\}} (r(u,i) - \hat{r}(u,i))^2 + \lambda(\|p_u\|^2 + \|q_i\|^2 + b_u^2 + b_i^2)$$

Actualización por descenso estocástico, para cada observación:

$$e \leftarrow r - \hat{r}$$

$$b_u \leftarrow b_u + \gamma(e - \lambda \cdot b_u) \quad p_u \leftarrow p_u + \gamma(e \cdot q_i - \lambda \cdot p_u)$$

$$b_i \leftarrow b_i + \gamma(e - \lambda \cdot b_i) \quad q_i \leftarrow q_i + \gamma(e \cdot p_u - \lambda \cdot q_i)$$

La miniatura entrena sobre el 54 % de una matriz de 12×8 y evalúa sobre las celdas ocultas:


Modelo	RMSE fuera de muestra
predecir siempre la media	0,7989
solo sesgos de usuario y artículo	0,5786
dos factores latentes + sesgos	0,3691

Los sesgos recorren más de la mitad del camino antes de que aparezca ningún «gusto». Sin esas dos líneas base, un RMSE suelto no dice nada.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A01 §1 · Producto escalar	qué mide $p_u \cdot q_i$ y por qué un producto escalar alto significa afinidad

6. Arquitectura o flujo



7. Qué observar en el paper original

- La insistencia en los **sesgos**. Es la parte más práctica del artículo y la que menos se cita: modelar primero lo aburrido.
- El **descenso estocástico sobre las celdas observadas**, frente a rellenar las vacías. Es la decisión que hace viable el método a escala.
- La discusión sobre **dinámica temporal**: los gustos cambian, y modelar la deriva mejoró sustancialmente los resultados en el Netflix Prize.
- La distinción entre **realimentación explícita** (notas) e **implícita** (qué se vio, qué se saltó), y cómo incorporarla.

8. Evidencia y resultados

Resultados sobre el conjunto del Netflix Prize, con la progresión de RMSE al añadir cada componente: media, sesgos, factores, dinámica temporal, realimentación implícita.

El artículo es una síntesis divulgativa de varios trabajos técnicos del equipo ganador, escrita para *IEEE Computer*. Es de las mejores puertas de entrada al tema que existen.

La miniatura reproduce el modelo básico —sesgos más factores— sobre una matriz de juguete donde el mecanismo se conoce, para que las dos líneas base sean comparables de verdad.

9. Impacto

- Es la base de los sistemas de recomendación durante una década, y sigue siendo la línea base obligatoria antes de intentar nada más complejo.
- El **Netflix Prize** que documenta cambió la práctica del campo: conjuntos abiertos, evaluación común y competición pública.
- La idea de **factores latentes aprendidos** conecta directamente con los embeddings de word2vec: representar entidades con vectores densos cuyas dimensiones no se declaran.
- Y su lección sobre las líneas base es transferible a cualquier problema: sin ellas, una métrica no se puede interpretar.

10. Limitaciones

1. **Arranque en frío**. Un usuario o artículo nuevo no tiene observaciones y el modelo no puede decir nada. Es el problema práctico más común y el artículo lo trata solo parcialmente.

2. **El RMSE no es calidad de recomendación.** Ordenar bien los diez primeros y acertar la nota son objetivos distintos. Netflix nunca desplegó el modelo ganador.
3. **Los factores no son interpretables** salvo por inspección, y esa interpretación es a posteriori.
4. **Supone que faltan al azar**, y no es cierto: la gente puntúa lo que ve, y ve lo que le recomiendan.
5. **No modela el efecto de la propia recomendación** sobre el comportamiento futuro, que es un bucle de realimentación real.

11. Errores comunes

Error	Corrección
«Los factores latentes corresponden a géneros»	A veces se parecen y a veces no. No hay ninguna garantía: son direcciones que minimizan el error, no categorías.
«Se puede rellenar con la media y factorizar»	Eso sesga la solución hacia la media. La aportación práctica es ajustar SOLO sobre las celdas observadas.
«Los sesgos son un detalle»	En la miniatura recorren más de la mitad del camino: de 0,7989 a 0,5786 antes de que aparezca ningún factor latente.
«Un RMSE bajo implica buenas recomendaciones»	El RMSE mide error de predicción de nota. La calidad de una lista de recomendaciones depende del orden, la diversidad y la novedad.
«Ganó el Netflix Prize, luego se usó en producción»	Netflix no desplegó el modelo ganador: el coste de ingeniería no compensaba la mejora sobre las métricas que de verdad les importaban.

12. Relación con trabajos anteriores

- **P53 PCA (1901)** — la descomposición en factores, aquí adaptada a una matriz con huecos.
- **Sarwar et al. (2001)** — el filtrado colaborativo por artículos, el método al que reemplaza.
- **P77 Lasso (1996)** — la regularización sin la cual estos modelos sobreajustan de inmediato.

13. Relación con trabajos posteriores

- **Bell y Koren (2007)** — las lecciones técnicas del Netflix Prize. doi:10.1145/1345448.1345465
- **P05 word2vec (2013)** — la misma idea de representar entidades con vectores densos aprendidos, aplicada al lenguaje.
- **Rendle et al. (2019)** — las líneas base bien ajustadas siguen ganando a muchos métodos neuronales. doi:10.1145/3298689.3347058
- **P11 RAG (2020)** — recuperar por similitud en un espacio de representación: el mismo mecanismo, otro problema.

14. Notebook asociado

P85_factorizacion_matricial.ipynb

Qué implementa: el descenso estocástico sobre celdas observadas con sesgos y regularización, y la comparación contra dos líneas base —media global y solo sesgos— en las celdas ocultas.

Qué NO implementa: no hay arranque en frío, ni dinámica temporal, ni realimentación implícita, ni métricas de ranking. La matriz es de 12×8 con densidad mucho mayor que la real.

```
ai-evolution paper-lab P85 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe la fórmula de predicción con sus cuatro términos.
Explicar	Explica por qué se ajusta solo sobre las celdas observadas.
Aplicar	Ejecuta el notebook y compara las tres líneas.
Analizar	Analiza por qué los sesgos deben modelarse antes que los factores.
Evaluar	«El RMSE bajó, luego las recomendaciones son mejores». Evalúa la afirmación.
Crear	Implementa la factorización sobre un conjunto público, con regularización elegida por validación, y compárala con un recomendador por popularidad.

16. Autoevaluación

1. ¿Qué representan los factores latentes?
2. ¿Por qué no se rellenan las celdas vacías?
3. ¿Qué aportan los términos de sesgo?
4. ¿Qué es el arranque en frío?
5. ¿Mide el RMSE la calidad de una recomendación?
6. ¿Qué supone el modelo sobre las celdas que faltan?
7. ¿Con qué idea posterior conecta directamente?

17. Respuestas esperadas

1. Direcciones en un espacio de pocas dimensiones que resumen a usuarios y artículos. Nadie las declara: emergen del ajuste, y a veces se parecen a géneros y a veces no.
2. Porque rellenar con la media sesga la solución hacia ella. Ajustar solo sobre lo observado, con descenso estocástico, es lo que hace el método viable y correcto.
3. Capturan que hay usuarios que puntúan alto todo y artículos que gustan a todos. En la miniatura recorren más de la mitad del camino: de RMSE 0,7989 a 0,5786.
4. Que un usuario o un artículo nuevo no tiene observaciones, y el modelo no puede predecir nada para él. Es el problema práctico más frecuente.
5. No. Mide el error al predecir la nota. La calidad de una lista depende del orden de los primeros elementos, de la diversidad y de la novedad, que son otros objetivos.
6. Que faltan al azar, y no es cierto: la gente puntúa lo que ve, y ve lo que le recomiendan. Ese sesgo de selección no está modelado.
7. Con los embeddings de word2vec: representar entidades mediante vectores densos aprendidos cuyas dimensiones no se declaran de antemano.

18. Fuentes primarias

- Koren, Y., Bell, R. y Volinsky, C. (2009). *Matrix Factorization Techniques for Recommender Systems*. **IEEE Computer**, 42(8), 30–37. doi:10.1109/MC.2009.263 · consultado 2026-08-17.
- Bell, R. y Koren, Y. (2007). *Lessons from the Netflix Prize Challenge*. doi:10.1145/1345448.1345465 · consultado 2026-08-17.
- Rendle, S. et al. (2019). *On the Difficulty of Evaluating Baselines*. doi:10.1145/3298689.3347058 · consultado 2026-08-17.



Evaluación — P85 · Técnicas de factorización matricial para sistemas de recomendación

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Matrix Factorization Techniques for Recommender Systems* (2009, IEEE Computer, 42(8), 30–37) · **Nivel:** L3

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P85_factorizacion_matricial.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).