

P95

Las siete herramientas de la inferencia causal, con reflexiones sobre aprendizaje automático

The Seven Tools of Causal Inference, with Reflections on Machine Learning

Judea Pearl · 2019 · Communications of the ACM, 62(3), 54–60

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-17.

P95 — Herramientas causales

Ruta probabilística · Ver no es hacer. Tres peldaños —asociar, intervenir, imaginar— y ninguna cantidad de datos permite subir del primero sin declarar supuestos.

Nivel: L3 · Motor: causalidad · Notebook: P95_causalidad.ipynb · Anexo: probabilidad y verosimilitud

1. Identificación

Campo	Valor
Título original	<i>The Seven Tools of Causal Inference, with Reflections on Machine Learning</i>
Autoría	Judea Pearl
Año	2019
Venue	Communications of the ACM, 62(3), 54–60
Fuente primaria	doi:10.1145/3241036
Acceso	Abierto
Fecha de consulta	2026-08-17

2. Problema anterior

El aprendizaje automático ajusta funciones sobre distribuciones observadas. Con eso responde preguntas de **asociación**: qué esperar de Y cuando se ve X .

Pero las decisiones que importan son de **intervención**: qué pasa con Y si **hago** X . Y esas dos preguntas tienen respuestas distintas cuando hay confusores — variables que influyen a la vez en quién recibe el tratamiento y en el resultado.

Ninguna cantidad de datos observacionales distingue un caso del otro. Es una limitación estructural, no de tamaño de muestra ni de capacidad del modelo.

3. Propuesta

La **escalera de la causalidad**, con tres peldaños que exigen cada vez más:

1. ASOCIACIÓN	$P(Y \mid X)$	ver	lo que hace el aprendizaje automático
2. INTERVENCIÓN	$P(Y \mid \text{do}(X))$	hacer	exige el grafo causal
3. CONTRAFÁCTICO	$P(Y_x \mid X', Y')$	imaginar	exige el modelo estructural completo

Y siete herramientas para operar en los peldaños superiores: modelos gráficos, el operador `do`, el criterio de puerta trasera, la fórmula de ajuste, el análisis de mediación, la transportabilidad entre poblaciones y el tratamiento de datos faltantes.

La tesis central: la estructura causal se **declara**, no se estima de la tabla.

4. Intuición sin fórmulas

Los termómetros y la fiebre. Ver un termómetro alto predice fiebre perfectamente. Romper el termómetro no cura a nadie.

La correlación es idéntica en los dos casos; la consecuencia de intervenir, opuesta. Y no hay forma de distinguirlas mirando más lecturas de termómetro.

Dónde deja de funcionar la analogía: aquí sabemos cuál causa a cuál. En un problema real esa es justamente la pregunta, y responderla exige conocimiento del dominio, experimentos o supuestos defendidos — nunca solo datos observacionales.

5. Matemática mínima

Confusor: variable que influye en el tratamiento Y en el resultado

Fórmula de ajuste (criterio de puerta trasera):
$$P(Y \mid \text{do}(X)) = \sum_z P(Y \mid X, Z = z) \cdot P(Z = z)$$

dentro de cada estrato

ponderado por la población total

La miniatura reproduce la **paradoja de Simpson** con un tratamiento y dos grupos de gravedad:


Grupo	Tasa con tratamiento	Tasa sin tratamiento	¿Gana el tratamiento?
leves	0,931	0,8667	sí
graves	0,730	0,6875	sí
agregado	0,780	0,8257	no
tras ajustar por gravedad	0,8325	0,7789	sí

Gana en los dos subgrupos y pierde en el total. Los tres números son correctos. Cuál hay que creer depende de si la gravedad es **causa** del tratamiento —hay que ajustar— o **consecuencia** suya —ajustar sería el error—. Los datos son idénticos en ambos casos.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A02 §3 · Verosimilitud y entropía cruzada	qué es exactamente una probabilidad condicional, y por qué $P(Y X)$ no es $P(Y \text{do}(X))$

6. Arquitectura o flujo



7. Qué observar en el paper original

- La formulación de los **tres peldaños** y el argumento de por qué no se puede subir sin información externa a los datos. Es el núcleo del artículo.
- El **criterio de puerta trasera**: qué conjunto de variables hay que ajustar y cuál no. Ajustar de más también es un error, y eso sorprende a casi todo el mundo.
- Las **reflexiones sobre aprendizaje automático** de la segunda mitad: qué le falta a un modelo que solo ajusta distribuciones, y por qué el tamaño no lo resuelve.
- La distinción entre **mediación** y **confusión**, que se confunden a menudo y llevan a ajustes opuestos.

8. Evidencia y resultados

Es un artículo de posición y síntesis en una revista de divulgación técnica. Presenta el marco y las herramientas; las demostraciones están en la literatura previa del autor.

No hay experimentos. Su fuerza es la claridad del marco y la precisión con la que separa lo que se puede y no se puede concluir de datos observacionales.

La miniatura construye un caso de Simpson con números elegidos para que la inversión sea nítida, y muestra que ninguna operación sobre la tabla decide cuál lectura es la correcta.

9. Impacto

- La escalera de la causalidad se ha convertido en vocabulario común para discutir qué puede y no puede responder un sistema de aprendizaje automático.
- Empujó el interés por la **inferencia causal** en aprendizaje automático: representaciones causales, generalización fuera de distribución, robustez ante cambios de entorno.

- Da un criterio operativo para leer cualquier resultado observacional: preguntar qué grafo se está suponiendo, y si ese supuesto se ha declarado.
- Y cierra el círculo con P91: el mismo grafo que hace tratable la inferencia probabilística es el que permite distinguir ver de hacer.

10. Limitaciones

1. **El grafo hay que ponerlo**, y en la mayoría de los problemas reales no se conoce. El artículo no resuelve cómo descubrirlo.
2. **El ajuste correcto depende del grafo supuesto**. Con otro grafo, ajustar por la misma variable puede ser el error.
3. **El tercer peldaño exige el modelo estructural completo**, mucho más que un grafo, y rara vez está disponible.
4. **La comunidad de resultados potenciales (Rubin) discute** parte del énfasis y del vocabulario; los dos marcos son en buena medida traducibles y la disputa es más de estilo de lo que parece.
5. **Es un artículo programático**: enuncia herramientas, no las enseña. Para aplicarlas hace falta la literatura técnica.

11. Errores comunes

Error	Corrección
«Con suficientes datos se puede inferir causalidad»	No de datos puramente observacionales. La paradoja de Simpson se vuelve más nítida con más datos, no desaparece.
«Correlación no implica causalidad, y ya está»	El artículo va mucho más allá: da las condiciones bajo las cuales sí se puede estimar un efecto causal de datos observacionales, y cuáles son.
«Ajustar por todas las variables disponibles es lo seguro»	Ajustar por un mediador o por un colisionador introduce sesgo. Qué ajustar depende del grafo, y ajustar de más también es un error.
«El aprendizaje automático resolverá esto con más capacidad»	Es una limitación estructural del primer peldaño, no de capacidad. Un modelo más grande ajusta mejor la misma distribución observada.
«Los contrafácticos se calculan con el grafo»	El tercer peldaño exige el modelo estructural completo —las ecuaciones, no solo las flechas—, y eso rara vez se tiene.

12. Relación con trabajos anteriores

- **P91 Redes bayesianas (1986)** — el mismo grafo, usado para inferencia probabilística en vez de causal.
- **Rubin (1974)** — el marco de resultados potenciales: la otra tradición de la inferencia causal.
- **P80 Las dos culturas (2001)** — la advertencia sobre interpretar modelos ajustados como si describieran mecanismos.

13. Relación con trabajos posteriores

- **Pearl y Mackenzie** — *The Book of Why*: la versión divulgativa del programa. bayes.cs.ucla.edu/WHY

- **Schölkopf et al. (2021)** — hacia el aprendizaje de representaciones causales.
doi:10.1109/JPROC.2021.3058954
- **P72 Neuro-simbólico (2020)** — la otra propuesta de incorporar conocimiento estructurado a lo que se aprende de datos.

14. Notebook asociado

P95_causalidad.ipynb

Qué implementa: la escalera de la causalidad con sus tres operaciones, una paradoja de Simpson completa con la inversión de signo, y el ajuste por el confusor con la fórmula de puerta trasera.

Qué NO implementa: no hay descubrimiento de estructura causal, ni criterio de puerta trasera implementado en general, ni contrafácticos —que exigen el modelo estructural completo—.

```
ai-evolution paper-lab P95 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Enumera los tres peldaños de la escalera y su operación.
Explicar	Explica qué es un confusor.
Aplicar	Ejecuta el notebook y comprueba la inversión de signo.
Analizar	Analiza por qué ajustar por la gravedad es correcto solo bajo un supuesto causal concreto.
Evaluar	«Con más datos la paradoja de Simpson desaparece». Evalúa la afirmación.
Crear	Toma una decisión de tu trabajo justificada por una correlación, dibuja el grafo causal que estás suponiendo sin decirlo y comprueba si el ajuste cambia la conclusión.

16. Autoevaluación

1. ¿Cuáles son los tres peldaños de la escalera?
2. ¿Qué diferencia hay entre $P(Y|X)$ y $P(Y|\text{do}(X))$?
3. ¿Qué es la paradoja de Simpson?
4. ¿Qué decide cuál lectura es la correcta?
5. ¿Es seguro ajustar por todas las variables?
6. ¿Puede el aprendizaje automático subir de peldaño con más datos?
7. ¿Qué exige el tercer peldaño?

17. Respuestas esperadas

1. Asociación — $P(Y|X)$, ver—, intervención — $P(Y|\text{do}(X))$, hacer— y contrafáctico — $P(Y_{\neg x}|X', Y')$, imaginar lo que habría pasado—.

2. El primero es la distribución observada de Y entre quienes tienen X . El segundo es lo que ocurriría si se **impusiera** X , eliminando las causas que normalmente determinan quién lo recibe.
3. Que una asociación puede invertir su signo al agregar o desagregar por un tercer factor. En la miniatura el tratamiento gana en los dos subgrupos y pierde en el total.
4. Un supuesto causal declarado fuera de los datos: si la gravedad causa el tratamiento hay que ajustar; si es consecuencia suya, ajustar es el error. Los números son idénticos en ambos casos.
5. No. Ajustar por un mediador o por un colisionador introduce sesgo. El criterio de puerta trasera dice exactamente qué conjunto ajustar.
6. No. Es una limitación estructural del primer peldaño. Más datos y más capacidad ajustan mejor la misma distribución observada, que no contiene la respuesta.
7. El modelo estructural completo: las ecuaciones que generan cada variable, no solo el grafo de quién influye en quién.

18. Fuentes primarias

- Pearl, J. (2019). *The Seven Tools of Causal Inference, with Reflections on Machine Learning*. **Communications of the ACM**, 62(3), 54–60. doi:10.1145/3241036 · consultado 2026-08-17.
- Pearl, J. y Mackenzie, D. *The Book of Why*. bayes.cs.ucla.edu/WHY · consultado 2026-08-17.
- Schölkopf, B. et al. (2021). *Toward Causal Representation Learning*. doi:10.1109/JPROC.2021.3058954 · consultado 2026-08-17.

Evaluación — P95 · Las siete herramientas de la inferencia causal, con reflexiones sobre aprendizaje automático

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *The Seven Tools of Causal Inference, with Reflections on Machine Learning* (2019, Communications of the ACM, 62(3), 54–60) · **Nivel:** L3

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P95_causalidad.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).