

P96

Un nuevo enfoque para los problemas de filtrado y predicción lineales

A New Approach to Linear Filtering and Prediction Problems

Rudolf E. Kálmán · 1960 · Journal of Basic Engineering, 82(1), 35–45

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-17.

P96 — Filtro de Kalman

Ruta encarnada · Fusiona un modelo y un sensor ponderando cada uno por su propia incertidumbre. Y esa ponderación se ajusta sola, paso a paso.

Nivel: L3 · Motor: kalman · Notebook: P96_kalman.ipynb · Anexo: probabilidad y verosimilitud

1. Identificación

Campo	Valor
Título original	<i>A New Approach to Linear Filtering and Prediction Problems</i>
Autoría	Rudolf E. Kálmán
Año	1960
Venue	Journal of Basic Engineering, 82(1), 35–45
Fuente primaria	doi:10.1115/1.3662552
Acceso	Restringido
Fecha de consulta	2026-08-17

2. Problema anterior

Un vehículo tiene dos fuentes de información sobre dónde está, y las dos mienten. El modelo del movimiento predice bien a corto plazo y acumula error sin límite. El sensor no acumula error pero es ruidoso en cada lectura.

Promediarlos trata igual a las dos fuentes, e ignora que la confianza en cada una cambia con el tiempo. Y el filtrado óptimo de Wiener, que sí resolvía el problema, exigía procesar todo el historial de señal y suponer estacionariedad — impracticable a bordo de nada.

3. Propuesta

Mantener dos cosas: la estimación del estado y **su varianza**. Con ellas, el ciclo es:

```
Predecir:  x̂ ← f(x, u)          P ← P + Q
Corregir:  K ← P / (P + R)      x ← x̂ + K · (z - x̂)    P ← (1 - K) · P
```

La **ganancia** K no es un parámetro que se ajuste: sale del cociente entre la incertidumbre del modelo y la del sensor. Si el sensor es malo, K baja sola y el filtro le hace menos caso.

Y es **recursivo**: solo necesita el estado anterior, no el historial. Cabe en la memoria de un ordenador de vuelo de 1969.

4. Intuición sin fórmulas

Caminar por casa a oscuras. Sabes cuántos pasos has dado desde la puerta —tu modelo— y de vez en cuando tocas un mueble —tu sensor—. Ninguna de las dos cosas es exacta.

Al principio confías en el conteo, porque acabas de salir de un sitio conocido. Cuanto más andas, menos vale el conteo y más caso haces a lo que tocas.

Dónde deja de funcionar la analogía: tú decides a ojo cuánto fiarte de cada cosa. El filtro lo calcula, y ese cálculo es exacto —óptimo, de hecho— si el sistema es lineal y el ruido gaussiano.

5. Matemática mínima

Predicción: $\hat{x}_k = A \cdot x_{k-1} + B \cdot u_k$

Ganancia: $K_k = P_k^- \cdot H^T (H \cdot P_k^- \cdot H^T + R)^{-1}$

Corrección: $x_k = \hat{x}_k + K_k(z_k - H \cdot \hat{x}_k)$

$P_k^- = A \cdot P_{k-1} \cdot A^T + Q$

$P_k = (I - K_k \cdot H) \cdot P_k^-$

Q = covarianza del proceso

R = covarianza del sensor

La miniatura sigue una posición durante 40 pasos:


Estrategia	Error
solo el sensor	1,8895
solo el modelo	0,7943
media móvil de 5	2,2179
filtro de Kalman	0,4559

El filtro no usa ninguna información adicional: las mismas dos fuentes, mejor combinadas. Y la ganancia arranca en **0,208** y baja a **0,106**; con un sensor diez veces peor, cae sola a **0,034**.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A02 §3 · Verosimilitud y entropía cruzada	por qué combinar dos estimaciones ponderando por la inversa de su varianza es lo óptimo

6. Arquitectura o flujo



7. Qué observar en el paper original

- Que el artículo aborda el problema en **espacio de estados**, no en el dominio de la frecuencia como Wiener. Ese cambio de representación es lo que lo hace recursivo y aplicable.
- La **ecuación de Riccati** para la covarianza, y el hecho de que en régimen estacionario la ganancia converge a una constante que se puede precalcular.
- Que el filtro es **óptimo** —mínimo error cuadrático medio— bajo linealidad y ruido gaussiano, y que fuera de esos supuestos deja de tener garantía.
- El contexto: Kálmán presenta el trabajo en ingeniería mecánica, y su adopción llega por la vía de la NASA antes que por la académica.

8. Evidencia y resultados

Es un artículo matemático: deriva las ecuaciones y demuestra la optimalidad bajo sus supuestos, con ejemplos de problemas de predicción.

No hay experimentos. La validación llega con la implementación de Schmidt en el Ames Research Center y su uso en la navegación del programa Apollo, que es lo que hizo famoso al filtro.

La miniatura compara cuatro estimadores sobre los mismos datos ruidosos para exhibir lo único que importa entender: que la ganancia sale de las varianzas y no de un ajuste manual.

9. Impacto

- Es probablemente el algoritmo de estimación más ejecutado del mundo: navegación aérea y marítima, GPS, seguimiento de objetivos, control de procesos, fusión de sensores en cualquier robot.
- Llevó a la Luna literalmente: la navegación del Apollo lo usaba.
- Sus variantes —extendido, unscented, filtros de partículas— cubren el caso no lineal, y todas heredan esta estructura de predecir y corregir.
- En robótica es la base de SLAM: el mismo mecanismo, con el mapa dentro del vector de estado.

10. Limitaciones

1. **Óptimo solo con sistema lineal y ruido gaussiano.** Fuera de ahí hay que usar variantes que ya no tienen garantía.
2. **Q y R hay que estimarlas.** Ponerlas mal es la causa más frecuente de que un filtro se comporte mal en producción: si R es demasiado optimista, el filtro persigue el ruido.
3. **Diverge en silencio.** Un modelo mal especificado produce estimaciones confiadas y erróneas, con la varianza reportada cada vez más pequeña.
4. **Supone que el modelo del sistema se conoce.** En muchos problemas reales esa es la parte difícil.
5. **Ruido correlacionado en el tiempo** rompe los supuestos, y ocurre constantemente con sensores reales.

11. Errores comunes

Error	Corrección
«El filtro promedia el modelo y el sensor»	Los pondera por sus varianzas, y ese peso cambia en cada paso. En la miniatura la ganancia pasa de 0,208 a 0,106 sin que nadie la toque.
«La ganancia es un hiperparámetro que se ajusta»	Sale del cociente entre las incertidumbres. Lo que sí hay que estimar es Q y R , y ese es el trabajo real.
«Si la varianza reportada es pequeña, la estimación es buena»	Un modelo mal especificado reduce la varianza mientras se aleja de la verdad. La confianza del filtro no es una comprobación independiente.
«Sirve para cualquier sistema»	Es óptimo para sistemas lineales con ruido gaussiano. Con no linealidades fuertes hay que usar el filtro extendido o de partículas, sin garantía de optimalidad.
«Una media móvil hace lo mismo y es más simple»	Trata todas las medidas por igual, ignora que hay un modelo del movimiento e introduce retraso. En la miniatura da 2,2179 frente a 0,4559.

12. Relación con trabajos anteriores

- **Wiener (1949)** — filtrado óptimo en el dominio de la frecuencia: correcto y no recursivo.
- **P87 Teorema de Bayes (1763)** — el filtro es actualización bayesiana con distribuciones gaussianas.
- **Gauss (1809)** — mínimos cuadrados, el antecedente del criterio que se minimiza.

13. Relación con trabajos posteriores

- **Kalman y Bucy (1961)** — la versión en tiempo continuo. doi:10.1115/1.3658902
- **P99 SLAM (2006)** — el mismo filtro con el mapa dentro del estado.
- **Julier y Uhlmann (1997)** — el filtro *unscented*, para no linealidades fuertes.
- **Grewal y Andrews (2010)** — la historia del filtro en el programa Apollo. doi:10.1109/MCS.2010.936465

14. Notebook asociado

P96_kalman.ipynb

Qué implementa: un filtro de Kalman escalar completo sobre una trayectoria ruidosa, comparado con el sensor solo, el modelo solo y una media móvil, con la evolución de la ganancia y su reacción a un sensor peor.

Qué NO implementa: es escalar y con velocidad conocida: no hay matrices de covarianza, ni estimación conjunta de velocidad, ni el caso no lineal, que es donde vive la dificultad real.

```
ai-evolution paper-lab P96 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe las ecuaciones de predicción y corrección.
Explicar	Explica de dónde sale la ganancia.
Aplicar	Ejecuta el notebook y observa cómo cambia la ganancia con un sensor peor.
Analizar	Analiza por qué la media móvil introduce retraso y el filtro no.
Evaluar	«El filtro reporta poca varianza, luego la estimación es buena». Evalúa la afirmación.
Crear	Implementa un filtro para una señal real de tu trabajo estimando Q y R de los datos, y compáralo con una media móvil.

16. Autoevaluación

1. ¿Qué dos fuentes combina el filtro?
2. ¿Qué es la ganancia y de dónde sale?
3. ¿Por qué es recursivo y por qué importa?
4. ¿Bajo qué supuestos es óptimo?
5. ¿Qué pasa si se estima mal R ?
6. ¿En qué se diferencia de una media móvil?
7. ¿Cómo se extiende a sistemas no lineales?

17. Respuestas esperadas

1. Una predicción del modelo del sistema y una medida del sensor, cada una con su propia incertidumbre.
2. Es el peso que se da a la medida frente a la predicción, y sale del cociente entre la varianza de la predicción y la suma de ambas varianzas. No se ajusta a mano.
3. Porque solo necesita el estado anterior y su varianza, no el historial completo. Eso permitió ejecutarlo en el hardware de los años sesenta, y es la razón de que se adoptara.
4. Sistema lineal y ruido gaussiano de media cero. Bajo esos supuestos minimiza el error cuadrático medio.
5. Si se supone al sensor mejor de lo que es, el filtro le hace demasiado caso y persigue el ruido; si se le supone peor, ignora información útil y se queda con la deriva del modelo.
6. La media móvil pesa todas las medidas por igual, no usa el modelo del movimiento e introduce retraso. El filtro pondera por incertidumbre y predice.
7. Con el filtro extendido —linealizando alrededor de la estimación— o el unscented —propagando puntos sigma—. Ninguno conserva la garantía de optimalidad.

18. Fuentes primarias

- Kálmán, R. E. (1960). *A New Approach to Linear Filtering and Prediction Problems*. **Journal of Basic Engineering**, 82(1), 35–45. doi:10.1115/1.3662552 · consultado 2026-08-17.
- Kalman, R. y Bucy, R. (1961). *New Results in Linear Filtering and Prediction Theory*. doi:10.1115/1.3658902 · consultado 2026-08-17.
- Grewal, M. y Andrews, A. (2010). *Applications of Kalman Filtering in Aerospace 1960 to the Present*. doi:10.1109/MCS.2010.936465 · consultado 2026-08-17.



Evaluación — P96 · Un nuevo enfoque para los problemas de filtrado y predicción lineales

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *A New Approach to Linear Filtering and Prediction Problems* (1960, Journal of Basic Engineering, 82(1), 35–45) · **Nivel:** L3

Parte A — Contexto histórico (20 pts)

- (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
- (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

- (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
- (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

- (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

- (10) Ejecuta `P96_kalman.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
- (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
- (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

- (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
- (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).