

P101

Una reducción del aprendizaje por imitación al aprendizaje en línea sin arrepentimiento

A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning

Stéphane Ross, Geoffrey J. Gordon, J. Andrew Bagnell · 2011 · AISTATS 2011 · arXiv:1011.0686

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-17.

P101 — DAgger

Ruta encarnada · Clonar a un experto parece aprendizaje supervisado y no lo es: el modelo cambia la distribución sobre la que se ejecuta, y el error se acumula.

Nivel: L3 · Motor: dagger · Notebook: P101_dagger.ipynb · Anexo: probabilidad y verosimilitud

1. Identificación

Campo	Valor
Título original	<i>A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning</i>
Autoría	Stéphane Ross, Geoffrey J. Gordon, J. Andrew Bagnell
Año	2011
Venue	AISTATS 2011 · arXiv:1011.0686
Fuente primaria	arXiv:1011.0686
Acceso	Abierto
Fecha de consulta	2026-08-17

2. Problema anterior

La clonación de comportamiento parece aprendizaje supervisado corriente: se recogen pares de estado y acción de un experto y se entrena un modelo a predecir la acción.

El problema no está en el entrenamiento sino en el despliegue. El modelo se entrena con los estados que visita **el experto** y se ejecuta sobre los estados que visita **él mismo**. Un solo error lo lleva a un estado que el experto nunca visitó, donde no tiene ejemplos y comete más errores. La desviación se realimenta, y el error total crece como T^2 con el horizonte.

3. Propuesta

Cerrar el bucle entre las dos distribuciones. En cada iteración:

1. **ejecutar** la política actual y recoger los estados que visita de verdad;
2. **preguntar al experto** cuál sería la acción correcta en esos estados;
3. **reentrenar** sobre el conjunto acumulado de todas las iteraciones.

La distribución de entrenamiento converge así a la de ejecución. El artículo demuestra, reduciendo el problema a aprendizaje en línea sin arrepentimiento, que el error pasa a crecer como T en lugar de T^2 .

4. Intuición sin fórmulas

Aprender a conducir viendo a alguien que conduce perfectamente. Nunca le ves corregir un derrape, porque nunca derrapa. El día que derrapas tú, no tienes ni idea de qué hacer.

Lo que hace DAGger es lo que hace un buen instructor: te deja conducir, y **te corrige en las situaciones a las que tú llegas**, no en las que él llegaría.

Dónde deja de funcionar la analogía: el instructor está en el coche. DAGger necesita poder consultar al experto sobre estados arbitrarios durante el entrenamiento, y en muchos dominios eso es imposible o carísimo.

5. Matemática mínima

Clonación: entrena con d_{π^*} (distribución del experto)
ejecuta sobre d_{π} (distribución de la política)

si el error por paso es ϵ , error total $\sim O(\epsilon \cdot T^2)$

DAGger: el conjunto de entrenamiento converge a d_{π}
error total $\sim O(\epsilon \cdot T)$

La miniatura pone un pasillo de 25 pasos y 5 carriles, con el experto siempre en el central:


Método	Éxito	Cobertura
clonación de comportamiento	264/300 (88 %)	25 estados
DAGger, iteración 1	271/300	25
DAGger, iteración 3	300/300	119 estados

La cobertura pasa de **25 a 119 estados**: los 25 del carril central más los 94 que la política visita cuando se desvía. Con horizonte 100, la diferencia teórica es 10 000 frente a 100.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A02 §3 · Verosimilitud y entropía cruzada	por qué entrenar sobre una distribución y evaluar sobre otra invalida la garantía del aprendizaje supervisado

6. Arquitectura o flujo



7. Qué observar en el paper original

- La **reducción a aprendizaje en línea**: el artículo no analiza DAgger directamente, lo reduce a un problema de arrepentimiento y hereda sus garantías. Es la aportación técnica.
- El análisis de **por qué T^2** : cada error aumenta la probabilidad de estar en un estado no visto, y ese efecto se compone a lo largo del horizonte.
- La discusión de la variante con **mezcla de políticas** (β decreciente): en las primeras iteraciones se ejecuta parcialmente al experto, para no recoger basura.
- Que el resultado se aplica también a **predicción estructurada**, no solo a control. El título lo dice y casi nadie lo cita por eso.

8. Evidencia y resultados

Análisis teórico con las cotas de arrepentimiento, más experimentos sobre videojuegos de conducción y sobre etiquetado de secuencias.

La cota de $O(T)$ es sobre el arrepentimiento acumulado bajo supuestos de convexidad. Trasladarla a un modelo profundo entrenado por descenso de gradiente es una extrapolación razonable, no un teorema aplicado.

La miniatura simula el efecto del cambio de distribución con una tasa de error que depende de si el estado está cubierto. No entrena nada: exhibe el mecanismo.

9. Impacto

- Es la referencia obligada del aprendizaje por imitación, y la explicación estándar de por qué la clonación de comportamiento se degrada.
- Su diagnóstico —entrenar sobre una distribución y ejecutar sobre otra— reaparece en conducción autónoma, en robótica de manipulación y en agentes con modelos de lenguaje que se entrenan con trayectorias de éxito.
- La familia de métodos que sigue —agregación de conjuntos de datos, corrección en línea— es hoy práctica estándar en aprendizaje de políticas a partir de demostraciones.
- Y aporta al programa un criterio de evaluación: una política clonada hay que **ejecutarla** para medirla, no evaluarla sobre las trayectorias del experto.

10. Limitaciones

1. **Exige un experto consultable durante el entrenamiento**, sobre estados arbitrarios. En muchos dominios eso es imposible o inaceptablemente caro.
2. **El experto tiene que ser bueno en estados raros**, incluidos los que él nunca visitaría. Una persona puede no saber qué hacer en un estado absurdo.
3. **La cota es sobre arrepentimiento** bajo supuestos de convexidad; el traslado a modelos profundos es empírico.
4. **El conjunto de entrenamiento crece** en cada iteración, y con él el coste de reentrenar.
5. **No resuelve la calidad del experto**. Si el experto es mediocre, DAgger converge a una política mediocre con más eficiencia.

11. Errores comunes

Error	Corrección
«La clonación de comportamiento es aprendizaje supervisado»	Lo es en el entrenamiento y no en el despliegue: la política cambia la distribución sobre la que se evalúa, y eso rompe la garantía del supervisado.
«Con más demostraciones del experto se arregla»	Más demostraciones cubren mejor la distribución del experto, que es justamente la que no se visita al ejecutar. El problema es de qué estados, no de cuántos.
«Basta con evaluar la política sobre los datos del experto»	Ahí acierta casi siempre. La evaluación honesta es ejecutarla y medir el resultado del episodio: la diferencia entre esas dos cifras es el problema del artículo.
«Dagger elimina el problema»	Reduce el crecimiento del error de T^2 a T . Sigue creciendo con el horizonte, solo que linealmente.
«Sirve siempre que haya un experto»	Hace falta poder consultarlo DURANTE el entrenamiento, sobre estados que él no eligió. Eso es mucho más exigente que tener demostraciones grabadas.

12. Relación con trabajos anteriores

- **Pomerleau (1989)** — ALVINN: conducción autónoma por clonación de comportamiento, el caso original y el que exhibe el problema.
- **P97 Subsunción (1986)** — la alternativa de cablear el comportamiento en vez de aprenderlo.

13. Relación con trabajos posteriores

- **P102 PPO (2017)** — aprender la política de la propia experiencia, sin experto que consultar.
- **Chi et al. (2023)** — *Diffusion Policy*: imitación con modelos generativos, que mitiga parte del problema representando distribuciones multimodales de acción. [arXiv:2303.04137](#)
- **P12 InstructGPT (2022)** — el mismo patrón en modelos de lenguaje: entrenar con demostraciones humanas y después corregir con retroalimentación sobre lo que el modelo genera de verdad.

14. Notebook asociado

P101_dagger.ipynb

Qué implementa: la comparación entre clonación de comportamiento y DAgger sobre un pasillo con carriles, con la evolución de la cobertura de estados y la tasa de éxito por iteración.

Qué NO implementa: no entrena ningún modelo: la política es una moneda sesgada cuya tasa de error depende de si el estado está cubierto. Se simula el efecto del cambio de distribución, no se aprende.

```
ai-evolution paper-lab P101 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Explica por qué la clonación de comportamiento no es aprendizaje supervisado corriente.
Explicar	Describe el ciclo de DAgger en tres pasos.
Aplicar	Ejecuta el notebook y observa la evolución de la cobertura.
Analizar	Analiza por qué el error crece como T^2 y no como T .
Evaluar	«La política acierta el 98 % sobre los datos del experto». Evalúa qué mide esa cifra.
Crear	Entrena una política por clonación sobre un entorno simple, mídela ejecutándola y aplica una iteración de DAgger.

16. Autoevaluación

1. ¿Cuál es el problema estructural de la clonación de comportamiento?
2. ¿Por qué el error crece como T^2 ?
3. ¿Qué hace DAgger en cada iteración?
4. ¿A qué reduce el artículo el problema?
5. ¿Qué exige DAgger que no exige la clonación?
6. ¿Elimina el problema del todo?
7. ¿Cómo hay que evaluar una política clonada?

17. Respuestas esperadas

1. Que se entrena con los estados que visita el experto y se ejecuta sobre los estados que visita ella misma. Un error la saca de la distribución de entrenamiento.
2. Porque cada error aumenta la probabilidad de estar en un estado no visto, donde la tasa de error es mayor, lo que aumenta la probabilidad del siguiente error. El efecto se compone a lo largo del horizonte.
3. Ejecutar la política actual, recoger los estados que visita, pedir al experto la acción correcta en esos estados y reentrenar sobre el conjunto acumulado.
4. A aprendizaje en línea sin arrepentimiento, y de ahí hereda las garantías que dan la cota $O(T)$.
5. Poder consultar al experto **durante** el entrenamiento, sobre estados arbitrarios que la política visita. No basta con tener demostraciones grabadas.
6. No. Reduce el crecimiento del error de T^2 a T : sigue creciendo con el horizonte, pero linealmente.
7. Ejecutándola y midiendo el resultado del episodio. Evaluarla sobre las trayectorias del experto mide algo distinto y siempre sale bien.

18. Fuentes primarias

- Ross, S., Gordon, G. y Bagnell, J. A. (2011). *A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning*. **AISTATS 2011**. arXiv:1011.0686 · consultado 2026-08-17.
- Pomerleau, D. (1989). *ALVINN: An Autonomous Land Vehicle in a Neural Network*. **NeurIPS 1988** · consultado 2026-08-17.
- Chi, C. et al. (2023). *Diffusion Policy: Visuomotor Policy Learning via Action Diffusion*. arXiv:2303.04137 · consultado 2026-08-17.



Evaluación — P101 · Una reducción del aprendizaje por imitación al aprendizaje en línea sin arrepentimiento

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning* (2011, AISTATS 2011 · arXiv:1011.0686) · **Nivel:** L3

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P101_dagger.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).