

P102

Algoritmos de optimización proximal de políticas

Proximal Policy Optimization Algorithms

John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, Oleg Klimov · 2017 · arXiv:1707.06347

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-17.

P102 — PPO

Ruta encarnada · Un lote con una estimación exagerada puede volver la política determinista y dejarla sin capacidad de rectificar. El recorte lo impide en una línea.

Nivel: L3 · Motor: ppo · Notebook: P102_ppo.ipynb · Anexo: probabilidad y verosimilitud

1. Identificación

Campo	Valor
Título original	Proximal Policy Optimization Algorithms
Autoría	John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, Oleg Klimov
Año	2017
Venue	arXiv:1707.06347
Fuente primaria	arXiv:1707.06347
Acceso	Abierto
Fecha de consulta	2026-08-17

2. Problema anterior

En gradiente de políticas, el tamaño del paso es crítico y no hay forma fácil de acertarlo. Un paso pequeño aprende demasiado despacio; uno grande puede volver la política casi determinista.

Y ese fallo no es simétrico: una política saturada deja de explorar, y como el gradiente de la sigmoide se anula en los extremos, **no puede volver**. Un solo lote con una estimación de ventaja exagerada arruina un entrenamiento de horas.

TRPO lo resolvía imponiendo una restricción de divergencia KL entre la política nueva y la vieja, pero exigía una optimización de segundo orden con producto Hessiano-vector: correcta, complicada de implementar y difícil de combinar con arquitecturas modernas.

3. Propuesta

Cambiar la restricción por un **recorte** dentro de la propia función objetivo:

```
r = π_nueva(a|s) / π_vieja(a|s)

L = mín( r·A , clip(r, 1-ε, 1+ε)·A )
```

Con ventaja positiva y r por encima de $1+\epsilon$, el objetivo se queda plano: aumentar más la probabilidad **no aporta nada**, así que el gradiente deja de empujar. Con ventaja negativa, el mínimo hace el trabajo simétrico

por el otro lado.

No hay restricciones, no hay segundo orden, no hay divergencia que calcular. Se optimiza con Adam como cualquier otra pérdida, y se pueden dar varias épocas sobre el mismo lote.

4. Intuición sin fórmulas

Un sistema de recompensas para un equipo. Si premias sin techo el resultado de un solo trimestre, alguien va a apostar todo a una jugada — y si sale mal, ya no hay equipo.

Poner un tope al premio no es desconfianza: es lo que impide que una señal ruidosa de un trimestre destruya la capacidad de reaccionar el siguiente.

Dónde deja de funcionar la analogía: el tope de PPO no está en la recompensa sino en **cuánto puede cambiar la política de una vez**. La recompensa se registra entera; lo que se acota es la reacción a ella.

5. Matemática mínima

$$L^{CLIP}(\theta) = \mathbb{E} \left[\min(r_t(\theta) \cdot \hat{A}_t, \text{clip}(r_t(\theta), 1-\epsilon, 1+\epsilon) \cdot \hat{A}_t) \right]$$

$A > 0$

y

$r > 1+\epsilon$

$\rightarrow$

objetivo plano: el gradiente se anula

$A < 0$

y

$r < 1-\epsilon$

$\rightarrow$

objetivo plano por el otro lado

La miniatura compara el objetivo y el entrenamiento con un entorno que **cambia a mitad**: la ventaja de la acción es +1,2 hasta el paso 40 y −1,2 después.

Magnitud	Sin recorte	Con recorte
objetivo a ratio 5,0	6,0	1,44
salto máximo de probabilidad en un paso	0,4382	0,1727
pasos saturados ($p > 0,99$ o $p < 0,01$)	60	53
probabilidad final tras el giro	0,9412	0,6909


El recorte acota el salto por paso, y eso es lo que decide si la política puede rectificar cuando la acción buena cambia.

[!TIP]

Puente matemático. Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A02 §1 · Softmax	de dónde sale la probabilidad de cada acción y por qué su gradiente se anula en los extremos

6. Arquitectura o flujo



7. Qué observar en el paper original

- Por qué el objetivo usa el **mínimo** de las dos expresiones y no directamente la recortada: es lo que hace el comportamiento correcto con ventaja negativa.
- Que se pueden dar **varias épocas sobre el mismo lote**, que es de donde sale la eficiencia de muestras frente a los métodos de una sola pasada.
- La **estimación de ventaja generalizada** (GAE), que el artículo usa y que es la mitad del rendimiento real de PPO.
- Que el artículo también presenta una variante con **penalización KL adaptativa**, y concluye empíricamente que el recorte funciona mejor. Esa conclusión es empírica, no teórica.

8. Evidencia y resultados

Experimentos sobre entornos de control continuo de MuJoCo y sobre juegos de Atari, comparando con TRPO, A2C y otros métodos, con curvas de aprendizaje y resultados agregados.

Los resultados son empíricos y el artículo no reclama garantía teórica: TRPO sí tenía una cota de mejora monótona bajo sus supuestos, y PPO la cambia por simplicidad.

Trabajo posterior (Engstrom et al., 2020) mostró que buena parte de la ventaja atribuida al recorte viene en realidad de **detalles de implementación** —normalización de observaciones, recorte de gradiente, ajuste del ritmo de aprendizaje—, lo cual es un correctivo importante al citarlo.

9. Impacto

- Se convirtió en el algoritmo de referencia del aprendizaje por refuerzo profundo, por la relación entre rendimiento y simplicidad de implementación.
- Es el algoritmo con el que se hace **RLHF**: el ajuste por retroalimentación humana de InstructGPT y de los modelos de chat posteriores usa PPO, con el modelo de referencia jugando el papel de la política vieja.
- Su idea central —no te alejes demasiado de la política anterior— es la misma que la penalización KL contra el modelo base en RLHF, y la misma que motiva DPO a buscar una alternativa sin bucle de refuerzo.
- Y aporta al programa un patrón de diseño: cuando la señal de aprendizaje es ruidosa, acotar la magnitud del cambio vale más que afinar su dirección.

10. Limitaciones

1. **No hereda la garantía de TRPO.** La mejora monótona no está demostrada para PPO; se justifica empíricamente.
2. **Muchos detalles de implementación importan** tanto como el recorte, y sin declararlos los resultados no son reproducibles (Engstrom et al., 2020).
3. **Sensible a epsilon y al ritmo de aprendizaje**, aunque menos que los métodos anteriores.
4. **Sigue siendo caro en muestras** comparado con métodos fuera de política.
5. **El recorte no impide todos los colapsos:** en la miniatura, la política recortada también pasa 53 pasos saturada. Los acota, no los elimina.

11. Errores comunes

Error	Corrección
«El recorte garantiza mejora monótona»	Eso lo tenía TRPO bajo sus supuestos. PPO cambia la garantía por simplicidad y se justifica empíricamente.
«El objetivo recortado es $\text{clip}(r) \cdot A$ »	Es el MÍNIMO entre $r \cdot A$ y $\text{clip}(r) \cdot A$. Sin el mínimo, el comportamiento con ventaja negativa sería el contrario del deseado.
«PPO funciona bien por el recorte»	Engstrom et al. (2020) mostraron que buena parte de la ventaja viene de detalles de implementación: normalización, recorte de gradiente y ajuste del ritmo.
«Una política determinista es una política entrenada»	Es una política que dejó de explorar. Si el entorno cambia o la estimación era mala, no puede rectificar: el gradiente se anula en los extremos.
«Epsilon es un detalle»	Determina cuánto puede moverse la política por lote. En la miniatura, la diferencia entre 0,44 y 0,17 de salto máximo.

12. Relación con trabajos anteriores

- **P26 DQN (2015)** — aprendizaje por refuerzo profundo basado en valor; PPO está en la otra familia, la de políticas.
- **Schulman et al. (2015)** — TRPO: la restricción de región de confianza que PPO simplifica. [arXiv:1502.05477](https://arxiv.org/abs/1502.05477)
- **P101 DAgger (2011)** — la alternativa cuando sí hay un experto que consultar.

13. Relación con trabajos posteriores

- **P12 InstructGPT (2022)** — RLHF implementado con PPO: el uso que lo llevó a los modelos de lenguaje.
- **P15 DPO (2023)** — la alternativa que elimina el bucle de refuerzo entero.
- **Engstrom et al. (2020)** — qué parte de PPO importa realmente. [arXiv:2005.12729](https://arxiv.org/abs/2005.12729)
- **P22 DeepSeek-R1 (2025)** — refuerzo a gran escala para razonamiento, heredero directo de esta familia.

14. Notebook asociado

Qué implementa: la forma del objetivo con y sin recorte para varios ratios, y un entrenamiento sobre un entorno cuya ventaja cambia de signo a mitad, midiendo el salto máximo por paso y la capacidad de rectificar.

Qué NO implementa: no hay estados, ni episodios, ni descuento, ni estimación de ventaja generalizada, ni varias épocas por lote. Falta casi todo el algoritmo real: se aísla el efecto del recorte.

```
ai-evolution paper-lab P102 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe la función objetivo de PPO.
Explicar	Explica por qué usa el mínimo de las dos expresiones.
Aplicar	Ejecuta el notebook y compara el salto máximo por paso.
Analizar	Analiza por qué una política saturada no se recupera.
Evaluar	«PPO es mejor que TRPO». Evalúa la afirmación.
Crear	Entrena PPO en un entorno de control clásico barriendo epsilon entre 0,05 y 0,5, y documenta la frontera entre aprender demasiado despacio y colapsar.

16. Autoevaluación

1. ¿Qué problema del gradiente de políticas resuelve?
2. ¿Qué es el ratio r ?
3. ¿Qué hace el recorte cuando la ventaja es positiva y r es grande?
4. ¿Por qué el objetivo usa el mínimo?
5. ¿Hereda la garantía de TRPO?
6. ¿Por qué una política saturada es un problema?
7. ¿Dónde se usa PPO fuera de la robótica?

17. Respuestas esperadas

1. Que un paso demasiado grande vuelve la política casi determinista y le quita la capacidad de rectificar, y acertar el tamaño del paso a mano es inviable.
2. El cociente entre la probabilidad que la política nueva asigna a la acción y la que le asignaba la vieja. Mide cuánto ha cambiado la política.
3. Deja el objetivo plano: por encima de $1+\epsilon$, aumentar más la probabilidad no incrementa el objetivo, así que el gradiente deja de empujar.
4. Para que el comportamiento con ventaja negativa sea el correcto. Con solo la expresión recortada, el gradiente empujaría en la dirección equivocada en ese caso.
5. No. TRPO tenía una cota de mejora monótona bajo sus supuestos; PPO la cambia por simplicidad y se justifica por rendimiento empírico.

6. Porque deja de explorar y el gradiente de la sigmoide se anula en los extremos: salir de ahí cuesta muchísimos pasos, si es que sale.
7. En RLHF: el ajuste de modelos de lenguaje con retroalimentación humana usa PPO, con el modelo de referencia haciendo de política vieja.

18. Fuentes primarias

- Schulman, J. et al. (2017). *Proximal Policy Optimization Algorithms*. arXiv:1707.06347 · consultado 2026-08-17.
- Schulman, J. et al. (2015). *Trust Region Policy Optimization*. arXiv:1502.05477 · consultado 2026-08-17.
- Engstrom, L. et al. (2020). *Implementation Matters in Deep RL: A Case Study on PPO and TRPO*. arXiv:2005.12729 · consultado 2026-08-17.



Evaluación — P102 · Algoritmos de optimización proximal de políticas

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Proximal Policy Optimization Algorithms* (2017, arXiv:1707.06347) · **Nivel:** L3

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P102_ppo.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).