

P103

Aleatorización de dominio para transferir redes profundas de la simulación al mundo real

Domain Randomization for Transferring Deep Neural Networks from Simulation to the Real World

Josh Tobin, Rachel Fong, Alex Ray, Jonas Schneider, Wojciech Zaremba, Pieter Abbeel · 2017 · IROS 2017, 23–30 · [arXiv:1703.06907](#)

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-17.

P103 — Aleatorización de dominio

Ruta encarnada · Deja de perseguir un simulador fiel. Haz que varíe tanto que la realidad sea una configuración más de las que el modelo ya ha visto.

Nivel: L2 · **Motor:** domain_randomization · **Notebook:** P103_domain_randomization.ipynb · **Anexo:** probabilidad y verosimilitud

1. Identificación

Campo	Valor
Título original	Domain Randomization for Transferring Deep Neural Networks from Simulation to the Real World
Autoría	Josh Tobin, Rachel Fong, Alex Ray, Jonas Schneider, Wojciech Zaremba, Pieter Abbeel
Año	2017
Venue	IROS 2017, 23–30 · arXiv:1703.06907
Fuente primaria	arXiv:1703.06907
Acceso	Abierto
Fecha de consulta	2026-08-17

2. Problema anterior

Entrenar un robot en el mundo real es lento, caro y peligroso: cada episodio consume tiempo de máquina y cada error puede romper algo. En simulación es instantáneo, paralelo y sin consecuencias.

El problema es que lo entrenado en simulación no funciona fuera. El **hueco entre simulación y realidad** se atacaba mejorando el simulador —más física, mejores texturas, calibración más fina—, una carrera cara y sin final: siempre queda algún fenómeno que nadie modeló, y el modelo aprendió a depender de la ausencia de ese fenómeno.

3. Propuesta

Dar la vuelta al objetivo. En vez de que el simulador se parezca a la realidad, que **varíe tanto que la realidad quede dentro de su rango**:

en cada episodio, sortear:
texturas · colores · iluminación · posición y ángulo de la cámara
posiciones de los objetos · ruido de los sensores

Si la variabilidad es suficiente, el modelo no puede resolver la tarea apoyándose en ninguno de esos detalles, porque cambian todo el tiempo. Está obligado a usar lo invariante. Y al desplegarlo, la realidad le parece una configuración más.

El artículo lo demuestra con detección de posición de objetos entrenada **solo con imágenes sintéticas no realistas**, transferida a un robot real sin ningún ajuste.

4. Intuición sin fórmulas

Aprender a leer con una sola tipografía frente a aprender con cincuenta. Quien aprendió con una sola falla ante una letra manuscrita; quien vio cincuenta ha tenido que quedarse con la forma esencial de cada letra.

Ninguna de las cincuenta era la manuscrita. Da igual: era una más.

Dónde deja de funcionar la analogía: las tipografías varían dentro de un espacio conocido. En robótica hay que **decidir qué aleatorizar**, y un fenómeno en el que nadie pensó —una superficie reflectante, un retardo de comunicación— cae fuera del rango y el método no ayuda.

5. Matemática mínima

No hay formalismo: el modelo se entrena minimizando la pérdida esperada sobre la distribución de configuraciones sorteadas, en lugar de sobre una configuración fija.


La miniatura entrena un regresor sobre un «mundo» donde la observación depende de tres factores de molestia:

Modelo	Error en su propio simulador	Error en la realidad
entrenado con simulador fijo	0,0501	0,8275
entrenado con parámetros aleatorizados	0,6828	0,5292

Las dos filas dicen lo mismo desde lados opuestos: el modelo del simulador fijo es excelente **donde entrenó** e inútil fuera; el aleatorizado es mediocre en todas partes y por eso funciona donde importa.

Ese es el precio, y hay que decirlo: se cambia rendimiento en el caso nominal por robustez ante el caso desconocido.

6. Arquitectura o flujo



7. Qué observar en el paper original

- Que las imágenes de entrenamiento son **deliberadamente poco realistas**: texturas aleatorias, colores imposibles. La fidelidad no es el objetivo y el artículo lo hace visible.
- La lista concreta de **qué se aleatoriza** y con qué rangos. Es la parte transferible y la que exige criterio.
- La transferencia **sin ningún ajuste** con datos reales, que es la afirmación fuerte del trabajo.
- La discusión sobre **cuánta aleatorización**: demasiada hace la tarea imposible de aprender, demasiado poca no cubre la realidad. No hay receta.

8. Evidencia y resultados

Experimentos de detección de posición de objetos sobre un robot real, con modelos entrenados exclusivamente con imágenes sintéticas, midiendo el error de localización en centímetros.

La afirmación fuerte —transferencia sin ajuste con datos reales— está respaldada por el experimento. Su alcance es una tarea de percepción concreta, no una garantía general.

La miniatura no reproduce nada de eso: construye un problema de regresión con factores de molestia para exhibir el compromiso con cuatro números. Y hay un detalle honesto que declara: **la realidad está dentro del rango aleatorizado por construcción**, que es justamente el supuesto que en la práctica hay que ganarse.

9. Impacto

- Se convirtió en una técnica estándar de sim-to-real, y buena parte de la robótica de manipulación actual la usa por defecto.
- OpenAI la llevó al extremo con la manipulación diestra de un cubo de Rubik (2019), aleatorizando también la **dinámica** —masas, fricciones, retardos— y no solo el aspecto.
- La idea general —entrenar sobre una distribución de entornos en vez de sobre uno— reaparece en robustez adversaria, en generalización fuera de distribución y en el diseño de conjuntos de entrenamiento diversos.
- Y da un criterio operativo: si tu modelo depende de una condición que no varía en entrenamiento, esa condición es una dependencia oculta y va a fallar.

10. Limitaciones

1. **Solo cubre lo que se aleatoriza.** Un fenómeno en el que nadie pensó cae fuera del rango y el método no ayuda en absoluto.
2. **Hay un óptimo y no hay receta.** Aleatorizar de más hace la tarea imposible de aprender; de menos, no cubre la realidad.
3. **Cuesta rendimiento en el caso nominal.** El modelo aleatorizado es peor en cualquier configuración concreta, y eso puede no compensar si el entorno de despliegue es estable.
4. **Necesita más cómputo de entrenamiento** para cubrir la variabilidad añadida.
5. **La aleatorización del aspecto es la fácil.** La de la dinámica —fricciones, retardos, elasticidades— es mucho más difícil de parametrizar bien.

11. Errores comunes

Error	Corrección
«Aleatorizar cierra el hueco entre simulación y realidad»	Lo cierra si la realidad cae dentro del rango sorteado. Un fenómeno no aleatorizado sigue siendo un hueco.
«Cuanta más aleatorización, mejor»	Con demasiada, la tarea se vuelve imposible de aprender: no queda señal invariante que explotar. Hay un óptimo y se busca por experimento.
«El modelo aleatorizado es mejor»	Es peor en cualquier configuración concreta, incluida la suya. Es mejor en promedio sobre configuraciones desconocidas , que es otra cosa.
«Sirve para cualquier hueco de sim-to-real»	Aleatorizar el aspecto es relativamente fácil; la dinámica es mucho más difícil de parametrizar, y ahí está el hueco que más cuesta.
«Hace innecesario un buen simulador»	Hace innecesario un simulador FIEL. Sigue haciendo falta que la física sea razonable y que los rangos cubran lo que va a pasar.

12. Relación con trabajos anteriores

- **P102 PPO (2017)** — la política que se entrena en el simulador y se quiere desplegar fuera.
- **P04 AlexNet (2012)** — el aumento de datos como forma de imponer invarianzas; esto es la misma idea llevada al entorno completo.
- **P100 Seguridad física (2009)** — por qué entrenar en el mundo real es caro y peligroso.

13. Relación con trabajos posteriores

- **OpenAI et al. (2019)** — aleatorización automática del dominio para manipulación diestra. [arXiv:1910.07113](#)
- **Peng et al. (2018)** — aleatorizar la dinámica, no solo el aspecto. [arXiv:1710.06537](#)
- **P106 OSWorld (2024)** — entornos reproducibles para agentes: el mismo problema de tener dónde entrenar y evaluar sin romper nada.

14. Notebook asociado

P103_domain_randomization.ipynb

Qué implementa: el entrenamiento de un regresor sobre un simulador fijo y sobre uno aleatorizado, con la evaluación cruzada de ambos en su propio simulador y en la «realidad».

Qué NO implementa: el mundo es una regresión lineal con tres factores de molestia: no hay imágenes, ni física, ni dinámica. Y la realidad cae dentro del rango aleatorizado por construcción, que es el supuesto que en la práctica hay que ganarse.

```
ai-evolution paper-lab P103 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Explica en qué consiste el hueco entre simulación y realidad.
Explicar	Describe la inversión conceptual que propone el artículo.
Aplicar	Ejecuta el notebook y compara los cuatro errores.
Analizar	Analiza por qué el modelo aleatorizado es peor en su propio simulador.
Evaluar	«Aleatorizamos, luego el modelo transferirá». Evalúa la afirmación.
Crear	Entrena un modelo con una sola configuración de datos y otro con condiciones aleatorizadas, y evalúa ambos fuera de distribución.

16. Autoevaluación

1. ¿Cuál es el enfoque clásico para cerrar el hueco sim-to-real?
2. ¿Qué propone este artículo en su lugar?
3. ¿Por qué el modelo aleatorizado es peor en su propio simulador?
4. ¿Cuál es el precio del método?
5. ¿Cuándo NO ayuda?
6. ¿Qué es más difícil de aleatorizar: el aspecto o la dinámica?
7. ¿Hace innecesario un buen simulador?

17. Respuestas esperadas

1. Mejorar la fidelidad del simulador: más física, mejores texturas, calibración más fina. Es una carrera cara y sin final.
2. Aleatorizar agresivamente los parámetros del simulador para que la realidad sea una configuración más dentro del rango de entrenamiento.
3. Porque no puede especializarse en ninguna configuración: la tarea que aprende es la que funciona en todas, y esa es menos precisa en cada una.
4. Rendimiento en el caso nominal a cambio de robustez ante el caso desconocido. Solo compensa si de verdad no se sabe dónde se va a desplegar.
5. Cuando la realidad cae fuera del rango sorteado: un fenómeno que nadie pensó en aleatorizar sigue siendo un hueco, y el método no lo cubre.
6. La dinámica —fricciones, masas, retardos, elasticidades— es mucho más difícil de parametrizar bien que las texturas y la iluminación.
7. Hace innecesario un simulador **fiel**, no un simulador razonable. La física tiene que ser sensata y los rangos tienen que cubrir lo que va a ocurrir.

18. Fuentes primarias

- Tobin, J. et al. (2017). *Domain Randomization for Transferring Deep Neural Networks from Simulation to the Real World*. **IROS 2017**. [arXiv:1703.06907](https://arxiv.org/abs/1703.06907) · consultado 2026-08-17.
- OpenAI et al. (2019). *Solving Rubik's Cube with a Robot Hand*. [arXiv:1910.07113](https://arxiv.org/abs/1910.07113) · consultado 2026-08-17.

- Peng, X. B. et al. (2018). *Sim-to-Real Transfer of Robotic Control with Dynamics Randomization*. arXiv:1710.06537 · consultado 2026-08-17.



Evaluación — P103 · Aleatorización de dominio para transferir redes profundas de la simulación al mundo real

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Domain Randomization for Transferring Deep Neural Networks from Simulation to the Real World* (2017, IROS 2017, 23–30 · arXiv:1703.06907) · **Nivel:** L2

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P103_domain_randomization.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).