

P109

La cola a escala

The Tail at Scale

Jeffrey Dean, Luiz André Barroso · 2013 · Communications of the ACM, 56(2), 74–80

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-17.

P109 — La cola a escala

Ruta de operación · Cien servidores con un p99 excelente producen un sistema cuya mediana es peor que la cola de cualquiera de ellos. Y eso es aritmética.

Nivel: L2 · Motor: cola_larga · Notebook: P109_cola_larga.ipynb · Anexo: complejidad y coste

1. Identificación

Campo	Valor
Título original	<i>The Tail at Scale</i>
Autoría	Jeffrey Dean, Luiz André Barroso
Año	2013
Venue	Communications of the ACM, 56(2), 74–80
Fuente primaria	doi:10.1145/2408776.2408794
Acceso	Restringido
Fecha de consulta	2026-08-17

2. Problema anterior

Un servicio tiene una latencia media de 50 ms y un p99 de 70 ms. Excelente. La petición del usuario necesita respuesta de cien servidores como ese, y tarda casi un segundo.

No hay ningún fallo: cada servidor cumple su objetivo. Lo que ocurre es que la petición completa tarda lo que tarde **el más lento de los cien**, y con cien intentos, lo que ocurre el 1 % de las veces ocurre casi siempre.

3. Propuesta

Tratar la variabilidad de latencia como una **propiedad de diseño** y no como ruido que se elimina optimizando.

El artículo distingue entre reducir las causas de la variabilidad —difíciles, y nunca del todo: " recolección de basura, contención de disco, vecinos ruidosos, gestión de energía— y **tolerarla** con técnicas explícitas:

- **peticiones de cobertura**: pedir a una segunda réplica cuando la primera tarda más de un umbral;
- **peticiones atadas** con cancelación cruzada, para no duplicar trabajo innecesario;
- **micro-particionado** y migración de particiones calientes;
- **degradación selectiva**: responder con resultados parciales antes que tarde.

4. Intuición sin fórmulas

Organizar una cena con veinte invitados que llegan en coche. Cada uno llega puntual el 95 % de las veces —excelente. La probabilidad de que **todos** lleguen puntuales es $0,95^{20} \approx 36 \%$.

La cena empieza cuando llega el último. Con veinte invitados, empezar tarde es lo normal aunque cada invitado por separado sea puntual.

Dónde deja de funcionar la analogía: en la cena puedes empezar sin el último. Muchos sistemas también pueden —es la degradación selectiva— y esa es precisamente una de las técnicas que el artículo recomienda.

5. Matemática mínima

Si cada servidor va lento con probabilidad p , la probabilidad de que ALGUNO de n lo esté es:

$$1 - (1 - p)^n$$

$p = 1 \%$, $n = 1$ → 1%
 $p = 1 \%$, $n = 100$ → 63%
 $p = 1 \%$, $n = 1000$ → $99,996 \%$

La miniatura mide una petición que necesita respuesta de todos los servidores:


Servidores	p50	p99
1	50,0 ms	70,4 ms
10	66,0 ms	934,3 ms
100	947,0 ms	969,7 ms
1 000	967,5 ms	985,4 ms

Con 100 servidores, **la mediana del sistema es trece veces peor que la cola de uno solo**. Las peticiones de cobertura bajan esa mediana a **69,7 ms** —un factor de 13,6×— y el p99 apenas se mueve: la cobertura **recorta** la cola, no la elimina.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A05 §1 · Notación O(): qué dice y qué no	por qué una probabilidad pequeña elevada a n deja de ser pequeña muy deprisa

6. Arquitectura o flujo



7. Qué observar en el paper original

- El catálogo de **causas de variabilidad**: recolección de basura, contención de recursos compartidos, gestión de energía, mantenimiento en segundo plano. Ninguna se elimina del todo.
- La distinción entre **reducir** la variabilidad y **tolerarla**. La segunda es la aportación práctica del artículo.
- Las **peticiones atadas** con cancelación cruzada, que es la versión eficiente de la cobertura: se envían dos y la primera en empezar cancela a la otra.
- El paralelismo explícito con la **tolerancia a fallos**: igual que se diseñan sistemas que toleran que un componente falle, hay que diseñarlos para que toleren que uno vaya lento.

8. Evidencia y resultados

El artículo presenta mediciones de servicios reales de Google, con distribuciones de latencia y el efecto medido de las técnicas de tolerancia.

La evidencia es operativa y a escala. Las cifras concretas dependen del sistema, pero el fenómeno —la amplificación de la cola por el abanico— es aritmética y no depende de nadie.

La miniatura reproduce esa aritmética con un modelo de latencia simple, y añade un dato honesto que matiza el entusiasmo: la cobertura mejora espectacularmente la mediana y apenas el p99, porque de vez en cuando fallan las dos réplicas.

9. Impacto

- Es lectura obligada en ingeniería de sistemas a escala, y fijó el vocabulario —«latencia de cola», «tolerancia a la cola»— con el que se discute el problema.
- Las **peticiones de cobertura** son hoy una técnica estándar en sistemas de búsqueda, recomendación y almacenamiento distribuido.
- Cambió el objetivo de las conversaciones de rendimiento: de optimizar la media a acotar el percentil alto.

- En sistemas de IA es directamente aplicable: un agente que hace veinte llamadas a herramientas sufre exactamente esta amplificación, y su latencia percibida la determina la más lenta.

10. Limitaciones

1. **La cobertura duplica tráfico** si se usa sin cuidado. El artículo describe variantes más finas, y aun así hay un coste que presupuestar.
2. **Supone que se puede esperar y reintentar.** Con operaciones que mutan estado, repetir exige idempotencia — que es el problema de P108.
3. **No elimina la cola:** la recorta. En la miniatura, el p99 apenas se mueve porque a veces fallan las dos réplicas.
4. **Las causas de variabilidad siguen ahí.** Tolerarlas es más barato que eliminarlas, y también menos definitivo.
5. **Las cifras dependen del sistema** y no se pueden trasladar: lo transferible es el razonamiento.

11. Errores comunes

Error	Corrección
«Si cada servicio cumple su p99, el sistema cumple su p99»	Con abanico grande, la petición tarda lo que el más lento. En la miniatura, cien servidores con p99 de 70 ms dan una mediana de 947 ms.
«Optimizar la media mejora la experiencia»	Con abanico grande lo que ve el usuario lo determina la cola, no la media. Bajar el p50 de un componente apenas cambia nada.
«Las peticiones de cobertura eliminan la cola»	La recortan. En la miniatura mejoran la mediana 13,6× y el p99 apenas: a veces fallan las dos réplicas.
«Basta con eliminar las causas de la variabilidad»	No se eliminan del todo: recolección de basura, contención, mantenimiento en segundo plano. El artículo propone tolerarlas, no perseguirlas.
«Esto solo pasa a escala de Google»	Es aritmética: depende del número de dependencias, no del tamaño de la empresa. Un agente con veinte llamadas a herramientas ya lo sufre.

12. Relación con trabajos anteriores

- **P107 Dapper (2010)** — sin traza no se puede saber qué componente aportó la cola.
- **Barroso y Hölzle** — *The Datacenter as a Computer*: el contexto donde el abanico grande es la norma.

13. Relación con trabajos posteriores

- **P108 CAP doce años después (2012)** — la otra cara: qué se sacrifica cuando se decide esperar.
- **Beyer et al.** — *Site Reliability Engineering*: cómo se fijan objetivos de nivel de servicio sobre percentiles. sre.google
- **P117 AgentBench (2023)** — un agente con muchas llamadas sufre esta misma amplificación, y por eso el límite de pasos importa.

14. Notebook asociado

Qué implementa: la medición de la latencia de una petición con abanico de 1, 10, 100 y 1 000 servidores, con la probabilidad de que alguno vaya lento, y el efecto de las peticiones de cobertura sobre la mediana y sobre el p99.

Qué NO implementa: el modelo de latencia es una gaussiana con una parada ocasional. La cola real tiene estructura temporal —ráfagas, correlación entre servidores— que aquí no está.

```
ai-evolution paper-lab P109 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe la fórmula de la probabilidad de que alguno de n servidores vaya lento.
Explicar	Explica por qué la mediana del sistema puede ser peor que el p99 de un componente.
Aplicar	Ejecuta el notebook y observa el efecto del abanico.
Analizar	Analiza por qué la cobertura mejora la mediana y no el p99.
Evaluar	«Cada servicio cumple su objetivo de latencia». Evalúa qué garantiza eso sobre el sistema.
Crear	Mide el p50 y el p99 de un servicio tuyo que haga llamadas en paralelo, y estima la contribución de la cola de cada dependencia.

16. Autoevaluación

1. ¿Por qué el abanico amplifica la cola?
2. ¿Qué probabilidad hay de que alguno de 100 servidores vaya lento si cada uno lo hace el 1 % de las veces?
3. ¿Qué son las peticiones de cobertura?
4. ¿Eliminan la cola?
5. ¿Qué diferencia hay entre reducir la variabilidad y tolerarla?
6. ¿Qué coste tiene la cobertura?
7. ¿Aplica esto fuera de sistemas gigantes?

17. Respuestas esperadas

1. Porque la petición tarda lo que tarde el más lento de los componentes. Con n intentos, un suceso poco probable en uno se vuelve probable en el conjunto.
2. El 63 %: $1 - 0,99^{100}$. Con 1 000 servidores, prácticamente el 100 %.
3. Enviar la misma petición a una segunda réplica cuando la primera supera un umbral de tiempo, y quedarse con la que llegue antes.
4. No: la recortan. En la miniatura mejoran la mediana en un factor de 13,6× y el p99 apenas, porque a veces las dos réplicas van lentas.

5. Reducirla ataca las causas —recolección de basura, contención— y nunca se consigue del todo. Tolerarla acepta que existirán y diseña para que no lleguen al usuario.
6. Tráfico duplicado en las peticiones que superan el umbral. Hay variantes —peticiones atadas con cancelación cruzada— que lo reducen, y aun así hay que presupuestarlo.
7. Sí. Depende del número de dependencias, no del tamaño de la empresa. Un agente con veinte llamadas a herramientas ya sufre la amplificación.

18. Fuentes primarias

- Dean, J. y Barroso, L. A. (2013). *The Tail at Scale*. **Communications of the ACM**, 56(2), 74–80. doi:10.1145/2408776.2408794 · consultado 2026-08-17.
- Barroso, L. A. et al. *The Datacenter as a Computer*. doi:10.2200/S00874ED3Vo1Y201809CACo46 · consultado 2026-08-17.
- Beyer, B. et al. *Site Reliability Engineering*. sre.google · consultado 2026-08-17.



Evaluación — P109 · La cola a escala

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *The Tail at Scale* (2013, Communications of the ACM, 56(2), 74–80) · **Nivel:** L2

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P109_cola_larga.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).