

P112

La puntuación de pruebas de ML: una rúbrica de preparación para producción

The ML Test Score: A Rubric for ML Production Readiness and Technical Debt Reduction

Eric Breck, Shanqing Cai, Eric Nielsen, Michael Salib, D. Sculley · 2017 · IEEE Big Data 2017, 1123–1132

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-17.

P112 — ML Test Score

Ruta de operación · Dos equipos con la misma exactitud y sistemas radicalmente distintos. La rúbrica los distingue; la métrica de calidad no.

Nivel: L2 · **Motor:** `ml_test_score` · **Notebook:** `P112_ml_test_score.ipynb` · **Anexo:** complejidad y coste

1. Identificación

Campo	Valor
Título original	<i>The ML Test Score: A Rubric for ML Production Readiness and Technical Debt Reduction</i>
Autoría	Eric Breck, Shanjing Cai, Eric Nielsen, Michael Salib, D. Sculley
Año	2017
Venue	IEEE Big Data 2017, 1123–1132
Fuente primaria	doi:10.1109/BigData.2017.8258038
Acceso	Restringido
Fecha de consulta	2026-08-17

2. Problema anterior

La decisión de promocionar un modelo a producción se tomaba mirando su métrica de calidad. Si el número era mejor que el del modelo anterior, se desplegaba.

Nada en esa decisión garantizaba que existieran pruebas del esquema de datos, que el entrenamiento fuera reproducible, que se pudiera revertir a la versión anterior o que alguien fuera a enterarse si el modelo se degradaba. El diagnóstico de P111 estaba escrito; faltaba convertirlo en algo que un equipo pudiera aplicar el lunes.

3. Propuesta

Una **rúbrica de 28 pruebas** repartidas en cuatro categorías:

datos · modelo · infraestructura · monitorización

con siete pruebas concretas en cada una —del tipo «el esquema de las características está validado», «se puede revertir a la versión anterior», «se vigila la antigüedad del modelo»—.

Y una regla de puntuación que es la mitad de la aportación: la puntuación global es el **mínimo** entre categorías, no la suma. Un sistema es tan robusto como su categoría más débil, y sumar permitiría compensar la ausencia total de monitorización con pruebas de datos excelentes.

4. Intuición sin fórmulas

La inspección técnica de un vehículo. No se aprueba por tener un motor potente: se comprueban frenos, luces, emisiones y dirección, y basta que una falle para no pasar.

Nadie propone compensar unos frenos inexistentes con un motor excelente.

Dónde deja de funcionar la analogía: la inspección técnica tiene criterios objetivos y medibles. Muchas de estas pruebas admiten grados —«¿está el esquema validado?» tiene respuestas intermedias— y la puntuación acaba dependiendo del criterio de quien la aplica.

5. Matemática mínima

puntuación = mín(puntuación_datos, puntuación_modelo,
puntuación_infraestructura, puntuación_monitorización) / 2

0 : no hay pruebas – más un experimento que un producto
1-2 : pruebas básicas
3+ : razonablemente probado

La miniatura puntúa dos equipos con exactitudes casi idénticas:


Equipo	Exactitud	Datos	Modelo	Infra.	Monit.	Puntuación
A	0,912	4	3	4	4	1,5
B	0,918	1	1	1	0	0,0

El equipo B tiene **mejor exactitud** y ninguna prueba de monitorización: su modelo puede degradarse durante meses sin que nadie se entere. La métrica de calidad no distingue estos dos sistemas; la rúbrica sí.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A05 §8 · Checklist antes de creerte una cifra de rendimiento	el mismo hábito aplicado a cualquier número: qué hay que comprobar antes de aceptarlo

6. Arquitectura o flujo



7. Qué observar en el paper original

- Las **28 pruebas concretas**. Son la parte directamente aplicable: se pueden copiar y usar como lista el mismo día.
- La regla del **mínimo**, y su justificación: los sistemas fallan por su parte más débil, no por su media.
- Los **datos de adopción** dentro de Google: qué puntuación tenían los equipos antes y después de introducir la rúbrica.
- Que la categoría de **monitorización** es la que peor puntúan casi todos los equipos, lo cual dice algo sobre dónde está el problema real.

8. Evidencia y resultados

El artículo presenta la rúbrica y los resultados de aplicarla a equipos reales dentro de Google, con distribuciones de puntuación por categoría.

La evidencia es de adopción y de diagnóstico, no de que la puntuación prediga incidentes. Esa correlación sería lo interesante y no se demuestra.

La miniatura usa cuatro pruebas por categoría en lugar de siete y dos equipos inventados, elegidos para que el contraste entre exactitud y preparación sea nítido.

9. Impacto

- Se convirtió en la lista de comprobación de referencia para decidir si un sistema de aprendizaje automático está listo para producción.

- Está detrás de buena parte de las prácticas de MLOps que hoy se dan por supuestas: validación de esquema, pruebas de integración del proceso completo, capacidad de revertir, vigilancia de la antigüedad del modelo.
- La regla del mínimo se ha trasladado a otras rúbricas de madurez.
- Y aporta al programa el criterio con el que se evalúan sus propios proyectos: no basta con que el modelo funcione, hay que poder decir cómo se sabría si dejara de funcionar.

10. Limitaciones

1. **No demuestra que la puntuación prediga incidentes.** Es plausible y no está medido.
2. **Las pruebas admiten grados** y la puntuación depende del criterio de quien la aplica: dos personas pueden puntuar distinto el mismo sistema.
3. **Se puede rellenar de forma ritual**, marcando casillas sin que las pruebas aporten nada.
4. **Está pensada para modelos supervisados clásicos.** Trasladarla a sistemas de agentes exige adaptar varias pruebas.
5. **Una puntuación alta no garantiza que el sistema funcione:** garantiza que si falla, alguien se enterará y podrá revertir. Son cosas distintas.

11. Errores comunes

Error	Corrección
«Si la métrica de calidad mejora, se puede promocionar»	La métrica mide el modelo. La rúbrica mide el sistema. En la miniatura, el equipo con mejor exactitud es el que no tiene ninguna prueba de monitorización.
«La puntuación es la suma de las categorías»	Es el mínimo. Sumar permitiría compensar la ausencia total de monitorización con pruebas de datos excelentes, y los sistemas no fallan así.
«Una puntuación alta significa que el sistema funciona bien»	Significa que es auditable y recuperable. Si falla, alguien se enterará y se puede revertir. Eso es distinto de que funcione.
«La rúbrica es para equipos grandes»	Las 28 pruebas son concretas y baratas comparadas con el coste de un incidente. Un equipo pequeño puede aplicarlas el mismo día.
«Marcar las casillas equivale a tener las pruebas»	Se puede rellenar de forma ritual, y entonces la puntuación mide papeleo. La rúbrica es una guía, no un sustituto del criterio.

12. Relación con trabajos anteriores

- **P111 Deuda técnica (2015)** — el diagnóstico que esta rúbrica convierte en lista de comprobación.
- **P110 Deriva de concepto (2014)** — la razón de que la monitorización sea una categoría propia.
- **P63 Reproducibilidad (2021)** — la misma idea aplicada a la publicación en lugar de al despliegue.

13. Relación con trabajos posteriores

- **P113 Deep RL que importa (2018)** — la trazabilidad de los experimentos que llevan a la decisión de promocionar.
- **P114 Tarjetas de modelo (2019)** — qué documentar del modelo que se promociona.
- **Google** — *Rules of Machine Learning*, la guía práctica del mismo grupo. [developers.google.com](https://developers.google.com/machine-learning/rules-of-ml/)

14. Notebook asociado

P112_ml_test_score.ipynb

Qué implementa: la puntuación de dos sistemas con exactitud casi idéntica sobre cuatro categorías de pruebas, con la regla del mínimo y el nivel de madurez resultante.

Qué NO implementa: cuatro pruebas por categoría en lugar de las siete del artículo, y dos equipos inventados elegidos para que el contraste sea nítido. No hay datos de adopción reales.

```
ai-evolution paper-lab P112 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Enumera las cuatro categorías de la rúbrica.
Explicar	Explica por qué la puntuación es el mínimo y no la suma.
Aplicar	Ejecuta el notebook y compara los dos equipos.
Analizar	Analiza por qué el equipo con mejor exactitud es el que más riesgo tiene.
Evaluar	«Tenemos una puntuación de 3, luego el sistema funciona». Evalúa la afirmación.
Crear	Puntúa un sistema tuyo con las cuatro categorías y escribe la prueba concreta que subiría la puntuación de la categoría más débil.

16. Autoevaluación

1. ¿Qué mide la rúbrica que no mide la métrica de calidad?
2. ¿Cuáles son las cuatro categorías?
3. ¿Por qué la puntuación es el mínimo?
4. ¿Qué categoría suelen puntuar peor los equipos?
5. ¿Garantiza una puntuación alta que el sistema funcione?
6. ¿Qué evidencia aporta el artículo?
7. ¿Se puede aplicar a sistemas de agentes?

17. Respuestas esperadas

1. El sistema en lugar del modelo: si hay pruebas de los datos, si el entrenamiento es reproducible, si se puede revertir y si alguien se enteraría de una degradación.
2. Datos, modelo, infraestructura y monitorización, con siete pruebas concretas en cada una.
3. Porque un sistema es tan robusto como su parte más débil. Sumar permitiría compensar la ausencia total de monitorización con pruebas de datos excelentes, y los sistemas no fallan así.
4. La monitorización. Es la que menos se hace y la que más cuesta cuando falta, porque su ausencia solo se nota cuando ya es tarde.

5. No. Garantiza que sea auditable y recuperable: si falla, alguien se entera y se puede revertir. Que funcione es otra cosa.
6. Datos de adopción y de puntuación de equipos reales. Lo que no demuestra es que la puntuación prediga incidentes, que sería el resultado interesante.
7. Con adaptaciones. Varias pruebas se trasladan directamente —reproducibilidad, reversión, monitorización— y otras exigen reformularse para trayectorias y herramientas.

18. Fuentes primarias

- Breck, E. et al. (2017). *The ML Test Score: A Rubric for ML Production Readiness and Technical Debt Reduction*. **IEEE Big Data** 2017, 1123–1132. doi:10.1109/BigData.2017.8258038 · consultado 2026-08-17.
- Sculley, D. et al. (2015). *Hidden Technical Debt in Machine Learning Systems*. papers.nips.cc · consultado 2026-08-17.
- Google. *Rules of Machine Learning*. developers.google.com · consultado 2026-08-17.



Evaluación — P112 · La puntuación de pruebas de ML: una rúbrica de preparación para producción

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *The ML Test Score: A Rubric for ML Production Readiness and Technical Debt Reduction* (2017, IEEE Big Data 2017, 1123–1132) · **Nivel:** L2

Parte A — Contexto histórico (20 pts)

- (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
- (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

- (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
- (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

- (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

- (10) Ejecuta `P112_ml_test_score.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
- (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
- (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

- (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
- (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).