

P114

Tarjetas de modelo para el reporte de modelos

Model Cards for Model Reporting

Margaret Mitchell, Simone Wu, Andrew Zaldivar, Parker Barnes, Lucy Vasserman, Ben Hutchinson, Elena Spitzer, Inioluwa Deborah Raji, Timnit Gebru · 2019 · FAT* '19, 220–229

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-17.

P114 — Tarjetas de modelo

Ruta de operación · Exactitud del 91 %. Desagregada, va del 94 % al 58 %, y el grupo peor servido es el 2 % de la muestra: por eso no mueve la cifra.

Nivel: L1 · **Motor:** tarjetas_de_modelo · **Notebook:** P114_tarjetas_de_modelo.ipynb · **Anexo:** probabilidad y verosimilitud

1. Identificación

Campo	Valor
Título original	Model Cards for Model Reporting
Autoría	Margaret Mitchell, Simone Wu, Andrew Zaldivar, Parker Barnes, Lucy Vasserman, Ben Hutchinson, Elena Spitzer, Inioluwa Deborah Raji, Timnit Gebru
Año	2019
Venue	FAT* '19, 220–229
Fuente primaria	doi:10.1145/3287560.3287596
Acceso	Abierto
Fecha de consulta	2026-08-17

2. Problema anterior

Un modelo se publica con una cifra: exactitud del 91 %. Con eso, quien lo va a integrar no puede responder ninguna de las preguntas que necesita: para qué sirve, para qué **no**, con qué datos se evaluó, a quién le funciona peor, qué umbral usa, quién lo mantiene.

La cifra agregada además esconde activamente el problema. Si un subgrupo es el 2 % de la muestra, su rendimiento puede ser pésimo sin mover la media ni un punto.

3. Propuesta

Un documento corto —una o dos páginas— que acompaña a cada modelo, con secciones fijas:

detalles del modelo · uso previsto · usos FUERA de alcance · factores relevantes
métricas y umbrales · datos de evaluación · datos de entrenamiento
ANÁLISIS CUANTITATIVO DESAGREGADO · consideraciones éticas · advertencias

Dos secciones son la aportación real. Los **usos fuera de alcance**, que obligan a escribir para qué no sirve el modelo —la pregunta que nadie se hace hasta que ya es tarde—. Y el **análisis cuantitativo desagregado**, que obliga a publicar la métrica por subgrupo y no solo la media.

4. Intuición sin fórmulas

El prospecto de un medicamento. No dice solo «eficaz»: dice para qué indicaciones, en qué dosis, qué contraindicaciones tiene, qué pasa en embarazo o en insuficiencia renal, y qué efectos adversos se observaron y con qué frecuencia.

Nadie aceptaría un medicamento cuya documentación fuera «funciona en el 91 % de los casos».

Dónde deja de funcionar la analogía: el prospecto está regulado y su contenido es obligatorio. La tarjeta de modelo es voluntaria, y quien la escribe elige qué subgrupos mostrar.

5. Matemática mínima

$$\text{exactitud_global} = \sum_i n_i \cdot a_i / \sum_i n_i$$

Un subgrupo pequeño con exactitud baja casi no mueve la global.

← una media ponderada por tamaño

La miniatura evalúa un modelo sobre 8 300 casos:

Grupo	n	Exactitud
A	6 200	0,940
B	1 500	0,900
C	420	0,681
D	180	0,578
global	8 300	0,912


La brecha entre el mejor y el peor subgrupo es de **36,2 puntos**. El grupo D es el **2,2 %** de la muestra: por eso no mueve la cifra global, y por eso hace falta desagregar para verlo.

Con la cifra publicada —91 %— el modelo parece bueno. Para una de cada cincuenta personas, acierta poco más que una moneda.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A02 §5 · Estimadores, sesgo y varianza	por qué una media ponderada puede ser alta con un componente pésimo, y cuánta incertidumbre tiene un subgrupo de 180 casos

6. Arquitectura o flujo



7. Qué observar en el paper original

- La sección de **usos fuera de alcance**. Es la más difícil de escribir y la que más incidentes evita: obliga a decir explícitamente para qué no vale el modelo.
- Los **factores relevantes**: qué dimensiones hay que desagregar y por qué. No es solo demografía; incluye instrumentación —qué cámara, qué micrófono— y entorno.
- Los **ejemplos completos** que trae el artículo, con tarjetas rellenas para modelos reales. Son la mejor guía para escribir la primera.
- Que el artículo es explícito en que la tarjeta es **transparencia, no mitigación**: hace visible el problema, no lo arregla.

8. Evidencia y resultados

Es un artículo de propuesta, con ejemplos de tarjetas rellenas para modelos reales de detección de rostros y de análisis de texto.

No hay estudio de adopción ni medición del efecto: la evidencia de que hacía falta viene de trabajos como *Gender Shades* (Buolamwini y Gebru, 2018), que documentó brechas enormes entre subgrupos en sistemas comerciales publicados con cifras agregadas.

La miniatura usa datos inventados con subgrupos anónimos, elegidos para que la aritmética de la media ponderada sea visible.

9. Impacto

- Es hoy práctica estándar: Hugging Face, Google Cloud y las principales plataformas de modelos incorporan tarjetas de modelo.
- Junto con P115 formó el par documental —modelo y datos— con el que se discute la transparencia de un sistema.
- La **evaluación desagregada** pasó de ser un extra a ser lo que se espera de una publicación seria.
- El Reglamento de IA de la Unión Europea exige documentación técnica cuyo contenido se parece mucho a estas secciones.

10. Limitaciones

1. **Es voluntaria** y quien la escribe elige qué mostrar. Una tarjeta puede omitir el subgrupo incómodo.
2. **Desagregar exige tener las etiquetas de grupo**, y recogerlas plantea su propio problema de privacidad y consentimiento.
3. **Elegir qué subgrupos son relevantes es una decisión difícil** y con consecuencias: los ejes que no se miren seguirán invisibles.
4. **Los subgrupos pequeños tienen mucha incertidumbre**: 180 casos dan un intervalo ancho, y la tarjeta debería decirlo.
5. **Documentar no arregla nada**. El artículo lo dice: es transparencia, no mitigación.

11. Errores comunes

Error	Corrección
«Con la exactitud global se sabe cómo funciona el modelo»	Es una media ponderada por tamaño. En la miniatura, 0,912 global esconde un subgrupo con 0,578 que es el 2,2 % de la muestra.
«Si un subgrupo va mal se nota en la cifra global»	No si es pequeño. Justamente por eso hace falta desagregar: la media está diseñada para no notarlo.
«La tarjeta de modelo es documentación decorativa»	Su sección clave —el análisis cuantitativo desagregado— es un resultado que hay que calcular, y los usos fuera de alcance son una decisión de diseño.
«Escribir la tarjeta mitiga el sesgo»	Lo hace visible. El artículo es explícito: es transparencia, no mitigación. Arreglarlo es otro trabajo.
«Basta desagregar por demografía»	Los factores relevantes incluyen instrumentación y entorno: qué cámara, qué micrófono, qué condiciones. Los ejes que no se miran siguen invisibles.

12. Relación con trabajos anteriores

- **P112 ML Test Score (2017)** — la rúbrica de preparación; la tarjeta es qué se documenta de lo que se promociona.
- **P82 Calibración (2005)** — otra propiedad que la exactitud agregada no captura.
- **Buolamwini y Gebru (2018)** — *Gender Shades*: el estudio desagregado que hizo evidente el problema. proceedings.mlr.press

13. Relación con trabajos posteriores

- **P115 Hojas de datos (2021)** — la pieza equivalente para los conjuntos de datos.

- **Raji et al. (2020)** — *Closing the AI Accountability Gap*: auditoría interna con estos documentos como insumo. doi:10.1145/3351095.3372873
- **Reglamento de IA de la UE (2024)** — documentación técnica obligatoria para sistemas de alto riesgo.

14. Notebook asociado

P114_tarjetas_de_modelo.ipynb

Qué implementa: la comparación entre la exactitud global y la desagregada por cuatro subgrupos, con el tamaño de cada uno, la brecha entre el mejor y el peor, y la lista de secciones de la tarjeta.

Qué NO implementa: los datos son inventados y los subgrupos, anónimos. Definir qué subgrupos son relevantes es la decisión difícil y aquí viene dada.

```
ai-evolution paper-lab P114 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Enumera las secciones de una tarjeta de modelo.
Explicar	Explica por qué un subgrupo pequeño no mueve la cifra global.
Aplicar	Ejecuta el notebook y calcula la brecha entre subgrupos.
Analizar	Analiza qué incertidumbre tiene la exactitud de un subgrupo de 180 casos.
Evaluar	«El modelo tiene un 91 % de exactitud, es adecuado para este caso». Evalúa la afirmación.
Crear	Escribe la tarjeta de un modelo tuyo, empezando por la sección de usos fuera de alcance.

16. Autoevaluación

1. ¿Qué esconde una exactitud agregada?
2. ¿Cuál es la sección clave de la tarjeta?
3. ¿Por qué la sección de usos fuera de alcance es importante?
4. ¿Qué se necesita para poder desagregar?
5. ¿Mitiga el sesgo una tarjeta de modelo?
6. ¿Qué factores hay que considerar además de la demografía?
7. ¿Qué limitación tiene ser un documento voluntario?

17. Respuestas esperadas

1. Que es una media ponderada por tamaño de subgrupo. Un grupo pequeño con rendimiento pésimo casi no la mueve: en la miniatura, 0,578 en el 2,2 % de la muestra.
2. El análisis cuantitativo desagregado: la métrica por subgrupo, no solo la media.

3. Porque obliga a escribir para qué **no** vale el modelo, que es la pregunta que nadie se hace hasta que ya se está usando mal.
4. Las etiquetas de grupo de cada caso de evaluación. Recogerlas plantea su propio problema de privacidad y consentimiento, y a menudo no se tienen.
5. No. Lo hace visible. El artículo es explícito en que es transparencia, no mitigación.
6. La instrumentación —qué cámara, qué micrófono, qué dispositivo— y el entorno. Los ejes que no se miran siguen invisibles.
7. Que quien la escribe elige qué mostrar, y puede omitir el subgrupo incómodo sin que nada lo impida.

18. Fuentes primarias

- Mitchell, M. et al. (2019). *Model Cards for Model Reporting*. **FAT*** '19, 220–229. doi:10.1145/3287560.3287596 · consultado 2026-08-17.
- Buolamwini, J. y Gebru, T. (2018). *Gender Shades*. proceedings.mlr.press · consultado 2026-08-17.
- Gebru, T. et al. (2021). *Datasheets for Datasets*. doi:10.1145/3458723 · consultado 2026-08-17.



Evaluación — P114 · Tarjetas de modelo para el reporte de modelos

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Model Cards for Model Reporting* (2019, FAT '19, 220–229) · Nivel:* L1

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P114_tarjetas_de_modelo.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).