

P115

Hojas de datos para conjuntos de datos

Datasheets for Datasets

Timnit Gebru, Jamie Morgenstern, Briana Vecchione, Jennifer Wortman Vaughan, Hanna Wallach, Hal Daumé III, Kate Crawford · 2021 · Communications of the ACM, 64(12), 86–92

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-17.

P115 — Hojas de datos

Ruta de operación · De diez preguntas sobre un conjunto de datos, cinco no se pueden responder mirándolo. Y son justo las que importan.

Nivel: L1 · **Motor:** `hojas_de_datos` · **Notebook:** `P115_hojas_de_datos.ipynb` · **Anexo:** probabilidad y verosimilitud

1. Identificación

Campo	Valor
Título original	<i>Datasheets for Datasets</i>
Autoría	Timnit Gebru, Jamie Morgenstern, Briana Vecchione, Jennifer Wortman Vaughan, Hanna Wallach, Hal Daumé III, Kate Crawford
Año	2021
Venue	Communications of the ACM, 64(12), 86–92
Fuente primaria	doi:10.1145/3458723
Acceso	Abierto
Fecha de consulta	2026-08-17

2. Problema anterior

Cualquier componente electrónico se distribuye con una hoja de características: rango de temperatura, tolerancias, condiciones de uso, límites absolutos. Nadie diseña un circuito sin leerla.

Los conjuntos de datos se comparten con un nombre y un enlace. Quien los reutiliza hereda todos los supuestos de quien los recogió —qué se filtró, a quién se preguntó, en qué periodo, con qué consentimiento— sin que ninguno esté escrito, y **muchos de ellos ya no se pueden reconstruir**.

3. Propuesta

Un cuestionario que sigue el ciclo de vida del conjunto, en siete secciones:

motivación · composición · recogida · preprocesado · usos · distribución · mantenimiento

con preguntas concretas del tipo «¿qué representa cada instancia?», «¿hubo consentimiento de las personas implicadas?», «¿qué filtros se aplicaron y qué dejaron fuera?», «¿para qué tareas **no** debería usarse?».

Y una tesis que es la mitad de la propuesta: la hoja se responde **mientras se crea el conjunto**, no después. No es un trámite de publicación: es parte de la construcción.

4. Intuición sin fórmulas

Heredar una receta de familia escrita en una tarjeta: «harina, huevos, leche, hornear».

Puedes reproducirla. Lo que no puedes reconstruir es si lleva harina de trigo o de espelta, si alguien de la familia era celíaco, por qué se quitó la mantequilla en algún momento o si la temperatura del horno de entonces era la de ahora. Esas decisiones se tomaron y nadie las anotó.

Dónde deja de funcionar la analogía: con una receta puedes probar y ajustar. Con un conjunto de datos usado para entrenar un modelo que decide sobre personas, probar y ajustar tiene coste real.

5. Matemática mínima

No hay formalismo. Lo que sí se puede exhibir es la asimetría entre lo reconstruible y lo que no.

La miniatura toma diez preguntas del cuestionario:

Responsible mirando el conjunto	No responsable a posteriori
¿para qué se creó?	¿qué poblaciones están representadas?
¿qué representa cada instancia?	¿hubo consentimiento ?
¿cómo se recogieron?	¿qué filtros se aplicaron y qué dejaron fuera?
¿en qué periodo?	¿para qué no debería usarse?
¿bajo qué licencia?	¿quién lo mantiene ?

5 de 10. Y no es una mitad cualquiera: cada hueco tiene una consecuencia operativa concreta.


Hueco	Consecuencia
poblaciones representadas	no se puede desagregar la evaluación por subgrupo
consentimiento	riesgo legal y ético que aparece ya en producción
filtros aplicados	no se sabe a quién silenció la limpieza del corpus
usos desaconsejados	el conjunto acaba usado para lo que no sirve
mantenimiento	nadie sabe si sigue siendo válido dentro de dos años

La primera consecuencia es exactamente lo que impide rellenar la sección clave de una tarjeta de modelo.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A02 §1 · De la frecuencia a la probabilidad	por qué la pregunta «¿de qué población es muestra esto?» es previa a cualquier cosa que se calcule con los datos

6. Arquitectura o flujo



7. Qué observar en el paper original

- El **cuestionario completo**, que es lo directamente reutilizable: se puede copiar y usar como plantilla el mismo día.
- La insistencia en el **momento**: responder mientras se recoge. Las autoras lo argumentan mostrando qué preguntas dejan de tener respuesta con el tiempo.
- La sección de **recogida**, con las preguntas sobre consentimiento, sobre si las personas fueron notificadas y sobre si pueden retirar sus datos.
- El paralelismo con la industria electrónica, que no es retórico: la hoja de características existe porque integrar un componente sin conocer sus límites produce fallos.

8. Evidencia y resultados

Es una propuesta razonada, con ejemplos de hojas rellenas para conjuntos conocidos —entre ellos *Labeled Faces in the Wild* y *Pang & Lee*— y con entrevistas a profesionales de la industria sobre qué documentación echan en falta.

No hay un experimento que mida el efecto de adoptarlas. La evidencia es cualitativa y de ejemplo, que es lo apropiado para una propuesta documental.

La miniatura reduce el cuestionario a diez preguntas y marca a mano cuáles son reconstruibles, para exhibir la asimetría. Qué preguntas lo son depende del conjunto concreto.

9. Impacto

- Es la referencia estándar para documentar conjuntos de datos, y el origen de las *dataset cards* de Hugging Face.
- Junto con P114 formó el par documental modelo-datos.
- Cambió lo que se espera de una publicación que introduce un conjunto: hoy se pide la documentación de procedencia y de composición.

- Dodge et al. (2021) aplicaron la idea a un corpus web real —C4— y encontraron exactamente lo que el artículo predice: los filtros habían eliminado desproporcionadamente contenido de determinadas comunidades, y nadie lo sabía.

10. Limitaciones

1. **Es voluntaria y costosa.** Responder el cuestionario completo lleva trabajo, y no hay incentivo formal para hacerlo.
2. **Muchos conjuntos existentes son indocumentables:** la información ya se perdió, y lo honesto es escribir «no se sabe».
3. **No dice qué hacer con un conjunto mal documentado** que ya se usa en producción.
4. **Documentar no mejora los datos:** hace explícitos sus límites. Es transparencia, no mitigación.
5. **Los conjuntos derivados** —filtrados, mezclados, deduplicados— rompen la trazabilidad, y hoy casi todos los corpus grandes lo son.

11. Errores comunes

Error	Corrección
«La hoja de datos se escribe al publicar el conjunto»	La mitad de las preguntas ya no tiene respuesta entonces: consentimiento, filtros aplicados, poblaciones representadas. Se responden mientras se recoge.
«Lo importante de un conjunto se ve mirándolo»	Se ve el qué, no el cómo ni el a quién. En la miniatura, 5 de 10 preguntas no son reconstruibles a partir del conjunto.
«Documentar el conjunto lo hace mejor»	Lo hace auditable. Un conjunto sesgado bien documentado sigue sesgado; la diferencia es que se sabe.
«Si no hubo problemas, el consentimiento da igual»	El riesgo legal y ético aparece cuando el sistema ya está en producción, y entonces no se puede reconstruir quién consintió qué.
«Los filtros de limpieza son neutrales»	Dodge et al. documentaron en C4 que los filtros eliminaron desproporcionadamente contenido de determinadas comunidades. Sin registrarlos, eso es invisible.

12. Relación con trabajos anteriores

- **P111 Deuda técnica (2015)** — las dependencias de datos no declaradas son la versión de ingeniería de este mismo problema.
- **P114 Tarjetas de modelo (2019)** — la pieza equivalente para modelos, y la que no se puede rellenar sin esta.
- **P61 Loros estocásticos (2021)** — qué hay dentro de los corpus grandes y qué no se sabe.

13. Relación con trabajos posteriores

- **Dodge et al. (2021)** — documentar C4 y encontrar lo que los filtros dejaron fuera. [doi:10.18653/v1/2021.emnlp-main.98](https://doi.org/10.18653/v1/2021.emnlp-main.98)
- **Hugging Face** — *dataset cards*, la implementación práctica más extendida. huggingface.co
- **P110 Deriva de concepto (2014)** — la sección de mantenimiento existe porque un conjunto caduca.

14. Notebook asociado

P115_hojas_de_datos.ipynb

Qué implementa: el cuestionario reducido a diez preguntas, con cuáles se pueden responder mirando el conjunto y cuáles no, y la consecuencia operativa concreta de cada hueco.

Qué NO implementa: el cuestionario real es mucho más largo y está agrupado en siete secciones. Qué preguntas son respondibles depende del conjunto: aquí están marcadas a mano para ilustrar la asimetría.

```
ai-evolution paper-lab P115 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Enumera las siete secciones del cuestionario.
Explicar	Explica por qué la hoja se escribe durante la recogida.
Aplicar	Ejecuta el notebook y separa las preguntas reconstruibles de las que no.
Analizar	Analiza qué impide, aguas abajo, no saber qué poblaciones están representadas.
Evaluar	«El conjunto está publicado con licencia abierta, luego se puede usar». Evalúa la afirmación.
Crear	Escribe la hoja de datos de un conjunto que uses, marcando explícitamente los «no se sabe».

16. Autoevaluación

1. ¿De dónde viene la metáfora de la hoja de datos?
2. ¿Cuándo hay que responder el cuestionario?
3. ¿Qué preguntas no son reconstruibles a posteriori?
4. ¿Qué impide no saber qué poblaciones están representadas?
5. ¿Qué encontró Dodge et al. al documentar C4?
6. ¿Mejora los datos escribir la hoja?
7. ¿Qué hacer con un conjunto ya indocumentable?

17. Respuestas esperadas

1. De la electrónica: cualquier componente se distribuye con su rango de operación, tolerancias y límites absolutos, y nadie lo integra sin leerlos.
2. Mientras se crea el conjunto. Media docena de preguntas —consentimiento, filtros, poblaciones— dejan de tener respuesta en cuanto pasa el tiempo.
3. Qué poblaciones están representadas, si hubo consentimiento, qué dejaron fuera los filtros, para qué no debería usarse y quién lo mantiene.
4. Desagregar la evaluación por subgrupo, que es justamente la sección clave de una tarjeta de modelo. Sin esa información, no se puede rellenar.

5. Que los filtros de limpieza habían eliminado desproporcionadamente contenido de determinadas comunidades, sin que nadie lo supiera ni lo hubiera decidido.
6. No. Los hace auditables. Un conjunto sesgado bien documentado sigue sesgado, con la diferencia de que se sabe y se puede decidir.
7. Escribir la hoja con «no se sabe» donde corresponda. Es información: dice de qué no se puede responder al usarlo.

18. Fuentes primarias

- Gebru, T. et al. (2021). *Datasheets for Datasets*. **Communications of the ACM**, 64(12), 86–92. doi:10.1145/3458723 · consultado 2026-08-17.
- Dodge, J. et al. (2021). *Documenting Large Webtext Corpora: A Case Study on the Colossal Clean Crawled Corpus*. doi:10.18653/v1/2021.emnlp-main.98 · consultado 2026-08-17.
- Mitchell, M. et al. (2019). *Model Cards for Model Reporting*. doi:10.1145/3287560.3287596 · consultado 2026-08-17.



Evaluación — P115 · Hojas de datos para conjuntos de datos

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Datasheets for Datasets* (2021, Communications of the ACM, 64(12), 86–92) · **Nivel:** L1

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P115_hojas_de_datos.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).