

P116

Por qué Johnny no sabe hacer prompts: cómo los no expertos intentan (y fallan) diseñar prompts

Why Johnny Can't Prompt: How Non-AI Experts Try (and Fail) to Design LLM Prompts

J.D. Zamfirescu-Pereira, Richmond Y. Wong, Bjoern Hartmann, Qian Yang · 2023 · CHI '23

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-17.

P116 — Por qué Johnny no sabe hacer prompts

Ruta de operación · Cuatro versiones de un prompt, tres idénticas en calidad real. Eligiendo con veinte ejemplos, se descarta la buena.

Nivel: L2 · **Motor:** `gestion_de_prompts` · **Notebook:** `P116_gestion_de_prompts.ipynb` · **Anexo:** probabilidad y verosimilitud

1. Identificación

Campo	Valor
Título original	<i>Why Johnny Can't Prompt: How Non-AI Experts Try (and Fail) to Design LLM Prompts</i>
Autoría	J.D. Zamfirescu-Pereira, Richmond Y. Wong, Bjoern Hartmann, Qian Yang
Año	2023
Venue	CHI '23
Fuente primaria	doi:10.1145/3544548.3581388
Acceso	Restringido
Fecha de consulta	2026-08-17

2. Problema anterior

Escribir un prompt parece accesible a cualquiera: se escribe en lenguaje natural y el resultado se lee de inmediato. Precisamente por eso se hace sin ninguna disciplina de ingeniería —sin versionar, sin conjunto de evaluación, mirando dos o tres ejemplos y quedándose con lo que «va mejor»—.

Y ahí está el problema: con muestras pequeñas, **el ruido tiene el mismo tamaño que las mejoras que se buscan**. La sensación de progreso es real; el progreso no.

3. Propuesta

Un estudio con participantes no expertos construyendo un asistente conversacional, observando qué hacen en realidad.

El patrón dominante que documentan es la **iteración oportunista**: cambiar algo, mirar un par de ejemplos, quedarse si parece mejor, no versionar, no medir. Y lo acompañan de un hallazgo más incómodo: los participantes generalizan desde anécdotas y desarrollan explicaciones sobre el comportamiento del modelo que no se sostienen.

La conclusión no es que haga falta más talento redactando. Es que el prompt necesita las prácticas del software: **conjunto de evaluación fijo, una hipótesis por cambio, versionado con el código y registro de qué se probó**.

4. Intuición sin fórmulas

Ajustar una receta probando un bocado de cada intento. Le pones más sal, pruebas, «mejor». Menos cocción, pruebas, «mejor». Al cabo de veinte iteraciones tienes la convicción de haberla mejorado mucho y ningún dato: cada bocado fue distinto, y tu paladar del intento uno no es el del veinte.

Dónde deja de funcionar la analogía: en la cocina hay comensales que acaban dando su opinión. Con un prompt, si nadie mide, el bucle se puede sostener indefinidamente.

5. Matemática mínima

Medir la calidad de un prompt sobre n ejemplos es estimar una proporción:

$$\text{desviación} \approx \sqrt{p(1-p) / n}$$

p = 0,7, n = 20 → ±0,102

p = 0,7, n = 200 → ±0,032

La miniatura toma cuatro versiones de un prompt, tres con calidad real **idéntica** (0,70) y una mejor (0,78):



Versión	Calidad real	Medida con 20 ejemplos	Medida con 200
v1	0,70	0,85	0,665
v2	0,70	0,70	0,770
v3	0,78	0,45	0,805
v4	0,70	0,80	0,700

Eligiendo con 20 ejemplos se elige **v1** y se descarta **v3**, que es la única que de verdad era mejor. Y no es mala suerte: la desviación esperada con 20 ejemplos (**0,102**) es mayor que la diferencia real entre versiones (0,08). El instrumento no tiene resolución para la pregunta.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A02 §5 · Estimadores, sesgo y varianza	cuántos ejemplos hacen falta para distinguir dos proporciones que difieren en 0,08

6. Arquitectura o flujo



7. Qué observar en el paper original

- Los **fragmentos de sesión** de los participantes. Son lo más útil del artículo: se reconoce en ellos el comportamiento propio.
- La distinción entre lo que los participantes **creían** que estaban haciendo y lo que hacían: una brecha sistemática y no un fallo individual.
- La discusión sobre **generalizar desde anécdotas** y construir teorías del comportamiento del modelo que no se sostienen.
- Las implicaciones de diseño para **herramientas** de prompting: qué debería ofrecer un entorno para que la práctica sistemática sea la fácil.

8. Evidencia y resultados

Es un estudio cualitativo con participantes reales, con análisis de sus sesiones y de sus verbalizaciones.

Su evidencia son observaciones de comportamiento, no una tabla de exactitudes. Y ese es el tipo de evidencia adecuado para la pregunta que hace: qué hace la gente cuando escribe prompts.

La miniatura no reproduce el estudio: simula el mecanismo aritmético —cuatro versiones y una muestra pequeña— para que se vea por qué la iteración oportunista falla incluso con buena intención. La «calidad» de cada prompt es una moneda sesgada; no hay ningún modelo detrás.

9. Impacto

- Es el argumento canónico de que **LLMOps es ingeniería y no redacción**, y se cita constantemente para justificar la inversión en evaluación.
- Impulsó la aparición de herramientas de evaluación de prompts —promptfoo, LangSmith y similares— cuya función principal es exactamente lo que el artículo echa en falta.
- La práctica de versionar el prompt junto al código, con su conjunto de evaluación, viene de aquí.
- Y aporta al programa la razón de que los proyectos con modelos de lenguaje exijan un conjunto de evaluación antes de la primera iteración, no después.

10. Limitaciones

1. **Es un estudio pequeño y cualitativo**, con participantes no expertos y una tarea concreta. No se puede extrapolar cuantitativamente.
2. **Los modelos de 2023 no son los de hoy**, y parte de las dificultades observadas se deben a modelos que seguían peor las instrucciones.
3. **No propone un método**: diagnostica y sugiere implicaciones de diseño.
4. **Un conjunto de evaluación fijo tiene su propio riesgo**: optimizar contra él acaba sobreajustándolo. Hace falta rotarlo y guardar un conjunto ciego.
5. **Evaluar salidas abiertas es caro y difícil**, y el artículo no resuelve cómo construir el conjunto que recomienda.

11. Errores comunes

Error	Corrección
«Si el prompt va mejor en unos ejemplos, va mejor»	Con 20 ejemplos la desviación de la medida es 0,102, mayor que la diferencia real entre versiones. En la miniatura se elige la peor de cuatro.
«Escribir prompts es cuestión de talento redactando»	El artículo muestra que el problema es de método, no de redacción: sin conjunto de evaluación fijo, la intuición no tiene con qué corregirse.
«Basta con tener un conjunto de evaluación»	Optimizar contra un conjunto fijo acaba sobreajustándolo. Hay que rotarlo y guardar un conjunto ciego que no se mira durante la iteración.
«Con modelos actuales esto ya no pasa»	Los modelos siguen mejor las instrucciones, y el problema del muestreo es aritmético: no depende del modelo sino del tamaño de la muestra.
«El prompt no es código, no hace falta versionarlo»	Es la parte del sistema que más cambia y la que menos se registra. Sin versión, no se puede revertir ni saber qué cambió cuando la calidad cae.

12. Relación con trabajos anteriores

- **P62 El benchmark del todo (2021)** — qué mide de verdad un conjunto de evaluación, que es la pieza que aquí falta.
- **P63 Reproducibilidad (2021)** — la misma exigencia aplicada a experimentos.
- **P113 Aprendizaje por refuerzo que importa (2018)** — el mismo error de muestreo, en otro dominio y con más varianza.

13. Relación con trabajos posteriores

- **Liu et al. (2023)** — revisión sistemática de métodos de prompting. doi:10.1145/3560815
- **promptfoo** — la familia de herramientas de evaluación que materializa la recomendación. promptfoo.dev
- **P117 AgentBench (2023)** — el mismo problema cuando lo que hay que evaluar es una trayectoria y no una salida.

14. Notebook asociado

P116_gestion_de_prompts.ipynb

Qué implementa: cuatro versiones de un prompt con calidad real conocida, medidas sobre 20 y sobre 200 ejemplos, con la versión que se elegiría en cada caso y el ruido esperado de la medida.

Qué NO implementa: la «calidad» de cada prompt es una moneda sesgada: no hay ningún modelo detrás y los números no representan a ningún sistema real. Solo exhibe la aritmética del muestreo.

```
ai-evolution paper-lab P116 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe la desviación esperada al estimar una proporción con n ejemplos.
Explicar	Explica qué es la iteración oportunista.
Aplicar	Ejecuta el notebook y compara la versión elegida con 20 y con 200 ejemplos.
Analizar	Analiza por qué el problema no se arregla escribiendo mejores prompts.
Evaluar	«Probé el cambio en cinco casos y funciona mejor». Evalúa la afirmación.
Crear	Construye un conjunto de evaluación fijo para un prompt tuyo y mide la versión actual antes de tocarla.

16. Autoevaluación

1. ¿Qué es la iteración oportunista?
2. ¿Por qué falla con muestras pequeñas?
3. ¿Cuántos ejemplos hacen falta para distinguir dos versiones que difieren en 0,08?
4. ¿Qué cuatro prácticas propone el enfoque sistemático?
5. ¿Es un problema de talento redactando?
6. ¿Qué riesgo tiene un conjunto de evaluación fijo?
7. ¿Qué tipo de evidencia aporta el artículo?

17. Respuestas esperadas

1. Cambiar algo, mirar dos o tres ejemplos, quedarse si parece mejor, no versionar y no medir. Es el patrón dominante que el estudio documenta.
2. Porque el ruido de la medida es del mismo tamaño que la mejora buscada. Con 20 ejemplos la desviación es 0,102 y la diferencia real entre versiones, 0,08.
3. Bastantes más de veinte. Con 200 la desviación baja a 0,032 y la diferencia empieza a ser distinguishable; con 20 el instrumento no tiene resolución.
4. Conjunto de evaluación fijo, una hipótesis por cambio, versionar el prompt con el código y registrar qué se probó y qué salió.
5. No. Es de método: sin conjunto de evaluación, la intuición no tiene con qué corregirse, y los participantes generalizaban desde anécdotas.
6. Que optimizar contra él acaba sobreajustándolo. Hay que rotarlo y mantener un conjunto ciego que no se mira durante la iteración.
7. Observaciones cualitativas del comportamiento de participantes reales. Es el tipo de evidencia adecuado para la pregunta que hace, y no se puede extrapolar cuantitativamente.

18. Fuentes primarias

- Zamfirescu-Pereira, J.D. et al. (2023). *Why Johnny Can't Prompt: How Non-AI Experts Try (and Fail) to Design LLM Prompts*. **CHI '23**. doi:10.1145/3544548.3581388 · consultado 2026-08-17.
- Liu, P. et al. (2023). *Pre-train, Prompt, and Predict: A Systematic Survey of Prompting Methods*. doi:10.1145/3560815 · consultado 2026-08-17.
- promptfoo. *Introduction*. promptfoo.dev · consultado 2026-08-17.

Evaluación — P116 · Por qué Johnny no sabe hacer prompts: cómo los no expertos intentan (y fallan) diseñar prompts

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Why Johnny Can't Prompt: How Non-AI Experts Try (and Fail) to Design LLM Prompts* (2023, CHI '23) · **Nivel:** L2

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P116_gestion_de_prompts.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).