

P118

Traducción automática neuronal de palabras raras con unidades de subpalabra

Neural Machine Translation of Rare Words with Subword Units

Rico Sennrich, Barry Haddow, Alexandra Birch · 2016 · ACL 2016, 1715–1725

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-18.

P118 — Unidades de subpalabra

Ruta de percepción · Mientras la unidad sea la palabra, siempre llegará una que no estaba. Si es más pequeña, el peor caso es deletrear — y deletrear siempre se puede.

Nivel: L2 · Motor: `bpe` · Notebook: `P118_bpe.ipynb` · Anexo: complejidad y coste

1. Identificación

Campo	Valor
Título original	<i>Neural Machine Translation of Rare Words with Subword Units</i>
Autoría	Rico Sennrich, Barry Haddow, Alexandra Birch
Año	2016
Venue	ACL 2016, 1715–1725
Fuente primaria	doi:10.18653/v1/P16-1162
Acceso	Abierto
Fecha de consulta	2026-08-18

2. Problema anterior

Un modelo con vocabulario de palabras completas tiene una lista fija, y todo lo que no está en ella se convierte en un único símbolo de «desconocido». Da igual que la palabra sea un nombre propio, un término técnico o una flexión perfectamente regular: el modelo la ve como el mismo agujero.

Lo absurdo es que casi siempre **las partes sí estaban**. Si el corpus tiene «caminar» y «cantando», el modelo ha visto la raíz `camin` y el sufijo `ando`, y aun así «caminando» le resulta ilegible. El vocabulario cerrado convierte un problema de composición en uno de cobertura.

3. Propuesta

Adaptar la compresión por pares de bytes —un algoritmo de 1994— a la segmentación de texto:

1. Partir cada palabra en caracteres, con una marca de fin de palabra.
2. Contar todos los pares de símbolos adyacentes del corpus.
3. Fusionar el par **más frecuente** en un símbolo nuevo.
4. Repetir un número fijo de veces, `k`.

Ese `k` es la única perilla, y determina el tamaño del vocabulario. Lo importante es lo que queda al final: el vocabulario contiene el alfabeto completo, así que **cualquier** cadena se puede segmentar. El peor caso es deletrear, y deletrear siempre se puede.

4. Intuición sin fórmulas

Un almacén que solo despacha muebles montados. Si alguien pide una estantería de una medida que no está en catálogo, la respuesta es «no lo tenemos», aunque el almacén esté lleno de tableros y tornillos.

Cambiar el catálogo a piezas resuelve el problema entero: cualquier mueble se puede componer, y los más pedidos siguen estando premontados porque salen más a cuenta.

Dónde deja de funcionar la analogía: en el almacén las piezas las diseñó alguien. Aquí las decide la frecuencia, sin que nadie le diga al algoritmo qué es una raíz o un sufijo.

5. Matemática mínima

BPE: partir de caracteres y repetir k veces:
fusionar el par de símbolos MÁS FRECUENTE del corpus

vocabulario = alfabeto $\cup$ {símbolos que las k fusiones producen}
↑
el alfabeto está dentro $\Rightarrow$ cobertura total

La miniatura entrena con 220 palabras y prueba con 120:

	Vocabulario de palabras	BPE con 60 fusiones
tamaño del vocabulario	100	87
palabras/trozos desconocidos	17 (14,2 %)	0
piezas por palabra	1,00	2,02


Las 17 desconocidas están formadas por raíces y sufijos que el modelo **sí** vio: lo que faltaba era la combinación. Y el precio de arreglarlo es la longitud: cada palabra ocupa el doble de posiciones en la secuencia.

Las primeras fusiones son parejas de letras frecuentes — `o</w>`, `or`, `a</w>` —; las últimas ya son sufijos completos como `ndo</w>`. Nadie programó qué es un sufijo.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A05 §2 · El cruce: atención frente a recurrencia	por qué duplicar la longitud de secuencia no es gratis cuando el coste de atención es cuadrático

6. Arquitectura o flujo



7. Qué observar en el paper original

- Que el algoritmo **no es lingüístico**. No hay lista de morfemas ni analizador: hay un contador de frecuencias, y eso es lo que lo hace aplicable a idiomas cuya morfología el ingeniero no conoce.
- El experimento sobre **palabras raras**, que es donde el método aporta: la mejora se concentra en nombres propios, compuestos y términos que aparecen una o dos veces.
- La discusión sobre **el tamaño del vocabulario** y su relación con la longitud de secuencia. Es el único compromiso, y el artículo lo hace explícito.
- Que la idea se toma prestada de la **compresión de datos**, sin ninguna motivación lingüística previa. Es un buen ejemplo de resultado que llega de otro campo.

8. Evidencia y resultados

El artículo demuestra su tesis con traducción automática: mejoras de BLEU en inglés-alemán e inglés-ruso, con análisis específico sobre las palabras raras.

La evidencia es de tarea, no de cobertura: no se limita a mostrar que no hay desconocidos, sino que traduce mejor. Eso es lo que convenció al campo.

La miniatura no traduce nada: mide cobertura y longitud sobre un corpus sintético de raíces y sufijos regulares, para exhibir el mecanismo. En texto real las fusiones frecuentes cruzan fronteras de morfema y los trozos dejan de ser interpretables.

9. Impacto

- Es la tokenización con la que se entrenaron **GPT-2**, **GPT-3**, **RoBERTa** y buena parte de los modelos posteriores. La variante sobre bytes en vez de caracteres eliminó incluso la necesidad de un alfabeto.
- Cerró el problema de la palabra desconocida, que llevaba décadas condicionando el diseño de sistemas de lenguaje.
- Llevó directamente a SentencePiece, que quitó el último supuesto que quedaba: que el texto viene partido por espacios.
- Y dejó una consecuencia que hoy se paga en dinero: la factura de un modelo de lenguaje se mide en tokens, y cuántos tokens ocupa un texto lo decide este algoritmo.

10. Limitaciones

1. **La segmentación no respeta la morfología.** Las fusiones frecuentes cruzan fronteras de morfema, y los trozos resultantes no son interpretables ni estables.
2. **Penaliza a los idiomas peor representados** en el corpus de entrenamiento del tokenizador: necesitan más piezas por palabra, y por tanto más tokens para decir lo mismo.
3. **Supone texto partido por espacios**, lo que deja fuera al japonés, el chino y el tailandés.
4. **La segmentación voraz por orden de fusión no es óptima:** no da la de mínima longitud.
5. **El tokenizador es parte del modelo.** Cambiarlo invalida los pesos, y eso se olvida con una frecuencia notable.

11. Errores comunes

Error	Corrección
«Agrandando el vocabulario se acaban las palabras desconocidas»	Se reducen, nunca se eliminan: la cola de palabras raras es infinita. Y cada palabra nueva es una fila más en la matriz de incrustaciones.
«Los trozos de BPE son morfemas»	Coinciden a veces y por accidente. El algoritmo solo cuenta frecuencias, y sus fusiones cruzan fronteras de morfema con toda naturalidad.
«BPE es preprocesado, no parte del modelo»	Es parte del modelo: cambiar el tokenizador invalida los pesos. Hay que versionarlo con el checkpoint, no con el código de datos.
«Un vocabulario más pequeño siempre es mejor»	Se paga en longitud de secuencia. En la miniatura, 87 unidades en vez de 100 palabras cuestan 2,02 piezas por palabra en lugar de 1.
«La tokenización trata igual a todos los idiomas»	No: los idiomas peor representados en el corpus del tokenizador necesitan más piezas por palabra, y pagan más tokens por decir lo mismo.

12. Relación con trabajos anteriores

- **P05 word2vec (2013)** — el vocabulario cerrado como supuesto de partida, con su matriz de incrustaciones por palabra.
- **P06 Secuencia a secuencia (2014)** — la arquitectura donde el problema de la palabra desconocida era más visible.
- **Gage (1994)** — el algoritmo de compresión del que se toma prestada la idea.

13. Relación con trabajos posteriores

- **P123 SentencePiece (2018)** — quita el supuesto de los espacios y hace la detokenización exacta.
- **Radford et al. (2019)** — BPE sobre bytes en GPT-2: ni siquiera hace falta un alfabeto.
- **Rust et al. (2021)** — cuánto penaliza un tokenizador mal ajustado a un idioma.
doi:10.18653/v1/2021.acl-long.243

14. Notebook asociado

P118_bpe.ipynb

Qué implementa: la tasa de palabras desconocidas con vocabulario de palabras frente a la de trozos fuera de vocabulario con BPE, el tamaño de cada vocabulario, las primeras fusiones aprendidas y el coste en piezas

por palabra.

Qué NO implementa: el corpus es sintético y morfológicamente regular, así que las fusiones caen limpiamente en morfemas. Y no se traduce nada: la tesis del artículo se demuestra con BLEU.

```
ai-evolution paper-lab P118 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Describe los cuatro pasos del algoritmo BPE.
Explicar	Explica por qué el vocabulario resultante cubre cualquier cadena.
Aplicar	Ejecuta el notebook y compara las dos tasas de desconocidos.
Analizar	Analiza el compromiso entre tamaño de vocabulario y longitud de secuencia.
Evaluar	«Ampliamos el vocabulario y bajó la tasa de desconocidas». Evalúa si eso resuelve el problema.
Crear	Tokeniza un corpus de tu dominio con dos tamaños de vocabulario y mide piezas por palabra. Comprueba qué pasa con los términos técnicos.

16. Autoevaluación

1. ¿Qué par se fusiona en cada paso?
2. ¿Por qué BPE no puede producir un trozo desconocido?
3. ¿Cuál es la única perilla del método?
4. ¿Qué se paga a cambio de la cobertura total?
5. ¿Son morfemas los trozos que produce?
6. ¿Por qué el tokenizador es parte del modelo?
7. ¿Qué idiomas quedan fuera del supuesto de BPE?

17. Respuestas esperadas

1. El par de símbolos adyacentes más frecuente en todo el corpus, contando con la multiplicidad de cada palabra.
2. Porque el alfabeto completo forma parte del vocabulario. En el peor caso, una palabra se segmenta letra a letra, y eso siempre es posible.
3. El número de fusiones, `k`, que determina el tamaño del vocabulario. Todo lo demás lo decide la frecuencia del corpus.
4. Longitud de secuencia. En la miniatura, 2,02 piezas por palabra en vez de 1, y con atención cuadrática eso no es gratis.
5. A veces y por accidente. El algoritmo solo cuenta frecuencias; sus fusiones cruzan fronteras de morfema con naturalidad y los trozos no son estables.
6. Porque los pesos están asociados a un vocabulario concreto. Cambiar el tokenizador invalida las incrustaciones y el modelo deja de significar lo mismo.

7. El japonés, el chino y el tailandés, entre otros: no separan palabras con espacios. Eso lo resuelve SentencePiece.

18. Fuentes primarias

- Sennrich, R., Haddow, B. y Birch, A. (2016). *Neural Machine Translation of Rare Words with Subword Units*. **ACL 2016**, 1715–1725. doi:10.18653/v1/P16-1162 · consultado 2026-08-18.
- Gage, P. (1994). *A New Algorithm for Data Compression*. **The C Users Journal**. dl.acm.org · consultado 2026-08-18.
- Kudo, T. y Richardson, J. (2018). *SentencePiece*. doi:10.18653/v1/D18-2012 · consultado 2026-08-18.



Evaluación — P118 · Traducción automática neuronal de palabras raras con unidades de subpalabra

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Neural Machine Translation of Rare Words with Subword Units* (2016, ACL 2016, 1715–1725) ·
Nivel: L2

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P118_bpe.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).