

P119

WaveNet: un modelo generativo de audio en crudo

WaveNet: A Generative Model for Raw Audio

Aäron van den Oord, Sander Dieleman, Heiga Zen, Karen Simonyan, Oriol Vinyals, Alex Graves, Nal Kalchbrenner,
Andrew Senior, Koray Kavukcuoglu · 2016 · arXiv:1609.03499

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español
que enlaza a la fuente primaria. Consultado 2026-08-18.

P119 — WaveNet

Ruta de percepción · Para ver un segundo de audio harían falta 16 000 capas. Saltando huecos que se duplican en cada una, bastan catorce.

Nivel: L3 · Motor: wavenet · Notebook: P119_wavenet.ipynb · Anexo: complejidad y coste

1. Identificación

Campo	Valor
Título original	WaveNet: A Generative Model for Raw Audio
Autoría	Aäron van den Oord, Sander Dieleman, Heiga Zen, Karen Simonyan, Oriol Vinyals, Alex Graves, Nal Kalchbrenner, Andrew Senior, Koray Kavukcuoglu
Año	2016
Venue	arXiv:1609.03499
Fuente primaria	arXiv:1609.03499
Acceso	Abierto
Fecha de consulta	2026-08-18

2. Problema anterior

La síntesis de voz funcionaba pegando trozos de grabaciones reales o generando parámetros que un vocoder convertía en sonido. Las dos vías tenían techo: la primera sonaba a costura y no se podía cambiar de voz, la segunda sonaba a robot.

Modelar la forma de onda directamente parecía imposible por una razón de escala. A 16 kHz, un segundo son 16 000 valores, y una convolución con núcleo de 2 necesita una capa por cada muestra de contexto. Para ver un segundo harían falta 16 000 capas.

3. Propuesta

Dos ideas, ninguna de ellas sobre arquitecturas nuevas:

- Convoluciones causales dilatadas.** Cada capa salta huecos que se duplican —1, 2, 4, 8, 16...—, de modo que el campo receptivo crece de forma **exponencial** con la profundidad en lugar de lineal. La causalidad —la salida en t solo depende de entradas hasta t — es obligatoria para que el modelo sirva para generar.
- Cuantización μ -law a 8 bits.** En vez de predecir un valor continuo, se predice una categoría entre 256, repartidas logarítmicamente para gastar resolución donde hay señal.

Y una consecuencia de diseño: el modelo se **condiciona**. Con la identidad del hablante genera voces distintas; con características lingüísticas, habla.

4. Intuición sin fórmulas

Buscar en una biblioteca de 16 000 libros. Mirándolos uno a uno, 16 000 pasos. Si en cambio saltas de 1 en 1, luego de 2 en 2, luego de 4 en 4 —doblando cada vez—, cubres toda la estantería en catorce saltos.

Y la regla de que solo puedes mirar hacia atrás no es un capricho: si al aprender pudieras mirar el libro siguiente, al escribir uno nuevo no tendrías dónde mirar.

Dónde deja de funcionar la analogía: los saltos dejan huecos. La red los rellena porque cada capa combina lo que las anteriores ya juntaron, no porque los vea directamente.

5. Matemática mínima

Campo receptivo con núcleo 2 y L capas:

sin dilatar

:

$1 + \sum_i 1$

=

$L + 1$

← LINEAL

dilatado 2^i

:

$1 + \sum_i 2^i$

=

2^L

← EXPONENCIAL

Capas	Sin dilatar	Dilatado
4	5	16
8	9	256
12	13	4 096

Para cubrir **un segundo a 16 kHz** hacen falta **14 capas** dilatadas frente a **15 999** sin dilatar: un factor de **1 143×**.


La causalidad se comprueba directamente: un impulso en la muestra 12 solo afecta a las muestras **12–19**, ninguna anterior.

Y la cuantización μ -law reparte los 256 códigos de forma logarítmica. El 10 % central de la amplitud —donde vive la voz— se lleva **109 códigos** con μ -law y solo **26** con la lineal: **4,2× más resolución** donde hace falta, con el mismo presupuesto de 8 bits.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A05 §1 · Notación O(): qué dice y qué no	la diferencia entre un crecimiento lineal y uno exponencial cuando lo que crece es lo que puedes ver

6. Arquitectura o flujo



7. Qué observar en el paper original

- Que la salida es un **softmax sobre 256 categorías**, no una regresión. Tratar la amplitud como clase y no como número es una decisión deliberada, y el artículo la justifica.
- El **condicionamiento global y local**: la identidad del hablante frente a las características lingüísticas en cada instante. Es lo que convierte el modelo en un sintetizador.
- Las **conexiones residuales y de salto** entre bloques dilatados, que son lo que permite apilar decenas de capas sin que el entrenamiento se rompa.
- El reconocimiento explícito de que **generar es lentísimo**: una muestra por paso, 16 000 pasos por segundo de audio. El artículo no lo esconde.

8. Evidencia y resultados

Evaluación con **opinión media de oyentes humanos** en inglés y mandarín, comparada contra los dos sistemas dominantes de la época. WaveNet reduce a la mitad la distancia con el habla real.

Es la métrica correcta para el problema: en síntesis de voz, ninguna pérdida numérica predice bien lo que un oyente percibe.

La miniatura no entrena nada. Calcula la geometría de las dilataciones, comprueba la causalidad con un impulso y mide la aritmética de la cuantización. Lo que no reproduce es lo más caro: generar.

9. Impacto

- Cambió la síntesis de voz de golpe, y las asistentes comerciales adoptaron descendientes suyos en menos de dos años.
- Las **convoluciones dilatadas** salieron del audio y se usan hoy en series temporales, segmentación y modelado de secuencias en general.
- Fue el vocoder de Tacotron 2, que es donde el sistema completo texto-a-voz alcanzó naturalidad indistinguible de una grabación.
- Y abrió la conversación sobre clonación de voz: cuando sintetizar deja de sonar a máquina, la pregunta pasa a ser de quién es esa voz.

10. Limitaciones

1. **Generar es secuencial y lentísimo**: una muestra por paso. El artículo original tardaba minutos en producir segundos, y eso lo hacía inviable en producción hasta que llegaron las variantes paralelas.

2. **El campo receptivo dice qué PUEDE ver el modelo, no qué usa.** Que alcance un segundo no significa que el segundo entero influya en la predicción.
3. **Sin condicionamiento produce balbuceo:** sonidos con textura de voz y sin contenido. Lo que lo convierte en sintetizador es el condicionamiento, no el modelo generativo.
4. **La cuantización a 8 bits introduce ruido audible,** aceptable pero real, y trabajos posteriores volvieron a 16 bits con otras técnicas.
5. **Necesita mucha voz grabada del hablante objetivo,** lo que en su momento limitaba el método a quien tuviera un estudio.

11. Errores comunes

Error	Corrección
«Dilatar es lo mismo que apilar más capas»	Apilar hace crecer el campo receptivo linealmente; dilatar, exponencialmente. Para un segundo a 16 kHz son 14 capas frente a 15 999.
«La causalidad es una restricción menor»	Sin ella el modelo se entrena mirando el futuro y no sirve para generar: al generar no hay futuro que mirar.
«Campo receptivo grande significa contexto usado»	Dice qué puede ver, no qué usa. Medir la influencia real exige ablaciones, no aritmética de capas.
« μ -law es solo una compresión heredada de la telefonía»	Es una decisión de dónde gastar resolución. En la miniatura da 109 códigos a las amplitudes bajas frente a 26 de la lineal, con los mismos 8 bits.
«WaveNet resolvió la síntesis de voz por sí solo»	Genera audio con textura de voz. Para que diga algo hace falta condicionarlo, y el sistema completo llegó con Tacotron 2.

12. Relación con trabajos anteriores

- **P04 AlexNet (2012)** — la convolución como operación central, aquí llevada a una dimensión y al tiempo.
- **P02 Retropropagación (1986)** — el mecanismo que permite entrenar decenas de capas apiladas.
- **Yu y Koltun (2016)** — convoluciones dilatadas para contexto multiescala en visión. [arXiv:1511.07122](#)

13. Relación con trabajos posteriores

- **P122 Tacotron 2 (2018)** — WaveNet como segunda etapa de un sistema completo de texto a voz.
- **van den Oord et al. (2018)** — Parallel WaveNet: destilación para generar en paralelo y hacerlo desplegable. [arXiv:1711.10433](#)
- **P130 VALL-E (2023)** — clonar una voz con tres segundos de audio, y el problema de identidad que eso plantea.

14. Notebook asociado

P119_wavenet.ipynb

Qué implementa: el crecimiento del campo receptivo con y sin dilatación, cuántas capas hacen falta para cubrir un segundo de audio, la comprobación de causalidad con un impulso y el reparto de códigos de la

cuantización μ -law frente a la lineal.

Qué NO implementa: no se entrena ni se genera nada. El coste real de WaveNet está en producir muestra a muestra, que es justamente lo que la miniatura no hace.

```
ai-evolution paper-lab P119 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe la fórmula del campo receptivo con dilatación exponencial.
Explicar	Explica por qué la convolución tiene que ser causal.
Aplicar	Ejecuta el notebook y comprueba la causalidad con el impulso.
Analizar	Analiza por qué μ -law da más resolución en las amplitudes pequeñas.
Evaluar	«El modelo tiene un campo receptivo de un segundo, luego usa un segundo de contexto». Evalúa la afirmación.
Crear	Calcula el campo receptivo de una red convolucional que uses y compáralo con la longitud real de tus entradas.

16. Autoevaluación

1. ¿Cómo crece el campo receptivo con dilatación exponencial?
2. ¿Cuántas capas hacen falta para un segundo a 16 kHz?
3. ¿Qué garantiza la causalidad?
4. ¿Por qué la salida es un softmax y no una regresión?
5. ¿Qué aporta la cuantización μ -law?
6. ¿Qué hace falta para que WaveNet diga algo?
7. ¿Cuál era su gran problema práctico?

17. Respuestas esperadas

1. Como 2 elevado al número de capas, frente al crecimiento lineal de una convolución sin dilatar. Con 12 capas, 4 096 muestras frente a 13.
2. Catorce dilatadas, frente a 15 999 sin dilatar: un factor de 1 143×.
3. Que la salida en el instante t solo dependa de entradas hasta t . Sin eso, el modelo se entrenaría mirando el futuro y al generar no habría futuro que mirar.
4. Porque trata la amplitud como una categoría entre 256 en vez de como un número. Eso permite distribuciones multimodales, que una regresión no captura.
5. Reparte los 256 niveles logarítmicamente. El 10 % central de la amplitud se lleva 109 códigos frente a 26 de la lineal, con el mismo presupuesto de 8 bits.
6. Condicionamiento. Sin él produce balbuceo con textura de voz. Con características lingüísticas y la identidad del hablante, habla.
7. La generación secuencial: una muestra por paso, 16 000 por segundo de audio. Eso lo hacía inviable hasta que llegaron las variantes paralelas.

18. Fuentes primarias

- van den Oord, A. et al. (2016). *WaveNet: A Generative Model for Raw Audio*. **arXiv:1609.03499**. arxiv.org/abs/1609.03499 · consultado 2026-08-18.
- Yu, F. y Koltun, V. (2016). *Multi-Scale Context Aggregation by Dilated Convolutions*. **arXiv:1511.07122** · consultado 2026-08-18.
- Shen, J. et al. (2018). *Natural TTS Synthesis by Conditioning WaveNet on Mel Spectrogram Predictions*. doi:10.1109/ICASSP.2018.8461368 · consultado 2026-08-18.



Evaluación — P119 · WaveNet: un modelo generativo de audio en crudo

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *WaveNet: A Generative Model for Raw Audio* (2016, arXiv:1609.03499) · **Nivel:** L3

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P119_wavenet.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).