

P120

Clasificación semisupervisada con redes convolucionales de grafo

Semi-Supervised Classification with Graph Convolutional Networks

Thomas N. Kipf, Max Welling · 2017 · ICLR 2017 · arXiv:1609.02907

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-18.

P120 — Redes convolucionales de grafo

Ruta de percepción · Seis nodos etiquetados de ciento veinte. Los rasgos no bastan, pero cada nodo tiene vecinos, y eso convierte seis etiquetas en información global.

Nivel: L2 · Motor: gcn · Notebook: P120_gcn.ipynb · Anexo: álgebra y geometría

1. Identificación

Campo	Valor
Título original	<i>Semi-Supervised Classification with Graph Convolutional Networks</i>
Autoría	Thomas N. Kipf, Max Welling
Año	2017
Venue	ICLR 2017 · arXiv:1609.02907
Fuente primaria	arXiv:1609.02907
Acceso	Abierto
Fecha de consulta	2026-08-18

2. Problema anterior

Muchos datos importantes son grafos: redes de citas, redes sociales, moléculas, grafos de dependencias. Y en casi todos, etiquetar es caro: se tienen unas decenas de nodos anotados sobre miles.

Las soluciones previas se repartían en dos extremos. Los métodos espectrales eran costosos y dependían de la descomposición del grafo completo, lo que impedía generalizar. Los métodos basados en rasgos ignoraban la estructura, y con pocas etiquetas eso deja al clasificador sin nada.

Nadie estaba usando la información más obvia: **quién es vecino de quién**.

3. Propuesta

Una aproximación de primer orden de la convolución espectral que se reduce a algo que cabe en una línea: **promediar los rasgos de cada nodo con los de sus vecinos**, normalizado por el grado, y pasar el resultado por una transformación lineal y una no linealidad.

$$H' = \sigma \left(D^{-1/2} \cdot \hat{A} \cdot D^{-1/2} \cdot H \cdot W \right) \qquad \text{con } \hat{A} = A + I$$

La matriz de adyacencia lleva la identidad sumada para que cada nodo se incluya a sí mismo. Apilar k capas equivale a mirar a k saltos de distancia. Y el artículo es explícito en que **dos o tres capas bastan**.

4. Intuición sin fórmulas

Un pueblo donde quieres saber a qué se dedica cada familia y solo tienes seis respuestas. Pero sabes quién se junta con quién.

Preguntando a los vecinos de cada casa y promediando lo que dicen, las seis respuestas se propagan: al segundo salto ya cubres el pueblo entero.

Dónde deja de funcionar la analogía: si sigues propagando indefinidamente, todo el pueblo acaba dando la misma respuesta promedio y dejas de distinguir barrios. Ese es el sobre-suavizado, y es exactamente lo que ocurre al apilar capas.

5. Matemática mínima

Una capa: $H' = \sigma(D^{(-1/2)} \cdot \hat{A} \cdot D^{(-1/2)} \cdot H \cdot W)$

$\hat{A} = A + I$

D

← el nodo se incluye a sí mismo

← matriz diagonal de grados, para normalizar

k capas = información a k saltos

La miniatura usa 120 nodos en 3 comunidades y **solo 6 etiquetados** (5 %):

Capas de propagación	Exactitud
0 (solo rasgos)	0,447
1	0,886
3	1,000
10	0,921
20	0,377


Con 20 capas queda **peor que no propagar** y cerca del azar (0,333). La causa se ve en la separación entre comunidades, que se hunde de **0,75 a 0,005**: un colapso de **150×**.

Ese colapso solo hace daño porque el motor incluye un **suelo de precisión** de ±0,02, como tendría cualquier sistema real. Sin él, un clasificador ideal resolvería diferencias arbitrariamente pequeñas y el sobre-suavizado no se vería.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A01 §4 · Matrices como transformaciones	qué le hace a un conjunto de vectores multiplicar repetidamente por la misma matriz, que es lo que ocurre al apilar capas

6. Arquitectura o flujo



7. Qué observar en el paper original

- La **derivación** desde la convolución espectral hasta la regla de una línea. El valor del artículo está tanto en el resultado como en mostrar que se puede simplificar tanto.
- El truco de la **renormalización** —sumar la identidad a la adyacencia— y por qué sin él los valores propios se desbordan al apilar capas.
- Que el modelo se entrena **de extremo a extremo con las pocas etiquetas disponibles**, sin ninguna regularización explícita basada en el grafo. La estructura entra por la arquitectura.
- Los resultados en **Cora, Citeseer y Pubmed**, que se convirtieron en el banco de pruebas estándar del área durante años — con los problemas que eso acabó teniendo.

8. Evidencia y resultados

Experimentos en redes de citas y en un grafo de conocimiento, con márgenes claros sobre los métodos previos y un coste de entrenamiento mucho menor.

La evidencia es sólida para la época, pero los conjuntos son pequeños y con una división fija que trabajos posteriores demostraron que sobreestimaba las diferencias entre métodos.

La miniatura no entrena pesos: propaga y clasifica por centroide. Sirve para exhibir el mecanismo y el sobre-suavizado, no para reproducir las cifras del artículo.

9. Impacto

- Es el artículo que popularizó las redes neuronales de grafo y las convirtió en un área con congresos propios.
- Su regla de propagación es el punto de partida de casi todo lo que vino después: GraphSAGE, GAT, paso de mensajes como marco general.
- Se aplica hoy en recomendación, descubrimiento de fármacos, detección de fraude y análisis de dependencias de software.
- Y dejó un problema abierto que sigue vivo: **por qué no se pueden apilar capas**, que es la pregunta que separa a las redes de grafo de las convolucionales profundas.

10. Limitaciones

1. **Supone homofilia**: que los vecinos tienden a compartir clase. En grafos heterófilos, propagar **empeora** el resultado.
2. **No se pueden apilar capas**. Más de tres y el sobre-suavizado destruye la señal, como muestra la miniatura.
3. **Es transductivo en su formulación original**: necesita el grafo completo al entrenar, y no aplica directamente a nodos nuevos.
4. **Escala mal**: la normalización exige conocer los grados de todo el grafo, lo que complica el entrenamiento por lotes.
5. **Los bancos de prueba clásicos eran demasiado pequeños** y su división fija exageraba las diferencias entre métodos. Buena parte de las mejoras publicadas sobre ellos no se sostuvo.

11. Errores comunes

Error	Corrección
«Más capas de grafo capturan más contexto»	Capturan más saltos y borran la señal. En la miniatura, 20 capas dan 0,377: peor que no propagar (0,447) y cerca del azar.
«Propagar siempre ayuda»	Solo si los vecinos tienden a compartir clase. En grafos heterófilos, promediar con los vecinos mete ruido en lugar de señal.
«El sobre-suavizado es un problema de optimización»	Es geométrico: multiplicar repetidamente por la matriz de propagación colapsa todas las representaciones hacia el mismo punto.
«Con pocas etiquetas no se puede hacer nada»	Con 6 etiquetas de 120 nodos —el 5 %— la miniatura llega a exactitud perfecta. La información estaba en la estructura, no en más etiquetas.
«Un GCN se aplica a cualquier grafo nuevo»	En su formulación original es transductivo: la normalización necesita el grafo completo. GraphSAGE y GAT resolvieron eso después.

12. Relación con trabajos anteriores

- **P02 Retropropagación (1986)** — el entrenamiento de extremo a extremo que hace viable aprender los pesos de cada capa.
- **P04 AlexNet (2012)** — la convolución sobre rejillas regulares, que es el caso particular que aquí se generaliza.
- **P53 PCA (1901)** — la intuición de que la estructura de los datos vive en un espacio de menor dimensión.

13. Relación con trabajos posteriores

- **P124 GAT (2018)** — pesar a cada vecino en vez de promediarlos por igual.
- **Gilmer et al. (2017)** — paso de mensajes como marco que unifica el área. [arXiv:1704.01212](#)
- **Li et al. (2018)** — el análisis formal de por qué apilar capas de GCN destruye la señal. [arXiv:1801.07606](#)

14. Notebook asociado

P120_gcn.ipynb

Qué implementa: la exactitud con solo el 5 % de nodos etiquetados en función del número de capas de propagación, y la distancia entre los centros de las comunidades, que es lo que mide el sobre-suavizado.

Qué NO implementa: no hay pesos entrenados: se propaga y se clasifica por centroide. Y el grafo tiene comunidades muy limpias; en grafos reales la homofilia es mucho más débil.

```
ai-evolution paper-lab P120 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe la regla de propagación de una capa de GCN.
Explicar	Explica por qué se suma la identidad a la matriz de adyacencia.
Aplicar	Ejecuta el notebook y localiza el número óptimo de capas.
Analizar	Analiza por qué el sobre-suavizado necesita un suelo de precisión para hacer daño.
Evaluar	«Nuestro grafo es grande, usaremos diez capas». Evalúa la decisión.
Crear	Mide la fracción de aristas que unen nodos de la misma clase en un grafo tuyo y decide si propagar tiene sentido.

16. Autoevaluación

1. ¿Qué hace una capa de GCN?
2. ¿Por qué se suma la identidad a la adyacencia?
3. ¿Cuántas capas conviene apilar?
4. ¿Qué es el sobre-suavizado?
5. ¿Qué supuesto sobre el grafo hace falta para que propagar ayude?
6. ¿Por qué el sobre-suavizado no se ve sin un suelo de precisión?
7. ¿Qué significa que el modelo sea transductivo?

17. Respuestas esperadas

1. Promediar los rasgos de cada nodo con los de sus vecinos, normalizado por el grado, y aplicar una transformación lineal y una no linealidad.
2. Para que cada nodo se incluya a sí mismo en el promedio. Sin eso, un nodo perdería su propia información en cada capa.
3. Dos o tres. El propio artículo lo dice, y la miniatura lo confirma: el óptimo está en 3 y a partir de ahí empeora.
4. El colapso de todas las representaciones hacia el mismo punto al propagar repetidamente. En la miniatura, la separación entre comunidades cae de 0,75 a 0,005.
5. Homofilia: que los vecinos tiendan a compartir clase. En grafos heterófilos, propagar empeora el resultado.
6. Porque colapsar la escala no cambia el orden relativo de los nodos, y un clasificador ideal resolvería diferencias arbitrariamente pequeñas. Ningún sistema real lo hace.
7. Que necesita el grafo completo al entrenar, porque la normalización depende de los grados. No se aplica directamente a nodos que no se vieron.

18. Fuentes primarias

- Kipf, T. N. y Welling, M. (2017). *Semi-Supervised Classification with Graph Convolutional Networks*. **ICLR 2017**. arxiv.org/abs/1609.02907 · consultado 2026-08-18.
- Gilmer, J. et al. (2017). *Neural Message Passing for Quantum Chemistry*. [arXiv:1704.01212](https://arxiv.org/abs/1704.01212) · consultado 2026-08-18.

- Li, Q., Han, Z. y Wu, X. (2018). *Deeper Insights into Graph Convolutional Networks for Semi-Supervised Learning*. [arXiv:1801.07606](#) · consultado 2026-08-18.



Evaluación — P120 · Clasificación semisupervisada con redes convolucionales de grafo

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Semi-Supervised Classification with Graph Convolutional Networks* (2017, ICLR 2017 · arXiv:1609.02907) · **Nivel:** L2

Parte A — Contexto histórico (20 pts)

- (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
- (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

- (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
- (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

- (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

- (10) Ejecuta `P120_gcn.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
- (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
- (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

- (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
- (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).